



Метадані

ДОКУМЕНТ

Заголовок

МЕТОД ГЛИБИННОГО МАШИННОГО НАВЧАННЯ ДЛЯ ІДЕНТИФІКАЦІЇ, КЛАСИФІКАЦІЇ ТА СЕМАНТИЧНОЇ СЕГМЕНТАЦІЇ ОБ'ЄКТІВ

Автор

Ю. П. Кочура,, старший викладач

Науковий керівник / Експерт

**Гордієнко Юрій Григорович, доктор
фізико-математичних наук, професор,
старший науковий співробітник**

ІД документу

334596303

ОРГАНІЗАЦІЯ

Назва організації

**National Technical University of Ukraine Igor Sikorskyi Kyiv
Politech Institute**

Підрозділ

ФІОТ, К-ра обчислювальної техніки

ЗВІТ


Дата звіту

2026-09-07

Дата редагування

Обсяг знайдених подібностей

Коефіцієнт подібності визначає, який відсоток тексту по відношенню до загального обсягу тексту було знайдено в різних джерелах. Зверніть увагу, що високі значення коефіцієнта не автоматично означають плагіат. Звіт має аналізувати компетентна / уповноважена особа.

**56064**

Кількість слів

403863

Кількість символів

Тривога

У цьому розділі відображаються ознаки **МОЖЛИВИХ** текстових маніпуляцій, які можуть впливати на результати аналізу подібності. Деякі зміни можуть бути непомітними під час читання документа, але впливати на результати перевірки. Оцініть, чи є такі зміни навмисними. У разі виникнення запитань зверніться до служби підтримки.

Заміна букв		47
Інтервали		0
Мікропробіли		0
Білі знаки		9
Парафрази (SmartMarks)		375

Джерела

Нижче наведений список джерел. В цьому списку є джерела із різних баз даних. Колір тексту означає в якому джерелі він був знайдений. Ці джерела і значення Коефіцієнту Подібності не відображають прямого плагіату. Необхідно відкрити кожне джерело і проаналізувати зміст і правильність оформлення джерела.

10 найдовших фраз

Колір тексту

1	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	123 (0.22 %)
2	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	78 (0.14 %)
3	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	70 (0.12 %)
4	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	63 (0.11 %)
5	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	58 (0.1 %)
6	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	56 (0.1 %)
7	https://www.wikiwand.com/uk/articles/%D0%9F%D0%BD%D0%B5%D0%B2%D0%BC%D0%BE%D1%82%D0%BE%D1%80%D0%B0%D0%BA%D1%81	54 (0.1 %)
8	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	49 (0.09 %)
9	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	47 (0.08 %)
10	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	45 (0.08 %)

База даних UKRNTI (0.9 %)



#	ЗАГОЛОВОК	КІЛЬКІСТЬ ІДЕНТИЧНИХ СЛІВ (ФРАГМЕНТІВ)
1	Методи та засоби забезпечення безпечного розпізнавання та параметризації результатів обробки голосової інформації Іосіфов Євген Анатолійович	193 (30) (0.34 %)
2	Інтелектуальна система підтримки прийняття рішень на базі нейронних мереж глибокого навчання для задач медичної діагностики Сидорський Володимир Сергійович	74 (3) (0.13 %)
3	Метод автоматизованого прогнозування несприятливих авіаційних подій для підвищення безпеки польотів при управлінні повітряним рухом Башинський Сергій Олександрович	42 (3) (0.07 %)

4	Інформаційна технологія інтелектуальної ієрархічної класифікації коротких описів товарів у сфері електронної комерції Нарушинська Ольга Олександрівна	29 (2) (0.05 %)
5	Методи та програмні засоби автоматичного діагностування в медичних системах Лящинський Павло Борисович	29 (2) (0.05 %)
6	Метод визначення параметрів генератору медичного озону для ефективного підвищення його продуктивності Махонін Микола Віталійович	22 (2) (0.04 %)
7	Методи попереднього опрацювання часових рядів для підвищення точності їхнього прогнозування моделями глибинного навчання Ємець Кирило Вікторович	21 (3) (0.04 %)
8	Оптичні та електрофізичні властивості плівок на основі ZnO та NiO Євтушенко Арсеній Іванович	14 (1) (0.02 %)
9	Методи та засоби створення високоефективних комп'ютеризованих систем централізованого сповіщення Колесник Сергій Євгенович	13 (2) (0.02 %)
10	Правові засади національно-патріотичного виховання у системі підготовки офіцерів запасу Ярема Валерій Володимирович	12 (1) (0.02 %)
11	Використання методів глибокого навчання для автоматизованого семантичного аналізу тематично структурованих текстових корпусів Стасюк Микола Іванович	11 (1) (0.02 %)
12	Алгоритми машинного навчання для побудови високоефективних систем проєктного управління Михайлов Нікіта Олегович	10 (1) (0.02 %)
13	Моделі та методи інформаційної технології діагностування онкопатологій молочної залози за гістопатологічними зображеннями Папченко Олександр Іванович	9 (1) (0.02 %)
14	Порушення менструального циклу після коронавірусної хвороби (COVID-19): клінічні особливості та підвищення ефективності лікування Петрук Алла Олегівна	7 (1) (0.01 %)
15	Оцінювання ефективності енергетичної системи будівлі в умовах теплового комфорту Буяк Надія Андріївна	7 (1) (0.01 %)
16	Методи моделювання задач цифрової обробки сигналів засобами гіперкомплексних обчислень Сукало Аліна Сергіївна	6 (1) (0.01 %)
17	Психологічні індивідуально-особистісні детермінанти суб'єктивного благополуччя майбутніх психологів Курова Анастасія Володимирівна	6 (1) (0.01 %)

Домашня база даних (3.04 %)



#	ЗАГОЛОВОК	КІЛЬКІСТЬ ІДЕНТИЧНИХ СЛІВ (ФРАГМЕНТІВ)
18	Метод обробки медичних зображень людини на основі нейронної мережі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	797 (22) (1.42 %)
19	Метод адаптації глибоких нейронних мереж до апаратного забезпечення зі спеціалізованою архітектурою 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	254 (33) (0.45 %)

20	Метод та програмні засоби мультимодального аналізу медичних даних на основі глибокого навчання 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	221 (19) (0.39 %)
21	341779 Text статті_Рецензування full 11/11/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (журн. Information, computing and intelligent systems)	84 (5) (0.15 %)
22	Спосіб розподіленої обробки даних на основі блокчейну в галузі телемедицини 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	78 (7) (0.14 %)
23	Реалізація спеціалізованої нейронної мережі на мобільній платформі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	66 (5) (0.12 %)
24	Метод сегментації зображень з використанням глибоких нейронних мереж 3/16/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	65 (7) (0.12 %)
25	МЕТОД ГІБРИДИЗАЦІЇ АРХІТЕКТУР НЕЙРОННИХ МЕРЕЖ ДЛЯ АНАЛІЗУ МУЛЬТИМОДАЛЬНИХ ДАНИХ 2/13/2026 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (ФІОТ, К-па обчислювальної техніки)	28 (2) (0.05 %)
26	Моделі та методи глибинного навчання для задач геопросторового аналізу 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	23 (3) (0.04 %)
27	Веб-сервіс для діагностики захворювань на базі ШІ 3/16/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	22 (4) (0.04 %)
28	Розробка нейромережевої моделі визначення оптичного потоку для впровадження на мікрокомп'ютері 12/12/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (ФІОТ, К-па обчислювальної техніки)	14 (2) (0.02 %)
29	Методологія забезпечення стійкості економічного розвитку машинобудівних підприємств на засадах бізнес-лідерства 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	13 (1) (0.02 %)
30	Дослідження ефективності виконання алгебраїчних операцій над матрицями на графічному процесорі 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	12 (1) (0.02 %)
31	Яковлев_ДР_ревізія_27.01.2025_12.12 1/27/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (ФІОТ, К-па обчислювальної техніки)	10 (1) (0.02 %)

32	БС_22_ДР_Соколова_плаг 5/31/2026 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (ФБМІ, К-па біомедичної кібернетики)	7 (1) (0.01 %)
33	Пецеля_А_ 5/11/2026 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (ФПСГПМ, К-па програмного забезпечення комп'ютерних систем)	7 (1) (0.01 %)
34	Алгоритмічне та програмне забезпечення систем захисту мультимедійних даних користувачів мережі інтернет 3/15/2025 National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute (National Technical University of Ukraine Igor Sikorskyi Kyiv Politech Institute)	6 (1) (0.01 %)

Інтернет (8.94 %)



#	ДЖЕРЕЛО URL	КІЛЬКІСТЬ ІДЕНТИЧНИХ СЛІВ (ФРАГМЕНТІВ)
35	https://link.springer.com/chapter/10.1007/978-981-19-7874-6_46	674 (35) (1.2 %)
36	https://scholar.google.com/tr/citations?user=YuckNtAAAAAJ&hl=en	386 (40) (0.69 %)
37	https://dl.acm.org/doi/abs/10.1109/TPAMI.2023.3322540	277 (18) (0.49 %)
38	https://arxiv.org/html/2502.13693v1	159 (9) (0.28 %)
39	https://www.melba-journal.org/pdf/2020:2.pdf	128 (8) (0.23 %)
40	https://arxiv.org/pdf/2302.08119	112 (5) (0.2 %)
41	https://cyberleninka.ru/article/n/ispolzovanie-tehnologii-giperpotocnosti-v-tselyah-povysheniya-skorosti-obrabotki-ml-algoritmov	106 (6) (0.19 %)
42	https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0288658	101 (5) (0.18 %)
43	https://link.springer.com/chapter/10.1007/978-3-032-17216-7_9	91 (10) (0.16 %)
44	https://dergipark.org.tr/en/pub/patd/issue/61233/900915	84 (4) (0.15 %)
45	https://arxiv.org/pdf/2312.04713.pdf	84 (5) (0.15 %)
46	https://arxiv.org/pdf/2007.11154	80 (2) (0.14 %)
47	https://www.wikiwand.com/uk/articles/%D0%9F%D0%BD%D0%B5%D0%B2%D0%BC%D0%BE%D1%82%D0%BE%D1%80%D0%B0%D0%BA%D1%81	77 (2) (0.14 %)
48	https://publica-rest.fraunhofer.de/server/api/core/bitstreams/3f849dfb-1600-4a0d-9648-80afc2fd6802/content	75 (4) (0.13 %)
49	https://arxiv.org/pdf/2307.05695	72 (6) (0.13 %)
50	https://arxiv.org/pdf/2201.05020	72 (6) (0.13 %)
51	https://ela.kpi.ua/items/38faea60-f0fb-4820-8fc8-a5f5e0cbe3a7	58 (2) (0.1 %)
52	https://d197for5662m48.cloudfront.net/documents/publicationstatus/292955/preprint_pdf/0a0e0b35992acfc65a04ab8b80de579e.pdf	57 (3) (0.1 %)
53	https://people.idsia.ch/~juergen/firstdeeplearner.html	53 (4) (0.09 %)

54	https://link.springer.com/article/10.1007/s10278-022-00666-z	52 (2) (0.09 %)
55	https://www.hindawi.com/journals/bmri/2020/7413673/	52 (2) (0.09 %)
56	https://dl.acm.org/doi/abs/10.1016/j.compbiomed.2021.105123	52 (2) (0.09 %)
57	https://cinst.chu.edu.iq/index.php/cinst/article/view/41	50 (5) (0.09 %)
58	https://dl.acm.org/doi/10.5555/3454287.3454294	48 (4) (0.09 %)
59	https://www.academia.edu/56346414/Explaining_the_Black_box_Smoothly_A_Counterfactual_Approach	46 (2) (0.08 %)
60	https://www.academia.edu/95330584/A_transfer_learning_method_with_deep_residual_network_for_pediatric_pneumonia_diagnosis	45 (4) (0.08 %)
61	https://link.springer.com/content/pdf/10.1007/s42979-024-02751-2.pdf	45 (4) (0.08 %)
62	https://www.hindawi.com/journals/jir/2020/1357983/	45 (3) (0.08 %)
63	https://arxiv.org/pdf/2107.05274	43 (2) (0.08 %)
64	https://www.mdpi.com/2075-4418/12/11/2724	43 (2) (0.08 %)
65	https://haridecoded.com/resources/AIX_NeurlPS_2021.pdf	42 (2) (0.07 %)
66	https://dir.ukrintel.ua/view/okd/cab047be0acda02d00ea036b415c1941	42 (4) (0.07 %)
67	https://medlec.org/lek3-147081.html	40 (1) (0.07 %)
68	https://www.medrxiv.org/content/10.1101/2020.12.14.20248158v1.full.pdf	39 (3) (0.07 %)
69	https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10284921/	38 (3) (0.07 %)
70	https://www.hindawi.com/journals/cin/2019/2373798/	38 (2) (0.07 %)
71	https://arxiv.org/pdf/2101.04230v1	37 (1) (0.07 %)
72	https://arxiv.org/pdf/1904.05956	37 (2) (0.07 %)
73	https://www.hindawi.com/journals/jhe/2022/4189781/	37 (2) (0.07 %)
74	https://www.hindawi.com/journals/ciid/2021/6652819/	36 (1) (0.06 %)
75	https://onat.edu.ua/wp-content/uploads/2019/11/%D0%94%D0%B8%D1%81%D1%81%D0%B5%D1%80%D1%82%D0%B0%D1%86%D0%B8%D1%8F-4-%D1%81%D0%B6%D0%B0%D1%82%D1%8B%D0%B9.pdf	36 (6) (0.06 %)
76	https://cyberleninka.ru/article/n/moskovskiy-eksperiment-po-primeneniyu-kompyuternogo-zreniya-v-luchevoy-dagnostike-vovlechnost-vrachey-rentgenologov	35 (1) (0.06 %)
77	https://arxiv.org/pdf/2204.07513v1	35 (1) (0.06 %)
78	https://repo.knmu.edu.ua/server/api/core/bitstreams/56f9b6ea-8b9f-4ccf-99f2-eac50ca31fc8/content	34 (1) (0.06 %)
79	https://www.hindawi.com/journals/cmmm/2021/8854892/	34 (1) (0.06 %)
80	https://www.hindawi.com/journals/complexity/2020/9428612/	34 (1) (0.06 %)
81	https://rjwave.org/ijedr/papers/IJEDR2601520.pdf	33 (2) (0.06 %)
82	https://www.ecva.net/papers/eccv_2024/papers_ECCV/papers/11886.pdf	33 (3) (0.06 %)
83	https://proceedings.neurips.cc/paper_files/paper/2023/file/d49042a5d49818711c401d34172f9900-Paper-Datasets_and_Benchmarks.pdf	32 (2) (0.06 %)

84	https://link.springer.com/article/10.1007/s13755-021-00146-8	32 (1) (0.06 %)
85	https://www.hindawi.com/journals/jhe/2022/9580991/	32 (2) (0.06 %)
86	https://pmc.ncbi.nlm.nih.gov/articles/PMC7357299/	31 (2) (0.06 %)
87	https://arxiv.org/html/1905.04149	30 (1) (0.05 %)
88	https://arxiv.org/pdf/2404.18981	30 (1) (0.05 %)
89	https://dl.acm.org/doi/abs/10.1145/3571600.3571619	30 (1) (0.05 %)
90	https://arxiv.org/pdf/2402.04273	29 (1) (0.05 %)
91	https://arxiv.org/pdf/2409.19821	28 (1) (0.05 %)
92	https://arxiv.org/html/2501.15448v1	28 (2) (0.05 %)
93	https://consilium.orscience.ru/2075-1753/article/view/95185/ru_RU	26 (2) (0.05 %)
94	https://arxiv.org/pdf/1911.09968	26 (2) (0.05 %)
95	https://arxiv.org/html/2401.02458	25 (3) (0.04 %)
96	https://www.nature.com/articles/s41597-024-03358-1.pdf	25 (1) (0.04 %)
97	https://arxiv.org/pdf/1909.10391.pdf	24 (2) (0.04 %)
98	https://he01.tci-thaijo.org/index.php/jnkp/article/view/249949	22 (2) (0.04 %)
99	https://pubmed.ncbi.nlm.nih.gov/34364071/	22 (1) (0.04 %)
100	https://link.springer.com/content/pdf/10.1007/978-3-031-73021-4_20	22 (1) (0.04 %)
101	https://www.hindawi.com/journals/jhe/2019/4180949/	20 (1) (0.04 %)
102	https://arxiv.org/pdf/2311.07263.pdf	19 (1) (0.03 %)
103	https://graphics.cs.uh.edu/wp-content/papers/2025/2025-MICCAI-Maarta.pdf	19 (1) (0.03 %)
104	https://archivepp.com/article/an-overview-on-x-ray-diagnostic-findings-in-covid-19-patients-aavflv3m3ifhzcf	19 (1) (0.03 %)
105	https://www.hindawi.com/journals/bmri/2022/2456550/	18 (1) (0.03 %)
106	https://pmc.ncbi.nlm.nih.gov/articles/PMC9646404/	18 (1) (0.03 %)
107	https://www.nature.com/articles/s42256-022-00516-1	18 (1) (0.03 %)
108	https://www.hindawi.com/journals/wcmc/2021/9957067/	18 (1) (0.03 %)
109	https://dl.acm.org/doi/10.5555/3666122.3666892	17 (1) (0.03 %)
110	https://arxiv.org/pdf/2007.14895	17 (2) (0.03 %)
111	https://arxiv.org/pdf/2103.08700	16 (1) (0.03 %)
112	https://arxiv.org/pdf/2403.09233	16 (2) (0.03 %)
113	https://e-archivo.uc3m.es/bitstreams/84d3e16b-045a-4096-96bf-0d2d4be9c24b/download	15 (1) (0.03 %)
114	https://arxiv.org/pdf/2505.13300	14 (2) (0.02 %)
115	https://dl.acm.org/doi/abs/10.5555/3454287.3454603	14 (1) (0.02 %)

116	https://link.springer.com/chapter/10.1007/978-3-031-23119-3_2	14 (1) (0.02 %)
117	https://arxiv.org/pdf/2004.06578	13 (1) (0.02 %)
118	https://arxiv.org/pdf/2406.19614	13 (2) (0.02 %)
119	https://arxiv.org/pdf/2107.10224v1.pdf	13 (1) (0.02 %)
120	https://link.springer.com/chapter/10.1007/978-981-16-8403-6_4	13 (2) (0.02 %)
121	https://arxiv.org/html/2410.15372v1	13 (2) (0.02 %)
122	https://www.emergentmind.com/papers/2312.06224	13 (1) (0.02 %)
123	https://arxiv.org/pdf/2212.04055.pdf	12 (1) (0.02 %)
124	https://openlibrary.telkomuniversity.ac.id/pustaka/files/184432/abstraksi/web-information-systems-engineering-wise-2021-22nd-international-conference-on-web-information-systems-engineering-wise-2021-melbourne-vic-australia-october-26-29-2021-proceedings-part-ii.pdf	12 (1) (0.02 %)
125	https://arxiv.org/pdf/2409.09484	12 (1) (0.02 %)
126	https://ieeexplore.ieee.org/xpl/dwnldReferences?arnumber=8695313	12 (2) (0.02 %)
127	https://pubs.rsna.org/doi/10.1148/radiol.2020200988	10 (1) (0.02 %)
128	https://openaccess.thecvf.com/content/WACV2024/papers/Sun_Towards_Better_Structured_Pruning_Saliency_by_Reorganizing_Convolution_WACV_2024_paper.pdf	10 (1) (0.02 %)
129	https://mspc.mk.ua/index.php/journal/article/download/245/166/199	10 (1) (0.02 %)
130	https://arxiv.org/pdf/2011.04051.pdf	10 (1) (0.02 %)
131	https://arxiv.org/html/2407.18070v1	9 (1) (0.02 %)
132	https://www.nature.com/articles/s41598-021-87523-1	9 (1) (0.02 %)
133	https://nathanwang000.github.io/cv/dissertation_jx.pdf	9 (1) (0.02 %)
134	https://dl.acm.org/doi/10.1145/3233547.3233573	9 (1) (0.02 %)
135	https://people.idsia.ch/~koutnik/pres/20160624-DL-IFI.pdf	9 (1) (0.02 %)
136	https://arxiv.org/pdf/2507.00673	9 (1) (0.02 %)
137	https://www.semanticscholar.org/paper/Proposed-Scoring-System-for-Evaluating-Severity-of-Bedair-Soliman/5c2aa714334af7bedde506ddfabd0c463e73b615/figure/0	8 (1) (0.01 %)
138	https://www.scielo.cl/scielo.php?script=sci_arttext&pid=S0717-93082021000100008	7 (1) (0.01 %)
139	https://liangli-zhen.github.io/assets/pdf/MedNAS.pdf	7 (1) (0.01 %)
140	https://preview.hindawi.com/journals/cin/2023/1305583/	6 (1) (0.01 %)
141	https://data.mlr.press/assets/pdf/v01-5.pdf	6 (1) (0.01 %)
142	https://arxiv.org/pdf/2505.01239	6 (1) (0.01 %)
143	https://nataboyko.blogspot.com/2020/12/blog-post.html	6 (1) (0.01 %)
144	https://arxiv.org/pdf/2406.03744	6 (1) (0.01 %)
145	https://arxiv.org/pdf/2310.06080.pdf	6 (1) (0.01 %)
146	https://arxiv.org/pdf/2008.05373v5.pdf	6 (1) (0.01 %)

147	https://arxiv.org/pdf/2412.19628	6 (1) (0.01 %)
148	https://www.academia.edu/121754177/Auditing_Large_Language_Models_A_Three_Layered_Approach	5 (1) (0.01 %)
149	https://dl.acm.org/doi/10.5555/3295222.3295349	5 (1) (0.01 %)
150	https://arxiv.org/pdf/2006.05929.pdf	5 (1) (0.01 %)
151	https://ijsrst.com/home/issue/view/article.php?id=IJSRST2295105	5 (1) (0.01 %)
152	https://link.springer.com/content/pdf/10.1007/s42600-021-00181-0.pdf	5 (1) (0.01 %)
153	https://www.scientific.net/JBBBE.45.57	5 (1) (0.01 %)

☒ Список прийнятих фрагментів

#	ЗМІСТ	КІЛЬКІСТЬ ОДНАКОВИХ СЛІВ (ФРАГМЕНТІВ)
---	-------	---------------------------------------

2

Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»
Міністерство освіти і науки України
Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»
Міністерство освіти і науки України
Кваліфікаційна наукова
праця на правах рукопису
КОЧУРАЮРІЙ ПЕТРОВИЧ
УДК 004.8
ДИСЕРТАЦІЯ
МЕТОД ГЛИБИННОГО МАШИННОГО НАВЧАННЯ ДЛЯ
ІДЕНТИФІКАЦІЇ, КЛАСИФІКАЦІЇ ТА СЕМАНТИЧНОЇ
СЕГМЕНТАЦІЇ ОБ'ЄКТІВ

121 «Інженерія програмного забезпечення»

2

12 «Інформаційні технології» Подається на здобуття наукового ступеня доктора філософії Дисертація містить результати власних досліджень.
Використання ідей, результатів і текстів інших авторів мають посилання на відповідне джерело.
Ю. П. Кочура
Науковий керівник: Гордієнко Юрій Григорович, доктор фізико-математичних наук, професор, старший науковий співробітник
Київ — 2026

2

АНОТАЦІЯ

Кочура Ю. П. Метод глибинного машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів. Кваліфікаційна наукова праця на правах рукопису. Дисертація на здобуття наукового ступеня доктора філософії за спеціальністю 121 «Інженерія програмного забезпечення» у галузі знань 12 «Інформаційні технології». – Національний технічний університет України «Київський політехнічний інститут імені Ігоря Сікорського», Київ, 2026.
Дисертаційна робота присвячена розробці нових та вдосконаленню існуючих методів глибинного машинного навчання для розв'язання задач ідентифікації, класифікації та семантичної сегментації об'єктів. Запропоновані методи спрямовані на покращення результатів аналізу медичних даних, зокрема діагностики легеневих захворювань шляхом інтеграції алгоритмів семантичної сегментації анатомічних структур і вилучення тіней кісток з рентгенограм, ансамблевої класифікації у федеративному навчанні, а також методів виключення викидів серед розподілу сегментованих масок та генеративної аугментації даних методом дистиляції набору даних (GDADD).
Вперше запропоновано інтегровану технологію попередньої обробки 2D рентгенограм, яка поєднує сегментацію ділянок, що містять цільові об'єкти, на

основі глибоких нейронних мереж типу кодер-декодер, із подальшою класифікацією патологій. На відміну від класифікації на основі всього зображення, це дозволяє зосередити аналіз на клінічно значущих ділянках і покращити результати діагностики за рахунок зменшення впливу нецільових анатомічних структур та зменшення розмірності вхідних даних у $3,2 \pm 0,7$ раза (середня частка площі сегментації – $0,32 \pm 0,06$). Експериментально встановлено, що вплив сегментації на результати класифікації залежить від масштабу вибірки: для малих і незбалансованих наборів даних (JSRT, BSE-JSRT) сегментація суттєво знижує ризик перенавчання моделі, тоді як для великого набору даних (CheXpert) її вплив обмежений і спостерігається лише для окремих класів патологій (Lung Opacity, Consolidation, Pleural Other).

Вперше запропоновано метод класифікації у федеративному навчанні, що поєднує ансамбль опорних моделей з архітектурами низької обчислювальної складності за стратегією «ширина важливіша за глибину». На відміну від існую-

3

чих підходів до збільшення глибини нейронних мереж, метод підвищує узагальнювальну здатність моделі та знижує ризик перенавчання за рахунок зменшення дисперсії передбачень при агрегуванні частково некорельованих похибок окремих моделей. Експериментально встановлено, що чутливість моделі до кількості локальних епох між раундами усереднення FedAvg зростає зі збільшенням кількості опорних моделей в ансамблі: для чотирьох опорних архітектур різниця валідаційної точності між максимальною та мінімальною кількістю локальних епох становила 13,39%, для двох – 5%, для однієї базової моделі – лише 1,89%.

²⁶ Досконалено метод глибинного навчання на основі згорткових нейронних мереж, який на відміну від відомих методів автоматизованої діагностики за рентгенограмами доповнено етапами сегментації анатомічних структур та вилучення з рентгенограм тіней кісток, що дозволяє зменшити перекриття патологічних ознак кістковими структурами, а також додатково скоротити розмірність вхідних даних приблизно у 2 рази (середня частка релевантної площі – $0,15 \pm 0,04$) за рахунок вилучення нерелевантних ознак, що знижує ризик перенавчання моделі за умов обмеженого розміру навчальної вибірки.

Подальшого розвитку набув метод виключення викидів серед сегментованих масок, який, на відміну від відомих підходів, ґрунтується на проєкції розподілу масок у простір зниженої розмірності за допомогою методу t-SNE з подальшою пороговою фільтрацією відносно ядра даних, що дозволило покращити якість вхідних даних для методів глибинного навчання під час класифікації патологічних станів легень за 2D-рентгенограмами.

Подальшого розвитку набув метод дистиляції набору даних шляхом узгодження навчальних траєкторій (DDMTT): запропоновано генеративну аугментацію даних GDADD, яка, на відміну від DDMTT, суттєво збільшує кількість синтетичних зображень на клас, синтезуючи набір даних, обсяг якого наближається до реального набору даних. За рахунок цього синтезовані зображення кодують ширший спектр інформативних ознак, що дозволяє моделям, навченим на такому наборі, досягати узагальнювальної здатності, зіставної з моделями, навченими на значно більшому реальному наборі даних. Експериментально підтверджено, що на збалансованому наборі даних PathMNIST валідаційна точність класифікації моделей, навчених на даних, синтезованих методом GDADD ($0,917 \pm 0,003$), є дещо вищою за класичні згорткові архітектури (ResNet-18, ResNet-50) та перевищує результати методів автоматизованого машинного навчання (auto-sklearn,

4

AutoKeras, Google AutoML Vision) на 9,9-28,1%; для незбалансованих наборів даних ефективність методу потребує подальшого вивчення.

Розроблені методи з використанням сегментації, вилучення тіней кісток, виключення викидів, генеративної аугментації даних та ансамблювання опорних моделей у рамках федеративного навчання є взаємодоповнювальними за характером дії: перші чотири методи спрямовані на послідовне зменшення різних типів надлишковості та шуму на рівні вхідних даних (просторової – сегментація, структурної – вилучення тіней кісток, статистичної – виключення викидів) та компенсацію дефіциту репрезентативності класів (аугментація даних), тоді як ансамблювання опорних моделей забезпечує підвищення надійності рішення на рівні агрегації прогнозів. Ефективність кожного компонента підтверджено експериментально за окремою лінією дослідження; частину методів інтегровано на рівні програмної платформи, розробленої в межах науково-дослідного проєкту

²² «Платформа штучного інтелекту для дистанційного автоматизованого виявлення та діагностики захворювань людини» (реєстраційний номер 2020_01/0490), що

виконувався за підтримки Національного фонду досліджень України у 2020-2021 роках (протокол №21 від 16–17 вересня 2020 року) за результатами конкурсу «Наука для безпеки людини та суспільства».

Отримані результати доповнюють існуючі уявлення про роль попередньої обробки та очищення даних у задачах медичної комп'ютерної діагностики та демонструють доцільність застосування відносно простих моделей у поєднанні з розробленими методами. Це створює підґрунтя для використання запропонованих методів у створенні програмних засобів інтелектуальної обробки та аналізу цифрових зображень, зокрема для створення систем підтримки клінічних рішень, призначених для роботи в умовах обмеженого розміру вибірки, дисбалансу класів і високого рівня шуму у вхідних даних.

Ключові слова: машинне навчання, глибоке навчання, нейронна мережа, ідентифікація, класифікація, семантична сегментація, прийняття рішень, штучний інтелект в охороні здоров'я.

Публікації. Основні результати за темою дисертації були висвітлені в 22 наукових працях, які розкривають основний зміст дисертації, зокрема у 16 наукових публікаціях, з яких 1 стаття у закордонному фаховому виданні першого квартиля (Q1), 7 статей у закордонних фахових виданнях третього квартиля (Q3), 6 статей у закордонних фахових виданнях четвертого квартиля (Q4), 1 стаття у

5

періодичному закордонному фаховому виданні, яке індексується у Scopus, без квартильного рейтингу (у тому числі 9 статей у періодичних виданнях, які в базі Scopus мають тип документа «Conference paper» та номер ISSN) і 1 стаття у фаховому виданні України категорії Б, а також у 6 матеріалах науково-технічних конференцій. Із 22 наукових праць 21 опубліковано у рецензованих наукових журналах та матеріалах конференцій, проіндексованих у міжнародній наукометричній базі даних Scopus. Загальна кількість цитувань в Scopus (ID: 57198345363) становить 525, Scopus h-index – 11:

1. ⁴³ Y. Gordienko, G. Nowakowski, Y. Kochura, V. Taran, and S. Stirenko, "Generative data augmentation by dataset distillation," in ⁴³ Communications in Computer and

Information Science, C. Tommasino, C. Russo, and M. Bernardini, Eds. Cham: Springer Nature Switzerland, 2026, vol. 2696, pp. 105–118. DOI: 10.1007/978-3-032-17216-7_9. ISSN 1865-0929. ISBN 978-303217215-0. SCOPUS, Q4.

2. Y. Gordienko, N. Gordienko, E. M. El Mhamdi, Y. Kochura, and S. Stirenko, "Multi-backbone ensembling for performance improvement in federated learning setup," in Lecture Notes in Networks and Systems, N. Min-Allah, K. Alissa, P. Sitek, M. Sano, S. Rodriguez, and A. Nongaillard, Eds. Cham: Springer Nature Switzerland, 2026, vol. 1598, pp. 129–138. DOI: 10.1007/978-3-032-04160-9_12. ISSN 2367-3370. ISBN 978-303204159-3. SCOPUS, Q4.

3. Y. Kochura, Y. Trochun, V. Taran, Y. Gordienko, O. Rokovyi, and S. Stirenko, ²¹ AeroNet: Domain-specific dataset for automation of unmanned aerial vehicles," Information, Computing and Intelligent systems, no. 7, pp. 83–95, 2025. DOI: 10.20535/2786-8729.7.2025.341779. ISSN 2786-8729. Scientific Professional Publications of Ukraine (Category B).

4. Y. Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, V. Taran, O. Alienin, and S. Stirenko, "Multimodal metadata augmentation for federated learning in medical applications," in Lecture Notes in Networks and Systems, X.-S. Yang, S. Sherratt, N. Dey, and A. Joshi, Eds. Springer Science and Business Media Deutschland GmbH, 2024, vol. 1002, pp. 537–547. DOI: 10.1007/978-981-97-3299-9_43. ISSN 2367-3370. ISBN 978-981973298-2. SCOPUS, Q4.

6

5. ²⁰ Y. Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, O. Alienin, V. Taran, and S. Stirenko, "Ensemble knowledge distillation for edge intelligence in medical applications," in Studies in Computational Intelligence. Springer Science and Business Media Deutschland GmbH, 2023, vol. 1100, pp. 135–168. ²⁰ DOI: 10.1007/978-3-031-32095-8_5. ISSN 1860-949X. SCOPUS, Q4.

6. ²⁰ Y. Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, O. Alienin, and S. Stirenko, "Fuzzy metadata augmentation for multimodal data classification," in ¹ Lecture Notes on Data Engineering and Communications Technologies. ¹ Springer Science and Business Media Deutschland GmbH, 2023, vol. 166, pp. 157–172. ²⁰ DOI: 10.1007/978-981-99-0835-6_11. ISSN 2367-4512. SCOPUS, Q 3.

7. V. Taran, Y. Gordienko, O. Rokovyi, O. Alienin, Y. Kochura, and ³⁶ S. Stirenko, "Edge intelligence for medical applications under field conditions," in ¹ Lecture Notes on Data Engineering and Communications Technologies. ¹ Springer Science and Business Media Deutschland GmbH, 2022, vol. 135, pp. 71–80. ¹⁹ DOI: 10.1007/978-3-031-04809-8_6. ISSN 2367-4512. SCOPUS, Q3.

8. O. Alienin³⁶, Y. Rokovyi, Y. Gordienko, Y. Kochura³⁵, V. Taran, and S. Stirenko. "Artificial intelligence platform for distant computer-aided detection (CADE) and computer-aided diagnosis (CADx) of human diseases," in Lecture Notes on Data Engineering and Communications Technologies. Springer Science and Business Media Deutschland GmbH, 2022, vol. 135, pp. 91–100. DOI: 10.1007/978-3-031-04809-8_8. ISSN 2367-4512. SCOPUS, Q3.
9. V. Doms, Y. Gordienko, Y. Kochura³⁵, O. Rokovyi, O. Alienin, and S. Stirenko. "Deep learning for melanoma detection with testing time data augmentation," in Lecture Notes on Data Engineering and Communications Technologies. Springer Science and BusinessMedia Deutschland GmbH, 2021, vol. 82, pp. 131–140. DOI: 10.1007/978-3-030-80475-6_13. ISSN 2367-4512. SCOPUS.
10. Y. Gordienko, Y. Kochura³⁵, V. Taran, N. Gordienko, O. Rokovyi, O. Alienin, and S. Stirenko. "Last mile" optimization of edge computing ecosystem with deep learning models and specialized tensor processing architectures," in Advances in Computers. S. Kim and G. C. Deka, Eds. Academic Press Inc., 2021, vol. 122, pp. 303–341. DOI: 10.1016/bs.adcom.2020.10.003. ISSN 0065-2458. ISBN 978-012823123-4. SCOPUS, Q1.
- 7
11. Y. Gordienko, Y. Kochura, V. Taran³⁶, N. Gordienko, A. Rokovyi, O. Alienin, and S. Stirenko¹⁹. "Scaling analysis of specialized tensor processing architectures for deep learning models," in Studies in Computational Intelligence. Cham: Springer, 2020, vol. 866, pp. 65–99. DOI: 10.1007/978-3-030-31756-0_3. ISSN 1860-949 X. SCOPUS, Q4.
12. P. Gang, W. Zeng, Y. Gordienko, Y. Kochura, O. Alienin, O. Rokovyi³⁶, and S. Stirenko. "Effect of data augmentation and lung mask segmentation for automated chest radiograph interpretation of some lung diseases," in Communications in Computer and Information Science, T. Gedeon, K. W. Wong, and M. Lee, Eds. Cham: Springer, 2019, vol. 1142, pp. 333–340. DOI: 10.1007/978-3-030-36808-1_36. ISSN 1865-0929. ISBN 978-303036807-4. SCOPUS, Q3.
13. Y. Gordienko, Y. Kochura³⁵, V. Taran, N. Gordienko, A. Bugaiov, and S. Stirenko. "Adaptive iterative pruning for accelerating deep neural networks," in 2019 11th International Scientific and Practical Conference on Electronics and Information Technologies, ELIT 2019 - Proceedings. Institute of Electrical and Electronics Engineers Inc., 2019, pp. 173–178. DOI: 10.1109/ELIT.2019.8892346. ISBN 978-172813561-8. SCOPUS.
14. Y. Kochura³⁶, Y. Gordienko, V. Taran, N. Gordienko, A. Rokovyi, O. Alienin, and S. Stirenko³⁵. "Batch size influence on performance of graphic and tensor processing units during training and inference phases," in Advances in Intelligent Systems and Computing, Z. Hu, S. Petoukhov, I. Dychka, and M. He, Eds. Cham: Springer, 2019, vol. 938, pp. 658–668. DOI: 10.1007/978-3-030-16621-2_61. ISSN 2194-5357. ISBN 978-303016620-5. SCOPUS, Q4.
15. V. Taran, Y. Gordienko, N. Gordienko, A. Rokovyi, Y. Kochura, O. Alienin, and S. Stirenko¹⁹. "Performance evaluation of deep learning networks for semantic segmentation of traffic stereo-pair images," in ACM International Conference Proceeding Series, B. Rachev and A. Smrikarov, Eds. Association for Computing Machinery, 2018, pp. 73–80. DOI: 10.1145/3274005.3274032. ISBN 978-145036425-6. SCOPUS.
16. S. Stirenko³⁹, Y. Kochura, O. Alienin, O. Rokovyi, Y. Gordienko, P. Gang, and W. Zeng. "Chest x-ray analysis of tuberculosis by deep learning with segmentation and augmentation," in 2018 IEEE 38th International Conference on Electronics and Nanotechnology, ELNANO 2018 - Proceedings. Institute of Electrical and Electronics Engineers Inc., 2018, pp. 422–428. DOI: 10.1109/ELNANO.2018.8477564. ISBN 978-153866383-7. SCOPUS.
17. P. Gang, W. Zhen³⁶, W. Zeng, Y. Gordienko, Y. Kochura, O. Alienin, O. Rokovyi, and S. Stirenko³⁶. "Dimensionality reduction in deep learning for chest x-ray analysis of lung cancer," in Proceedings - 2018 10th International Conference on Advanced Computational Intelligence, ICACI 2018. Institute of Electrical and Electronics Engineers Inc., 2018, pp. 878–883. DOI: 10.1109/ICACI.2018.8377579. ISBN 978-153864362-4. SCOPUS.
18. Y. Gordienko, P. Gang⁶¹, J. Hui, W. Zeng⁵⁴, Y. Kochura, O. Alienin, O. Rokovyi, and S. Stirenko. "Deep learning with lung segmentation and bone shadow exclusion techniques for chest x-ray analysis of lung cancer," in Advances in Intelligent Systems and Computing, Z. Hu, S. Petoukhov, I. Dychka, and M. He, Eds. Cham: Springer, 2018, vol. 754, pp. 638–647. DOI: 10.1007/978-3-319-91008-6_63. ISSN 2194-5357. ISBN 978-331991007-9. SCOPUS, Q3.
19. Y. Kochura⁴¹, S. Stirenko, O. Alienin, M. Novotarskiy, and Y. Gordienko. "Perfor-

mance analysis of open source machine learning frameworks for various parameters in single-threaded and multi-threaded modes," in Advances in Intelligent Systems and Computing, N. Shakhovska and V. Stepashko, Eds. Cham: Springer, 2018, vol. 689, pp. 243–256. DOI: 10.1007/978-3-319-70581-1_17. ISSN 2194-5357. ISBN 978-331970580-4. SCOPUS, Q3.

20. P. Gang, J. Hui, S. Stirenko, Y. Gordienko, T. Shemsedinov, O. Alienin, Y. Kochura, N. Gordienko, A. Rojbi, J. Lopez Benito, and E. Artetxe Gonzalez,

³⁶ "User-driven intelligent interface on the basis of multimodal augmented reality and brain-computer interaction for people with functional disabilities," in Advances in Intelligent Systems and Computing, K. Arai, S. Kapoor, and R. Bhatia, Eds. Cham: Springer, 2018, vol. 886, pp. 612–631. DOI: 10.1007/978-3-030-03402-3_43. ISSN 2194-5357. ISBN 978-303003401-6. SCOPUS, Q3.

21. Y. Kochura, S. Stirenko, and Y. Gordienko, ³⁵ "Comparative performance analysis of neural networks architectures on h2o platform for various activation functions."

9

in 2017 IEEE International Young Scientists Forum on Applied Physics and Engineering, YSF ⁵⁷ 2017. Institute of Electrical and Electronics Engineers Inc., 2017, pp. 70–73. DOI: 10.1109/YSF.2017.8126654. ISBN 978-153862994-9. SCOPUS.

22. ²³ Y. Kochura, S. Stirenko, O. Alienin, M. Novotarskiy, and Y. Gordienko, "Comparative analysis of open source frameworks for machine learning with use case

in single-threaded and multi-threaded modes," in Proceedings of the 12th International Scientific and Technical Conference on Computer Sciences and Information Technologies, CSIT 2017, vol. 1, ⁵⁷ Institute of Electrical and Electronics Engineers Inc., 2017, pp. 373–376. DOI: 10.1109/STC-CSIT.2017.8098808. ISBN

978-153861638-3. SCOPUS.

10

ABSTRACT

Kochura Y. P. Deep machine learning method for object identification, classification and semantic segmentation. ³⁴ Qualifying scientific work, the manuscript.

The PhD thesis in the speciality 121 «Software engineering», within the field of knowledge 12 «Information technologies». ⁶⁶ National Technical University of Ukraine «Igor Sikorsky Kyiv Polytechnic Institute», Kyiv, 2026.

The PhD ¹⁵ thesis is devoted to the development of new and the improvement of existing deep machine learning methods for solving the problems of object identification, classification, and semantic segmentation. The proposed methods focus on improving the results of medical data analysis, in particular the diagnosis of lung diseases, through the integration of algorithms for semantic segmentation of anatomical structures and bone suppression in chest radiographs, ensemble classification in federated learning, as well as methods for outlier exclusion from the distribution of segmented masks and generative data augmentation by dataset distillation (GDADD). For the first time, an integrated technology has been proposed for the pre-processing of 2D X-ray images, combining segmentation of the areas containing target objects, based on deep encoder-decoder neural networks, with subsequent classification of pathologies. Unlike whole-image-based classification, this makes it possible to focus the analysis on clinically significant areas and improve diagnostic results by reducing the influence of non-target anatomical structures and reducing the dimensionality of the input data by a factor of 3.2 ± 0.7 (with a mean segmented-area fraction of 0.32 ± 0.06). It has been experimentally established that the effect of segmentation on classification results depends on the scale of the dataset: for small and imbalanced datasets (JSRT, BSE-JSRT), segmentation substantially reduces the risk of model overfitting, whereas for a large dataset (CheXpert) its effect is limited and observed only for specific pathology classes (Lung Opacity, Consolidation, Pleural Other).

For the first time, a classification method has been proposed for federated learning that combines an ensemble of base models with low computational complexity architectures following a "width over depth" strategy. Unlike traditional approaches based on increasing the depth of neural networks, this method improves the generalization ability of the model and reduces the risk of overfitting by decreasing the variance of predictions when aggregating partially uncorrelated errors of individual models. It has been experimentally established that the model's sensitivity to the number

11

of local training epochs between FedAvg averaging rounds increases with the number of base models in the ensemble: for four base architectures, the difference in validation accuracy between the maximum and minimum number of local epochs was 13.39%, for two – 5%, and for a single base model – only 1.89%.

The deep learning method based on convolutional neural networks has been improved: unlike known methods of automated X-ray-based diagnosis, it has been supplemented with stages of anatomical structure segmentation and bone shadow suppression in X-ray images, which reduces the overlap of pathological features with bone structures and additionally reduces the dimensionality of the input data by approximately a factor of 2 (with a mean relevant-area fraction of 0.15 ± 0.04) by removing irrelevant features, thereby lowering the risk of model overfitting under conditions of a limited training sample size.

Further developed is the method for outlier exclusion from segmented masks, which, unlike known approaches, is based on projecting the mask distribution into a reduced-dimensionality space using the t-SNE method, followed by threshold filtering relative to the data core, which made it possible to improve the quality of the input data for deep learning methods in the classification of pathological lung conditions from 2D chest X-rays.

Further developed is the dataset ⁴³distillation by matching training trajectories (DDMTT) method. ⁴³generative data augmentation by dataset distillation (GDADD) is proposed, which, unlike DDMTT, substantially increases the number of synthetic images per class, synthesizing a dataset whose volume approaches that of the real dataset. As a result, the synthesized images encode a wider range of informative features, enabling models trained on such a dataset to achieve a generalization ability comparable to that of models trained on a significantly larger real dataset. It has been experimentally confirmed that, on the balanced PathMNIST dataset, the validation classification accuracy of models trained on data synthesized by the GDADD method (0.917 ± 0.003) is slightly higher than that of classical convolutional architectures (ResNet-18, ResNet-50) and exceeds the results of automated machine learning methods (auto-sklearn, AutoKeras, Google AutoML Vision) by 9.9–28.1%; for imbalanced datasets, the effectiveness of the method requires further study.

The developed methods, which employ segmentation, bone shadow suppression, outlier exclusion, generative data augmentation, and base-model ensembling within federated learning, are complementary in nature: the first four methods are aimed

12

at sequentially reducing different types of redundancy and noise at the level of input data (spatial – segmentation, structural – bone shadow suppression, statistical – outlier exclusion) and compensating for the deficit in class representativeness (data augmentation), whereas base-model ensembling improves the reliability of the decision at the level of prediction aggregation. The effectiveness of each component has been confirmed experimentally along a separate line of research; some of the methods have been integrated at the level of a software platform developed within the framework of the research project "Artificial Intelligence Platform for Remote Automated Detection and Diagnosis of Human Diseases"(registration number 2020.01/0490), carried out ²²with grant support from the National Research Foundation of Ukraine in ²²2020–2021 (protocol No. 21 of September 16–17, 2020) under the "Science for Human Security and Society" call.

The obtained results complement existing understanding of the role of preprocessing and data cleaning in medical computer-aided diagnosis tasks and demonstrate the feasibility of using relatively simple models in combination with the developed methods. This creates a basis for using the proposed methods in the development of software tools for the intelligent processing and analysis of digital images, in particular for the development of clinical decision support systems designed to operate under conditions of limited dataset size, class imbalance, and high noise levels in the input data.

Keywords: machine learning, deep learning, neural network, identification, classification, semantic segmentation, decision making, artificial intelligence in healthcare.

Publications. The principal findings of the PhD thesis have been presented in 22 scientific publications that reflect the main content of the PhD thesis, including 16 journal articles (1 article in an international peer-reviewed journal in the first quartile (Q1), 7 articles in international peer-reviewed journals in the third quartile (Q3), 6 articles in international peer-reviewed journals in the fourth quartile (Q4), 1 article in an international peer-reviewed periodical indexed in Scopus without a quartile ranking (including 9 articles published in journals that are classified in the Scopus database by document type as "Conference paper" and bear an ISSN), and ⁶⁶1 article in a journal included in the List of Scientific Professional Publications of Ukraine (Category B), as well as ⁶⁶6 papers in the proceedings of scientific and technical conferences. Of these 22 publications, 21 were published in peer-reviewed journals and conference proceedings

indexed in the international scientific database Scopus. The total number of citations in Scopus (ID: 57198345363) is 525, Scopus h-index – 11:

1. ⁴³ Gordienko, G. Nowakowski, Y. Kochura, V. Taran, and S. Stirenko, "Generative data augmentation by dataset distillation," in ⁴³ Communications in Computer and Information Science, C. Tommasino, C. Russo, and M. Bernardini, Eds. Cham: Springer Nature Switzerland, 2026, vol. 2696, pp. 105–118. DOI: 10.1007/978-3-032-17216-7_9. ISSN 1865-0929. ISBN 978-303217215-0. SCOPUS, Q4.
2. Y. Gordienko, N. Gordienko, E. M. El Mhamdi, Y. Kochura, and S. Stirenko, "Multi-backbone ensembling for performance improvement in federated learning setup," in Lecture Notes in Networks and Systems, N. Min-Allah, K. Alissa, P. Sitek, M. Sano, S. Rodriguez, and A. Nongaillard, Eds. Cham: Springer Nature Switzerland, 2026, vol. 1598, pp. 129–138. DOI: 10.1007/978-3-032-04160-9_12. ISSN 2367-3370. ISBN 978-303204159-3. SCOPUS, Q4.
3. Y. Kochura, Y. Trochun, V. Taran, Y. Gordienko, O. Rokovyi, and S. Stirenko, ²¹ AeroNet: Domain-specific dataset for automation of unmanned aerial vehicles," Information, Computing and Intelligent systems, no. 7, pp. 83–95, 2025. DOI: 10.20535/2786-8729.7.2025.341779. ISSN 2786-8729. Scientific Professional Publications of Ukraine (Category B).
4. Y. Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, V. Taran, O. Alienin, and S. Stirenko, "Multimodal metadata augmentation for federated learning in medical applications," in Lecture Notes in Networks and Systems, X.-S. Yang, S. Sherratt, N. Dey, and A. Joshi, Eds. Springer Science and Business Media Deutschland GmbH, 2024, vol. 1002, pp. 537–547. DOI: 10.1007/978-981-97-3299-9_43. ISSN 2367-3370. ISBN 978-981973298-2. SCOPUS, Q4.
5. ²⁰ Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, O. Alienin, V. Taran, and S. Stirenko, "Ensemble knowledge distillation for edge intelligence in medical applications," in Studies in Computational Intelligence. Springer Science and Business Media Deutschland GmbH, 2023, vol. 1100, pp. 135–168. ²⁰ DOI: 10.1007/978-3-031-32095-8_5. ISSN 1860-949X. SCOPUS, Q4.
6. ²⁰ Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, O. Alienin, and S. Stirenko, "Fuzzy metadata augmentation for multimodal data classification," in ¹ Lecture Notes on Data Engineering and Communications Technologies. ¹ Springer Science and Business Media Deutschland GmbH, 2023, ²⁰ vol. 166, pp. 157–172. ²⁰ DOI: 10.1007/978-981-99-0835-6_11. ISSN 2367-4512. SCOPUS, Q3.
7. V. Taran, Y. Gordienko, O. Rokovyi, O. Alienin, Y. Kochura, and S. Stirenko, ¹⁹ Edge intelligence for medical applications under field conditions," in ¹ Lecture Notes on Data Engineering and Communications Technologies. ¹ Springer Science and Business Media Deutschland GmbH, 2022, vol. 135, pp. 71–80. ¹⁹ DOI: 10.1007/978-3-031-04809-8_6. ISSN 2367-4512. SCOPUS, Q3.
8. O. Alienin, ³⁶ O. Rokovyi, Y. Gordienko, Y. ³⁵ Kochura, V. Taran, and S. Stirenko, "Artificial intelligence platform for distant computer-aided detection (CADE) and computer-aided diagnosis (CADx) of human diseases," in Lecture Notes on Data Engineering and Communications Technologies. ¹ Springer Science and Business Media Deutschland GmbH, 2022, vol. 135, pp. ¹⁹ 91–100. DOI: 10.1007/978-3-031-04809-8_8. ISSN 2367-4512. SCOPUS, Q3.
9. V. Doms, Y. Gordienko, Y. Kochura, O. Rokovyi, O. Alienin, and S. Stirenko, "Deep learning for melanoma detection with testing time data augmentation," in Lecture Notes on Data Engineering and Communications Technologies. Springer Science and BusinessMedia Deutschland GmbH, 2021, vol. 82, pp. 131–140. DOI: 10.1007/978-3-030-80475-6_13. ISSN 2367-4512. SCOPUS.
10. Y. Gordienko, Y. ³⁵ Kochura, V. Taran, N. Gordienko, O. Rokovyi, O. Alienin, and S. Stirenko, "'Last mile' optimization of edge computing ecosystem with deep learning models and specialized tensor processing architectures," in Advances in Computers, S. Kim and G. C. Deka, Eds. Academic Press Inc., 2021, vol. 122, pp. 303–341. ¹⁹ DOI: 10.1016/bs.adcom.2020.10.003. ISSN 0065-2458. ISBN 978-012823123-4. SCOPUS, Q1.
11. ³⁶ Y. Gordienko, Y. Kochura, V. Taran, ³⁶ Y. Gordienko, A. Rokovyi, O. Alienin, and ¹⁹ S. Stirenko, "Scaling analysis of specialized tensor processing architectures for deep learning models," in Studies in Computational Intelligence. Cham: Springer, 2020, vol. 866, pp. 65–99. ¹⁹ DOI: 10.1007/978-3-030-31756-0_3. ISSN 1860-949 X. SCOPUS, Q4.
15. ³⁶ F. Gang, W. Zeng, Y. Gordienko, Y. Kochura, O. Alienin, O. Rokovyi, ³⁶ and S. Stirenko, "Effect of data augmentation and lung mask segmentation for automated chest radiograph interpretation of some lung diseases," in Communications in Computer and Information Science, T. Gedeon, K. W. Wong, and M. Lee, Eds. Cham: Springer, 2019, vol. 1142, pp. 333–340. DOI: 10.1007/978-3-030-36808-

1_36. ISSN 1865-0929. ISBN 978-303036807-4. SCOPUS, Q3.

13. Y. Gordienko, Y. Kochura, V. Taran, N. Gordienko, A. Bugaiov, and S. Stirenko, "Adaptive iterative pruning for accelerating deep neural networks," in 2019 11th

International Scientific and Practical Conference on Electronics and Information Technologies, ELIT 2019 - Proceedings. Institute of Electrical and Electronics

Engineers Inc., 2019, pp. 173–178. DOI: 10.1109/ELIT.2019.8892346. ISBN 978-172813561-8. SCOPUS.

14. V. Kochura, Y. Gordienko, V. Taran, N. Gordienko, A. Rokovyi, O. Alienin, and

S. Stirenko, "Batch size influence on performance of graphic and tensor processing units during training and inference phases," in Advances in Intelligent Systems and

Computing, Z. Hu, S. Petoukhov, I. Dychka, and M. He, Eds. Cham: Springer, 2019, vol. 938, pp. 658–668. DOI: 10.1007/978-3-030-16621-2_61. ISSN 2194-

5357. ISBN 978-303016620-5. SCOPUS, Q4.

15. V. Taran, Y. Gordienko, N. Gordienko, A. Rokovyi, Y. Kochura, O. Alienin,

and S. Stirenko, "Performance evaluation of deep learning networks for seman-

tic segmentation of traffic stereo-pair images," in ACM International Confer-

ence Proceeding Series, B. Rachev and A. Smrikarov, Eds. Association for Computing Machinery, 2018, pp. 73–80. DOI: 10.1145/3274005.3274032. ISBN

978-145036425-6. SCOPUS.

16. S. Stirenko, Y. Kochura, O. Alienin, O. Rokovyi, Y. Gordienko, P. Gang,

and W. Zeng, "Chest x-ray analysis of tuberculosis by deep learning with

segmentation and augmentation," in 2018 IEEE 38th International Confer-

ence on Electronics and Nanotechnology, ELNANO 2018 - Proceedings.

Institute of Electrical and Electronics Engineers Inc., 2018, pp. 422–428. DOI:

10.1109/ELNANO.2018.8477564. ISBN 978-153866383-7. SCOPUS.

17. P. Gang, W. Zhen, W. Zeng, Y. Gordienko, Y. Kochura, O. Alienin, O. Rokovyi,

and S. Stirenko, "Dimensionality reduction in deep learning for chest x-ray analysis

16

of lung cancer," in Proceedings - 2018 10th International Conference on Advanced

Computational Intelligence, ICACI 2018. Institute of Electrical and Electronics Engineers Inc., 2018, pp. 878–883. DOI:

10.1109/ICACI.2018.8377579. ISBN

978-153864362-4. SCOPUS.

18. Y. Gordienko, P. Gang, J. Hui, W. Zeng, Y. Kochura, O. Alienin, O. Rokovyi,

and S. Stirenko, "Deep learning with lung segmentation and bone shadow exclu-

sion techniques for chest x-ray analysis of lung cancer," in Advances in Intelli-

gent Systems and Computing, Z. Hu, S. Petoukhov, I. Dychka, and M. He, Eds.

Cham: Springer, 2018, vol. 754, pp. 638–647. DOI: 10.1007/978-3-319-91008-

6_63. ISSN 2194-5357. ISBN 978-331991007-9. SCOPUS, Q3.

19. Y. Kochura, S. Stirenko, O. Alienin, M. Novotarskiy, and Y. Gordienko, "Perfor-

mance analysis of open source machine learning frameworks for various param-

eters in single-threaded and multi-threaded modes," in Advances in Intelligent Sys-

tems and Computing, N. Shakhovska and V. Stepashko, Eds. Cham: Springer,

2018, vol. 689, pp. 243–256. DOI: 10.1007/978-3-319-70581-1_17. ISSN 2194-

5357. ISBN 978-331970580-4. SCOPUS, Q3.

20. P. Gang, J. Hui, S. Stirenko, Y. Gordienko, T. Shemsedinov, O. Alienin,

Y. Kochura, N. Gordienko, A. Rojbi, J. Lopez Benito, and E. Artetxe Gonzalez,

"User-driven intelligent interface on the basis of multimodal augmented reality and

brain-computer interaction for people with functional disabilities," in Advances

in Intelligent Systems and Computing, K. Arai, S. Kapoor, and R. Bhatia, Eds.

Cham: Springer, 2018, vol. 886, pp. 612–631. DOI: 10.1007/978-3-030-03402-

3_43. ISSN 2194-5357. ISBN 978-303003401-6. SCOPUS, Q3.

21. Y. Kochura, S. Stirenko, and Y. Gordienko, "Comparative performance analysis of neural networks architectures on h2o platform for various

activation functions," in 2017 IEEE International Young Scientists Forum on Applied Physics and Engi-

neering, YSF 2017. Institute of Electrical and Electronics Engineers Inc., 2017,

pp. 70–73. DOI: 10.1109/YSF.2017.8126654. ISBN 978-153862994-9. SCOPUS.

22. Y. Kochura, S. Stirenko, O. Alienin, M. Novotarskiy, and Y. Gordienko, "Com-

parative analysis of open source frameworks for machine learning with use case

in single-threaded and multi-threaded modes," in Proceedings of the 12th Inter-

national Scientific and Technical Conference on Computer Sciences and Infor-

17

mation Technologies, CSIT 2017, vol. 1. Institute of Electrical and Electronics

Engineers Inc., 2017, pp. 373–376. DOI: 10.1109/STC-CSIT.2017.8098808. ISBN

978-153861638-3. SCOPUS.

18

ЗМІСТ

Ст.

АНОТАЦІЯ	2
ПЕРЕЛІК УМОВНИХ ПОЗНАЧЕНЬ	21
ВСТУП	22
РОЗДІЛ 1. ЗАСТОСУВАННЯ ГЛИБИННОГО НАВЧАННЯ В ОХО- РОНІ ЗДОРОВ'Я	32
1.1 Вплив штучного інтелекту на трансформацію охорони здоров'я ..	32
1.2 Рентгенівське випромінювання	34
1.3 Рентгенографія грудної клітки	37
1.4 Застосування штучного інтелекту для діагностичного аналізу медичних даних	39
1.5 Висновки до розділу	45
РОЗДІЛ 2. НАБОРИ ДАНИХ ТА МЕТОДИ ЇХ ОБРОБКИ	47
2.1 Існуючі набори медичних даних для CAdE/CADx	48
2.2 Встановлення та адаптація наборів медичних даних із ознаками COVID-19	54
2.3 Анотація медичних даних	57
2.3.1 Маркування медичних датасетів з ознаками аномалій та хвороб легень	58
2.3.2 Маркування медичних датасетів з ознаками COVID-19 ...	62
2.3.3 Зауваження щодо особливостей використання медичних даних за результатами рентгенографії та КТ	66
2.4 Особливості збору та підготовки даних	67
2.4.1 Методи штучного розширення набору даних	68
2.4.2 Запропонований підхід до організації процесу анотації даних для спеціалізованих задач	73
2.5 Візуалізація результатів тестування і створення теплових мап для тестової підмножини даних	79
2.6 Методи ШІ для CAdE/CADx	85
2.6.1 Методи класифікації	86
2.6.2 Методи семантичної сегментації	89
2.6.3 Основні операції згорткових нейронних мереж	91
19	
2.7 Деякі підходи глибокого машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів ..	95
2.8 Висновки до розділу	101
РОЗДІЛ 3. МЕТОДИ ГЛИБИННОГО МАШИННОГО НАВЧАННЯ ДЛЯ ІДЕНТИФІКАЦІЇ, КЛАСИФІКАЦІЇ ТА СЕМАНТИЧНОЇ СЕГ- МЕНТАЦІЇ ОБ'ЄКТІВ	103
3.1 Інтегрована технологія попередньої обробки 2D-рентгенограм ...	104
3.1.1 Метод сегментації	105
3.1.2 Метод сегментації на зображеннях без кісткових структур .	107
3.1.3 Метод виключення викидів серед розподілу сегментованих масок на основі зменшення розмірності методом t-SNE	110
3.2 Метод класифікації у федеративному навчанні за допомогою ансамблю опорних моделей	114
3.3 Метод генеративної аугментації даних на основі дистилації навчальних траєкторій	118
3.4 Висновки до розділу	122
РОЗДІЛ 4. АНАЛІЗ ТА ОЦІНЮВАННЯ РЕЗУЛЬТАТІВ ДОСЛІД- ЖЕННЯ	124
4.1 Аналіз результатів застосування методу попередньої обробки графічних даних із використання сегментації цільових ділянок ...	124
4.2 Рентгенологічний аналіз туберкульозу на основі глибокого навчання з сегментацією та розширенням даних	129
4.2.1 Використане обладнання, методи та дані	131
4.2.2 Ефект розширення даних без втрат інформації	133
4.2.3 Ефект розширення даних з втратою інформації	133
4.2.4 Навчання та валідація моделей	134
4.2.5 Аналіз результатів дослідження	136
4.3 Вибір та налаштування моделей глибокого навчання із застосуванням штучного розширення різноманітності даних ...	140
4.4 Сегментація легень та вилучення тіней кісток для рентгенологічного аналізу новоутворень легень за допомогою	

глибинного навчання	143
4.4.1 Дані та методи	145
20	
4.4.2 Навчання та валідація моделей	146
4.4.3 Час навчання моделі та прискорення	149
4.5 Вплив доповнення даних та сегментації на автоматизовану інтерпретацію рентгенограм грудної клітки при захворюваннях легень	151
4.5.1 Результати експериментального дослідження	152
4.5.2 Аналіз та оцінювання результатів	155
4.6 Аналіз результатів застосування ансамблю опорних моделей у федеративному навчанні	156
4.6.1 Отримані результати	158
4.6.2 Аналіз результатів дослідження	162
4.7 Аналіз результатів застосування генеративної аугментації даних методом дистилляції набору даних	163
4.7.1 Синтезовані та реконструйовані зображення	163
4.7.2 Вплив на ефективність моделі кількості дистильованих зображень на клас для наборів даних CIFAR	165
4.7.3 Вплив на ефективність моделі кількості дистильованих зображень на клас для наборів даних MedMNIST	168
4.7.4 Аналіз результатів дослідження	172
4.8 Інтеграція розроблених методів до складу платформи дистанційного автоматизованого виявлення та діагностики патологій та аномалій у медичних даних	175
4.9 Висновки до розділу	178
ВИСНОВКИ	182
СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ	186
СПИСОК РИСУНКІВ	208
СПИСОК ТАБЛИЦЬ	215
ДОДАТОК А. СПИСОК ПУБЛІКАЦІЙ ЗДОБУВАЧА ЗА ТЕМОЮ ДИСЕРТАЦІЇ ТА ВІДОМОСТІ ПРО АПРОБАЦІЮ РЕЗУЛЬТАТІВ	216
А. 1 Список публікацій здобувача за темою дисертації	216
А. 2 Відомості про апробацію результатів	220

21	
ПЕРЕЛІК УМОВНИХ ПОЗНАЧЕНЬ	
КТ – комп'ютерна томографія	
НМ – нейронна мережа, нейронні мережі	
ШІ – штучний інтелект	
AP (Anteroposterior) – передньо-задня проєкція рентгенографії	
CADe (Computer-Aided Detection) – комп'ютерна детекція	
CADx (Computer-Aided Diagnosis) – комп'ютерна діагностика	
CNN (Convolutional Neural Network) – згортова нейронна мережа	
CXR (Chest X-ray) – рентгенівський знімок грудної клітки (рентгенограма)	
DD (Dataset Distillation) – дистилляція набору даних	
DDMTT (Dataset Distillation by Matching Training Trajectories) – дистилляція набору даних шляхом зіставлення траєкторій навчання	
DL (Deep Learning) – глибоке навчання	
GDADD (Generative Data Augmentation by Dataset Distillation) – генеративна аугментація даних на основі дистилляції набору даних	
GPU (Graphics Processing Unit) – графічний процесор	
GradCAM (Gradient-weighted Class Activation Mapping) – зважене градієнтом відображення активації класу	
MBE (Multi-Backbone Ensembling) – ансамблювання кількох базових мереж	
MBNN (Multi-Backbone Neural Network) – багатобазова (мультибекбонова) нейронна мережа	
PA (Posteroanterior) – задньо-передня проєкція рентгенографії	
ReLU (Rectified Linear Unit) – випрямляч або випрямлений лінійний вузол	
t-SNE (t-distributed Stochastic Neighbor Embedding) – t-розподілене вкладення стохастичної близькості	
TPU (Tensor Processing Unit) – тензорний процесор	
TTA (Test-Time Augmentation) – аугментація під час тестування	
XAI (Explainable AI) – пояснюваний штучний інтелект	
VIT (Vision Transformer) – зоровий трансформер	

ВСТУП

Актуальність теми. Упродовж останнього десятиліття спостерігається інтенсивне зростання уваги до дослідження та впровадження технологій штучного інтелекту (ШІ) з метою автоматизації виробничих процесів і підвищення їх ефективності [1]. Така тенденція значною мірою зумовлена потребою в оптимізації ресурсних витрат, посиленні контролю над технологічними операціями та підвищенні якості обслуговування споживачів. Одним із провідних напрямків цього розвитку є використання методів ШІ для вирішення широкого спектра прикладних завдань, зокрема в галузі комп'ютерного зору: в автономному транспорті [2], [3], системах розпізнавання облич [4], [5], медичній діагностиці [6], [7] тощо. Інтеграція таких рішень сприяє суттєвому підвищенню якості результатів завдяки зростанню точності, швидкодії та адаптивності обробки даних. У результаті як великі корпорації, так і представники малого та середнього бізнесу активно впроваджують рішення на основі ШІ у свої виробничі процеси для ефективного реагування на сучасні виклики та підсилення своєї конкурентоспроможності на ринку [1].

Не менш стрімке зростання застосування методів ШІ спостерігається і у галузі охорони здоров'я, де збільшується кількість лікарів, які використовують інтелектуальні методи обробки даних для підтримки прийняття клінічних рішень [8]. Особливого значення в цьому контексті набуває застосування методів комп'ютерного зору для аналізу рентгенограм грудної клітки – найпоширенішого радіологічного дослідження, яке виконує ключову роль для скринінгу, діагностики та лікування захворювань органів грудної порожнини, багато з яких є лідируючими причинами смертності у світі [9], [10]. Сучасні системи комп'ютерного зору продемонстрували високу ефективність у задачах класифікації та сегментації медичних зображень [11], [12], однак залишається потреба в їх подальшій оптимізації для досягнення точності, швидкодії та надійності, співставних або вищих за результати експертів-радіологів. Ця потреба додатково посилюється тим, що наявні методи оцінювання систем медичного ШІ нерідко виявляються недостатньо валідними та не відображають повною мірою реальну клінічну ефективність моделей, що обґрунтовує необхідність розробки більш строгих, орієнтованих на конкретні клінічні завдання підходів до вимірювання їхньої продуктивності [13]. Фокус досліджень саме на діагностиці легеневих захворювань зумовлений низ-

23

кою важливих чинників. По-перше, за оцінками Всесвітньої організації охорони здоров'я на 2018 рік лідируючою онкологічною патологією серед чоловіків у всьому світі було захворювання легень (14.5% від загального числа випадків у чоловіків та 8.4% у жінок) [14]. Ці дані підтверджують гостроту та актуальність даної проблеми. Своєчасне виявлення легеневих патологій, зокрема онкологічних, дозволить пацієнтам отримати доступ до ефективного лікування на ранніх етапах, що може суттєво підвищити шанси на одужання. По-друге, діагностика легеневих захворювань за рентгенограмами грудної клітки особливо чутлива до людського фактора: помилки сприйняття становлять 60–80% усіх радіологічних помилок [15], а патології легень (зокрема дрібні вузлики, ранні стадії туберкульозу чи накладання анатомічних структур) належать до складних випадків часто через обмежену контрастність тканин і накладання ребер на легеневу паренхіму. Через людський фактор певний рівень помилок у діагностиці є неминучим навіть у досвідчених спеціалістів. По-третє, застосування ШІ саме в цій галузі здатне дати суттєвий практичний ефект: використання ШІ медичними працівниками може істотно прискорити обробку великих обсягів даних, що є критично важливим для реалізації широкомасштабних скринінгових програм та національних ініціатив у сфері охорони здоров'я. Крім того інтелектуальні системи можуть виступати засобом підтримки прийняття клінічних рішень: зменшити навантаження на медичний персонал та підвищити точність інтерпретації там, де людський фактор є найвразливішим місцем.

Методи глибинного навчання (deep learning) є невід'ємною складовою сучасних технологій штучного інтелекту, які ґрунтуються на використанні багаточарових штучних нейронних мереж, демонструють високу ефективність у вирішенні завдань ідентифікації, класифікації, семантичної сегментації об'єктів, розпізнаванні та перекладі мови тощо. Протягом останнього десятиліття було запропоновано низку ефективних архітектур глибоких нейронних мереж (AlexNet [16], VGG [17], GoogLeNet (Inception) [18], YOLO [19], ViT [20] та ін.), які забезпечили відчутне зростання достовірності результатів на етапі тестування моделей.

Незважаючи на наявність ефективних архітектур сегментації медичних зоб-

ражень (U-Net [21] та її модифікації), методів виявлення й очищення викидів та технік дистилляції набору даних (DDMTT) [22], застосування цих методів в умовах обмежених і незбалансованих медичних наборів даних залишається недостатньо

24

дослідженням. Зокрема, не з'ясовано вплив кожного етапу попередньої обробки на діагностичну точність за окремими типами патологій, а також межі застосовності зменшення розмірності вхідних даних залежно від масштабу вибірки. Проблема полягає в оптимізації існуючих архітектур нейронних мереж та/або алгоритмів класифікації й семантичного аналізу з метою досягнення показників точності, повноти та швидкості передбачення, які були б зіставними або кращими за результати фахівців-експертів в аналізі медичних даних, зокрема в діагностиці легеневих захворювань.

Метою даної дисертаційної роботи є покращення показників продуктивності методів глибокого машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів порівняно з існуючими підходами, зокрема для задачі діагностики легеневих захворювань.

17 для досягнення поставленої мети необхідно було 13 вирішити такі задачі: 1. Проаналізувати переваги та недоліки існуючих методів машинного та

глибокого навчання, які застосовуються до задач комп'ютерного зору та сформулювати шляхи вдосконалення результатів ідентифікації, класифікації та семантичної сегментації об'єктів на цифрових зображеннях, зокрема для задачі діагностики легеневих захворювань на основі 2D рентгенограм;

2. Розробити технологію попередньої обробки графічних даних на основі глибоких нейронних мереж типу кодер-декодер для сегментації ділянок, що містять цільові об'єкти;

3. Удосконалити метод глибокого навчання на основі згорткових нейронних мереж шляхом інтеграції сегментації анатомічних структур та вилучення тіней кісток з рентгенограм;

4. Адаптувати методику зменшення розмірності даних на основі t-SNE для виключення викидів серед розподілу сегментованих масок;

5. Розробити метод класифікації у федеративному навчанні на основі ансамблю опорних моделей з архітектурами низької обчислювальної складності;

6. Розвинути метод дистилляції набору даних шляхом узгодження навчальних траскторій: запропонувати генеративну аугментацію даних для збільшення кількості синтетичних зображень на клас, синтезуючи набір даних, обсяг якого наближається до реального набору даних, що доз-

25

воляє моделям, навченим на такому наборі, досягати узагальнювальної здатності, зіставної з моделями, навченими на значно більшому реальному наборі даних.

Об'єкт дослідження. Процес програмної обробки та аналізу цифрових зображень, спрямований на ідентифікацію, класифікацію та семантичну сегментацію представлених на них об'єктів.

Предмет дослідження. Методи попередньої обробки даних¹, ансамблевої класифікації у федеративному навчанні та генеративної аугментації даних шляхом дистилляції набору даних, що застосовуються при розробленні програмного забезпечення для ідентифікації, класифікації та семантичної сегментації об'єктів на цифрових зображеннях.

Методи дослідження. Для досягнення мети та вирішення завдань дисертаційного дослідження у роботі використано такі методи:

1. Методи глибокого навчання. Методи побудови нейромережових архітектур, оптимізації та регуляризації використовувалися для проектування, розроблення, налаштування, навчання та оцінювання ефективності моделей як програмних компонентів у задачах ідентифікації, класифікації та семантичної сегментації об'єктів на цифрових зображеннях, зокрема в задачах діагностики легеневих захворювань з 2D рентгенограм.

2. Метод структурно-функціонального аналізу. Використовувався для пошуку взаємозалежностей і причинно-наслідкових зв'язків між архітектурними компонентами моделей глибокого навчання та їхньою узагальнювальною здатністю.

3. Методи статистичного аналізу. Використовувалися для планування експериментальних досліджень, а також для отримання узагальненої інформації про набори даних на яких відбувалось навчання та тестування

моделей.

4. Методи обробки даних. Використовувалися для збору, підготовки та зчитування даних, а також для представлення та збереження результатів.

Зв'язок роботи з науковими програмами, планами, темами, грантами. Тема дисертаційної роботи тісно пов'язана із науково-дослідними роботами, які проводяться на базі кафедри обчислювальної техніки (факультет інформатики та обчислювальної техніки, Національний технічний університет України) Підхід, який орієнтований на дані, стосується отримання правильного типу та систематичної зміни даних з метою вдосконалення якості та продуктивності моделей машинного навчання.

26
ни «Київський політехнічний інститут імені Ігоря Сікорського» та входить до затвердженого плану наукової роботи кафедри, що враховує розпорядження Кабінету Міністрів України від 2 грудня 2020 р. No 1556-р про схвалення Концепції розвитку штучного інтелекту в Україні. Робота виконана в рамках науково-дослідного проекту «Платформа штучного інтелекту для дистанційного автоматизованого виявлення та діагностики захворювань людини» (реєстраційний номер 2020.01/0490), який реалізовувався за рахунок грантової підтримки Національного фонду досліджень України (протокол No21 від 16-17 вересня 2020 року) на 2020-2021 роки в рамках конкурсу «Наука для безпеки людини та суспільства».

Наукова новизна результатів, отриманих автором, полягає у наступному:

– Вперше запропоновано інтегровану технологію попередньої обробки 2D рентгенограм, яка поєднує сегментацію цільових ділянок на основі глибоких нейронних мереж типу кодер-декодер із подальшою класифікацією патологій. На відміну від класифікації за ознаками всього зображення, запропонована технологія дозволяє зосередити аналіз на клінічно значущих ділянках, знизити вплив нецільових анатомічних структур, зменшити розмірність вхідних даних та покращити результати діагностики окремих легеневих захворювань.

– Вперше запропоновано метод класифікації у федеративному навчанні, що поєднує ансамбль опорних моделей з архітектурами низької обчислювальної складності за стратегією «ширина важливіша за глибину», який на відміну від існуючих підходів до збільшення глибини нейронних мереж, дозволяє підвищити узагальнювальну здатність моделі та зменшити ризик перенавчання за рахунок зменшення дисперсії передбачень при агрегуванні частково некорельованих похибок окремих моделей, при цьому експериментально встановлено, що вииграш від ансамблювання залежить від кількості локальних епох навчання між раундами усереднення моделей.

– Удосконалено метод глибинного навчання на основі згорткових нейронних мереж, який на відміну від відомих методів автоматизованої діагностики за рентгенограмами доповнено етапами сегментації анатомічних структур та вилучення з рентгенограм тіней кісток, що дозволяє зменшити перекриття патологічних ознак кістковими структурами, а також додатково скоротити розмірність вхідних даних за рахунок вилучення не-

27
levantних ознак, що знижує ризик перенавчання моделі за умов обмеженого розміру навчальної вибірки.

– Отримав подальший розвиток метод виключення викидів серед сегментованих масок, який, на відміну від відомих підходів, ґрунтується на проєкції розподілу масок у простір зниженої розмірності за допомогою методу t-SNE з подальшою пороговою фільтрацією відносно ядра даних, що дозволило покращити якість вхідних даних для методів глибинного навчання під час класифікації патологічних станів легень за 2D-рентгенограмами.

– Отримав подальший розвиток метод дистиляції набору даних шляхом узгодження навчальних траєкторій (DDMTT): запропоновано генеративну аугментацію даних GDADD, яка, на відміну від DDMTT, суттєво збільшує кількість синтетичних зображень на клас, синтезуючи набір даних, обсяг якого наближається до реального набору даних. За рахунок цього синтезовані зображення кодують ширший спектр інформативних ознак, що дозволяє моделям, навченим на такому наборі, досягати узагальнювальної здатності, зіставної з моделями, навченими на значно більшому реальному наборі даних.

Наукове та практичне значення. Технологія попередньої обробки рентгеновських знімків грудної клітки, яка поєднує сегментацію легень, вилучення

тіней кісток і виключення викидів серед розподілу сегментованих масок за допомогою методу t-SNE, дозволяє зменшити рівень шуму у вхідних даних і підвищити здатність моделей до узагальнення особливо за умов обмеженої кількості навчальних прикладів. Розроблений метод ансамблевої класифікації у федеративному навчанні дозволяє підвищити узагальнювальну здатність моделей без централізованого збору медичних даних, що створює основу для реалізації розподілених програмних засобів аналізу медичних даних в умовах обмежень щодо конфіденційності пацієнтів і територіальної розподіленості медичних закладів. Отримана подальшого розвитку техніка генеративної аугментації даних шляхом дистиляції набору даних (GDADD) дозволяє формувати компактні синтетичні набори даних, придатні для навчання моделей за відсутності доступу до великих реальних датасетів, зокрема для збалансованих наборів даних, а для незбалансованих наборів ефективність методу потребує подальшого вивчення і вдосконалення. Отримані результати доповнюють існуючі уявлення про роль поперед-

28

ньої обробки та очищення даних у задачах медичної комп'ютерної діагностики, а також демонструють доцільність застосування відносно простих моделей у поєднанні з запропонованими підходами. Розроблена технологія попередньої обробки графічних даних за допомогою сегментації ділянок, які містять цільові об'єкти, може ефективно застосовуватися для навчання глибоких нейронних мереж та діагностики легеневих хвороб з 2D рентгенограм за наявності обмеженої кількості даних.

Запропоновані підходи можуть бути використані для розроблення програмних засобів інтелектуальної обробки та аналізу цифрових зображень, зокрема для створення систем підтримки клінічних рішень, орієнтованих на роботу за умов обмеженого розміру вибірки, дисбалансу класів і високого рівня шуму у вхідних даних.

Ступінь достовірності отриманих результатів забезпечується коректним використанням перевірених практикою методів машинного навчання та математичного апарату, а також використанням загальноприйнятих метрик для оцінки ефективності навчених моделей в поставлених задачах на незалежних тестових вибірках.

Особистий внесок. Усі результати дисертаційного дослідження, які виносяться на захист, отримано автором особисто. Основні результати за темою дисертації, які висвітлено у наукових працях, опублікованих у співавторстві, супроводжуються зазначенням особистого внеску здобувача в кожній із публікацій. За відсутності в тексті публікації окремо зазначеного розподілу внеску співавторів внесок здобувача та інших співавторів вважається рівноцінним. У кожній із наукових праць, що опубліковано у співавторстві, здобувачу належить такий внесок. У роботі [23] здобувачем проведено аналіз переваг та недоліків фреймворків машинного навчання з відкритим вихідним кодом для однопоточного та багатопоточного режимів навчання моделей. У роботах [24], [25] здобувачем проведено експериментальне дослідження продуктивності деяких архітектур нейронних мереж на платформі H2O для різних функцій активації та метрик зупинки. У роботі [26] здобувачем запропоновано комплексний підхід попередньої обробки рентгенограм грудної клітки для підвищення точності та швидкості навчання згорткових нейронних мереж. У роботі [27] здобувачем досліджено ефективність семантичної сегментації, що базується на архітектурі ICNet. У публікації [28] здобувачем досліджено вплив семантичної сегментації легень та геометричної трансформа-

29

ції даних на точність комп'ютерної діагностики туберкульозу за допомогою глибоких згорткових нейронних мереж на малих і незбалансованих наборах даних. У роботі [29] здобувачем проаналізовано можливість інтеграції різних режимів взаємодії людини з комп'ютером для користувачів з обмеженими функціональними можливостями. У роботі [30] за допомогою методу сегментації легень, що був розроблений здобувачем, створено нові набори даних для підвищення точності глибоких нейронних мереж у виявленні ознак аномальних станів легень за рентгеновськими знімками грудної клітки. У публікації [31] здобувачем проведено експериментальне дослідження ефективності сегментації легень та аугментації даних для підвищення точності CADx захворювань легень на основі DenseNet121 на наборі даних CheXpert з еталонною розміткою радіологів. У роботі [32] здобувачем проаналізовано ефективність методу адаптивного ітеративного прунінгу для прискорення роботи згорткових нейронних мереж з контрольованими втратами точності класифікації. У роботах [33], [34] здобувачем проведено експериментальне дослідження впливу розміру пакету даних на ефективність навчання і

тестування моделей глибокого навчання та проаналізовано обчислювальну складність деяких глибоких нейронних мереж (VGG16, ResNet50) при використанні спеціалізованих прискорювачів. У роботі [35] здобувачем запропоновано використання ансамблю опорних моделей для покращення ефективності класифікації у рамках федеративного навчання, а також проведено експериментальне дослідження впливу кількості опорних моделей та локальних епох на продуктивність моделі LCNet050 в умовах розподіленого федеративного навчання. У роботі [36] здобувачем запропоновано підхід до організації процесу анотації даних для спеціалізованих задач детекції та трекінгу об'єктів, зокрема з урахуванням підвищених вимог до анотації цільових об'єктів у динамічних та візуально переважаних сценах (лісових масивах, міських умовах тощо), де велика кількість перекриваючих один одного об'єктів, змінне освітлення, змінний масштаб об'єктів та складна фоновіа текстура. У роботі [37] здобувачем запропоновано розширення застосування методу дистиляції набору даних шляхом узгодження навчальних траєкторій на медичні набори даних MedMNIST. У роботах [38], [39] здобувачем проведено експериментальне навчання та валідацію одноmodalних і multimodalних моделей, а також здійснено аналіз та інтерпретацію отриманих результатів. У роботі [40] здобувачем здійснено підготовку та аналіз медичних даних для тестування методу ансамблевого відбору моделей на основі дистиляції

30

знань. У роботі [41] здобувачем проведено експериментальне навчання та тестування глибоких нейронних мереж (EfficientNetB0, EfficientNetB6, DenseNet121, MobileNetV2) для бінарної класифікації із застосуванням аугментації даних на етапі тестування. У роботах [42], [43] здобувачем здійснено аналіз медичних даних та інтерпретацію отриманих результатів щодо продуктивності периферійних обчислювальних прискорювачів. Це дало змогу обґрунтувати практичну застосовність периферійних обчислювальних архітектур для розгортання систем автоматизованої діагностики в умовах обмежених обчислювальних ресурсів, зокрема у віддалених медичних закладах без доступу до потужної серверної інфраструктури. У роботі [44] здобувачем здійснено тестування розроблених у дисертаційній роботі методів ідентифікації, класифікації та семантичної сегментації на медичних даних у складі платформи штучного інтелекту для дистанційного автоматизованого виявлення (CADe) та автоматизованої діагностики (CADx) патологій та аномалій.

19. Апробація результатів дисертації. Основні результати дисертаційної роботи були обговорені та представлені на таких конференціях:

4. 12th International Scientific and Technical Conference on Computer Sciences and Information Technologies (CSIT), 05-08 вересня 2017, Львів, Україна.
35. IEEE Young Scientists Forum on Applied Physics and Engineering (YSF), 17-20 жовтня 2017, Львів, Україна.
35. The First International Conference on Computer Science, Engineering and Education Applications (ICCSEEA2018), 18-20 січня 2018, Київ, Україна.
6. IEEE 38th International Conference on Electronics and Nanotechnology (ELNANO), 22-24 квітня 2018, Київ, Україна.
85. 19th International Conference on Computer Systems and Technologies (CompSysTech'18), 10-14 вересня 2018, Русе, Болгарія.
35. The Second International Conference on Computer Science, Engineering and Education Applications (ICCSEEA2019), 26-27 січня 2019, Київ, Україна.
35. 11th International Scientific and Practical Conference on Electronics and Information Technologies (ELIT-2019), 16-18 вересня 2019, Львів, Україна.
8. 22nd International Conference on Distributed Computing and Artificial Intelligence, 25-27 червня 2025, Лілльський університет, Франція.

31

Структура та обсяг дисертації. Дисертація має такі основні структурні елементи: титульний аркуш, анотацію державною та англійською мовами, зміст, перелік умовних позначень, основну частину (вступ, чотири розділи дисертації, висновки), список використаних джерел, список рисунків, список таблиць та додатки. Загальний обсяг дисертації становить 221 сторінок з яких 164 сторінки основного тексту. У дисертації наведено 65 рисунків та 10 таблиць. Список використаних джерел включає 213 найменувань. Дисертація містить 1 додаток на 6 сторінках.

32

РОЗДІЛ 1. ЗАСТОСУВАННЯ ГЛИБИННОГО НАВЧАННЯ В ОХОРОНІ ЗДОРОВ'Я

1.1 Вплив штучного інтелекту на трансформацію охорони здоров'я

Останні досягнення в галузі обчислювальних технологій, машинного навчання і особливо глибинного навчання, суттєво сприяють появі інноваційних рішень для автоматизації процесів виявлення різноманітних захворювань на основі медичних даних. Це стало також можливим завдяки доступності все більшої кількості відкритих спеціалізованих наборів даних, які відображають різні аспекти стану здоров'я людини. Такі датасети активно використовуються у наукових дослідженнях і часто надаються для академічної спільноти на безоплатній основі. Ці досягнення разом з відкритими наборами медичних даних прискорюють та докорінно змінюють сферу охорони здоров'я, впливаючи не лише на радіологію, зокрема комп'ютерну томографію (КТ), магнітно-резонансну томографію (МРТ), ультразвук і рентгенографію, але й на такі галузі як кардіологія, дерматологія, генетика, а також електронні медичні записи тощо. У всіх цих напрямках ШІ розширює можливості пошуку прихованих закономірностей в даних, а також пришвидшує клінічні процеси.

Клайв Хамбі (Clive Humby) влучно охарактеризував дані як «нову нафту двадцять першого століття», підкреслюючи їхню стратегічну цінність для сучасного суспільства. Подібно до нафти, дані потребують попереднього опрацювання та очищення, перш ніж їх можна буде ефективно використати. Щоб створити дійсно цінну сутність на основі даних потрібні надійні методи для їх аналізу. Згідно зі звітом медичної школи Стенфордського університету за 2020 рік, кількість лікарів, які приймають клінічні рішення на основі даних, неухильно зростає [45]. Це свідчить про те, що сучасна система охорони здоров'я перебуває в активній фазі адаптації до практичного використання даних та впровадження новітніх технологій. Як було вже згадано раніше, ключовими драйверами цієї трансформації є поява відкритих наборів медичних даних, а також стрімкий прогрес у галузі штучного інтелекту. Це в свою чергу створює передумови для ефективного застосування сучасних методів ШІ з метою аналізу даних про стан здоров'я пацієнта, що дозволяє своєчасно виявляти ознаки захворювання та приймати обґрунтовані рішення на основі клінічних доказів щодо подальшого лікування. Медич-

33

ний персонал сучасних закладів охорони здоров'я має доступ до надзвичайно великого обсягу діагностичних даних, зібраних за допомогою рентгенографії, КТ, МРТ та інших інструментальних методів дослідження. Як правило, після проведення таких обстежень лікарі змушені самостійно аналізувати отримані дані та інтерпретувати їх результати для формування клінічних висновків. Застосування методів штучного інтелекту в медичній практиці може суттєво пришвидшити обробку великих обсягів даних, що є особливо важливим для реалізації програм широкомасштабного скринінгу та національних ініціатив у сфері охорони здоров'я. Крім того, такі технології сприяють зниженню ризику медичних помилок, забезпечуючи підтримку прийняття клінічних рішень завдяки автоматизованому аналізу даних та наданню лікарю релевантних діагностичних підказок. Результати сучасних досліджень демонструють, що використання ШІ може суттєво підвищити точність виявлення характерних ознак, що спричинили появу патологічних змін [46]—[48]. Нещодавні досягнення у сфері глибинного навчання дозволили досягти рівня продуктивності співставного з експертною оцінкою у задачах інтерпретації медичних знімків [10], [47], [49], [50]. Це стало можливим завдяки використанню глибоких нейронних мереж у поєднанні з великими анотованими наборами даних [10], [47], [51].

Одним із найбільш активно досліджуваних напрямів у галузі медичної візуалізації є аналіз рентгеновських знімків грудної клітки (CXR), який відіграє ключову роль у діагностиці багатьох захворювань. Серед основних завдань, що вирішуються за допомогою методів машинного та глибинного навчання для обробки CXR-знімків можна виділити завдання сегментації легень [30], [52], аналіз туберкульозу та злоякісних новоутворень [28], [30], [53], виявлення патологічних відхилень [54], розробку механізмів інтерпретації рішень моделей [55], а також створення прогнозів на основі багатомодальних джерел даних [56]—[58]. Однак, незважаючи на такі успіхи, широке впровадження рішень на основі штучного інтелекту у клінічну практику залишається складним завданням [59]. Основними викликами на цьому шляху є потреба у великій кількості високоякісних і збалансованих наборів даних; наявність суттєвого дисбалансу класів, коли зразки з патологіями зустрічаються значно рідше, ніж нормальні зображення; висока варіативність апаратів і протоколів отримання знімків; а також необхідність інтерпретованості рішень для лікарів. Вирішення цих проблем є критично важливим для

34

підвищення точності, надійності та практичної цінності систем комп'ютерної діа-

гностики.

Результати дослідження, які надані компанією Grand View Research [60] показують, що ринок штучного інтелекту в охороні здоров'я демонструє стрімке зростання. У 2024 році глобальний обсяг інвестицій складав близько 26-32 млрд доларів США, а до 2030 року прогнозується збільшення до 187-208 млрд доларів із середньорічним темпом зростання понад 38%. Така динаміка свідчить про високу актуальність впровадження ШІ-технологій у медичну практику, що створює нові можливості для підвищення якості діагностики, лікування та організації медичної допомоги. Найбільшу частку ринку ШІ в медицині займає Північна Америка (понад 54%), що пояснюється високим рівнем інвестицій і наявністю провідних інноваційних центрів. Серед технологій домінує машинне навчання, яке у 2024 році охоплювало понад 35% ринку. Основним сегментом застосування є програмне забезпечення для медичної діагностики і лікування (понад 46%), а також роботизовані хірургічні системи, які становлять понад 13% ринку [60].

1.2 Рентгенівське випромінювання

Короткохвильове електромагнітне випромінювання, яке сьогодні носить назву X-променів або рентгенівського випромінювання вперше було відкрито всесвітньо відомим українським ученим та винахідником Іваном Пулюєм, майже на сім років раніше за німецького фізика Вільгельма Рентгена. Втім, приписують це відкриття саме Рентгену, яке датується 8 листопада 1895 року [61], [62]. Сьогодні рентгенівське випромінювання широко використовується у медицині для проведення скринінгу та діагностики населення.

X-промені – електромагнітні хвилі. За корпускулярно-хвильовим дуалізмом електромагнітне випромінювання можна розглядати як потік фотонів. Енергія фотона E з частотою ν і довжиною хвилі λ дорівнює:

$$E = h\nu = \frac{hc}{\lambda}$$

с

λ

, (1.1)

де h – стала Планка, c – швидкість світла у вакуумі, $hc = 1.2397 \times 10^{-6} \text{ eV} \cdot \text{м}$.

Електромагнітний спектр (див. рисунок 1.1) можна розділити на кілька діапазонів. Він починається з дуже довгих радіохвиль, що застосовуються, зокрема,

35

в магнітно-резонансній томографії (МРТ), далі охоплює мікрохвильовий, інфрачервоний, оптичний та ультрафіолетовий діапазони. Наступною частиною спектра є рентгенівське випромінювання (X-промені), яке використовується у рентгенографії та комп'ютерній томографії (КТ), а завершується спектр ультракороткими високоенергетичними γ -променями, що знаходять застосування в ядерній візуалізації [63]. Довжина хвилі рентгенівського випромінювання має порядок ангстрема (10^{-10} м), а отже, відповідні енергії фотонів мають порядок 103 eV ($1 \text{ eV} = 1.602 \times 10^{-19} \text{ Дж}$).

X-промені генеруються у вакуумній трубці, всередині якої розташовано катод та анод (рисунок 1.2а). Катодний струм J вивільняє електрони на катоді шляхом теплового збудження. Ці електрони прискорюються до анода під дією різниці потенціалів U між катодом та анодом. Прискорені електрони бомбардують анод та взаємодіють з електронами ядер аноду, вивільняючи свою енергію, частково у вигляді рентгенівських променів, тобто у вигляді гальмівного та характеристичного випромінювання.

Інфрачервоне

випромінювання

700 нм

400 нм

Радіохвилі Мікрохвилі

Оптичне

випромінювання

Ультрафіолетове

випромінювання X-промені γ -промені

Довжина хвилі, λ [м]

Енергія фотона, E [eV]

102 101 1 10⁻¹ 10⁻² 10⁻³ 10⁻⁴ 10⁻⁵ 10⁻⁶ 10⁻⁷ 10⁻⁸ 10⁻⁹ 10⁻¹⁰ 10⁻¹¹ 10⁻¹² 10⁻¹³
10⁻⁸ 10⁻⁷ 10⁻⁶ 10⁻⁵ 10⁻⁴ 10⁻³ 10⁻² 10⁻¹ 1 101 102 103 104 105 106 107

МРТ Ендоскопія

Рентгенографія

КТ

Ядерна

візуалізація

Прискорений електрон, коли проходить поблизу ядра, сповільнюється, а його траєкторія відхиляється. Втрачена енергія випромінюється у вигляді галь-

36

мівного рентгенівського фотона. Приблизно 80% усіх рентгенівських променів у рентгенівському пучку складається з Х-променів, створених гальмівним випромінюванням [64]. Характеристичне рентгенівське випромінювання виникає, коли прискорений високоенергетичний електрон вибиває електрон із внутрішньої електронної оболонки атома, при цьому обидва електрони вириваються з атома, залишаючи «дірку» у внутрішній оболонці. Це вакантне місце займає електрон із зовнішньої оболонки атома, віддаючи частину своєї енергії, яка випромінюється у вигляді рентгенівського фотона. Гальмівне випромінювання дає неперервний рентгенівський спектр, тоді як характеристичне випромінювання дає характерні піки, накладені на неперервний спектр (рисунок 1.2б). Рентгенологи можуть змінювати параметри струму та напруги на рентгенівському апараті, щоб маніпулювати властивостями отриманого рентгенівського випромінювання. Різні спектри рентгенівських променів застосовуються до різних частин тіла.

Радіохвилі

Свинцевий екран

АнодКатод

Вакуум

Фокусний щит

Х-промені

30–100 кВ

а)

Характеристичне

випромінювання

Гальмівне

випромінювання

Довжина хвилі, λ [Å]

In

те

нс

ив

ні

ст

ь

б)

Рисунок 1.2 — Схема вакуумної трубки для генерації Х-променів а). Розподіл інтенсивності у рентгенівському спектрі молібдену для різних напруг б).

Потенціал збудження К-серії становить 20.1 кВ. Цей ряд з'являється як характерні піки на кривій 25 кВ. Піки **Kα** і **Kβ** обумовлені падінням електрона з L-оболонки та M-оболонки відповідно [63]

37

1.3 Рентгенографія грудної клітки

Рентгенографія грудної клітки (в англійській літературі також відома як chest x-ray або CXR) вважається найчастішим радіологічним дослідженням у всьому світі, щороку проводиться понад 1.4 млрд. процедур [65]. Цей метод має вирішальне значення для скринінгу, діагностики та лікування захворювань органів грудної порожнини, багато з яких є лідируючими причинами смертності у всьому світі [66]. Статистичні дані, які подані Національною службою здоров'я України на урядовому порталі показують, що рентгенографія грудної клітки є найбільш часто запитуваною діагностикою серед українців [67].

Рентгенографія органів грудної клітки виконується у трьох основних проєкціях, що визначаються положенням пацієнта відносно джерела випромінювання та детектора: задньо-передня (posteroanterior, PA), передньо-задня (anteroposterior, AP) та бічна. Задньо-передня та передньо-задня проєкції відносяться до фронтальних, відмінність між ними полягає у розташуванні джерела випромінювання: позаду пацієнта (PA) або спереду (AP). AP-зображення зазвичай отримують у положенні лежачи, тоді як PA – у вертикальному положенні. Бічна проєкція як правило виконується додатково до PA-знімка, формується при проходженні променів збоку, переважно справа наліво. Рівень опромінення під час бічної рентгенографії грудної клітки перевищує показники, характерні для фронтальних проєкцій, що зумовлює недоцільність її рутинного застосування у стандартній діагностичній практиці [68].

Профілактичні рентгенівські обстеження окремих груп населення України проводять лікувально-профілактичні заклади охорони здоров'я, які надають первинну та вторинну медичну допомогу. Залежно від мети, рентгенівські обстеження поділяють на дві категорії: скринінгові (профілактичні) та діагностичні. Скринінгові обстеження призначаються для осіб із груп ризику і проводяться з метою раннього виявлення патологій легень та середостіння. Діагностичні обстеження проводяться з метою встановлення точного клінічного діагнозу, оцінки функціонального стану органів та систем, а також моніторингу ефективності лікування. Профілактичні обстеження органів грудної порожнини виконуються за допомогою рентгенівських апаратів для скринінгових досліджень, що можуть бути плівковими або з цифровою обробкою зображень [69].

38

Під час проведення профілактичного обстеження органів грудної порожнини виконується один рентгенівський знімок (кадр) на помітному виходу у прямій проекції. Особам віком понад 50 років додатково проводиться правобічне бокове сканування. З метою зменшення променевого навантаження та уникнення артефактів, пов'язаних із рухами пацієнта, слід забезпечувати мінімальну експозицію шляхом застосування високої анодної напруги [69]. За умови оптимального співвідношення контрастності та різкості на рентгенограмі мають чітко візуалізуватися контури верхніх 3–4 грудних хребців і міжхребцевих щілин, анатомічні структури кісток плечового пояса, трахея та правий головний бронх. Легеневий малюнок повинен бути добре диференційованим по всій площині зображення, за винятком кортикальних відділів легень. Правильність позиціонування пацієнта перевіряється за положенням медіальних кінців ключиць, які повинні розташовуватися на однаковій відстані від серединної лінії (хребта). На цифрових приймачах зображення бажано отримувати з належною якістю без необхідності подальшого коригування яскравості та контрастності електронного зображення. Рентгенограми повинні відповідати стандарту – бути максимально уніфікованими за параметрами контрастності, різкості та оптичної щільності тіней [69].

Щодо перегляду (інтерпретації) рентгенологічних зображень, а також оцінки виявлених патологічних змін та їх подальшої реєстрації, Міністерство охорони здоров'я України регламентує діяльність лікарів-рентгенологів відповідно до чинних нормативно-правових актів та галузевих стандартів. Ці положення визначають алгоритми аналізу діагностичних зображень, вимоги до документування результатів досліджень, а також критерії достовірності та точності постановки попереднього діагнозу. Щоб зменшити ризик діагностичних помилок під час оцінки рентгенівських знімків доцільно застосовувати подвійну незалежну інтерпретацію (двома лікарями) або повторну інтерпретацію (тим самим лікарем через день), із обов'язковим урахуванням результатів попередніх досліджень. У випадку, коли діагностичні висновки розходяться, перевагу слід надавати тому діагнозу, який свідчить про більш серйозну патологію. За умови недостатньої впевненості лікаря-рентгенолога у відсутності активних рентгенологічних чи клінічних проявів туберкульозного ураження, а також при встановленні змін у динаміці порівняно з попередніми дослідженнями, рекомендовано направляти пацієнта на розширене клініко-рентгенологічне дообстеження [69].

39

1.4 Застосування штучного інтелекту для діагностичного аналізу медичних даних

Глибинне навчання наразі є ключовою технологією, яка лежить в основі більшості застосувань комп'ютерного зору, зокрема у завданнях медичної візуалізації, комп'ютерної діагностики та аналізу зображень. Поряд із цим, глибинне навчання широко використовується у автономних транспортних засобах, промисловій автоматизації та контролі якості, обробці природної мови, кібербезпеці і багатьох інших галузях. Однак глибокі нейронні мережі є надзвичайно залежними від даних та зазвичай потребують навчання на великих наборах для досягнення високої точності результатів. Проте, навіть використання масштабних датасетів не гарантує успішного узагальнення мережі на дані, які відмінні від тих, що використовувалися під час навчання (поза розподілом навчального набору), наприклад, на зображення, які отримані іншим сенсором. Це є складним завданням, оскільки глибокі нейронні мережі схильні до перенавчання на штучних статистичних закономірностях навчальних даних. Анування великих наборів даних є надзвичайно трудомістким і ресурсозатратним процесом, особливо для завдань на рівні пікселів, якою є семантична сегментація. Передусім небажаним є повторне виконання анотації щоразу при зміні сенсора. Це питання є вкрай важливим у медичній галузі, де анотація даних на рівні пікселів потребує залучення

висококваліфікованих фахівців і значною мірою ускладнюється різноманітністю сенсорних пристроїв, що використовуються у різних медичних установах [70]. Саме тому деякі результати цієї дисертації спрямовані на розв'язання зазначеної проблеми шляхом розробки підходів, що підвищують стійкість моделей до варіативності даних та зменшують залежність від великих обсягів даних. Упродовж останніх років було опубліковано багато наукових праць, які присвячені застосуванню методів машинного та глибокого навчання до широкого спектра медичних задач. Ці дослідження успішно вирішують складні задачі не лише завдяки створенню нових моделей та архітектур нейронних мереж, а й через інтеграцію кількох етапів обробки медичних даних, таких як попередня обробка, сегментація, вилучення ознак, класифікація та прогнозування в єдиний наскрізний процес, реалізація якого раніше була неможливою за допомогою традиційного програмування. Як результат, такі системи часто дозволяють досягти продуктивності на рівні практикуючих лікарів-експертів. Разом із тим варто

40

зазначити, що переважна більшість наукових досліджень, пов'язаних з застосуванням ШІ в медицині, як правило здійснюються у чітко контрольованих умовах для яких характерне використання великих обчислювальних потужностей та спеціалізованих наборів даних, які лише частково відображають реальні клінічні сценарії. Таким чином, дослідницьке (експериментальне) середовище рідко може охопити усю складність, варіативність та реальні умови медичної практики. Рішенням цієї проблеми може бути використання федеративного навчання – підходу, який дозволяє інтегрувати знання, що були отримані з розподілених даних, які зберігаються у різних клінічних установах у глобальну модель глибокого навчання. Такий підхід дозволяє не лише поєднати переваги дослідницького та експериментального середовищ, але також вирішити проблему конфіденційності та безпеки даних, оскільки медичні дані є вкрай чутливими, підлягають правовому регулюванню через що не можуть бути легко поширені та використані третіми особами.

Діагностичний аналіз медичних даних методами машинного навчання потребує ручного вилучення ознак. Такий підхід є досить трудомістким та вимагає від інженера глибоких знань в предметній галузі для кращого розуміння особливостей пов'язаних з даними. Натомість, методи глибокого навчання дозволяють автоматизувати цей процес завдяки тому, що модель глибокого навчання може самостійно видобувати з даних потрібні ознаки за якими в кінці буде виконано передбачення. На рисунку 1.3 проілюстровані аспекти двох основних підходів, які засновані на машинному та глибокому навчанні для діагностичного аналізу медичних зображень.

Останні досягнення, які пов'язані з появою великих мовних моделей (LLM) створюють передумови для переосмислення особливостей використання та взаємодії людини з системами ШІ в медицині. LLM є прикладом моделі-основи (foundation model)¹ – попередньо навченої моделі на великому наборі даних, яку можна з мінімальними зусиллями адаптувати до різних сфер і завдань. За своєю природою великі мовні моделі є багатозадачними, оскільки здатні узагальнювати інформацію та застосовувати її у різних сценаріях, зокрема для автоматизації вирішення питань первинної медичної допомоги, підтримки прийняття клінічних рішень та багато іншого. Як показано у роботі [57], спеціально налаштована для медичної галузі велика мовна модель Med-PaLM (Google) досягає 67.7% точності 1 Велика X-модель.

41

Видобування ознак

Модель

Класифікація

Пневмонія

COVID-19

Набряк легень

...

Модель

Видобування ознак

+

Класифікація

Пневмонія

COVID-19

Набряк легень

...

Машинне навчання

Глибинне навчання

Рисунок 1.3 — Машинне та глибинне навчання у задачах діагностичного аналізу медичних даних

на медичному іспитовому бенчмарку MedQA і стала першою системою штучного інтелекту, яка отримала прохідний бал на цьому тесті. Удосконалена версія Med-PaLM 2 [71] перевершила попередній результат і встановила нову найкращу точність на рівні 86.5%. Мультимодальна версія Med-PaLM M крім тесту включає такі модальності як дерматологія, офтальмологія (зображення сітківки), радіологія (3D та 2D), патологія, медичні записи та геноміка. На рисунку 1.4 показано приклад роботи Med-PaLM M у ході аналізу рентгенограми.

Основними науковими викликами у сфері сегментації медичних зображень залишаються відсутність універсальності більшості сучасних моделей, їхня залежність від конкретної модальності та складність узагальнення на нові задачі.

2 Охоплює використання інформації з різних джерел: зображення, електронні медичні записи, носимих пристроїв тощо.

42

Рисунок 1.4 — Велика мовна модель Med-PaLM M аналізує рентгенограму [57]

Крім того, значна частина методів не здатна ефективно працювати з об'єктами зі слабо вираженими контурами та низьким контрастом, що є типовим для медичних даних. MedSAM вирішує ці проблеми завдяки донавчанню на надзвичайно великому та різноманітному наборі медичних зображень, що дозволяє досягати високої точності у широкому спектрі задач і модальностей. Порівняно з попередніми рішеннями, MedSAM демонструє значно кращу узагальнюваність, перевершує сучасні моделі-основи сегментації та не поступається або навіть перевищує продуктивність вузькоспеціалізованих моделей. Це визначає MedSAM як перспективну платформу для створення універсальних рішень у медичній візуалізації [58].

Однією з ключових вимог створення моделі-основи для універсальної сегментації медичних зображень є здатність ефективно працювати за умов широкої варіативності у параметрах візуалізації, анатомічних особливостях та проявах патологій. З цією метою у роботі [58] було сформовано великий набір даних, який налічував 1 570 263 пари зображення-маска, до якого увійшли дані з 10 модаль-

43

ностей медичної візуалізації, понад 30 типів онкологічних захворювань, а також численні варіації протоколів візуалізації (див. рис. 1.5).

Розробка сучасних медичних систем на основі ШІ для застосування у клінічних умовах потребує зовнішньої валідації, залучення кількох установ та проспективних даних³. У клінічних дослідженнях проспективні дані вважаються більш надійними, оскільки збір інформації відбувається за визначеними критеріями. У роботі [72] вивчалися різні аспекти організації наукових досліджень, що визначають ефективність алгоритмів штучного інтелекту для діагностичного аналізу медичних зображень. Як показали результати, серед понад 516 статей, які опубліковані як у медичних, так і не медичних журналах, лише 6% (31) використовували зовнішню валідацію результатів і всього 15 робіт охоплювали валідацію в кількох установах. Відсутність зовнішньої валідації може призводити до високого ризику завищеної оцінки ефективності моделей, оскільки вони оцінюються на даних з тих самих установ, де були натреновані, що обмежує їх здатність до узагальнення. Обмежена кількість залучених установ та використання виключно ретроспективних даних додатково знижують надійність отриманих результатів. У підсумку це може призводити до невідповідності між заявленою та реальною продуктивністю моделі під час її впровадження в клінічну практику, що ставить під загрозу безпеку пацієнтів і ускладнює інтеграцію таких систем у медичні процеси.

Важливим практичним аспектом впровадження систем автоматизованої діагностики (CADE/CADx) на основі глибинного навчання є можливість їх ефективного розгортання на периферійних обчислювальних пристроях (edge computing) безпосередньо в місці надання медичної допомоги, без необхідності передавання чутливих медичних даних на віддалені сервери. У роботах [42], [43] представлено результати дослідження ефективності спеціалізованих периферійних обчислювальних прискорювачів (Google Coral Edge TPU, Intel Movidius) для інференсу моделей глибинного навчання. Наведено кількісні оцінки продуктивності із відповідними значеннями середнього та стандартного відхилення. Зокрема, для пристрою Google Coral встановлено, що перехід з операційної системи

Windows 10 на Ubuntu 18.04 забезпечує прискорення часу виконання однієї ітерації до 2,13 разів, перехід з USB 2.0 на USB 3.0 – до 2 разів, а використання режиму розгону (overclocking) – до 1,2 разів. Сукупне застосування зазначених 3 Це протилежність ретроспективним даним, які збирають з уже наявних записів або баз даних.

44

Рисунок 1.5 — Анатомічні структури, патологічні стани та методи медичної візуалізації разом з масками експертної анотації та результатами сегментації моделі-основи MedSAM [58]

оптимізацій забезпечує загальне прискорення часу виконання однієї ітерації до 4,9 разів. Додатково, у роботі [42] розглядається багаторівнева ієрархічна методологія оптимізації моделей глибинного навчання для периферійних обчислювальних прискорювачів зі спеціалізованою архітектурою: тензорних процесорів (TPU, Tensor Processing Unit), процесорів для обробки візуальних даних (VPU, Vision Processing Unit) та нейронних процесорів (NPU, Neural Processing Unit), ефективність якої підтверджено на практичній задачі діагностики патологій легень за рентгеновськими знімками. Отримані результати підтверджують практичну доцільність використання периферійних обчислювальних архітектур для розгортання розроблених у цій дисертації методів автоматизованої діагностики в умовах обмежених обчислювальних ресурсів, зокрема у віддалених медичних закладах без доступу до потужної серверної інфраструктури.

45

1.5 Висновки до розділу

Уданому розділі розглянуто ключові аспекти застосування глибинного навчання в охороні здоров'я, а також проаналізовано сучасний стан впровадження технологій штучного інтелекту у медичну практику. Встановлено, що методи штучного інтелекту разом з відкритими наборами медичних даних і спеціалізованим апаратним забезпеченням, яке оптимізоване для навчання та тестування нейронних мереж, виступають ключовими драйверами цифрової трансформації в даній галузі. Впровадження надійних методів штучного інтелекту у медичну практику може підвищити точності діагностики захворювань, зменшити навантаження на лікарів, а також пришвидшити обробку великих обсягів даних, що є особливо важливим для реалізації програм широкомасштабного скринінгу та національних ініціатив у сфері охорони здоров'я. Особливу увагу приділено рентгенографії грудної клітки (chest X-ray, CXR) – найпоширенішому радіологічному дослідженню, яке виконує ключову роль для скринінгу, діагностики та лікування захворювань органів грудної порожнини, багато з яких є лідируючими причинами смертності у всьому світі.

Встановлено, що основні завдання, які вирішуються методами глибинного навчання під час аналізу CXR-знімків є сегментація легень, виявлення патологій, інтерпретація рішень моделі і прогнозування на основі багатомодальних даних. Водночас широке впровадження штучного інтелекту у клінічну практику обмежується потребою у великих і високоякісних наборах даних, дисбалансом класів (обмежена кількість даних по рідкісних захворюваннях), варіативністю апаратів і протоколів отримання знімків, а також необхідністю забезпечення інтерпретованості результатів для лікарів, що є вирішальним для підвищення надійності, точності та практичної цінності систем комп'ютерної діагностики. Високі результати прогнозів часто досягаються не лише завдяки створенню нових моделей та архітектур нейронних мереж, а й через інтеграцію кількох ефективних етапів обробки медичних даних (попередня обробка, сегментація, вилучення ознак, класифікація, прогнозування) у єдиний наскрізний процес. Завдяки цьому точність подібних систем часто досягає рівня практикуючих лікарів-експертів. Водночас більшість наукових досліджень зазвичай виконуються у чітко контрольованих умовах для яких характерним є використання значних обчислювальних потужностей і спеціалізованих наборів даних, які лише частково відображають реальні клінічні сце-

46

нарії. Перспективним методом для подолання цих обмежень є застосування федеративного навчання, що дозволяє інтегрувати знання з даних, які розподілені між різними клінічними установами у єдину глобальну модель. Цей підхід не лише поєднує переваги дослідницького та експериментального середовищ, але також забезпечує конфіденційність і безпеку медичних даних, що є критично важливим для дотримання правових норм (зокрема GDPR, HIPAA) та етичних принципів медичної практики у сфері охорони здоров'я.

Аналітичні дані представлені у даному розділі демонструють стрімке зростання світового ринку штучного інтелекту у медицині, а також збільшення кіль-

кості практикуючих лікарів, які приймають клінічні рішення на основі інтелектуальних методів обробки даних. Це свідчить про те, що сучасна система охорони здоров'я перебуває в активній фазі адаптації до практичного використання методів штучного інтелекту для аналізу медичних даних та інтеграції новітніх технологій у клінічну практику. Таким чином, на цьому етапі доцільним є розробка методу глибокого машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів з 2D рентгенограм, що дозволить досягти продуктивності співставної з продуктивністю фахівців-експертів у галузі діагностики легеневих захворювань за рахунок сегментації легень, вилучення тіней кісток, виключення викидів серед розподілу сегментованих масок за допомогою t-SNE та зменшення розмірності вхідних даних.

У наступних розділах подано детальний опис вирішення завдань, які ставились у межах даного дисертаційного дослідження.

47

РОЗДІЛ 2. НАБОРИ ДАНИХ ТА МЕТОДИ ЇХ ОБРОБКИ

Історично увага дослідників у галузі штучного інтелекту концентрувала-ся переважно на вдосконаленні архітектур моделей за наперед заданого набору даних, тобто на підході, орієнтованому на модель [73]. Однак підвищення складності архітектури моделі за наперед заданого набору даних не гарантує кращої поведінки системи в реальних умовах застосування, оскільки залишає поза увагою розмаїття репрезентованих випадків, їх складність та точність відображення даними сутності поставленої задачі [74]. Крім того, моделі, розроблені в такий спосіб, зазвичай є вузькоспеціалізованими й погано переносяться на суміжні задачі [73]. Недостатня увага до даних здатна спричинити так звані каскади даних [75], тобто накопичувальні негативні ефекти, за яких проблема, що виникла на ранньому етапі роботи з даними, посилюється на наступних етапах обробки й непередбачувано проявляється у функціонуванні кінцевої системи штучного інтелекту, зокрема у вигляді зниження точності та закріплення систематичних упереджень моделі [76]. У задачах з високою ціною помилки, до яких належить і медична діагностика, такі наслідки суттєво обмежують практичну придатність системи. Це зумовило поступове зміщення дослідницького фокусу в бік підходу, орієнтованого на дані, який передбачає систематичне вдосконалення обсягу та якості даних за відносно стабільної архітектури моделі [73], [77]. Хоча цей перехід ще триває, він уже підтверджений низкою практичних результатів у різних галузях штучного інтелекту: прогрес великих мовних моделей значною мірою пояснюється саме масштабом і якістю використовуваних навчальних даних [78]–[80], а в аналізі медичних зображень якість і репрезентативність навчальних вибірок є вагомими чинниками узагальнювальної здатності моделей [81].

Значна частина медичних закладів світу функціонує в умовах обмеженого доступу до кваліфікованого персоналу для інтерпретації медичних зображень: забезпеченість радіологами в країнах з низьким рівнем доходу становить лише 1,9 на мільйон населення проти 97,9 на мільйон у країнах з високим рівнем доходу [82], [83]. Це підкреслює актуальність засобів автоматизованої підтримки діагностичних рішень. Водночас практичне застосування таких засобів часто ускладнюється відсутністю потужних обчислювальних ресурсів та великих анотованих наборів даних у таких закладах.

48

2.1 Існуючі набори медичних даних для CADe/CADx

Рак легень залишається серйозною глобальною проблемою, особливо в регіонах з високим рівнем забруднення повітря, що погіршує перебіг захворювання. Це одна з найбільш поширених форм онкології, яка характеризується високим рівнем смертності. Одним з ефективних підходів у боротьбі з цією недугою є раннє виявлення шляхом скринінгу. Результати показують, що своєчасна діагностика значно підвищує шанси на успішне лікування та зменшує ризик тяжких ускладнень. Зокрема, скринінг із використанням комп'ютерної томографії визнається у світі як дієвий засіб зниження смертності від раку легень [84].

Але цей підхід має порівняно низький рівень поширення через високу вартість та обмежену доступність для більшості населення у різних частинах світу. На даний момент, як уже зазначалось, CXR є найпопулярнішим та найдоступнішим діагностичним інструментом для моніторингу стану здоров'я та діагностики багатьох захворювань легень, включаючи пневмонію, туберкульоз, рак тощо. Однак, виявлення ознак цих захворювань є відносно складною процедурою, яка передбачає залучення спеціалістів з експертними знаннями предметної області. При цьому, робота експертів-рентгенологів ускладнюється тривалим ручним аналізом знімків для виявлення ознак захворювань, а також нестачею таких фахівців у

даних області. Наприклад, у Китаї щорічна кількість діагностованих випадків на рак легень є дуже великою (> 600 тис.), але кількість сертифікованих рентгенологів є низькою (~ 80 тис.) для проведення загальнонаціонального обстеження (> 1.4 млрд. громадян).

Наявність відкритих наборів даних, які включають зображення КТ та CXR, дозволяє вченим з обробки даних навчати, перевіряти та налаштовувати власні алгоритми глибокого навчання для комп'ютерної діагностики захворювань. Варто підкреслити, що більшість відкритих медичних датасетів невеликі за обсягом, часто мають обмежене різноманіття та зазвичай не охоплюють рідкісні захворювання. Сучасна медицина стрімко переходить до використання даних як основи для нових відкриттів та вдосконалення лікування. Разом із тим, однією з найбільших перешкод на цьому шляху є брак якісних і репрезентативних наборів медичних даних, необхідних для навчання надійних моделей штучного інтелекту. Складність централізованого збору таких даних зумовлена як етичними нормами, так і законодавчими обмеженнями щодо конфіденційності. У більшості галузей охо-

49

рони здоров'я централізований збір або публічне поширення даних ускладнене через суворі норми конфіденційності, що є цілком виправдано, оскільки медична інформація є дуже чутливою.

Датасет JSRT

Наприклад, поява бази даних¹, яка містить знімки вражених на рак легень та знімки здорових людей, запропонованої Японським товариством радіологічних технологій (Japanese Society of Radiological Technology – JSRT), відкриває цей шлях для багатьох дослідницьких груп у всьому світі [85]. Ця стандартна база даних цифрових зображень була створена JSRT у співпраці з Японським радіологічним товариством (JRS) у 1998 році. З тих пір база даних JSRT використовується багатьма дослідниками у світі для різних дослідницьких цілей, таких як обробка зображень, стиснення зображень, оцінка відображення зображень, автоматизована діагностика (CADx), система архівування та комунікації зображень, а також для навчання та тестування моделей.

Ще один перспективний варіант для поліпшення прогнозу моделі виявляти захворювання, пов'язаний з вилученням зі знімку деяких частин тіла, які закривають легені, наприклад, ребра та ключиці. Дослідницька група з діагностики грудної порожнини (Будапешт, Угорщина) надала у якості послуги для спільноти, яка займається візуалізацією медичних зображень, версію набору даних JSRT, а саме BSE-JSRT, без тіней кісток [86]. В іншому дослідженні двоступеневий алгоритм усунення тіней зі знімків CXR, спричинених кістками ребер, базувався на розмежуванні ребер за допомогою нового гібридного підходу самошаблону (self-template), а потім на придушенні цих окреслених ребер за допомогою регресійної моделі, яка враховує зміну проксимальної товщини кісток по вертикальній осі [87]. Нижче наведено додаткові відомості про набори даних, які використані у цій роботі. На рисунку 2.1 показано один приклад, який взятий з двох різних наборів даних для одного і того ж пацієнта.

¹ База даних, датасет, набір даних використовуються у тексті як синоніми.

50

- а) Оригінал із розташуванням пухлини, JSRT [85]
- б) Без тіней кісток, BSE-JSRT [86]
- в) Метаінформація

Рисунок 2.1 — Приклад оригінального зображення (2048 × 2048 пікселів) JSRT [85] з ділянкою ракової пухлини а), відповідного зображення без кісток з набору даних BSE-JSRT [86] б) та метаінформації, яка відповідає цьому зображенню в). Розташування та область пухлини позначаються відповідно точкою та колом а)

Набір даних JSRT містить 247 зображень (рис. 2.1а) з них 154 зображень з легеневиими новоутвореннями (типу ракових) та 93 зображень здорових людей [85]. Набір даних BSE-JSRT містить 247 таких самих зображень, що і набір даних JSRT, але без тіней ключиць та ребер (рис. 2.1б), які були видалені спеціальними алгоритмами [86]. Одним із подальших завдань цієї роботи (на наступних етапах) є необхідність урахування різниці в ефективності застосування підходів DL до оригінального набору даних JSRT (далі він буде згадуватись як набір даних No 01) та набору даних BSE-JSRT, тобто набір даних JSRT з якого були виключені

тіні ключиць та ребер (далі набір даних No 02).

У наступній частині роботи буде більш детально продемонстровано методи сегментації легень та техніки вилучення тіней кісток для аналізу 2D CXR знімків методами DL з метою спрощення процесу виявлення рентгенологами підозрілих ознак та новоутворень у легенях людини. Аналіз проводився на наступних наборах даних: набір даних No 01, набір даних No 02, оригінальний набір даних JSRT після сегментації (далі набір даних No 03) та набір даних BSE-JSRT після сегментації та без тіней кісток (далі набір даних No 04).

51

Датасет LIDC

Цю ініціативу підтримали інші медичні та дослідницькі установи. Консорціум бази даних легеневих знімків (LIDC) пропонує набір даних, що містить зображення, зроблені різними способами (комп'ютерна томографія – КТ, цифрова рентгенографія – DX, комп'ютерна рентгенографія – CR) для > 1000 пацієнтів і містить > 244 000 зображень із роздільною здатністю в площині ділянки 512 × 512 пікселів з відхиленням в межах 0.542-0.750 мм [88].

Датасет MC-SH

Національна медична бібліотека США створила два відкритих набори даних CXR для сприяння досліджень з автоматизованої діагностики легеневих захворювань із особливим акцентом на туберкульоз легень [89], [90]. Набір даних округу Монтгомері (MC) зібрано у співпраці з Міністерством охорони здоров'я та соціальних служб округу Монтгомері, штат Меріленд, США. Набір даних лікарні Шеньчжень (SH) був отриманий у Shenzhen No. 3 People's Hospital, Китай. Обидва набори даних містять нормальні та аномальні рентгенівські знімки грудної клітки з проявами туберкульозу та включають відповідні висновки рентгенолога.

Датасет Chexpert

CheXpert – це великий набір даних, який складається з 224 316 рентгенограм грудної клітки 65 240 пацієнтів [47]. Його було промарковано в автоматичному режимі на присутність 14 спостережень, які зустрічаються у радіологічних звітах, фіксуючи невизначеності, властиві під час інтерпретації рентгенограм. На підставі валідаційного набору з 200 рентгенологічних досліджень грудної клітки, які були промарковано вручну 3 сертифікованими радіологами, було виявлено, що для різних патологій корисні різні методи врахування невизначеності інтерпретації. Найкращу навчову DL модель було оцінено на тестовому наборі, що складається з 500 CRX, прокоментованих консенсусом із 5 сертифікованих рентгенологів, та порівняно ефективність цієї DL моделі з результатами 3 додаткових рентгенологів при виявленні 5 вибраних патологій. Для деяких хвороб модельні

52

криві ROC лежать над усіма 3 операційними точками рентгенолога. Наразі цей датасет запропоновано як загальний стандарт для оцінки ефективності моделей інтерпретації рентгенограми грудної клітки.

Датасет PadChest

Це промаркований широкомасштабний набір рентгенівських знімків грудної клітки з високою роздільною здатністю для CADe/CADx та відповідними підготовленими звітами [91]. Цей набір даних включає понад 160 000 зображень, отриманих від 67 000 пацієнтів. Знімки інтерпретували та досліджували рентгенологи госпіталю Сан-Хуан (Іспанія) з 2009 по 2017 рік, охоплюючи шість різних позицій та додаткову інформацію про отримання зображень та демографію пацієнта.

Звіти були позначені 174 різними рентгенологічними висновками, 19 диференціальними діагнозами та 104 анатомічними місцями, організованими як ієрархічна систематика, зіставлена зі стандартною термінологією UMLS. 27% звітів були анотовані вручну кваліфікованими лікарями, а решта – контрольованим методом, заснованим на нейронній мережі.

Датасет MRNet

Набір даних MRNet складається з 1370 MPT досліджень колінного суглоба, проведених у Медичному центрі Стенфордського університету [92]. Набір даних містить 1104 (80,6%) патологічних станів, серед яких 319 (23,3%) – травми передньої хрестоподібної зв'язки та 508 (37,1%) – травмами меніска; маркування було виконано шляхом ручного аналізу клінічних звітів.

Датасет MIMIC-CXR-JPG

Це великий набір даних з 377 110 рентгенівських знімків грудної клітки, отриманих від 227 827 пацієнтів у медичному центрі Beth Israel Deaconess Medical Center у період з 2011 по 2016 роки [93]. Зображення забезпечені 14 ярликами,

отриманими з двох засобів обробки природних мов, застосованих до відповідних текстових звітів радіологів. MIMIC-CXR-JPG повністю походить із бази даних MIMIC-CXR і має на меті забезпечити зручну оброблену версію MIMIC-CXR, а також забезпечити стандартне посилання на розділення даних та мітки зображень. Для захисту конфіденційності пацієнта, з усіх зображень була вилучена ідентифікаційна інформація пацієнта. Набір даних надається у вільному доступі для полегшення та заохочення широкого спектру досліджень у галузі медичного комп'ютерного зору.

Датасет MURA

MURA (MUculoskeletal Radiographs) – це великий набір рентгенівських знімків кісток, який є доступним для спільноти [94]. Цей набір даних може допомогти прийти до значного прогресу в технологіях медичної візуалізації та допомогти діагностувати на рівні експертів патологічні стани там, де доступ до кваліфікованих рентгенологів обмежений. Це важливо, оскільки на захворювання опорно-рухового апарату страждають понад 1.7 мільярда людей у всьому світі та є найпоширенішою причиною сильних, довгострокових болів та інвалідності, зі щорічним збільшенням відвідувань відділень невідкладної допомоги.

Датасет ChestX-ray14

Нещодавно було опубліковано датасет ChestX-ray14, який деякий час був найбільшим загальнодоступним набором даних рентгенографії грудної клітки, що містить понад 100 000 рентгенівських знімків із фронтальним оглядом 14 різних захворювань легень [51].

2.2 Встановлення та адаптація наборів медичних даних із ознаками COVID-19

Цей підрозділ містить підсумок огляду наявних наборів медичних даних про стан легень із ознаками COVID-19 (постійно оновлюються внаслідок збільшення кількості даних по цій хворобі і не є остаточним).

Наразі сукупність медичних даних щодо рентгенологічних особливостей може бути підсумована наступним чином.

Первинними виявленнями COVID-19 [95] є атипова або організована пневмонія [96], [97]. До 18% випадків демонструють нормальні рентгенограми грудної клітки або КТ при легкому/ранньому перебігу хвороби [98]. Двостороннє та/або багатодільне ураження поширене, частіше з нижчим розподілом зони.

Рентгенографія [98], [99]:

1. Нерівномірні або розсіяні помутніння повітряного простору (airspace opacities), ущільнення (consolidation) або непрозорість матового скла (ground-glass opacity – GGO).
2. Рідко зустрічається плевральний випіт (pleural effusion).

Комп'ютерна томографія (КТ) [96], [97], [100]:

1. Непрозорість матового скла (GGO).
2. GGO у вигляді нерегулярної бруківки (crazy paving appearance), тобто GGO із між-/внутрішньодольковим потовщенням перегородки (inter-/intra-lobular septal thickening).
3. Ущільнення повітряного простору.
4. Потовщення бронхів у вогнищі ураження.
5. Тракційні бронхоектази.
6. Субплевральне збереження структури (subpleural sparing).

Датасет COVID-19: сегментація

Цей набір даних [101], [102] являє собою загальну колекцію із 100 сегментованих рентгенограм грудної клітки людини з випадками захворювання на коронавірус (COVID-19). Файл анотацій поданий у форматі COCO.

Кожна анотація містить сегментацію анатомічних класів (ліва легеня, права легеня, середостіння, дихальні шляхи), класи патології (симптом “матового скла”, ущільнення, плевральний випіт, пневмоторакс), об'єкти (ендотрахеальна трубка, центральний венозний катетер, моніторингові зонди, назогастральна трубка, грудна трубка, Tubings). Кожне зображення вручну анотовано кваліфікованими рентгенологами.

Формат: PNG, JPG, JPEG

Файл архіву на сервері: covid-19-chest-xray-segmentations-dataset-master.zip

Датасет COVID-19: детекція

Цей набір даних [101], [103] являє собою загальну колекцію із 616 рентгено-

грам грудної клітки людини з випадками захворювання на коронавірус (COVID-19). Тип анотації – обмежувальні рамки легень (Lung Bounding Boxes). Файл анотацій поданий у форматі COCO.

Кожна анотація містить дві обмежувальні рамки (ліва легеня, права легеня) з додатковими тегами, такими як Finding, Modality, Sex, Survival, View. Кожне зображення вручну анотовано кваліфікованими рентгенологами.

Формат: PNG, JPG, JPEG

Файл архіву на сервері: covid-19-chest-xray-segmentations-dataset-master.zip

Датасет COVID-19 (ieee8023)

Цей набір даних [101], [104]—[106] містить 6500 сегментованих рентгенограм у проекціях AP/PA.

Джерело 1. Спільними зусиллями зареєстровано 517 випадків COVID-19 [101], також доступні експортні версії цього набору даних. Ліцензії для зображень з набору даних подані у metadata.csv файлі.

Джерело 2. 5863 зображень взято з [105] і також доступні та зазвичай згадуються в цьому наборі даних Kaggle [106]. Ліцензія:CC4.0.

Формат: JPEG

56

Файл архіву на сервері: covid-19-xray-dataset-master.zip

Датасет COVID-19 (Radiomica)

Набір даних AlforCOVID [107] містить великий архів медичних знімків пацієнтів Італії, які хворі на COVID-19. Усі зображення, які подані у цьому наборі даних, є рентгенологічними дослідженнями грудної клітки, які проводилися під час госпіталізації пацієнтів з підозрою на COVID-19. У всіх 823 пацієнтів, включених до цієї бази даних, було підтверджено молекулярний тест на SARS-CoV-2.

Обстеження були проведені в Італії під час першої хвилі пандемії. Пацієнти у наборі даних поділені на 2 групи, виходячи з їх клінічного стану: легка (без вентиляційної підтримки) та важка (неінвазивна вентиляційна підтримка або відділення інтенсивної терапії, або смерть).

Формат: DICOM

Файл архіву на сервері: AlforCOVID imaging archive.zip

Датасет COVID-19 (UCSD-AI4H)

Зображення цього датасету [108] зібрані з публікацій, пов'язаних з COVID19, з medRxiv, bioRxiv, NEJM, JAMA, тощо. КТ, що містять аномалії COVID-19, відібрані для набору з описами. Усі авторські права на дані належать авторам та видавцям публікацій, звідки було зібрано ці дані. Деталі про набір даних описано в цьому препринті [109]. Метаінформація (наприклад, ідентифікатор пацієнта, інформація про пацієнта, DOI, опис зображення) подана у файлі COVID-CT-MetaInfo.xlsx

Формат: PNG

Файл архіву на сервері: COVID-CT-master.zip

Датасет BIMCV-COVID19+

Набір даних BIMCV-COVID19+ [110] – це великий набір даних рентгенівських знімків грудної клітки CXR (CR, DX) та комп'ютерною томографією (КТ) па-

57

цієнтів із COVID-19, а також їх рентгенологічними знахідками, патологіями, результатами полімеразної ланцюгової реакції (ПЛР), тестами на антитіла та рентгенологічні звіти з Банку даних медичних зображень Валенсії (Valencian Region Medical Image Bank – BIMCV). Висновки відображаються на стандартній термінології Єдиної медичної мовної системи (Unified Medical Language System – UMLS) та охоплюють широкий спектр грудних утворень, порівняно з кількістю сутностей, зазначених у попередніх наборах даних. Зображення зберігаються у високій роздільній здатності, а сутності локалізуються з використанням анатомічних міток у форматі Medical Imaging Data Structure (MIDS). Крім того, група експертів-рентгенологів коментувала 23 зображення, включаючи семантичну сегментацію рентгенологічних висновків. Більше того, надається всеохоплююча інформація, включаючи демографічну інформацію про пацієнта, типи проекцій та параметри отримання зображення під час дослідження, серед іншого. База даних містить 7377 CR, 9463 DX та 6687 КТ досліджень.

Датасет BIMCV-COVID19-

Набір даних BIMCV-COVID19- [111] – це великий набір даних рентгенівських знімків грудної клітки CXR (CR, DX) та комп'ютерною томографією (КТ) серед яких немає пацієнтів з COVID-19. Отримані дані відображаються згідно стандартній термінології UMLS та охоплюють широкий спектр грудних утво-

рень, порівняно з кількістю сутностей, зазначених у попередніх наборах даних. Зображення зберігаються у високій роздільній здатності, а сутності локалізуються з використанням анатомічних міток у форматі MIDS.

2.3 Анотація медичних даних

Нижче на прикладі датасетів загального призначення продемонстровано існуючий підхід до маркування медичних даних.

58

2.3.1 Маркування медичних датасетів з ознаками аномалій та хвороб легень

Раніше було подано загальний опис датасету Chexpert у підрозділі 5. Нижче наводиться приклад виводу метаданих (рис. 2.2) про наявні типи хвороб у даному датасеті (після попередньої обробки 2).

Cardiomegaly (кардіомегалія, іноді мегакардія або мегалокардія) – це медичний стан, при якому спостерігається стан «збільшення серця», який може виникнути внаслідок безлічі інших захворювань, таких як ожиріння або ішемічна хвороба серця. Кардіомегалія може бути досить серйозною недугою: залежно від того, яка частина серця збільшена, пацієнт може страждати від серцевої недостатності. Останні дослідження показують, що кардіомегалія асоціюється з більш високим ризиком раптової серцевої смерті [112].

Emphysema – емфізема (CA21 за визначенням BOO3), визначається аномальним і постійним збільшенням повітряних просторів на деякій відстані від кінцевих бронхіол, супроводжується руйнуванням стінок повітряного простору без явного фіброзу (тобто фіброзу не видно неозброєним оком). Емфізема може існувати у осіб, які не мають перешкод повітряному потоку; проте це частіше зустрічається серед пацієнтів, у яких помірна або важка обструкція повітряного потоку [113].

1. Компенсаторна емфізема (CB40.4).
 2. Інтерстиціальна емфізема, що бере початок у перинатальному періоді (KB27.0).
 3. Емфізема внаслідок вдихання хімічних речовин, газів, парів або парів (CA81).
 4. Емфізема середостіння (CB40.3).
 5. Травматична підшкірна емфізема, не класифікована в інших рубриках (NFOA.7).
 6. Емфізема, хірургічна (підшкірна) (NE81).
 7. Емфізема з хронічним (обструктивним) бронхітом (CA22).
 8. Емфізематозний (обструктивний) бронхіт (CA22.1).
- 2 Детальний розгляд коду наведено в наступному розділі.

59

```
1 labels = ['Cardiomegaly',  
2 'Emphysema',  
3 'Effusion',  
4 'Hernia',  
5 'Infiltration',  
6 'Mass',  
7 'Nodule',  
8 'Atelectasis',  
9 'Pneumothorax',  
10 'Pleural_Thickening',  
11 'Pneumonia',  
12 'Fibrosis',  
13 'Edema',  
14 'Consolidation']
```

Рисунок 2.2 — Фрагмент лістингу міток з Chexpert

Емфізема легень – збільшення об'єму альвеол за рахунок руйнування перегородок між ними, легені збільшуються в об'ємі, не спадаються, стають м'якими, дихальні проходи звужуються, видих вимагає при емфіземі великих зусиль, газообмін кисню і вуглекислого газу в альвеолах через пошкодження тканин і закупорки знижується до небезпечного рівня; емфізема спостерігається зазвичай при хронічному бронхіті, бронхіальній астмі, які проходять з порушенням бронхіальної прохідності, при цьому поступово розвивається розширення альвеол з наступними деструктивними змінами їхніх стінок, в результаті в легенях збільшується кількість повітря, що не видаляється після глибинного видиху (залишкове повітря), цей стан, відомий як розрив перетинки, призводить до значної деформації архітектури легень.

Effusion – випіт (CB27 за визначенням BO3), наявність рідини в плевраль-

ній порожнині внаслідок надмірної транссудації або ексудації з плевральних порожнин.

1. Плеврит з випотом.
2. Туберкульоз дихальної системи (1B10).
3. Хілозний випіт (CB24).
4. Плеврит (MD31).

Hernia – грижа, захворювання, що характеризується випинанням вмісту порожнини крізь оточуючу стінку разом з усіма її сполучнотканинними шарами.

Infiltration – скупчення в тканинах організму клітинних елементів із застоюванням крові та лімфи, з утворенням інфільтрату тканина збільшується в обсязі, змінює колір, стає більш щільною.

60

Mass – маса або легенева маса, визначається як аномальна пляма або ділянка в легенях розміром більше 3 см, плями менше 3 см в діаметрі вважаються легневими вузликами (lung nodule).

Nodule – легневий вузлик (lung nodule), відносно невелика щільність в легенях, менша 3 см в діаметрі, легневий мікровузлик має діаметр менше 3 мм.

Вузлик найчастіше являє собою доброякісну пухлину, таку як гранульома або гамартома, але приблизно в 20% випадків він являє собою злоякісний рак, особливо у літніх людей та курців.

Atelectasis – ателектаз легень (CB40.2 Pulmonary collapse), патологічний стан, при якому внаслідок закриття просвіту бронхів та наступного розсмоктування повітря нижче місця закриття відбувається спадання легеневої тканини, частіше частки або сегменту легень та її ущільнення.⁶⁷ Ателектаз може також розвинути-
ся внаслідок стискання легеневої тканини ззовні масивним плевральним випотом. Причиною закупорки бронха можуть бути пухлини, стороннє тіло, збільшений лімфатичний вузол, а також в'язкий секрет бронхів при пневмоніях, бронхітах, бронхоектазах. Виникнення ателектазу іноді сприяє хірургічне втручання на органах черевної порожнини, що супроводжується порушенням вентиляції легень у зв'язку із загальним знеболюванням.

Pneumothorax¹⁴³ – пневмоторакс, скупчення газу (найчастіше, повітря) в плевральній порожнині з одночасним підвищенням тиску в ній, відбувається поступовий колапс легень.⁴⁷ Є ускладненням деяких хвороб чи травм грудної клітки, іноді може бути самостійним захворюванням.⁴⁷ Повітря може потрапити в порожнину плеври при пораненнях, що проникають у грудну клітку, в тому числі відламками ребер. При спонтанному пневмотораксі повітря потрапляє через розривання емфізематозних альвеол на поверхні легень, розпаді легеневої тканини (туберкульоз, пухлина, абсцес). При цьому порожнина плеври може сполучатися з легенею та органами травлення – стравоходом, шлунком, кишкою. Іноді повітря вводять у плевральну порожнину з лікувальною метою.

Pleural Thickening (потовщення плеври) – це збільшення об'єму однієї або обох легневих плеври.

Pneumonia – пневмонія (CA40 Pneumonia), хвороба легень, часто, але не завжди викликана інфекцією бактерій, вірусів, грибків або паразитів. Це захворювання характеризується лихоманкою, ознобом, кашлем з виділенням мокротиння, болями в грудях та задишкою.

61

Fibrosis – пневмосклероз (Pulmonary fibrosis), захворювання легень, при якому легенева паренхіма рубцюється (тобто заміщується сполучною тканиною — цей процес називається "склероз" чи "фіброз"), що призводить до серйозних проблем з функцією зовнішнього дихання. Надмірне формування фіброзної тканини призводить до потовщення стінок альвеол та зниження постачання кисню у кров. У результаті пацієнти страждають постійною задишкою. У деяких пацієнтів можна визначити конкретну причину захворювання, в той час як у інших причину знайти не вдається і в цьому випадку хворобу називають ідіопатичним легневим фіброзом. Наразі не існує лікування, що дозволило би позбавитись такого ураження легень у вигляді заміни на сполучну тканину в результаті пневмосклерозу.

Edema – набряк легень (CB01 Pulmonary oedema), тяжкий, загрозливий для життя стан, синдром, що виникає внаслідок виходу рідкої частини крові з судинного русла через альвеолярно-капілярну стінку у повітряно-кислотну частину легень при підвищеному тиску крові у легневих венах та капілярах або в результаті збільшення проникності альвеолярно-капілярної стінки.

1. Гострий набряк легень.
2. Хронічний набряк легень.
3. Набряк легень через хімічні речовини, гази, пари або пари (CA81.1).
4. Набряк легень із згадкою про хвороби серця NOS або серцеву недостатність (BD11).

Consolidation – легенева консолідація, область нормально стисливої легеневої тканини, яка замість повітря наповнена рідиною. Стан відзначається індурацією (набряк або затвердіння нормально м'яких тканин) нормально аерованої легені. Рідиною може бути набряк легенів, запальний екссудат, гній, інгаляційна вода або кров (з бронхіального дерева або крововилив з легеневої артерії). Для діагностики пневмонії має бути присутня консолідація: ознаки крупозної пневмонії характерні і клінічно називаються консолідацією.

62

2.3.2 Маркування медичних датасетів з ознаками COVID-19

Раніше було подано загальний опис датасету COVID-19 (ieee8023) у підрозділі 2.2. Нижче наводиться приклад виводу метаданих (рис. 2.3) про наявні типи хвороб у даному датасеті (після попередньої обробки 3).

Датасет містить зображення наступних хвороб та аномалій легень:

No Finding – стан без ознак хвороб або аномалій.

Unknown – стан без будь-якого маркування (можливо помилкове зображення або втрата метаданих).

todo – стан запланованого маркування (маркування відсутнє).

Tuberculosis – туберкульоз (лат. tuberculosis; або ТБ – скорочення від туберкульозна бактерія), поширене й у багатьох випадках летальне інфекційне захворювання з хронічним перебігом і частою багатовислідністю уражень.

Pneumonia (пневмонія) – хвороба, для якої характерне запалення легень (при інфікуванні бактеріями, значно рідше – вірусами та іншими мікроорганізмами, ураженні деякими медичними препаратами, ураженні легень при аутоімунних захворюваннях тощо).

1. Pneumonia/Aspiration – аспіраційна пневмонія, це різновид легеневої інфекції, яка обумовлена відносно великою кількістю матеріалу зі шлунка або рота, що потрапляє в легені; ускладнення можуть включати абсцес легенів, включно із хімічно індукованим запаленням легенів як підтип, який виникає від кислого, але неінфекційного вмісту шлунка, що потрапляє в легені.

2. Pneumonia/Lipoid – ліпоїдна пневмонія, специфічна форма запалення легень (пневмонія), яка розвивається при попаданні ліпідів у бронхіальне дерево; розлад іноді називають холестериною пневмонією у випадках, коли цей ліпід є фактором.

3. Pneumonia/Fungal – грибкова пневмонія, інфекція легенів грибами, яка може бути викликана ендемічними або умовно-патогенними грибами або їх поєднанням, смертність від грибкових пневмоній може досягати 90% у пацієнтів з ослабленим імунітетом.

(a) Pneumonia/Fungal/Pneumocystis – пневмоцистна пневмонія (пневмоцистоз, ПЦП), небезпечна для життя форма пневмонії,

3 Детальний розгляд коду наведено в наступному розділі.

63

яка виникає у людей з ослабленою імунною системою, одна з поширених опортуністичних інфекцій (ВІЛ-асоційованих інфекцій) при ВІЛ-інфекції/СНІДі.

(b) Pneumonia/Fungal/Aspergillosis – захворювання органів дихання тварин і людей, яке спричинює пліснявий грибок

Aspergillus niger з роду аспергіл, його відносять у людей до опортуністичних інфекцій

4. Pneumonia/Bacterial – бактеріальна пневмонія, це вид пневмонії, викликаний бактеріальною інфекцією.

(a) Pneumonia/Bacterial/Streptococcus – стрептокок, рід сферичних грам-позитивних бактерій, які здатні спричинити стрептококовий фарингіт, бешиху, певну кількість випадків менінгіту, бактеріальної пневмонії, ендокартиту, і, навіть, харчових отруєнь.

(b) Pneumonia/Bacterial/Chlamydia – *Chlamydia pneumoniae* (попередня назва *Chlamydia pneumoniae*), вид бактерій із родини *Chlamydiaceae*, який викликає гострі респіраторні захворювання, зокрема – бронхіти, і м'які форми пневмонії із тенденцією до хронізації процесу.

(c) Pneumonia/Bacterial/*E. coli* – кишкова паличка (*Escherichia coli*, звичайно скорочується до *E. coli*, від лат. *coli* – “кишко-ва”), один з головних видів бактерій, деякі штами яких викликають накопичення рідини, що призводить до набряку (edema)

навколо легенів, що перешкоджає роботі серця, викликаючи підвищення артеріального тиску.

(d) Pneumonia/Bacterial/Klebsiella – Клебсієла пневмонії (*Klebsiella pneumoniae*) або паличка Фрідлендера, це грамнегативна, нерухлива, інкапсульована, факультативна анаеробна бактерія у формі палички, яка міститься у нормальній флорі рота, шкіри та кишечника, але може спричинити руйнівні зміни в легенях людини та тварин при аспірації, зокрема в альвеолах, що призводить до утворення кривавого, коричневого або жовтого кольору желе, подібного до мокротиння.

64

(e) Pneumonia/Bacterial/Legionella – *Legionella pneumophila*, грамнегативна рухома паличкоподібна бактерія роду *Legionella*, основний збудник легіонельозу (або “хвороби легіонерів”), що отримала свою назву внаслідок спалаху захворювання в 1976 році серед відвідувачів конвенції Американського легіону, що проводилася у Філадельфії.

(f) Pneumonia/Bacterial/Mycoplasma – мікоплазмова пневмонія (також відома як «ходяча пневмонія»), це форма бактеріальної пневмонії, спричиненої бактеріальними видами *Mycoplasma pneumoniae*, також відома як PPLo, що є абревіатурою від Pleuro Pneumonia Like Organism.

(g) Pneumonia/Bacterial/Nocardia – рід паличкоподібних бактерій, які спричинюють декілька захворювань, зокрема нокардіоз, який характеризується розпадом легеневої тканини з утворенням множинних порожнин.

(h) Pneumonia/Bacterial/Staphylococcus/MRSA – метицилінрезистентний золотистий стафілокок (англ. Methicillin-resistant *Staphylococcus aureus* – MRSA), бактерія, що найчастіше викликає шкірні інфекції, в деяких випадках це викликає пневмонію (легеневу інфекцію) та інші інфекції, які можуть стати важкими і викликати сепсис.

5. Pneumonia/Viral (вірусна пневмонія) – це пневмонія, викликана вірусом.

(a) Pneumonia/Viral/COVID-2019 – вірус SARS-CoV-2 від “Severe Acute Respiratory Syndrome Coronavirus 2”, і захворювання, спричинене ним, яке отримало назву коронавірусна хвороба 2019, скорочено COVID-19.

(b) Pneumonia/Viral/SARS – тяжкий гострий респіраторний синдром (ТГРС) (англ. Severe Acute Respiratory Syndrome / SARS) – вірусне інфекційне захворювання, особливий варіант коронавірусної інфекції, здатний до небезпечного епідемічного поширення, в тому числі й внутрішньогоспітального, з переважанням повітряно-крапельної передачі інфекції з ураженням дихальної системи та, у тяжких випадках, з появою атипової пневмонії з виразною гострою дихальною недостатністю.

65

(c) Pneumonia/Viral/Varicella – пневмонія вітряної віспи (просторічне – вітрянка, англ. chickenpox, лат. varicella), різновид вірусної пневмонії, спричиняє множинні маленькі округлі кальцифічні ураження легенів, є найсерйознішим ускладненням дисемінованої вірусної інфекції вітряної віспи зі смертністю 9-50%.

(d) Pneumonia/Viral/Herpes – пневмонія простого герпесу (ТСП), або трахеобронхіальна інфекція, виникає, коли дихальні шляхи заражені вірусом простого герпесу (ВПГ).

(e) Pneumonia/Viral/MERS-CoV – близькосхідний коронавірусний респіраторний синдром (БКРС) (англ. Middle East respiratory syndrome coronavirus, MERS-CoV), клінічний синдром інфекційного походження з переважним ураженням органів дихання, який спричинює вид вірусів роду *Betacoronavirus*, підродина *Coronavirinae*, що ймовірно спричинює злипання альвеол за рахунок підвищення поверхневого натягнення рідини в них, що зумовлює розвиток гострого респіраторного дистрес-синдрому дорослих (ГРДСД).

6. Pneumonia/Influenza (віруси грипу) – найпоширеніша вірусна причина

пневмонії, первинна грипозна пневмонія проявляється стійкими симптомами кашлю, болю в горлі, головного болю, міалгії та нездужання протягом більше трьох-п'яти днів.

(а) Pneumonia/Influenza/H1N1 – підтип вірусу грипу А, штам цього підтипу вірусу А/H1N1 став причиною спалаху свинячого грипу у 2009 році, частково – грипу в 2005-2006 роках, також штам цього вірусу викликав епідемію іспанки в 1918 році. Після зараження грипом 1918 клітин легенів це часто призводило до надмірної стимуляції імунної системи шляхом вивільнення цитокінів (білка, який викликає імунну відповідь) у легеневої тканини. Це призводить до значної міграції лейкоцитів до легенів, що призводить до руйнування легеневої клітин та виділення крові та слизу в альвеоли та дихальні шляхи. Це ускладнює дихання пацієнта і може призвести до задухи. На відміну від інших пандемій, які в основному вбивають старих і зовсім

66

молодих, пандемія 1918 року знищила незвичайну кількість молодих людей, що могло бути пов'язано з їх здоровою імунною системою, що викликала занадто сильну і шкідливу реакцію на інфекцію.

1 meta["finding"].unique()

```
array(['Pneumonia/Viral/COVID-19', 'Pneumonia', 'Pneumonia/Viral/SARS',  
'Pneumonia/Fungal/Pneumocystis',  
'Pneumonia/Bacterial/Streptococcus', 'No Finding',  
'Pneumonia/Bacterial/Chlamydia', 'Pneumonia/Bacterial/E.Coli',  
'Pneumonia/Bacterial/Klebsiella', 'Pneumonia/Bacterial/Legionella',  
'Unknown', 'Pneumonia/Lipoid', 'Pneumonia/Viral/Varicella',  
'Pneumonia/Bacterial', 'Pneumonia/Bacterial/Mycoplasma',  
'Pneumonia/Viral/Influenza', 'todo', 'Tuberculosis',  
'Pneumonia/Viral/Influenza/H1N1', 'Pneumonia/Fungal/Aspergillosis',  
'Pneumonia/Viral/Herpes', 'Pneumonia/Aspiration',  
'Pneumonia/Bacterial/Nocardia', 'Pneumonia/Viral/MERS-CoV',  
'Pneumonia/Bacterial/Staphylococcus/MRSA'], dtype=object)
```

Рисунок 2.3 — Фрагмент лістингу міток з COVID-19 (ieee8023)

2.3.3 Зауваження щодо особливостей використання медичних даних за результатами рентгенографії та КТ

За даними багатьох джерел первинними виявленнями COVID-19 на рентгенограмі грудної клітки та КТ є дані про атипову пневмонію [114], [115] або організовану пневмонію (organizing pneumonia) або пневмосклероз [97], [116]. Однак візуалізація має обмежену чутливість до COVID-19, оскільки до 18% пацієнтів демонструють нормальні рентгенограми грудної клітки або КТ у легкій або ранній стадії захворювання, але цей показник зменшується до 3% при важкій формі захворювання [98], [117]. Доволі поширеним є двостороннє та/або багатовольне ураження [118], [119].

Хоча рентгенографія грудної клітки менш чутлива, ніж КТ грудної клітки, вона зазвичай є найбільш поширеним методом візуалізації, який використовується для пацієнтів з підозрою на COVID-19 [99]. Рентгенограма грудної клітки може бути нормальною при ранньому/легкому перебігу захворювання. У тих випадках, коли COVID-19 потребував госпіталізації, 69% пацієнтів мали аномальну рентгенограму грудної клітки на початку прийому, а 80% пацієнтів мали рентге-

67

нологічні відхилення під час госпіталізації [99]. Результати стають більш чіткими приблизно через 10-12 днів після появи симптомів захворювання [99].

Британське товариство торакальної візуалізації (British Society of Thoracic Imaging – BSTI) опублікувало звіт щодо рентгенографічного дослідження грудної клітки із потенційними ознаками COVID-19 [120] із наступними станами:

1. Наявність класичного/ймовірного COVID-19: нижньодольні та переважно периферичні множинні помутніння, які є двосторонніми (набагато частіше, ніж односторонніми).
2. Невизначеність щодо COVID-19: не відповідає класичним або не пов'язаним з COVID-19 ознакам.
3. Наявність інших аномалій, які не є COVID-19: пневмоторакс / крупозна пневмонія / плевральний випіт / набряк легенів / інше.
4. Нормальний стан: але не виключена наявність COVID-19.

Але треба зауважити, що поточна рекомендація переважної більшості нау-

кових товариств та професійних радіологічних асоціацій полягає в тому, що візуалізацію не слід використовувати як інструмент скринінгу/діагностики COVID-19, а використовувати її лише для оцінки ускладнень [121].

2.4 Особливості збору та підготовки даних

Після того як була сформульована мета для задачі машинного навчання, визначено формат вхідних та вихідних даних моделі та критерії успіху – можна розпочинати збір даних, які необхідні для навчання моделі. Переважна більшість дослідників в галузі ШІ займаються покращенням моделей і лише незначна частка працюють над покращенням даних [75]. Це і не дивно, оскільки сам збір даних може бути трудомістким завданням, проте розмітка даних – найбільш трудомістка задача як з точки зору часу підготовки так і фінансів, особливо, якщо мова йде про підготовку великого та якісного набору даних. Саме через брак бюджету та ресурсів, зовсім невелика частка дослідників можуть собі дозволити здійснити збір та підготовку даних у встановлені строки для вирішення прикладних задач на високому рівні. Надійність набору даних залежить від того, як дані збирались та які підходи використовувались під час анотації. Якщо дані породжені недосвідченими фахівцями – це може призвести до низької якості даних. Золотий набір даних – високоякісний набір даних, підготовлений вручну, який використовується для навчання та оцінки ефективності моделей.

68

ними працівниками, поспіхом чи моделлю з низькою якістю, то надійність таких даних може виявитись дуже низькою. Для збільшення надійності даних, анотація має здійснюватись досвідченими працівниками, а самі мітки мають бути повторно перевірені кількома іншими спеціалістами чи експертами з розмітки даних. Для анотації даних медичного характеру потрібні спеціалізовані знання медичних працівників, які можуть визначити діагноз за діагностичними вимірами. Аналогічна ситуація виникає й для інших вузькоспеціалізованих задач, розв'язання яких потребує залучення експертів з відповідної галузі. Попереднє уявлення про надійність зібраних даних можна сформулювати шляхом проведення контролю якості на обмеженій випадковій підмножині набору даних. Натомість у випадках, коли дані отримано за допомогою вимірювальних приладів, відомості щодо точності окремих вимірювань зазвичай подано у відповідній технічній документації обладнання.

Важливо пам'ятати, що ключовим фактором, який впливає на якість моделі є якість даних. На практиці з даними можуть виникати такі проблеми як погана якість первинних даних та розмітки, зашумленість даних (пошкоджені приклади, наприклад, зображення можуть бути розмитими або неповними), зсув даних (неузгодженість із явищем, яке дані представляють), низька передбачувальна здатність (у даних недостатньо інформації для навчання), викиди тощо.

2.4.1 Методи штучного розширення набору даних

Нестача даних для навчання нейронних мереж є поширеною проблемою, яка може суттєво обмежувати ефективність моделей глибокого навчання. Дану проблему на практиці зазвичай можна вирішити завдяки додатковому збору нових даних, генерації синтетичних даних або доповнити датасет за допомогою простих перетворень над існуючими даними. Збір додаткових даних вважається найнадійнішим підходом, проте він зазвичай є дорогим і трудомістким, особливо, коли мова йде про ручну анотацію даних з залученням експертів в певній предметній галузі, наприклад, медицині. Альтернативним рішенням може бути створення синтетичних даних за допомогою генеративних моделей або симуляційних середовищ, проте цей процес часто виявляється технічно складним і може не точно відображати реальний розподіл даних, що призведе до поганого узагальнення моделі. Найдоступнішим методом є штучне доповнення даних шляхом застосування

69

різноманітних перетворень до прикладів з наявного набору, таких як обертання, масштабування, шум або зміна яскравості тощо. Хоча цей підхід дозволяє швидко і ефективно розширити обсяг даних, пошук дієвої стратегії доповнення може вимагати численних експериментів та додаткового налаштування під конкретну задачу. Найкращі результати на практиці часто досягаються завдяки поєднанню цих підходів.

Штучне розширення набору даних для тренування. Сучасні методи

штучного розширення (доповнення) набору даних для тренування (data

augmentation – DA) ⁽¹⁸⁾ може бути достатньо ефективним для навчання моделей гли-

бинного навчання. За допомогою перетворень базових зображень у датасетах можна вирішити проблему нестачі даних для навчання моделей, шляхом отри-

мання нових даних, які є результатом перетворень базових зображень. Деякі з таких перетворень, що застосовуються до зображень для навчання нейронних мо-

дей: геометричне перетворення, такі як перевертання, повороти, зміщення, обрізка, масштабування, зміна кольорового простору, відтінків кольору, зміна яскравості та застосування шумів.

Рисунок 2.4 — Штучне розширення набору даних [122], [123]

Нейронні мережі можуть бути інваріантами у висновках до певних перетворень: кут огляду, розмір об'єкта, яскравість зображення, або ж до комбінацій таких перетворень. В реальній ситуації об'єкти інтересу можуть знаходитись у різних умовах: бути у різному положенні у просторі, мати велику або ж малу яскравість, знаходитись у різних масштабах тощо. Щоб врахувати такий розвиток подій необхідно навчати модель з різними додатковими, штучно модифікованими даними.

70

18 процес модифікації вхідних даних може бути реалізовано двома основними методами:

1. Заздалегідь обробити усі наявні дані і таким чином збільшити кількість вхідних даних у датасеті.
2. Виконати перетворення безпосередньо перед подачею даних на вихід моделі.

Перший варіант має назву попереднього штучного збільшення набору даних (offline augmentation).

Такий метод зазвичай використовується для невеликих датасетів, так як збільшивши об'єм датасета на значення, яке пропорційне кількості перетворень, можемо отримати завеликий об'єм. Другий варіант має назву

штучного збільшення набору даних, дозволяє збільшити кількість даних «на льоту» – безпосередньо перед подачею даних на вихід моделі (online augmentation). Такий метод краще застосовувати до відносно великих датасетів.

18 1. Перевертання. Можна перевертати зображення по вертикалі або горизонталі, тобто віддзеркалити його.

2. Обертання. При даній операції розміри зображення можуть не зберегтись після повороту. Якщо зображення квадратне, то після обертання відповідні розміри залишаться незмінними. При умові, що зображення прямокутне, то при оберті у 180 градусів розміри залишаться незмінними. Обертання на кути, що не кратні 90 градусам в будь-якому разі змінить розмір зображення.

3. Масштабування. Зображення можна масштабувати усередину або навпаки. При масштабуванні назовні розміри зображення у результаті будуть більші, ніж розміри базового зображення. І навпаки, при масштабуванні усередину розміри стануть зменшуватися. Зазвичай для вирівнювання використовують інструменти, такі як вирізання із вихідного зображення розмірів базового.

4. Вирізання. На відміну від масштабування випадкова частина вихідного зображення вирізається із оригінального. Після цього розмір вихідного зображення змінюється до розмірів оригінального зображення. Такий метод називається кадруванням зображення.

71

5. Зсув. Зсув реалізується за допомогою зміщення зображення по осям X або Y, або ж комбінований варіант. Такий метод корисний, адже більшість об'єктів на реальних зображеннях можна розташувати у будь-якому місці, тобто у різних координатах. Це тренує нейронну мережу на пошук об'єктів по всій площі вхідного зображення. Підвищення частоти перетворень здатне призвести до перенавчання моделі, адже модель навчається на одному і тому ж прикладі декілька разів.

Штучне розширення набору даних для тестування. Штучне розширення набору даних під час тестування (test time augmentation – TTA), дозволяє більш точно визначити ефективність моделі за рахунок збільшення варіацій тестових екземплярів та усереднення передбачень. Суть даного підходу полягає у тому, що перетворення для розширення даних, які описані вище для навчання моделі, можна також застосовувати й під час інференсу (тестування). Для цього тестові вхідні дані зазнають перетворень так само, як і під час тренування моделі. Перетворені дані подаються у якості вхідних ознак до нейронної мережі, яка базується на цих ознаках та додатково вивчених у прихованих шарах, і здійснює прогноз. Результатом визначення ефективності моделі буде середнє значення від отриманих передбачень. Одним із перших відомих прикладів застосування принципу усереднення передбачень за кількома трансформованими версіями тестового зображення є робота [16], в якій під час тестування мережа AlexNet здійснювала передбачення на основі десяти фрагментів зображення (патчів): чотирьох кутових, центрального та їхніх горизонтальних відображень з подальшим усередненням результатів.

Генеративна аугментація на основі дистиляції набору даних. Окремим, порівняно новим напрямом розширення наборів даних є генеративна аугментація на основі дистиляції набору даних (Dataset Distillation, DD) [124], [125]. Дистиляція набору даних стала критично важливою технікою для вирішення проблеми зростаючих обчислювальних вимог та вимог до зберігання даних, характерних для підходів глибокого навчання [126]. На відміну від існуючих глибоких нейронних мереж, які потребують великих обсягів даних та обчислювальних потужностей [127]–[132], DD синтезує невеликий набір високоінформативних прикладів

даних, які зберігають знання, закладені у великих наборах даних [124]. Моделі, натреновані на таких дистильованих наборах даних, можуть досягати продуктивності, порівнянної з моделями, натренованими на повних наборах даних, що ро-

72

бить DD перспективним підходом для ефективного навчання та зберігання даних. Загалом, дистиліяція набору даних є ефективною альтернативою існуючим методам скорочення даних, забезпечуючи підвищену ефективність навчання моделей, економію ресурсів зберігання та покращену узагальнювальну здатність за рахунок генерації синтетичних даних. Здатність DD стискати та абстрагувати ключову інформацію робить цей підхід важливим інструментом оптимізації нейронних мереж у сферах інтерпретованості, проектування та охорони здоров'я, одночасно підвищуючи ефективність та безпеку даних. У цьому контексті проблеми масштабованості, мультимодальності та складності розмітки для реальних наборів даних, що використовуються в практичних задачах, ще не вирішені повністю. Саме тому подальші дослідження підходів DD мають додатково проводитися для глибшого розуміння цієї техніки.

Через високовимірну природу даних глибокого навчання дистиліяція знань у невелику кількість екземплярів є складним завданням. Методи DD можна умовно розділити на кілька категорій [126]. У підходах на основі мета-навчання (meta-learning) дистильовані дані розглядаються як гіперпараметри, що оптимізуються у вкладеному циклі для покращення узагальнювальної здатності [124]. Методи зіставлення даних (data-matching), своєю чергою, оновлюють синтетичні дані шляхом імітації впливу реальних даних на процес тренування моделі або в просторі параметрів, або в просторі ознак [22], [133], [134].

Факторизована дистиліяція набору даних використовує ідею про те, що високимірні дані зображень лежать на низьковимірному многовиді і можуть бути реконструйовані за допомогою спеціалізованих декодерів [126], [135], [136]. Замість безпосереднього зберігання синтетичних зображень, факторизована DD оптимізує компактні представлення ознак (коди) разом із відповідними декодерами, що зменшує вимоги до зберігання даних та надлишковість. Такий підхід покращує стиснення даних при збереженні важливої інформації. Факторизовану DD поділяють на три типи: DD на основі кодів (code-based DD), DD на основі декодерів (decoder-based DD) та DD на основі кодів і декодерів (code-decoder DD), кожен з яких пропонує різні компроміси між ефективністю та якістю реконструкції, що робить цей підхід потужною стратегією дистиліяції наборів даних. DD використовується в різноманітних галузях, що вимагають ефективного навчання моделей та зберігання даних. Цей підхід виявився особливо корисним у безперервному навчанні (continual learning) [137], [138] та пошуку архі-

73

тектур нейронних мереж (neural architecture search) [139], [140], де обробка великих наборів даних є обчислювально затратною задачею. Крім того, завдяки збереженню інформації про градієнти, дистиліяція набору даних відіграє важливу роль у забезпеченні приватності даних, федеративному навчанні та підвищенні стійкості моделей до змагальних атак (adversarial robustness), знижуючи ступінь розкриття вихідних даних у процесі навчання [141], [142]. Одним із показових застосувань DD є алгоритми пояснюваного штучного інтелекту (explainable AI, XAI) [143]: завдяки малому розміру синтетичних наборів даних стає можливим точно вимірювати вплив навчальних прикладів на тестові передбачення. Якщо тестові й навчальні зображення спираються на одні й ті самі синтетичні зображення, це полегшує відстеження процесу прийняття рішень моделлю, що робить дистиліяцію набору даних цінним інструментом для XAI. DD також застосовується у візуальному дизайні для генерації репрезентативних текстур шляхом обрізання синтетичних зображень, а також для моделювання сумісності предметів одягу, використовуючи синтетичні зображення для відображення істотних візуальних патернів [144], [145]. В охороні здоров'я DD сприяє обміну медичними зображеннями, покращуючи анонімність даних та забезпечуючи обмін даними між лікарнями [146], що дозволяє медичним закладам спільно навчати моделі ШІ для комп'ютерної діагностики (CADx), знижуючи ризики для приватності пацієнтів та витрати на впровадження.

Таким чином, дистиліяція набору даних дозволяє синтезувати компактний набір штучних зображень, що відтворює узагальнювальні властивості вихідного набору даних. Детальний опис розробленого в межах дослідження [37] методу генеративної аугментації даних на основі дистиліяції набору даних (GDADD) та результати його застосування наведено в наступних розділах.

2.4.2 Запропонований підхід до організації процесу анотації даних для

спеціалізованих задач

У цьому підрозділі запропоновано авторський підхід до організації процесу анотації даних для спеціалізованих задач детекції та трекінгу об'єктів, який розглянуто на прикладі створення набору даних UAeroNet [36]. Створення високопродуктивного конвеєра анотації даних вимагає стратегічного поєднання робочої сили з технічними знаннями, інструментами та операціями, здатними забезпечити

74

ти високу якість підготовлених даних. На рисунку 2.5 наведено ключові складові для організації високоякісної підготовки даних для задач машинного навчання.

О р 12

Інструменти

анотації

Безпека даних Оплата праці Якість даних Робоча сила

Анотація даних

Рисунок 2.5 — Складові для організації високоякісної підготовки даних

Якість і масштабованість результатів анотації даних безпосередньо залежать від того, наскільки узгоджено функціонує кожна складова цього процесу: інструмент анотації, механізм забезпечення безпеки даних, модель оплати праці лейблерів, система контролю якості розмітки та сформована робоча сила. Інструмент анотації (спеціалізоване програмне забезпечення) є необхідним компонентом будь-якого процесу розмітки даних. Для різних типів анотації існують спеціалізовані інструменти, як з відкритим кодом, так і комерційні. Вибір конкретного інструменту визначається кількома взаємопов'язаними факторами. Насамперед наявні на ринку рішення часто оцінюються на відповідність специфіці конкретного завдання анотації, після чого приймається рішення щодо стратегії його впровадження: розробку власного рішення, придбання комерційного продукту або використання наявного програмного забезпечення з відкритим кодом. Розробка інструменту з нуля або адаптація наявного рішення може надати більшу гнучкість у внесенні змін, дозволяючи налаштувати функціонал програмного забезпечення під специфічні потреби завдання і забезпечити максимальний контроль і безпеку даних. Незалежно від обраної стратегії, інструмент для анотації даних повинен забезпечувати безшовну інтеграцію із сучасними технологіями, зокрема підтримувати імпорт та експорт розмітки у популярні формати, наприклад, YOLO (You Only Look Once), COCO (Common Objects in

75

Context), PASCALVOC (Visual Object Classes) тощо, а також бути сумісним із популярними фреймворками машинного навчання та комп'ютерного зору, такими як TensorFlow, PyTorch та/або OpenCV (Open Source Computer Vision Library) тощо. Не менш важливою умовою ефективної та точної анотації даних залишається інтуїтивний та зручний у роботі інтерфейс інструменту анотації.

Забезпечення безпеки даних під час анотації набуває особливого значення, коли йдеться про чутливу інформацію. Для таких завдань лейблери мають відповідати нормативним та іншим вимогам залежно від необхідного рівня захисту даних. Це передбачає організацію роботи в контрольованому середовищі з відповідним навчанням персоналу та неухильним дотриманням встановлених процесів, політик і процедур. На практиці необхідний рівень захисту досягається шляхом поєднання організаційних і технічних заходів. До організаційних заходів належать підписання лейблерами угод про нерозголошення (або рівнозначних документів, що визначають їхні зобов'язання щодо обробки даних), а також їхнє навчання протоколам безпеки з подальшим моніторингом дотримання встановлених вимог. Технічний рівень захисту може бути забезпечений, зокрема, обмеженням прав запису на пристроях анотації, що дозволить знизити ризик витоку даних. Крім того для роботи, яка виконується безпосередньо на робочому місці, додатково можуть застосовуватись фізичні заходи безпеки, наприклад, відеоспостереження.

Ще однією складовою організації процесу анотації даних є модель оплати праці лейблерів, яка безпосередньо позначається як на загальній вартості проєкту, так і на якості підготовлених даних. Формування вартості анотацій є багатфакторним і повинно враховувати особливості самих даних (тип, обсяг та якість вхідних даних: зображень, відео чи інших форматів), особливості завдання розмітки (тип анотації: сегментація, обмежувальні рамки, тощо та встановлені часові рамки для виконання), а також вимоги до якості анотацій. Збільшення обсягу даних чи деталізації розмітки, як правило, пропорційно підвищує вартість проєкту, оскільки збільшується об'єм завдання та/або складності виконання. Додатко-

ве ускладнення вносять високі вимоги до точності підготовлених даних, які часто передбачають окремі процедури перевірки якості анотацій, що у підсумку збільшує сукупну вартість роботи. Кваліфікація лейблерів також відіграє суттєву роль: лейблери з більшим досвідом можуть забезпечити вищу точність анотації, однак їхні послуги будуть дорожчими. Додатковим фактором зростання вартості ано-

76

тації даних для певних завдань є потреба у спеціалізованих предметних знаннях (наприклад, у галузі медицини).

Якість розмітки є найважливішою складовою процесу анотації даних, що безпосередньо впливає на якість усього підготовленого набору даних. Оптимізація процесу анотації даних для досягнення найвищої якості за наявних ресурсів є неперервним процесом, оскільки якість анотації залежить від низки факторів: функціональності інструменту анотації, однозначності інструкцій з розмітки даних, досвіду лейблерів, робочого процесу забезпечення якості підготовки даних, а також типу й характеру даних, що підлягають розмітці. Особливу роль у забезпеченні якості підготовлених даних відіграють інструкції з анотації: вони слугують орієнтиром для лейблерів, допомагаючи коректно інтерпретувати дані відповідно до вимог завдання і забезпечують дотримання єдиних правил усіма учасниками процесу, що набуває особливого значення під час роботи великих команд. Уніфікація інструкцій дозволяє зменшити кількість помилок і досягти однакового підходу до розмітки незалежно від конкретного виконавця.

Підготовка значних обсягів даних потребує залучення робочої сили, чисельність якої має узгоджуватись з обсягом набору даних і частотою розмітки. Команда лейблерів може бути сформована одним із кількох шляхів: залученням власних співробітників (пряме управління процесом), співпрацею із зовнішніми виконавцями чи спеціалізованими компаніями з розмітки даних, або використанням краудсорсингових платформ для масштабних завдань.

Ручна розмітка даних (тобто формування еталонної розмітки — ground truth) залишається найбільш надійним, хоча й найбільш трудомістким способом підвищення точності моделей машинного навчання. Знизити трудомісткість цього процесу можуть спеціалізовані інструменти анотації з інтуїтивним інтерфейсом, регулярний аудит точності розмітки, а також застосування методу активного навчання, який орієнтований на виявлення найбільш інформативних зразків серед неанотованих даних (див. рис. 2.6).

Сутність активного навчання [147] полягає в тому, що модель самостійно визначає, які дані доцільно передати на ручну розмітку. Насамперед це приклади з класами, які недостатньо представлені у наявній розмітці або приклади, щодо яких модель демонструє найменшу впевненість у власних прогнозах. Такий підхід дозволяє суттєво скоротити обсяг даних, які потребують ручної анотації без істотної втрати точності моделі. Сам процес активного навчання виконується іте-

77

Крок 1

Анотація первинних даних

Крок 2

Навчання моделі на підготовлених даних

Крок 3

Виявлення прикладів з низьким рівнем достовірності

Крок 4

Анотуйте кожен приклад вручну та додайте до навчальної вибірки

Крок 5

Додаткове навчання моделі з новими навчальними даними

Крок 6

Контролюйте процес анотації та точність

Рисунок 2.6 — Алгоритм активного навчання [147]

ративно: відібрані приклади з низьким рівнем достовірності анотуються вручну і додаються до навчальної вибірки, після чого модель вчиться на нових даних і цей цикл повторюється до досягнення потрібного рівня точності. Активне навчання є особливо доцільним, коли анотація даних є дорогим і тривалим процесом, проте його застосування обмежене потребою в початковому розміченому наборі для запуску процедури відбору прикладів. Якщо такий набір є нерепрезентативним чи упередженим, алгоритм ризикує на кожній ітерації обирати неоптимальні для розмітки зразки.

Окремої уваги потребує підготовка лейблерів до анотації цільових об'єктів у динамічних та візуально перевантажених сценах (наприклад, у лісових маси-

вах чи міських умовах), оскільки велика кількість перекриваючих один одного об'єктів, змінне освітлення, змінний масштаб об'єктів та складна фонові текстура суттєво підвищують вимоги до кваліфікації й практичного досвіду виконавця розмітки.

Блок-схема робочого процесу (Рис. 2.7) ілюструє послідовність етапів отримання даних, їх розмітки та попередньої обробки для спеціалізованих задач машинного навчання.

78

Початок проєкту

Доступно

достатньо

даних?

Чи існують

зовнішні набори

даних?

Можна застосувати

методи генерації

даних?

Згенеруйте

синтетичні дані

Додати мітки?

Покращити

представлення

даних?

Дослідіть або

інтегруйте дані

Сильно

зашумлені?

Маєте достатньо

розмічених даних?

Використовуйте

навчання з

частковим залучення

учителя

Достатній

бюджет?

Використовуйте

слабке маркування

Анотація даних

через краудсорсинг

Очищення

даних

Неправильний

формат для моделі?

Трансформація

даних

Дані складні

для навчання?

Інжиніринг

ознак

Ні

Так Так

Ні

Так

Дані

Мітки

Так

Ні Ні

Так

Так

Ні

Так

Ні

Так

Рисунок 2.7 — Блок-схема робочого процесу для збору, підготовки та попередньої обробки даних

Першим етапом є оцінка доступності даних та можливості залучення зовнішніх або синтетичних джерел для забезпечення достатнього обсягу й різноманітності набору даних. Наступним етапом є анотація даних та підвищення якості розмітки: залежно від обсягу набору даних і доступних ресурсів анотація може здійснюватися з використанням напівконтрольованого навчання (semi-supervised learning), слабкого контрольованого навчання (weak supervision) або краудсорсингу. Завершальним етапом є попередня обробка даних, що включає очищення даних для зменшення шуму, перетворення даних відповідно до вимог моделі та формування ознак (інжиніринг ознак) для підвищення здатності моделі до навчання.

79

2.5 Візуалізація результатів тестування і створення теплових карт для тестової підмножини даних

Grad-CAM (Gradient-weighted Class Activation Mapping) [148] – це метод створення теплових карт, який застосовується до вже навченої нейронної мережі після завершення навчання та встановлення параметрів моделі.

Grad-CAM працює шляхом:

1. Визначення останнього згорткового шару у структурі нейронної мережі, який зберігає просторову інформацію, необхідну для побудови карти активації.

2. Аналізу градієнтів, які поширюються від вихідного шару мережі до вибраного згорткового шару, з метою оцінки внеску кожної карти ознак у прийняття рішення щодо певного класу.

Ініціалізація класу для візуалізації знімків із тепловими мапами [148]:

```
1 class ChestXrayDataSet_plot(Dataset):
2     def __init__(self, input_X, transform=None):
3         self.data = input_X[np.uint8(test_X*255)]
4         self.transform = transform
5         self.root_dir = mgpath[0]
6         self.transform = transform
7
8     def __getitem__(self, index):
9         if torch.is_tensor(index):
10             index = index.tolist()
11         img_name = os.path.join(self.root_dir, self.data.loc[index, 'filename'])
12         image = Image.open(img_name).convert('RGB')
13         image = np.array(image.resize((256, 256)))
14         image = np.uint8(image*255)
15         image = self.transform(image)
16         return image
17
18     def __len__(self):
19         return len(self.data)
```

Підготовка тестової підмножини даних. Для візуалізації теплових карт за допомогою методу Grad-CAM, буде використовуватися тестова підмножина даних X_test, яка була визначена раніше:

```
1 X_test.reset_index(drop=True, inplace=True)
2 test_dataset = ChestXrayDataSet_plot(input_X = X_test,
3 transform=transforms.Compose([
4     transforms.ToPILImage(),
5     transforms.ToTensor(),
```

80

```
6 transforms.Normalize([0.485, 0.456,
7     0.406]), →→
7 [0.229, 0.224,
8     0.225]) →→
8 ]))
```

Перевірка кількості знімків у тестовій підмножині:

```
1 X_test['finding'].value_counts(dropna=False)
Pneumonia/Viral/COVID-19 167
Name: finding, dtype: int64
```

Перевірка знімків тестової підмножини даних: файли та маркери:

```
1 X_test[['filename', 'finding']]
filename \
0 bb0e626a.jpg
```

```

1 88de9d8c39e946abd495b37cd07d89e5-2ee6-0.jpg
2 rct.2020200034.fig5-day4.jpeg
3 1.CXRCTThoraximagesofCOVID-19fromSingapore.pdf...
4 1052b0fe.jpg
... ..
162 16672_1_1.jpg
163 FE9F9A5D-2830-46F9-851B-1FF4534959BE.jpeg
164 16953_4_1.jpg
165 2966893D-5DDF-4B68-9E2B-4979D5956C8E.jpeg
166 gr1_lrg-a.jpg
finding
0 Pneumonia/Viral/COVID-19
1 Pneumonia/Viral/COVID-19
2 Pneumonia/Viral/COVID-19
3 Pneumonia/Viral/COVID-19
4 Pneumonia/Viral/COVID-19
... ..
162 Pneumonia/Viral/COVID-19
163 Pneumonia/Viral/COVID-19
164 Pneumonia/Viral/COVID-19
165 Pneumonia/Viral/COVID-19
166 Pneumonia/Viral/COVID-19
[167 rows x 2 columns]
PropagationBase для методу Grad-CAM [148]:
1 print("generate heatmap .....")
2 # ===== Grad CAM Function =====
3 class PropagationBase(object):
4 def __init__(self, model, cuda=True):
5 self.model = model
6 self.model.eval()
7 if cuda:

81
8 self.model.cuda()
9 self.cuda = cuda
10 self.all_fmaps = OrderedDict()
11 self.all_grads = OrderedDict()
12 self._set_hook_func()
13 self.image = None
14
15 def _set_hook_func(self):
16 raise NotImplementedError
17
18 def _encode_one_hot(self, idx):
19 one_hot = torch.FloatTensor(1, self.preds.size()[-1]).zero_()
20 one_hot[0][idx] = 1.0
21 return one_hot.cuda() if self.cuda else one_hot
22
23 def forward(self, image):
24 self.image = image
25 self.preds = self.model.forward(self.image)
26 #self.probs = F.softmax(self.preds, dim=1)[0]
27 #self.prob, self.idx = self.preds[0].data.sort(0, True)
28
29 return self.preds.cpu().data.numpy()
30
31 def backward(self, idx):
32 self.model.zero_grad()
33 one_hot = self._encode_one_hot(idx)
34 self.preds.backward(gradient=one_hot, retain_graph=True)
Фрагмент лістингу класу GradCAM [148]:
1 class GradCAM(PropagationBase):
2 def _set_hook_func(self):
3 def func_f(module, input, output):
4 self.all_fmaps[id(module)] = output.data.cpu()
5
6 def func_b(module, grad_in, grad_out):

```

```

7 self.all_grads[id(module)] = grad_out[0].cpu()
8
9 for module in self.model.named_modules():
10 module[1].register_forward_hook(func_f)
11 module[1].register_backward_hook(func_b)
12
13 def _find(self, outputs, target_layer):
14 for key, value in outputs.items():
15 for module in self.model.named_modules():
16 if id(module[1]) == key:
17 if module[0] == target_layer:
18 return value
19 raise ValueError("Invalid layer name: {}".format(target_layer))

82
20
21 def _normalize(self, grads):
22 l2_norm = torch.sqrt(torch.mean(torch.pow(grads, 2))) + 1e-5
23 return grads / l2_norm.item()
24
25 def _compute_grad_weights(self, grads):
26 grads = self._normalize(grads)
27 self.map_size = grads.size()[2:]
28 return nn.AvgPool2d(self.map_size)(grads)
29
30 def generate(self, target_layer):
31 fmaps = self._find(self.all_fmaps, target_layer)
32 grads = self._find(self.all_grads, target_layer)
33 weights = self._compute_grad_weights(grads)
34 gcam = torch.FloatTensor(self.map_size).zero_()
35 for fmap, weight in zip(fmaps[0], weights[0]):
36 gcam += fmap * weight.data
37
38 gcam = F.relu(Variable(gcam))
39 gcam = gcam.data.cpu().numpy()
40 gcam -= gcam.min()
41 gcam /= gcam.max()
42 gcam = cv2.resize(gcam, (self.image.size(3), self.image.size(2)))
43 return gcam
44
45 def FinalImage(self, gcam, raw_image):
46 raw_image = raw_image*0.229+0.485
47 gcam = cv2.applyColorMap(np.uint8(gcam * 255.0), cv2.COLORMAP_JET)
48 gcam = np.float32(gcam) / (600)
49 gcam = gcam.astype(np.float) +
raw_image.numpy()[0].astype(np.float).reshape(256,256,1)→→
50 gcam = gcam / gcam.max()
51
52 return np.uint8(gcam * 255.0)

```

Фрагмент лістингу підготовки моделі для побудови теплових мап [148]:

```

1 with torch.no_grad():
2 model.eval()
3 gt = torch.FloatTensor()
4 gt = gt.cuda()
5 pred = torch.FloatTensor()
6 pred = pred.cuda()
7 for i, (data_t, target_t_t) in enumerate(validation_loader):
8 target_t = target_t_t.type(torch.float)
9 data_t, target_t = data_t.cuda(device), target_t.cuda(device)
10 gt = torch.cat((gt, target_t), 0)
11 input_var = Variable(data_t.view(-1, 3, 224, 224).cuda())
12 output = model(input_var)

```

83

Створення теплових мап для тестової підмножини даних [148]:

```

1 # ===== Create heatmap =====
2

```

```

3 heatmap_output = []
4 image_id = []
5 output_class = []
6
7 thresholds = 0.15
8 dataiter = iter(validation_loader)
9 images = dataiter.next()
10 gcam = GradCAM(model=model, cuda=True)
11 for index in range(len(test_dataset)):
12 input_img = Variable((test_dataset[index]).unsqueeze(0).cuda(),
requires_grad=True)→→
13 probs = gcam.forward(input_img)
14 activate_classes = np.where((probs > thresholds)[0]==True)[0] # get the
activated class→→
15 for activate_class in activate_classes:
16 gcam.backward(idx=activate_class)
17 output = gcam.generate(target_layer="densenet121.features.denseblock4.dens_c
elayer16.conv2")→→
18 ##### this output is heatmap #####
19 if np.sum(np.isnan(output)) > 0:
20 print("fxxx nan")
21 img = gcam.FinalImage(output, test_dataset[index])
22 heatmap_output.append(img)
23 image_id.append(index)
24 output_class.append(activate_class)
25 print("test image", str(index), "finished ", activate_class) #,
activate_class, "-", "expected class", encoded_classes["Target"][0]→→

```

Візуалізація теплових мап

Усі зображення, які подані нижче є рентгенівськими зображеннями легень з Covid-19 для яких подано візуалізацію теплових мап на основі прогнозів, зроблених моделлю. Для візуалізації результатів роботи моделі використано вибірку з перших 50 рентгенограм тестового набору:

```
1 heatmap_output_1 = heatmap_output[:50]
```

Нижче представлено теплові мапи та прогноз моделі для перших 50 рентгенограм з тестового набору.

Лістинг для візуалізації теплових мап для перших 50 рентгенограм з тестового набору:

```

84
1 fig, axis = plt.subplots(10,5, figsize=(26, 60))
2 for i, ax in enumerate(axis.flat):
3 ax.imshow(heatmap_output_1[i]) # add image
4 ax.set(title = f"Predicted class: {output_class[i]} \nExpected class:
{encoded_classes["Target"][0]}")→→

```

Рисунок 2.8 — Візуалізація теплових мап для перших 25 (з 50) тестових зображень

85

Рисунок 2.9 — Візуалізація теплових мап для наступних 25 (з 50) тестових зображень

2.6 Методи ШІ для CADe/CADx

Сучасний розвиток обчислювальних технологій, зокрема графічних процесорів загального призначення (GPU) [149], [150], машинного навчання та особ-

86

ливо глибокого навчання [127], суттєво підвищили ефективність розв'язання задач комп'ютерного зору. Ці досягнення вже демонструють значний практичний ефект у медицині, зокрема в автоматизованій діагностиці.

Прикладом є модель CheXNet, яка продемонструвала здатність автоматично виявляти пневмонію на рентгенівських знімках грудної клітки з точністю, що перевищує рівень діагностики практикуючих рентгенологів [151]. Подібні результати свідчать про високий потенціал застосування інтелектуальних систем у якості допоміжних засобів для автоматизованого виявлення (CADe) та діагностики (CADx) патологічних змін, які зафіксовані на медичних знімках. Використання методів глибокого навчання дозволяє автоматизувати процеси виявлення, класифікації та семантичної сегментації підозрілих ділянок (уражень, новоутворень тощо), що істотно підвищує швидкість і якість прийняття діагностичних рішень.

2.6.1 Методи класифікації

Передові методи аналізу рентгенограм грудної клітки, що виконують класифікацію на рівні всього зображення, здебільшого реалізуються на основі глибоких згорткових нейронних мережах. Такий підхід відрізняється від методів, що орієнтовані на обробку окремих ділянок або сегментованих областей зображення. Однією з перших успішних архітектур для прогнозування на рівні всього зображення стала AlexNet [16], розроблена в університеті Торонто Олександром Крижевським, Іллею Суцкевером та Джефрі Гінтоном. Ця мережа складалась з п'ятих згорткових та трьох повноз'язних шарів. Вона значно перевершила попередні підходи, засновані на вручну сконструйованих ознаках, завдяки збільшеній кількості шарів і параметрів порівняно з LeNet-5. Вирішальним фактором успіху стало використання графічних процесорів (GPU) для навчання, що згодом стало стандартом для глибокого навчання [152]. Ця модель здобула значну популярність після перемоги 2012 року в конкурсі ImageNet Large Scale Visual Recognition Challenge (ILSVRC) [153], суттєво випередивши конкурентів (див. рис. 2.10). Щорічний конкурс ILSVRC був започаткований у 2009 році американсько-китайською дослідницею Фей-Фей Лі, передбачав класифікацію більше мільйона зображень із ручною розміткою на 1000 різних категорій [152]. У цьому дослідженні під ідентифікацією об'єктів розуміється їх класифікація – визначення належності до певного класу або категорії на зображенні.

87

Рисунок 2.10 — Переможці конкурсу ILSVRC з 2012 року ґрунтуються на глибокому навчанні [152]

Після появи AlexNet було запропоновано низку інших відомих архітектур. Мережі сімейства VGG [17] вирізнялися значно більшою кількістю шарів та меншим розміром ядра: глибина зросла до 8-19 згорткових шарів у поєднанні з трьома повноз'язними шарами, а розмір ядра зменшився до 3. У 2015 році з'явилася архітектура Inception (GoogLeNet) [18], яка використовувала одночасно згортки різного розміру (1×1 , 3×3 , 5×5) та операції субдискретизації всередині спеціальних блоків (Inception modules), що дозволяло мережі ефективно захоплювати ознаки на різних масштабах у межах одного шару. Сімейство ResNet [154] було представлено у 2016 році і запровадило концепцію залишкових блоків (residual blocks) із пропускними з'єднаннями (skip connections), що суттєво покращило стабільність і точність навчання глибоких нейронних мереж. Цей принцип швидко став основою для багатьох наступних архітектур. Мережі DenseNet [155] розширили ідею пропускних з'єднань, забезпечивши повний обмін інформацією між усіма шарами блоку. Оновлена версія Inception (Inception-ResNet) [156] також використала цей підхід, поєднуючи багатомасштабні згортки з залишковими блоками. Архітектура Xception [157] ґрунтувалась на Inception і застосовувала окремі згортки для просторових координат та каналів (див. рис. 2.11), забезпечуючи вищу продуктивність порівняно з Inception V3. У 2019 році дослідниками з Google AI було представлено сімейство згорткових мереж EfficientNet [158]. Основна ідея цієї архітектури полягала в досягненні збалансованого співвідношення між точністю та обчислювальною ефективністю. Для проектування базової моделі EfficientNet-B0 автори застосували нейронний пошук архітектур (Neural Architecture Search - NAS), що дозволив автоматично визначити оптимальну структуру мережі з максимальною точністю за мінімальних обчислювальних витрат. Після отриман-

88

ня базової архітектури EfficientNet-B0, подальші моделі масштабуються завдяки спеціально розробленому методу складеного масштабування (compound scaling), який одночасно враховує глибину, ширину та роздільну здатність вхідного зображення, що забезпечує високу продуктивність при меншій кількості параметрів та обчислень. Завдяки такому підходу EfficientNet забезпечує точність на рівні сучасних архітектур при суттєво вищій обчислювальній ефективності порівняно з ResNet та DenseNet. Як показано у таблиці 2.1, розвиток згорткових мереж супроводжувався збільшенням глибини та впровадженням нових будівельних блоків. Ці архітектури та їх модифікації широко використовуються сьогодні в медичних дослідженнях для задач класифікації.

$7 \times 7 \times 3$

$3 \times 3 \times 1$

$5 \times 5 \times 3$

$1 \times 1 \times 3$

$\times 128$

$5 \times 5 \times 128$

Роздільний фільтр

Вхід

Проміжний вихід

Фільтр

Вихід

= ·

=

Рисунок 2.11 — Роздільна згортка по глибині

Крім згорткових нейронних мереж для класифікації зображень все частіше застосовуються зорові трансформери (Vision Transformers -ViT) [20], які здатні завдяки механізму уваги ефективно вивчати глобальні залежності в зображеннях. Водночас у чистій архітектурі ViT локальні залежності вивчаються менш ефективно, ніж у класичних CNN, а сама реалізація зіштовхується з обчислювальними обмеженнями при роботі з зображеннями високої роздільної здатності [159]. Для подолання цих обмежень були запропоновані гібридні підходи, які поєднують властивості CNN та трансформерів. Зокрема, Swin Transformer [160] використовує ієрархічну структуру та локальну увагу у стилі ковзаючих вікон, а ConVNeXt [159] демонструє, що сучасна архітектура CNN, модернізована з урахуванням ідей трансформерів (LayerNorm, GELU, великі ядра згортки), може досягати конкурентоспроможну продуктивність у порівнянні з трансформерами, при цьому зберігаючи простоту та ефективність стандартних згорткових мереж.

89

Таблиця 2.1 — Порівняння популярних архітектур згорткових мереж для прогнозування на рівні всього зображення

Архітектура Ключові особливості Кількість шарів

Вплив / значення

AlexNet (Крижевський

та ін., 2012)

5 згорткових + 3 повно-

зв'язні; ReLU; Dropout;

використання GPU

8 Початок ери глибинно-

го навчання, перемога в

ILSVRC-2012

VGG (Симонян & Зіссер-

ман, 2014)

Послідовні 3×3 згортки,

збільшена глибина

8–19 Простота структури, ба-

зова модель для багатьох

досліджень

Inception (GoogLeNet)

(Середі та ін., 2015)

Блок Inception з пара-

лельними згортками різ-

них розмірів

22 Оптимізація ресурсів,

вища точність порівняно

з VGG

ResNet (Хе та ін., 2016) Залишкові блоки

(residual blocks) з про-

пускними з'єднаннями

(skip connections)

18–152+ Подолання проблеми

зникнення градієнта,

встановлення нових

рекордів

DenseNet (Хуан та ін.,

2017)

Повні зв'язки між шара-

ми в межах блоку (dense

connectivity)

121–201+ Ефективне використання

параметрів, висока уза-

гальнювальна здатність

Хception (Шолле, 2017) Поділ просторових та

міжканальних згорток

(depthwise separable

convolutions)

~71 Краща продуктивність за

Inception V3

EfficientNet (Тан & Ле,

2019)

Композитне масштабу-

вання глибини, ширини

та роздільної здатності;

MVConv-блоки; оптимі-

зована продуктивність

та точність

200-800+

(B0-B7)

Висока точність при

меншій кількості па-

раметрів, популярна

для передавального

навчання та задач на

обмежених ресурсах

2.6.2 Методи семантичної сегментації

Сегментація – це завдання класифікації на рівні пікселів, що полягає у при-
своєнні кожному пікселю зображення певної мітки, яка позначає клас до якого
відноситься цей піксель. У контексті аналізу інформації, що подана у вигляді зоб-
ражень або відео, це завдання відоме як семантична сегментація – дозволяє перед-
бачити категорію для всіх пікселів на зображенні. На практиці крім семантичної
сегментації може використовуватись також екземплярна та паноптична сегмен-
тація. Для екземплярної сегментації характерним є те, що крім класифікації пік-
селів за категоріями також можна розрізнити окремі об'єкти (екземпляри), які
підлягають підрахунку в межах одного класу. Паноптична сегментація поєднує
семантичну та екземплярну сегментацію, дозволяючи одночасно визначити клас

90

пікселів для фону та об'єктів, а також розрізнити окремі екземпляри об'єктів у
середині одного класу. У контексті медичного застосування мітки зазвичай відо-
бражають анатомічні структури (легені, серце, ребра), патології (пухлини, ново-
утворення, затемнення) або сторонні предмети (катетери, електроди, трубки).
Для підвищення точності прогнозів моделей, дослідники намагалися ви-
ключити ділянки, які не відносяться до легень або не представляють інтерес.
Таке завдання включає сегментування лівої та правої легеневої ділянки на стан-
дартних знімках CXR. Нещодавно було запропоновано кілька підходів сегмента-
ції, вони базуються на моделях активних фігур, моделях активного зовнішнього
вигляду та методі класифікації багатороздільних пікселів. Ці методи апробовані
на базі даних JSRT, у якому усі об'єкти були вручну сегментовані двома людьми-
спостерігачами [161]. Незважаючи на те, що останнім часом було запропоновано
багато нових методів медичного застосування для сегментації об'єктів на CXR та
MPT-зображеннях [162], сегментація ділянок легень все ще залишається викли-
ком.

Ранні методи сегментації за допомогою глибокого навчання базувались на
класичних згорткових мережах, які розроблялись для задач класифікації [163].
Для визначення категорії кожного пікселя застосовувався підхід із ковзним вік-
ном, який обробляє окремі фрагменти зображення. Через велике перекриття
сусідніх фрагментів та обробку пікселя за пікселем цей підхід був обчислю-
вально затратним і обмеженим лише для малих зображень. Щоб подолати об-
меження ранніх методів були запропоновані повністю згорткові мережі (Fully
Convolution Network – FCN) у яких класичні повнозв'язні шари були замінені
згортковими [164]. Такий підхід дозволив обробляти зображення більшого розмі-
ру і отримувати вихід у вигляді карти ймовірностей для всіх пікселів одночасно,
а не лише для одного. Повністю згорткова мережа U-Net [21] з'явилась у 2015
році і стала найбільш цитованою роботою в історії у галузі медичної обробки
зображень. Архітектура U-Net складається зі стискаючого шляху (downsampling)
і розширюючого шляху (upsampling), що відновлює вихід до роздільної здатно-
сті вхідного зображення. U-Net реалізує підхід енкодер-декодер із пропусковими
з'єднаннями (зазвичай конкатенаціями), які напругу з'єднують відповідні шари
енкодера та декодера з однаковою просторовою роздільністю. Це дає змогу деко-

деру використовувати як високороздільні ознаки з енкодера так і низькороздільні ознаки з глибших шарів мережі, таким чином зберігаючи дрібні деталі, які втра-

91

чаються під час пулінгу. Переважна більшість сучасних підходів з медичної сегментації базуються на модифікованих та/або адаптованих архітектурах повністю згорткових мереж або U-Net, що дозволяє підвищити точність класифікації пікселів.

Для проведення сегментації легень, тобто для вирізання лівої та правої ділянки легень від серця та інших частин у стандартних CXR, раніше успішно була застосована повністю згорткова нейронна мережа U-Net. U-Net має архітектуру для швидкої та точної сегментації зображень, яка продемонструвала високу точність у ряді завдань, присвячених сегментації нейрональних структур в електронно-мікроскопічних стеках, виявленню карієсу при рентгенографії прикусу та відстеженню клітин за допомогою мікроскопії пропускового світла [21]. Нещодавно цей підхід був успішно використаний для сегментації легень на знімках CXR з таких наборів даних як MC та JSRT із використанням вручну підготовлених масок [165].

2.6.3 Основні операції згорткових нейронних мереж

Незважаючи на те, що перші експерименти зі згортковими нейронними мережами на основі алгоритму зворотного поширення помилки були здійснені ще у 1989 році [166], лише з появою AlexNet [167] у 2012 році вдалося повною мірою продемонструвати їхній потенціал для вивчення візуальних ознак. Цей прорив спричинив активний розвиток та появу низки нових архітектур, серед яких VGG [17], Inceptions [18], ResNe(X)t [154], [168], YOLO [19], DenseNet [155], MobileNet [169], EfficientNet [158] та RegNet [170]. Кожна з цих моделей була зосереджена на різних аспектах: підвищенні точності, оптимізації обчислювальних ресурсів та масштабованості. У результаті було сформовано низку фундаментальних підходів і принципів, що стали основою для проектування нових архітектур нейронних мереж [159].

Коли людина дивиться на зображення, вона майже миттєво розрізняє предмети, форми та кольори, тоді як для комп'ютера цей процес має зовсім іншу природу. Завдяки високій здатності мозку до інтерпретації візуальних даних, різниця між самим зображенням і його низькорівневим цифровим представленням (пікселями) майже непомітна для нашого сприйняття. Наприклад, на рисунку 2.12 людина може легко обробити побачене зображення а) і практично відразу сказа-

92

ти, що це є рентгенограма грудної клітки, тоді як для комп'ютера це ж саме зображення буде представлене у вигляді тензора (зображення б)), де кожен елемент тензора відповідає за відносну інтенсивність світла для кожного пікселя. Нульова інтенсивність відповідає чорному кольору, а 255 – білому⁶. Для зображень у відтінках сірого використовується лише один канал інтенсивності, тоді як кольорові зображення у форматі RGB мають три канали: червоний, зелений та синій. Таким чином, кольорове зображення можна подати як три окремі матриці, кожна з яких відображає рівень інтенсивності відповідного кольору в кожному пікселі.

а) б)

Рисунок 2.12 — Візуальне сприйняття зображення людиною а) та комп'ютером б)

Позначимо ширину та висоту вхідної карти ознак I , розмір фільтра F , нульове доповнення⁷ P , крок згортки S та розмір карти ознак на виході O . На рисунку 2.13 подані ці позначення на прикладі рентгенограми грудної клітки. Тоді, розмір карти ознак, яку ми отримаємо на виході згортового шару, буде визначатись:

$O =$

$I - F + \text{Рстарт} + \text{Ркінць}$

S

$+ 1$ (2.1)

Досить часто $\text{Рстарт} = \text{Ркінць}$, P , у такому випадку ми можемо замінити

$\text{Рстарт} + \text{Ркінць}$ на $2P$ у формулі 2.1.

⁶ У цифрових зображеннях кожен піксель зазвичай кодується за допомогою 8 біт на канал, що є стандартом для багатьох зображень.

⁷ Нульове доповнення означає додавання P нулів до кожної сторони меж входу.

93

F

F

Вхід Фільтр Вихід

I РкінецьРстарт

I

Рстарт

Ркінець

O

O

Рисунок 2.13 — Розмір карти ознак на виході згорткового шару

У згорткових шарах замість одного глобального детектора ознак маємо набір менших детекторів, які прийнято називати фільтрами або ядрами. Математичні операції, які виконуються у цих шарах точніше описуються не згортою, а взаємною кореляцією (англ. cross-correlation) [171]. Згортковий шар виконує операцію взаємної кореляції між вхідними даними та фільтром, після чого до результату додається зміщення. Ці фільтри ми можемо переміщати уздовж горизонтального та вертикального положення вхідного зображення або вхідної карти активацій і для кожної позиції фільтра обчислити зважену суму (скалярний добуток). По суті, для кожного з цих невеликих фільтрів ми створюємо карту відповідей, яку прийнято називати картою активації, яка представляє собою вивчені мережею ознаки у вхідних даних. Результуюча карта активації виражає у кількісній формі присутність шаблону фільтра в різних ділянках зображення. Процес згортання зображення рентгенограми за допомогою різних фільтрів представлено на рисунку 2.14. Після взаємної кореляції до отриманої карти активації застосовується як правило операція максимального агрегування. Вибір максимального значення з сусідніх зазвичай здійснюється у вікні розміром 2×2 і кроком 2, щоб зменшити роздільну здатність карти ознак в два рази. Власне згортка, навпаки, зазвичай виконується з вікном 3×3 і кроком 1. Зменшення розміру карти ознак використовується для зменшення кількості коефіцієнтів під час обробки, а також для впровадження ієрархічних просторових фільтрів шляхом створення послідовних

94

шарів згортки для перегляду усе більш великих вікон з точки зору долі вихідних даних, які вони охоплюють [172].

Варто зазначити, що зменшення розмірності карти ознак може здійснюватися не лише за допомогою операції вибору максимального значення із сусідніх (max pooling). Альтернативними підходами є використання згортки з прогалинами (strided convolutions) або операції вибору середнього значення за сусідніми елементами (average pooling), коли кожен локальний шаблон перетворюється шляхом взяття середнього значення для кожного каналу замість максимального. Проте на практиці саме операція вибору максимального значення часто забезпечує вищу ефективність. Це пояснюється тим, що ознаки, як правило, кодують просторову присутність деякого шаблону в різних ділянках карти активації, тому максимальна присутність шаблону набагато інформативніша, ніж середня присутність [172].

Карти ознак

Фільтри

Оригінальний вхід

Рисунок 2.14 — Фільтри та карти ознак

Шари згортки та агрегації (pooling), які розглянуто вище, зазвичай призводять до зменшення просторових розмірів карти ознак (висоти та ширини) або, у кращому випадку, зберігають їх незмінними. Водночас для багатьох прикладних задач виникає потреба у зворотному перетворенні, яке, навпаки, збільшує просторову розмірність карти ознак. Такий підхід є необхідним, зокрема, під час генерації зображень високої роздільної здатності або при відображенні низьковимірних ознак у простір більшої розмірності, як це реалізується в автокодувальниках та методах семантичної сегментації. У випадку семантичної сегментації, де класифікація виконується на рівні окремих пікселів, особливо важливою є відповідність просторових розмірів вхідних та вихідних карт ознак. Це забезпечує коректне відображення кожного пікселя вихідного зображення у відповідну про-

95

сторову позицію вхідних даних, дозволяючи формувати результат класифікації для кожної точки зображення. Збільшення просторових розмірів карт ознак здійснюється за допомогою транспонованої згортки (transposed convolution), яка також ще називається розгорткою (deconvolution). Розмір карти ознак, яку отримаємо на виході транспонованої згортки, визначається за формулою:

$$O = (I - 1)S + F - \text{Рстарт} - \text{Ркінець} \quad (2.2)$$

Для випадку, коли $\text{Рстарт} = \text{Ркінець}$, P , формула 2.2 прийме такий вид:

$$O = (I - 1)S + F - 2P \quad (2.3)$$

У формулах 2.2 та 2.3 використано наступні позначення: I – ширина та висота вхідної карти ознак, F – ширина та висота фільтра, S – крок транспонованої згортки, P – доповнення, O – розмір карти ознак на виході.

2.7 Деякі підходи глибинного машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів

Глибинне навчання є одним із найбільш динамічно зростаючих напрямів штучного інтелекту, що забезпечує високоточну ідентифікацію, класифікацію та семантичну сегментацію об'єктів у широкому спектрі задач комп'ютерного зору. Ефективність сучасних глибоких нейронних мереж визначається як їх архітектурними особливостями, так і можливістю обробки великих наборів даних у режимі реального часу з високою точністю результатів. Саме тому поряд з розробкою нових нейромережових архітектурних рішень інтенсивно розвиваються спеціалізовані апаратні прискорювачі (GPU - Graphics Processing Unit, TPU - Tensor Processing Unit, IPU - Intelligence Processing Unit, тощо), які спроектовані для більш ефективного виконання обчислень, пов'язаних з навчанням та тестуванням нейронних мереж. Перші багатифункціональні графічні процесори (GPU) розроблялись компанією NVIDIA для роботи з графікою, але завдяки багатоядерній архітектурі поточкових мультипроцесорів вони також добре підходять для задач глибокого навчання. На відміну від GPU, тензорні процесори (TPU) мають іншу філософію проєктування. Перший TPU був розроблений компанією Google з орієнтацією на тензорні операції з матрицями, які є ключовими для обчислюваль-

96

них блоків нейронних мереж. Архітектура TPU включає спеціалізовані матричні множники та оптимізацію під тензорні обчислення для прискореного виконання операцій множення матриць, високошвидкісну внутрішню пам'ять та інтерфейси для ефективної комунікації між обчислювальними вузлами.

У роботі [23] виконано порівняльний аналіз та сформульовано висновки щодо переваг і недоліків деяких найбільш універсальних і популярних відкритих фреймворків для машинного навчання – TensorFlow, DeepLearning4j та H2O. Для фреймворку H2O виконано тести продуктивності алгоритмів глибинного навчання в однопоточному та багатопоточному режимах на CPU і GPU. У роботі [24] наведено результати тестування архітектур нейронних мереж на платформі H2O для різних функцій активації та критеріїв зупинки навчання. Показано, що випадковий (сліпий) вибір гіперпараметрів може суттєво збільшити час виконання без істотного підвищення точності. Робота [25] узагальнює експериментальні результати з попередніх двох статей [23], [24]. Крім вибору фреймворку на продуктивність обчислень критично впливають також версія бібліотеки, кількість потоків, які обробляють інформацію, а також реалізація самого алгоритму. Цей результат є важливим з точки зору оптимізації як наявних, так і нових методів машинного навчання, особливо для задач розпізнавання зображень.

У контексті задач ідентифікації, класифікації та семантичної сегментації, де обробка зображень часто відбувається в реальному часі, вибір апаратної платформи має критичне значення. Традиційно для цього використовувалися графічні процесори, однак поява спеціалізованих тензорних процесорів (наприклад, Google TPU) відкрила нові можливості підвищення швидкодії як на етапі навчання, так і під час інференсу моделей. У роботі [33] досліджувався систематичний вплив розміру пакета (batch size) на продуктивність GPU (NVIDIA Tesla K80) та TPU (Google Cloud TPuv2) під час етапів навчання та передбачення нейронної мережі, яка складалась з трьох згорткових та двох повнозв'язних шарів (див. рис. 2.15).

Було виявлено значні переваги TPuv2, зокрема до 10-разового прискорення на етапі тренування (без урахування накладних витрат) та до 2-разового прискорення під час інференсу, за умови великих розмірів пакету. На рисунку 2.16 наведено порівняльне прискорення обчислень на NVIDIA Tesla K80 та Google TPuv2, обидва спеціалізовані прискорювачі були доступні як хмарні ресурси платформи Google Colaboratory. Практична ефективність обох типів апаратних засобів

97

1

28

x

28

InputLayer

1

28

×
 28
 BatchNorm1
 64
 14
 ×
 14
 conv1
 64
 14
 ×
 14
 Dropout1
 64
 14
 ×
 14
 BatchNorm2
 128
 7
 ×
 7
 conv2
 128
 7
 ×
 7
 Dropout2
 128
 7
 ×
 7
 BatchNorm3
 256
 3
 ×
 3
 conv3
 256
 3
 ×
 3
 Dropout3
 2304
 Flatten 256
 Dence1
 256
 elu
 256
 Dropout4
 10
 Dence2
 10
 softmax

Рисунок 2.15 — Архітектура згорткової мережі

оцінювалася за результатами численних запусків згорткової нейронної мережі на стандартних наборах даних MNIST та Fashion-MNIST. Було отримано значне прискорення навіть за умов використання лише 8 обчислювальних ядер Google TPuv2 у порівнянні з досить потужною GPU-картою NVIDIA Tesla K80. Показано, що точні значення прискорення залежать від рівня завантаження обчислювальних блоків TPuv2 та зростають зі збільшенням обсягу оброблюваних даних. Для наборів даних MNIST та Fashion-MNIST із зображеннями розміром 28×28 пікселів, прискорення спостерігалось для обсягів даних понад 512 зображень на етапі навчання та понад 40 000 зображень на етапі передбачення [33]. У роботі [34] розглянуто обчислювальну складність алгоритмічно різних компонентів глибоких нейронних мереж з точки зору їх подальшого використання на спеціалізованих тензорних процесорах. Для демонстрації принципових від-

мінностей між архітектурами TPU та GPU було проведено оцінювання реальної обчислювальної складності ряду алгоритмічно різних глибоких нейронних мереж на основі запропонованого методу масштабного аналізу залежностей часу виконання та прискорення (speedup) на етапах навчання та передбачення як функцій розміру пакета та розміру зображення [33]. Особливу увагу приділено аналізу продуктивності широко використовуваних та алгоритмічно різних мереж: VGG16, ResNet50 та CapsNet у хмарній реалізації – Google Cloud TPUv2. Запропонований метод масштабного аналізу дав змогу оцінити ефективність використання цих архітектур без необхідності детального знання їх внутрішньої будови. Крім того було встановлено, що залежності масштабування та показники степеневих залежностей (scaling powers) відрізняються як для алгоритмічно різ-

98

Рисунок 2.16 — Порівняльне прискорення обчислень на GPU K80 та TPUv2 [33] для різних нейронних мереж (VGG16, ResNet50, CapsNet), так і для архітектурно різних апаратних платформ (GPU та TPU). Таким чином, результати дослідження дають змогу точно оцінити вищу продуктивність (пропускну здатність) архітектур типу Google TPUv2 у порівнянні з GPU за умови великої кількості обчислень, низьких накладних витрат та високого рівня завантаження обчислювальних блоків TPU, що досягається завдяки використанню великих розмірів зображень і пакетів [34]. Розгортання великих моделей глибокого навчання на мобільних пристроях: смартфони, носима електроніка, роботи, дрони, безпілотні автомобілі тощо (див. рис. 2.17), що характеризуються обмеженими обчислювальними ресурсами та обсягами доступної пам'яті, супроводжується значними технічними викликами, зокрема підвищеними вимогами до швидкодії та ефективності використання апаратних ресурсів.

Незважаючи на те, що великі моделі глибокого навчання демонструють високу продуктивність, проте вони споживають значну кількість енергії, оскільки модель потрібно зберігати у зовнішній пам'яті і кожного разу завантажувати для обробки нового зразка інформації. За відсутності повторного використання даних загальні енергетичні витрати переважно визначаються необхідністю доступу до

99

Смартфони Носима електроніка Роботи

Дрони Безпілотні автомобілі

Джерело: зображення з відкритих джерел мережі Інтернет.

Рисунок 2.17 — Глибоке навчання на мобільних пристроях пам'яті [173]. Витрати енергії на одне завантаження становлять від 5 пДж для 32-бітних коефіцієнтів у вбудованій SRAM і до 640 пДж для 32-бітних коефіцієнтів у зовнішній пам'яті LPDDR2 DRAM. Великі мережі не можуть повністю розміститися у вбудованій пам'яті, тому вимагають енерговитратних доступів до DRAM. Наприклад, виконання нейронної мережі з 1 млрд зв'язків на частоті 20 Гц потребуватиме $(20 \text{ Гц})(1 \text{ Г})(640 \text{ пДж}) = 12.8 \text{ Вт}$ лише для доступу до DRAM, що значно перевищує енергетичні можливості типового мобільного пристрою [173].

Методи стиснення нейронних мереж: відсікання (pruning), спільне використання ваг (weight sharing), квантування (quantization), перенесення знань (knowledge distillation) дозволяють розмістити сучасні глибокі нейронні мережі у вбудованій пам'яті SRAM. Однак, обробка таких стиснутих моделей є складною задачею. При відсіканні (pruning) матриця стає розрідженою, а індекси відносними. При спільному використанні ваг зберігається лише короткий (4-бітний) індекс для кожної ваги. Це додає додаткові рівні непрямого звертання, що призводить до підвищеної складності та неефективності на CPU та GPU. Для ефективного використання стиснутих моделей використовують спеціалізовані прискорювачі, які виконують оптимізоване множення розріджених матриць на вектори та обробляють спільне використання ваг без втрати ефективності моделі [173].

100

Серед структурних методів особливої популярності набуло відсікання [174], [175], яке полягає у видаленні малозначущих каналів (фільтрів) згорткових шарів. На відміну від методів факторизації тензорів чи розріджених з'єднань, каналне відсікання забезпечує суттєве зменшення обчислювальної складності моделі без потреби у спеціалізованому апаратному забезпеченні.

У роботі [32] запропоновано метод адаптивного ітераційного відсікання для прискорення глибоких нейронних мереж, який відрізняється від класичної схеми «відсікання-перенавчання» тим, що на кожній ітерації виконуються адаптивні зміни гіперпараметрів: розміру пакета, кількості епох донавчання, мінімальної кількості каналів на шар та порога відсікання. Такий підхід дозволяє компенсува-

ти втрати точності, спричинені агресивним видаленням каналів і досягати вищих коефіцієнтів прискорення.

У роботі [27] виконано порівняльний аналіз архітектур PSPNet та ICNet для задачі семантичної сегментації стереопар дорожніх сцен з датасету Cityscapes [176]. Оцінювання здійснювалося за точністю сегментації (mIoU) та часом обробки, що дало змогу виявити статистично значущі відмінності між архітектурами. Розподіли точності для різних міст та каналів виявилися асиметричними, з довгими хвостами та значною кількістю викидів, причому для PSPNet вони були більш вираженими, ніж для ICNet. Остання демонструвала стабільніші результати як за точністю, так і за часом обчислень (див. рис. 2.18), що робить її більш придатною для застосувань із жорсткими часовими вимогами. Крім того, встановлено, що правий канал стереопар не є просто дублюванням лівого, оскільки результати сегментації відрізняються більше, ніж можна пояснити випадковими флуктуаціями, що свідчить про додаткову інформативність цих даних. Також виявлено помітні відмінності між результатами для різних міст, що підкреслює необхідність донавчання моделей перед використанням у нових умовах. У статті [29] запропоновано новий погляд на інтелектуальні інтерфейси керувані користувачем, що базуються на поєднанні мультимодальної доповненої реальності та нейро-комп'ютерного інтерфейсу. Такий підхід відкриває нові можливості застосування у сферах реабілітації та допомоги людям з обмеженими можливостями, освіті, охороні здоров'я тощо. Інтеграція нейро-комп'ютерного інтерфейсу з технологіями доповненої реальності створює передумови для формування нових, більш гнучких і персоналізованих сервісів, які значно перевершують можливості окремих каналів взаємодії.

101

Рисунок 2.18 — Порівняння точності сегментації та часу обчислень для ICNet і PSPNet [27]

2.8 Висновки до розділу

У другому розділі сформовано цілісний підхід до розроблення технології автоматизованої обробки та аналізу цифрових зображень, що поєднує медичні набори даних, методи їх збору та візуалізації, особливості маркування і попередньої обробки, а також сучасні методи глибокого навчання як основу для створення ефективних систем діагностики легеневих захворювань за 2D рентгенограмами. Подано коротку характеристику деяких відкритих датасетів, серед яких JSRT, LIDC, CheXpert, PadChest, MIMIC-CXR-JPG, ChestX-ray14 та інші, що забезпечують можливість навчання і тестування алгоритмів глибокого навчання у галузі медичної візуалізації. Окрему увагу приділено наборам даних із ознаками COVID-19, які стали основою для розробки інтелектуальних систем для виявлення нових патологій.

Проаналізовано підходи та особливості анотації 2D рентгенограм, включаючи дані з ознаками COVID-19. Встановлено, що ключовими викликами при створенні та використанні медичних датасетів залишається дисбаланс класів, обмежений доступ до високоякісних даних і потреба у забезпеченні конфіденційно-

102

сті пацієнтів. Слід зазначити, що важливим фактором, який безпосередньо визначає якість розроблюваної моделі глибокого навчання, є якість вихідних даних. На практиці нерідко виникають проблеми з первинними даними та їх анотацією, спостерігається значна зашумленість або зсув даних, недостатня передбачувальна здатність вибірки чи наявність викидів. Усі ці чинники знижують ефективність навчання та потребують розробки методів попередньої обробки і корекції даних. Водночас, попри наявність окремих ефективних рішень для сегментації, очищення викидів та дистилляції даних, їх застосування в умовах обмежених і незбалансованих медичних наборів даних залишається недостатньо вивченим. Таким чином, подальші дослідження у цьому напрямку мають бути зосереджені не лише на адаптації та вдосконаленні архітектур нейронних мереж, але й на створенні надійних підходів до підготовки та контролю якості даних, що є критично важливим для забезпечення стабільності і надійності результатів моделі.

Основні результати даного розділу опубліковані у роботах [23]—[25], [27], [29], [32]—[34], [36], [37]. У наступному розділі розв'язується задача адаптації та вдосконалення методів глибокого навчання для ефективної діагностики легеневих захворювань з 2D рентгенограм. Окрему увагу приділено розробці технології попередньої обробки зображень шляхом сегментації цільових ділянок на основі глибоких нейронних мереж типу кодер-декодер.

103

РОЗДІЛ 3. МЕТОДИ ГЛИБИННОГО МАШИННОГО НАВЧАННЯ ДЛЯ ІДЕНТИФІКАЦІЇ, КЛАСИФІКАЦІЇ ТА СЕМАНТИЧНОЇ СЕГМЕНТАЦІЇ ОБ'ЄКТІВ

За результатами проведеного дослідження, відповідно до сформульованих завдань, розроблено нові та вдосконалено існуючі методи глибинного машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів, що охоплюють такі складові:

1. Розроблено інтегровану технологію попередньої обробки 2D рентгенограм, яка поєднує сегментацію цільових ділянок на основі глибоких нейронних мереж типу кодер-декодер із подальшою класифікацією патологій, що дозволяє зосередити аналіз на клінічно значущих ділянках, знизити вплив нецільових анатомічних структур та зменшити розмірність вхідних даних;
2. Розроблено метод класифікації у федеративному навчанні на основі ансамблю опорних моделей з архітектурами низької обчислювальної складності за стратегією «ширина важливіша за глибину», що дозволяє підвищити узагальнювальну здатність моделі та знизити ризик перенавчання за рахунок зменшення дисперсії передбачень при агрегуванні частково некорельованих похибок окремих моделей;
3. Удосконалено метод глибинного навчання на основі згорткових нейронних мереж шляхом інтеграції сегментації анатомічних структур та вилучення тіней кісток з рентгенограм, що дозволяє зменшити перекриття патологічних ознак кістковими структурами та додатково скоротити розмірність вхідних даних;
4. Набув подальшого розвитку метод виключення викидів серед розподілу сегментованих масок на основі проєкції у простір зниженої розмірності методом t-SNE з пороговою фільтрацією відносно ядра даних, що дозволило підвищити якість вхідних даних для методів глибинного навчання;
5. Набув подальшого розвитку метод дистиляції набору даних шляхом узгодження навчальних траєкторій (DDMTT): запропоновано метод генеративної аугментації даних (GDADD), який дозволяє синтезувати набір даних, обсяг якого наближається до реального, забезпечуючи узагаль-

104

нювальну здатність моделей, зіставну з моделями, навченими на значно більшому реальному наборі даних.

Перелічені методи є взаємодоповнювальними за характером дії. Технологія попередньої обробки 2D-рентгенограм, удосконалений метод глибокого навчання з інтеграцією сегментації анатомічних структур та вилучення тіней кісток, метод виключення викидів серед розподілу сегментованих масок і метод генеративної аугментації даних спрямовані на послідовне зменшення різних типів надлишковості та шуму на рівні вхідних даних (просторової – сегментація, структурної – вилученням тіней кісток, статистичної – виключенням викидів) і компенсацію дефіциту репрезентативності класів (аугментації даних), тоді як метод ансамблевої класифікації у федеративному навчанні на основі опорних моделей з архітектурами низької обчислювальної складності забезпечує підвищення надійності рішення на рівні агрегації прогнозів за умов обмежених обчислювальних ресурсів. Ефективність кожного з методів підтверджено експериментально за окремою лінією дослідження; частину методів інтегровано на рівні програмної платформи, що обґрунтовує перспективність їх подальшого застосування для підвищення узагальнювальної здатності та надійності систем автоматизованого аналізу візуальних даних до задач ідентифікації, класифікації та сегментації, зокрема за умов обмежених обчислювальних ресурсів. Кількісна оцінка сукупного ефекту від спільного застосування розроблених методів у єдиному наскрізному експерименті становить завдання подальших досліджень.

3.1 Інтегрована технологія попередньої обробки 2D-рентгенограм

Підрозділ присвячено інтегрованій технології попередньої обробки 2D-рентгенограм: пункт 3.1.1 висвітлює метод сегментації ділянок, що містять цільові об'єкти; пункт 3.1.2 – удосконалений метод глибокого навчання на основі згорткових нейронних мереж, що інтегрує сегментацію анатомічних структур та вилучення тіней кісток з рентгенограм; пункт 3.1.3 – метод виключення викидів серед розподілу сегментованих масок на основі зменшення розмірності методом t-SNE.

105

3.1.1 Метод сегментації

Значення для діагностики та лікування. Рентгенографія є критично важ-

ливим методом для виявлення та моніторингу патологічних змін у тканинах органів грудної порожнини. Ручна інтерпретація рентгенівських знімків залишається стандартом для закладів охорони здоров'я, проте цей підхід є ресурсозатратним, потребує високої експертизи, особливо при оцінці дрібних абомалопомітних патологічних станів.

Радіологічні помилки зазвичай діляться на дві основні категорії: помилки сприйняття та когнітивні помилки [177]. Помилка сприйняття означає аномалію, яка виявляється лише при ретроспективному аналізі, після того як її не помітили під час первинної інтерпретації зображення. Когнітивна помилка, навпаки, виникає тоді, коли патологія була ідентифікована, але її природа або діагноз були інтерпретовані неправильно. Дослідження показують, що помилки сприйняття зустрічаються значно частіше, складаючи від 60% до 80% усіх радіологічних помилок [15], [178]. Саме ці помилки, які також називають помилками спостерігача, є головною причиною високої частоти невиявлених аномалій, особливо на рентгенівських знімках грудної клітки [177]. Варто зазначити, що певні аномалії можуть залишатись непоміченими через технічні або фізичні обмеження методів візуалізації, такі як низька роздільна здатність зображення, обмежена контрастність тканин або низьке співвідношення сигнал/шум [178].

Розробка надійних автоматизованих методів для сегментації цільових ділянок та точної класифікації патологічних станів на рівні сегментованих масок на 2D рентгенограмах може допомогти зменшити кількості радіологічних помилок. Сегментація дозволяє виділити область легень, забезпечуючи точну локалізацію потенційних уражень, а подальша класифікація на рівні сегментованих масок дає змогу ідентифікувати тип патології всередині цих областей.

Математична постановка задачі. Нехай $X \in \mathbb{R}^{H \times W}$ – це 2D рентгенограма грудної клітки з датасету, де H та W позначають відповідно висоту та ширину зображення. Завдання полягає у знаходженні функції відображення $f: X \rightarrow S$, де $S \in [0,1]^{H \times W}$ – сегментована маска, що вказує ймовірність приналежності кожного пікселя до цільової області. Далі, на основі отриманої сегментованої маски легень виконується класифікація: $g: S \rightarrow \mathcal{C}$, де $\mathcal{C} \in [0,1]^C$ – це вектор ймовірностей для C визначених класів.

106

Цільова сегментаційна маска визначається наступним чином:

$M \in \{0,1\}^{H \times W}$,

де $M_{ij} = 1$, якщо піксель (i,j) належить цільовій області, інакше $M_{ij} = 0$.

Цільовий вектор, що кодує наявність або відсутність певного класу для сегментаційної маски, задано так:

$y = (y_1, y_2, \dots, y_C)$, $y_i \in \{0,1\}$,

де $y_i = 1$, якщо у сегментованій області присутній клас i , інакше $y_i = 0$.

Узагальнена схема методу. Запропонована узагальнена схема методу попередньої обробки графічних даних із використанням сегментації ділянок, які містять цільові об'єкти, наведено на рисунку 3.1.

Початок

Зображення рентгенограми

Попередня обробка

(нормалізація)

Модель 1:

сегментація

Модель 2:

ідентифікація та

класифікація на сегмен-

тованих зображеннях

Чи досягнуто

бажаної точності

на валідацій-

ній вибірці?

Донавчання моделі

Результати передбачення моделі

Кінець

Так

Ні

Рисунок 3.1 — Метод попередньої обробки графічних даних із використанням сегментації ділянок, які містять цільові об'єкти

107

Метод включає послідовне вирішення задачі сегментації та подальшої кла-

сифікації на рівні сегментованих масок і передбачає такі основні кроки:

1. Зчитування зображення рентгенограми;
2. Попередня обробка (нормалізація інтенсивності пікселів, масштабування та вирівнювання розмірів);
3. Сегментація цільових ділянок (легень), використовуючи Модель 1;
4. Класифікація патологій на основі сегментованих масок (Модель 2);
5. Оцінка ефективності за однією з метрик (точність, повнота, влучність, F1 оцінка) на валідаційній вибірці;
6. Донавчання моделі, якщо не досягнуто бажаного критерію успішності;
7. Формування підсумкового передбачення.

3.1.2 Метод сегментації на зображеннях без кісткових структур

Технологія видалення тіней кісткових структур дозволяє покращити сприйняття рентгенівських знімків, усуваючи кісткові тіні, які можуть маскувати патології. Такий підхід сприяє підвищенню точності виявлення патологій [179]. Існує кілька комерційних рішень, що реалізують цю технологію, зокрема ClearRead Xray [180] та CareStream Bone Suppression [181], які затверджені U.S. Food and Drug Administration (FDA). Ці методи підвищують інформативність рентгенівських знімків грудної клітки незалежно від того, виконані вони портативним або стаціонарним апаратом. Сучасні методи усунення кісткових структур на рентгенівських знімках грудної клітки базуються на глибоких нейронних мережах, які генерують зображення з пригніченням тіней кісток, що у підсумку дозволяє підвищити візуалізацію патологій. Основні підходи для видалення тіней кісток включають моделі типу автокодувальник, де мережа навчається перетворювати стандартне зображення у зображення без тіней, а також методи на основі U-Net [21] та GAN [182], які здійснюють сегментацію кісток і подальший синтез зображення. Головними перевагами цих методів є висока точність і здатність ефективно працювати з різними типами знімків, тоді як основним обмеженням є потреба у великих навчальних наборах, які повинні включати оригінальні зображення та їх версії без кісток.

Запропонований модифікований метод попередньої обробки рентгенівських знімків із видаленням кісткових структур та послідовною сегментацією діля-

108

нок, що містять цільові об'єкти, представлено на рисунку 3.2. На відміну від попереднього метода, де сегментація застосовується безпосередньо до оригінального знімка, тут передбачено попереднє видалення тіней кісток. Такий підхід дозволяє підвищити ефективність діагностики патологічних станів легень за рахунок виявлення ознак патологій, які могли бути замасковані кістковими структурами.

Початок

Рентгенограма

очищена від тіней кісток

Попередня обробка

(нормалізація)

Модель 1:

сегментація

Модель 2:

ідентифікація та

класифікація на сегментованих зображеннях

Чи досягнуто

бажаної точності

на валідацій-

ній вибірці?

Донавчання моделі

Результати передбачення моделі

Кінець

Так

Ні

Рисунок 3.2 — Метод попередньої обробки графічних даних без кісткових

структур із використанням сегментації ділянок, які містять цільові об'єкти

Модель 1: сегментація. Сегментація легень виконується за допомогою архітектури U-Net (див. рис. 3.3) для виокремлення релевантної області рентгенограми, що дозволяє зменшити вплив шуму та зосередити подальший аналіз на легеневих структурах для виявлення патологій.

109

6464 I

128 128 1/2
 256 256 1/4
 512 512 1/8
 1024 1024 1/1
 6
 Bottleneck Conv
 512 512 512 1/8
 256 256 256 1/4
 128 128 128 1/2
 64 64 64 1

Sigmoid
 Конкатенація
 Конкатенація
 Конкатенація
 Конкатенація

Conv 3×3 MaxPool 2×2 TConv 2×2

Рисунок 3.3 — Архітектура U-Net з пропускними зв'язками між шарами енкодера та декодера

Архітектура U-Net побудована за принципом енкодер-декодер з пропускними зв'язками (конкатенаціями), які з'єднують відповідні шари енкодера та декодера, що мають однаковий розмір просторових ознак. Такий механізм дає змогу декодеру використовувати одночасно як ознаки з енкодера, що мають високу роздільну здатність, так і низькороздільні ознаки з глибших шарів мережі.

Модель 2: ідентифікація та класифікація. Архітектура спроектованої згорткової нейронної мережі [30] була задана у вигляді послідовності 4-х згорткових шарів з операціями максимального агрегування (max pooling), а також 2-х повнозв'язних шарів, де останній забезпечував класифікацію між нормальним та аномальним станом пацієнта.

Вхідне зображення $X \in \mathbb{R}^{2048 \times 2048 \times 3}$ перетворюється чотирма згортковими блоками:

$Z(l) = \text{MaxPool}2 \times 2$

(
 $\text{ReLU}(W(l) * Z(l-1) + b(l))$
)

, $l = 1, 2, 3$.

$Z(4) = \text{ReLU}(W(4) * Z(3) + b(4))$,

де $Z(0) = X$, $*$ – операція двовимірної згортки, $W(l)$ – ядра розміру 3×3 з числом фільтрів $c_l \in \{32, 64, 128, 256\}$.

Векторизація: $v = \text{vec}(Z(4)) \in \mathbb{R}^n$.

Прихований шар: $h = \text{ReLU}(W_1 v + b_1) \in \mathbb{R}^{128}$, $W_1 \in \mathbb{R}^{n \times 128}$.

110

Вихідний шар: $\hat{y} = \sigma(w^T h + b_2)$, $\sigma(z) =$

$\frac{1}{1 + e^{-z}}$

, $\hat{y} \in [0, 1]$ – імовірність

класу «аномальний стан».

Функція втрат: $\mathcal{L}(y, \hat{y}) = -$

$[$
 $y \log \hat{y} + (1 - y) \log(1 - \hat{y})$
 $]$

, $y \in \{0, 1\}$.

3.1.3 Метод виключення викидів серед розподілу сегментованих масок на основі зменшення розмірності методом t-SNE

Інше застосування зменшення розмірності було використано для пошуку та виключення найбільш різномірних (віддалених) масок легень (рис. 4.4а), які виникають через мінливість легень та помилки під час ручної сегментації. Для цього було застосовано добре відомий метод t-розподілене вкладення стохастичної близькості (t-distributed Stochastic Neighbor Embedding – t-SNE) [183]—[185]. Вибір цього методу обумовлений його здатністю зберігати локальну структуру подібності між об'єктами при проєкції з високовимірному простору у дво- чи тривимірний простір, що дозволяє візуально та кількісно ідентифікувати точки, які істотно відхиляються від основного розподілу. Застосування t-SNE дозволило вбудувати багатовимірні зображення масок легень у тривимірний простір, який візуалізовано на діаграмі розкиду (рис. 3.4).

Метод t-SNE відображає кожну багатовимірну маску легень у 3D (рис. 3.4) або 2D (рис. 3.5) просторі як деяку точку в просторі, де подібні об'єкти моделю-

ються сусідніми точками, а різномірні об'єкти моделюються віддаленими точками.

Вхідними даними методики є набір сегментованих масок $X = \{x_1, x_2, \dots, x_N\}$ та параметри методу t-SNE: розмірність цільового простору d , перплексія $\text{Perp}(P_i)$, що визначає ефективну кількість найближчих сусідів, які враховуються при побудові розподілу подібності та кількість ітерацій оптимізації. Методику реалізовано у три послідовні етапи.

Етап 1. Побудова матриці подібності у вихідному просторі ознак.

Для кожної пари точок $x_i, x_j \in X$ обчислюються умовні ймовірності подібності P_{ij} (формула (3.2)), що відображають ймовірність вибору точки x_j як сусіда точки x_i відповідно до гауссового розподілу, центрованого в x_i . На основі отриманих умовних ймовірностей формується симетрична матриця подібності P

111

Рисунок 3.4 — Візуалізація моделі t-SNE для багатомірної маски легень за допомогою тривимірної точки, де подібні маски легень моделюються за допомогою точок, що знаходяться поруч, а найбільш неподібні маски відображаються як віддалені точки. Легенда: червоний колір – маски зображень з новоутвореннями (вузликами) у легенях, синій – без новоутворень (формула (3.3)), яка описує структуру локальної близькості між усіма масками вихідного набору даних.

Етап 2. Проекція у простір зниженої розмірності.

Координати $Y = \{y_1, \dots, y_N\}$ у просторі розмірності d ($d = 2$ або 3 , обрано для забезпечення можливості візуальної інтерпретації результату) ініціалізуються випадковим чином. Для кожної пари точок у зниженому просторі обчислюється матриця подібності Q на основі розподілу Стюдента. Остаточне розміщення точок Y визначається шляхом ітераційної мінімізації розбіжності Кульбака–Лейблера між розподілами P та Q , що забезпечує узгодженість локальної структури сусідства у вихідному та зниженому просторах. Ітераційний процес продовжується до досягнення збіжності функції втрат.

Етап 3. Ідентифікація та виключення викидів.

На отриманій проєкції Y визначається ядро даних – область найбільшої щільності точок, що відповідає типовим (репрезентативним) маскам набору да-

112

Рисунок 3.5 — Візуалізація масок легень із трансформацією t-SNE, що зберігає відстань з рис. 3.4, щоб скласти враження про найбільш несхожі (віддалені) маски легень них. Для кожної точки $y_i \in Y$ обчислюється мінімальна відстань до ядра даних; якщо ця відстань перевищує порогове значення θ , відповідна вихідна маска x_i класифікується як викид, оскільки її положення у просторі зниженої розмірності свідчить про суттєву відмінність від основного розподілу масок за структурними ознаками. Виключення таких точок дозволяє сформувати очищений набір даних $X^* = X \setminus \{\text{викиди}\}$, який надалі використовується для навчання та перевірки моделей глибокого навчання.

Застосування розробленої методики до набору сегментованих легеневих масок дозволило не лише очистити дані, а й виявити змістовні закономірності у природі самих викидів. За допомогою методу t-SNE було виявлено два типи найбільш несхожих (віддалених) легеневих масок. Один такий тип масок пов'язаний із внутрішньою мінливістю легень, наприклад, коли легені аномально малі (рис. 4.4а). Інший тип викликаний помилками під час ручної сегментації легень, наприклад, коли область серця не була виключена.

Зрештою, за допомогою такого пошуку та виключення найбільш віддалених масок легень (5% усіх зображень) можна отримати додатковий похідний набір даних No 5, який може більш ефективно використовуватися для навчання та перевірки моделі.

113

Подальший потенціал для вдосконалення методів глибокого навчання полягає у застосуванні цього підходу до інших медичних або рентгенівських наборів даних.

Ефективне число сусідів, що враховується для точки x_i під час обчислення схожості:

$$\text{Perp}(P_i) = 2$$

$$H(P_i), H(P_i) = -$$

$$\sum_j$$

$P_{j|i} \log_2 P_{j|i}$ (3.1)

Початок

Зображення рентгенограми

Попередня обробка

(нормалізація)

Модель 1:

сегментація

Фільтрація викидів

за допомогою t-SNE

Модель 2:

ідентифікація та

класифікація на сегмен-

тованих зображеннях

Чи досягнуто

бажаної точності

на валідацій-

ній вибірці?

Донавчання моделі

Результати передбачення моделі

Кінець

Так

Ні

Рисунок 3.6 — Метод попередньої обробки графічних даних із використанням сегментації ділянок, які містять цільові об'єкти, та виключення викидів серед розподілу сегментованих масок за допомогою t-SNE

114

Умовна ймовірність для кожної пари точок x_i, x_j :

$P_{j|i} =$

$\exp$

(

$- \|x_i - x_j\|$

2

$2\sigma^2$

)

$\sum$

$k \neq i \exp$

(

$- \|x_i - x_k\|$

2

$2\sigma^2$

) (3.2)

Симетричну матрицю P обчислюємо за формулою:

$P =$

$P_{j|i} + P_{i|j}$

$2n$

, (3.3)

n — кількість точок у датасеті.

3.2 Метод класифікації у федеративному навчанні за допомогою ансамблю опорних моделей

Ансамбль з кількох базових моделей поєднує кілька шляхів виділення ознак для підвищення стійкості та ефективності порівняно з мережами з однією базовою архітектурою, такими як CNN, шляхом опрацювання різних масштабів і контекстів даних [186]—[191]. Нещодавні дослідження відзначають переваги застосування ансамблю з кількох базових моделей для вирішення завдань, таких як мультимодальна інтеграція та навчання з урахуванням масштабів, які широко застосовуються у медичній візуалізації, дистанційному зондуванні та автономному транспорті. Зокрема, у контексті мультимодальної класифікації зображень нечітке доповнення метаданими (Fuzzy Metadata Augmentation, FMDA) досліджено в роботі [39], де додавання змодельованих текстових "експертних" висновків до зображень CIFAR10/CIFAR100 та MedMNIST забезпечило статистично значуще підвищення точності класифікації (12–26% за AUC). Розвитком цього підходу для умов федеративного навчання є багатомодальне доповнення метаданими (MMA) [38], де подібне доповнення медичних зображень текстовою інформацією дало змогу покращити результати класифікації на медичному наборі даних PathMNIST в умовах дисбалансу класів. Ансамблеві підходи на основі дистиляції знань для периферійних обчислю-

вальних систем розглянуто в роботі [40]. У роботі застосовано техніку послідовного відбору моделей із сукупності кандидатів для кількох родин архітектури ResNet, що відрізняються глибиною та кількістю параметрів. Ефективність мо-

115

делей оцінено на стандартних наборах даних CIFAR10/CIFAR100 та на спеціалізованих медичних наборах даних MedMNIST з метою порівняння результатів між цими двома типами даних. Отримані результати показали, що ефективність моделі на стандартних наборах даних CIFAR10/CIFAR100 не корелює з її ефективністю на медичних даних MedMNIST, тобто висока точність на стандартних наборах даних не гарантує збереження високої точності на медичних даних. Також встановлено, що вибір родини архітектури впливає на ефективність класифікації більше, ніж вибір конкретної моделі в межах цієї родини. Крім того, деякі архітектури, що є потужними та ефективними для CIFAR10/CIFAR100, виявилися надлишково великими для MedMNIST, що вказує на можливість зменшення кількості їх параметрів без істотного погіршення точності класифікації.

Серед численних доступних архітектур багатобазових нейронних мереж (MBNN) варто виділити паралельні багаторівневі потоки HRNet [187], ієрархічні з'єднання Res2Net [186] та динамічні маршрутизації, такі як MoE [190]. Їхні застосування охоплюють завдання від автоматичного виявлення та локалізації хірургічних інструментів [192] до автономного водіння [193] та багатозадачного навчання [194], при цьому фреймворки на кшталт MBBNet і MBMT-Net демонструють найкращі результати навіть за меншої кількості параметрів у деяких випадках.

Стратегії розширення даних, такі як Multi-Backbone Double Augmentation та Synchronized Multi-Augmentation, додатково підвищують ефективність багатобазових нейронних мереж [189], [191]. Водночас обмеження апаратного забезпечення периферійних систем ШІ (наприклад, обмежена потужність та обсяг пам'яті) вимагають балансування ширини та глибини мережі. У цій роботі досліджується, чи збільшення ширини базової архітектури дає кращі результати порівняно зі збільшенням глибини мережі, з урахуванням ефективності та точності у таких умовах.

Архітектури нейронних з низькими вимогами до обчислювальної потужності та пам'яті, такі як LCNet, компактні версії EfficientNet та інші, є ідеальними для федеративного навчання на периферійних системах ШІ, оскільки вони дозволяють ефективно долати ключові проблеми обмежених обчислювальних ресурсів, комунікаційного навантаження, енергоефективності, забезпечення приватності та масштабованості. LCNet дозволяє ефективно виконувати локальне навчання на периферійних пристроях і брати участь у глобальному оновленні моделей,

116

сприяючи впровадженню федеративного навчання у ресурсозалежних реальних умовах з високою продуктивністю.

Метою є дослідження концепції «ширина важливіша за глибину» шляхом розробки паралельних архітектур багатобазового ансамблю (MBE) з мережами, які характеризуються низькими вимогами до обчислювальної потужності та пам'яті для використання у федеративному навчанні. Основні завдання полягають у застосуванні MBE на базі ресурсоефективних сімейств глибоких нейронних мереж, таких як LCNet [195] у середовищі федеративного навчання зі стратегією FedAvg [196], змодельованою за допомогою фреймворку Flower [197]; оцінці продуктивності на стандартному наборі даних CIFAR-100; та дослідженні впливу складності моделі, розміру пакета, кількості локальних епох і числа багатобазових моделей.

Моделі-орієнтири. У даному дослідженні сімейство глибоких нейронних мереж LCNet [195] розглядається як типовий приклад компактних глибоких нейронних мереж, придатних і широко використовуваних для застосувань на периферійних пристроях ШІ. Ці глибокі нейронні мережі продемонстрували високу ефективність у класифікації та інших завданнях на різних наборах даних, зокрема CIFAR [198], ImageNet [16] та інших. LCNet є ресурсоефективною згортковою нейронною мережею, розробленою для підвищення точності та швидкодії на процесорах (CPU), особливо на архітектурах Intel із підтримкою MKLDNN-оптимізацій [195]. LCNet використовує блоки DepthSepConv, оптимізовані для швидкого інференсу та мінімальної затримки. Серед ключових особливостей – застосування активаційної функції H-Swish [199] (див. (3.4)) та стратегічне розташування модулів Squeeze-and-Excitation [200] для збалансування продуктивності й швидкодії. Завдяки такій комбінації LCNet забезпечує підвищену точність без суттєвого зростання часу інференсу, що робить її придатною для використання в

умовах обмежених ресурсів.

$$H\text{-Swish}(x) = x \cdot \text{ReLU6}(x + 3)$$

6

3.4

де $\text{ReLU6}(x) = \min(\max(0, x), 6)$.

Моделі з кількома базовими мережами. MBNN-моделі були побудовані шляхом послідовного підключення вхідного шару до однієї або кількох базових мереж LCNet. Після цього застосовуються шар перетворення у вектор (flatten) та усереднення (див. рис. 3.7). Шар усереднення виконує функцію методу ансам-

117

блювання, агрегуючи виходи від базових мереж для формування кінцевого передбачення. Запропоновані багатобазові версії архітектури LCNet050 для різної кількості бекбонів (NMB) продемонстровано на рис. 3.7: а) NMB = 1 (орієнтир), б) NMB = 2, в) NMB = 4.

а) NMB = 1 (орієнтир) б) NMB = 2

в) NMB = 4

Рисунок 3.7 — Приклади багатобазових версій архітектури LCNet050 для різної кількості бекбонів (NMB), застосованих до набору даних CIFAR-100: а)

NMB = 1 (орієнтир), б) NMB = 2 та в) NMB = 4

Робочий процес FedAvg [196], що демонструє взаємодію «сервер-клієнт» і агрегування моделей, наведено на рисунку 3.8.

118

Рисунок 3.8 — Стратегія агрегації локальних моделей FedAvg у Flower: (1) на кроці t сервер розсилає глобальну модель θ_t клієнтам; (2) клієнти виконують локальне навчання та обчислюють оновлені значення ваг $\theta_{it}+1$; (3) сервер агрегує локальні оновлення ваг для формування нової глобальної моделі θ_{t+1}

3.3 Метод генеративної аугментації даних на основі дистиляції навчальних траєкторій

Для подолання проблеми зростаючих вимог до обчислювальних ресурсів та обсягів пам'яті для зберігання даних у глибинному навчанні застосовано підхід генеративної аугментації даних методом дистиляції набору даних (Generative Data Augmentation by Dataset Distillation, GDADD) [37], який базується на техніці дистиляції набору даних шляхом узгодження навчальних траєкторій (Dataset Distillation by Matching Training Trajectories, DDMTT) [22] та розширює її застосування на значно (на порядки) збільшені значення параметра IPC (images per class), а також на медичні набори даних MedMNIST.

Сутність методу DDMTT, покладеного в основу підходу GDADD, полягає у використанні експертних траєкторій: попередньо обчислених послідовностей параметрів нейронної мережі для керування процесом навчання моделі-студента на синтетичних даних.

Вхідними даними методу GDADD є повний реальний набір даних Dreal, що містить пари «зображення–мітка класу», архітектура нейронної мережі-експерта (спрощена згортоква нейронна мережа (ConvNet)), цільовий розмір синтетичного набору даних (кількість зображень на клас, IPC), кількість незалежних експертних моделейE, кількість кроків градієнтного спуску моделі-студентаN, горизонт зіставлення експертної траєкторіїM, кількість ітерацій дистиляції.

Етап 1. Формування експертних траєкторій. На початковому етапі здійснюється навчання множини незалежних експертних моделей на повному реаль-

119

ному наборі даних Dreal. Для кожної експертної моделі на кожній епосі навчання фіксується знімок параметрів мережі, у результаті чого формується експертна траєкторія: впорядкована послідовність станів параметрів $\{\theta^*0, \theta^*1, \dots, \theta^*T\}$, що відображає еталонний процес навчання на реальних даних. Оскільки експертні траєкторії обчислюються один раз і надалі можуть багаторазово використовуватися в різних спробах дистиляції без повторного навчання експертних моделей, це забезпечує можливість швидкого й ефективного експериментування з різними конфігураціями методу.

Етап 2. Дистиляція синтетичного набору даних. Синтетичний набір даних Dsyn ініціалізується (як правило, випадковим чином або на основі випадкової вибірки реальних зображень) і оптимізується ітеративно: на кожній ітерації модель-студент навчається протягом кількох кроків на поточному синтетичному наборі, після чого траєкторія параметрів студента порівнюється з відповідним сегментом експертної траєкторії. Синтетичні зображення коригуються за допомогою градієнтного спуску таким чином, щоб мінімізувати відстань між траєк-

торією студента та експертною траєкторією, тобто щоб навчання на синтетичних даних якнайточніше відтворювало динаміку навчання на реальних даних. Вихідними даними методу є: дистильований синтетичний набір даних D_{syn} заданого розміру (кількість зображень на клас, IPC), який за своїми властивостями узагальнення наближається до повного реального набору даних D_{real} . Ключовою перевагою такого підходу є те, що моделі, навчені на дистильованому наборі D_{syn} , за належної організації процесу дистилляції демонструють продуктивність, зрівняну з продуктивністю моделей, навчених на повному наборі D_{real} , при цьому обсяг синтетичних даних є на порядки меншим за обсяг вихідного реального набору.

Формальний запис цільової функції узгодження траєкторій. Нехай експертна траєкторія задана послідовністю параметрів $\{\theta^*0, \theta^*1, \dots, \theta^*T\}$, отриманою в результаті навчання експертної моделі на реальному наборі даних D_{real} . Для кожної ітерації дистилляції випадковим чином обирається початкова точка θ^*t на експертній траєкторії (де t – випадково вибрана епоха-початок сегмента). Параметри моделі-студента ініціалізуються

120

значеннями експертної траєкторії в цій точці:

$$\theta^*t = \theta$$

*

t (3.5)

Далі модель-студент навчається протягом N кроків градієнтного спуску на поточному синтетичному наборі даних D_{syn} , у результаті чого отримуються параметри θ^{*t+N} . Ціль дистилляції полягає в тому, щоб ці параметри якнайточніше узгоджувалися з параметрами експертної траєкторії після M епох навчання на реальних даних, тобто з θ^*t+M (де, як правило, $M \geq N$).

Функція втрат узгодження траєкторій визначається як нормалізована квадратична відстань між досягнутим станом студента та відповідним станом експерта:

$$L(D_{syn}) =$$

$$\frac{1}{2} \|\theta^{*t+N} - \theta^*t+M\|^2$$

$$(3.6)$$

Нормалізація в знаменнику (на відстань, яку проходить сама експертна траєкторія за M епох) забезпечує незалежність значення функції втрат від масштабу параметрів на різних ділянках траєкторії та від конкретної епохи t , що робить оптимізацію більш стабільною. Синтетичні зображення D_{syn} оновлюються шляхом мінімізації L за допомогою градієнтного спуску:

$$D_{syn} \leftarrow D_{syn} - \eta \nabla D_{syn} L(D_{syn}) \quad (3.7)$$

де η – швидкість навчання для синтетичних зображень.

Псевдокод методу GDADD подано нижче:

- 1: Вхід: реальний набір даних D_{real} ; кількість експертів E ; кількість синтетичних зображень на клас IPC (у режимі GDADD: IPC = 101, до значень, що наближають обсяг D_{syn} до обсягу D_{real}); кількість кроків навчання студента N ; горизонт експертної траєкторії M ; кількість ітерацій дистилляції.
- 2: Навчити E незалежних експертних моделей на наборі D_{real} та зберегти для кожної експертну траєкторію $\{\theta^*0, \theta^*1, \dots, \theta^*T\}$.
- 3: Ініціалізувати синтетичний набір даних D_{syn} розміром $|D_{syn}| = IPC \times C$ (де C – кількість класів) випадковим шумом або випадковою вибіркою реальних зображень.

121

- 4: До тих пір поки не досягнута задана кількість ітерацій дистилляції або збіжність функції втрат виконувати
- 5: Випадково обрати експертну траєкторію та початкову епоху t .
- 6: Ініціалізувати параметри моделі-студента: $\theta^*t = \theta$
- *
- t .
- 7: Цикл $i = 1$ до N виконувати
- 8: Виконати один крок навчання моделі-студента на D_{syn} із застосуванням диференційовних аугментацій.
- 9: Кінець циклу
- 10: Отримати параметри моделі θ^{*t+N} .
- 11: Обчислити функцію втрат $L(D_{syn})$ як нормалізовану відстань між θ^{*t+N} та θ^*t+M (див. формулу (3.6)).
- 12: Оновити синтетичний набір даних D_{syn} градієнтним спуском відповідно до рівняння (3.7).

13: Кінець циклу

14: Вихід: дистильований синтетичний набір даних D_{syn} в режимі GDADD: $|D_{syn}| \rightarrow |D_{real}|$, що забезпечує ефект генеративної аугментації.

Архітектура мережі, що використовується для дистилляції набору даних, базується на архітектурах ConvNet [201] і має навмисно спрощену конструкцію, що дає змогу здійснити безпосередній аналіз ефективності методу дистилляції, забезпечуючи при цьому порівнюваність з попередніми дослідженнями [22]. Мережа складається з кількох згорткових блоків, кількість яких адаптується залежно від роздільної здатності вхідних зображень, при цьому для кожного набору даних, використаного в експериментах, визначено окрему конфігурацію. Кожен згортковий блок використовує 128 фільтрів розміром 3×3 з функцією активації ReLU та шар усередненої агрегації (average pooling) у вікні розміром 2×2 та кроком (stride) 2, детальніший опис реалізації наведено в роботі [22]. Використання такої компактної архітектури дозволяє ізолювати вплив методу дистилляції, уникаючи побічних факторів, пов'язаних зі складністю архітектури мережі. Такий вибір мережі забезпечує пряму порівнюваність отриманих результатів із попередніми роботами [22] та спорідненими дослідженнями [201], [202], що сприяє коректному оцінюванню та бенчмаркінгу процесу дистилляції набору даних.

122

3.4 Висновки до розділу

У даному розділі запропоновано нові та вдосконалено існуючі методи глибинного машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів. Відповідно було:

1. Вперше запропоновано інтегровану технологію попередньої обробки 2D рентгенограм, яка поєднує сегментацію цільових ділянок на основі глибоких нейронних мереж типу кодер-декодер із подальшою класифікацією патологій. На відміну від класифікації за ознаками всього зображення, запропонована технологія дозволяє зосередити аналіз на клінічно значущих ділянках, знизити вплив нецільових анатомічних структур, зменшити розмірність вхідних даних та покращити результати діагностики окремих легеневих захворювань.
2. Вперше запропоновано метод класифікації у федеративному навчанні, що поєднує ансамбль опорних моделей з архітектурами низької обчислювальної складності за стратегією «ширина важливіша за глибину», який на відміну від існуючих підходів до збільшення глибини нейронних мереж, дозволяє підвищити узагальнювальну здатність моделі та зменшити ризик перенавчання за рахунок зменшення дисперсії передбачень при агрегуванні частково некорельованих похибок окремих моделей, при цьому експериментально встановлено, що вигреш від ансамблювання залежить від кількості локальних епох навчання між раундами усереднення моделей.
3. Удосконалено метод глибинного навчання на основі згорткових нейронних мереж, який на відміну від відомих методів автоматизованої діагностики за рентгенограмами доповнено етапами сегментації анатомічних структур та вилучення з рентгенограм тіней кісток, що дозволяє зменшити перекриття патологічних ознак кістковими структурами, а також додатково скоротити розмірність вхідних даних за рахунок вилучення нерелевантних ознак, що знижує ризик перенавчання моделі за умов обмеженого розміру навчальної вибірки.
4. Отримав подальший розвиток метод виключення викидів серед сегментованих масок, який, на відміну від відомих підходів, ґрунтується на проєкції розподілу масок у простір зниженої розмірності за допомогою

123

методу t-SNE з подальшою пороговою фільтрацією відносно ядра даних, що дозволило покращити якість вхідних даних для методів глибинного навчання під час класифікації патологічних станів легень за 2D-рентгенограмами.

5. Отримав подальший розвиток метод дистилляції набору даних шляхом узгодження навчальних траєкторій (DDMTT): запропоновано генеративну аугментацію даних GDADD, яка, на відміну від DDMTT, суттєво збільшує кількість синтетичних зображень на клас, синтезуючи набір даних, обсяг якого наближається до реального набору даних. За рахунок цього синтезовані зображення кодують ширший спектр інформативних ознак, що дозволяє моделям, навченим на такому наборі, досягати узагальнювальної здатності, зіставної з моделями, навченими на значно більшому

реальному наборі даних.

Основні результати даного розділу опубліковані у роботах [26], [28], [30], [31], [35], [37]. Наступний розділ присвячено аналізу та обговоренню результатів, отриманих у процесі застосування розроблених методів.

124

РОЗДІЛ 4. АНАЛІЗ ТА ОЦІНЮВАННЯ РЕЗУЛЬТАТІВ ДОСЛІДЖЕННЯ

Запропонований комплексний метод глибинного машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів спрямований на підвищення ефективності та надійності автоматизованих методів аналізу візуальних даних, зокрема таких, що представлені у вигляді рентгенограм, шляхом створення та оптимізації методів і моделей глибинного машинного навчання. Запропонований метод аналізу візуальних даних дозволяє покращити результати за рахунок:

1. Використання ефективних методів аугментації та попередньої обробки даних;
2. Використання моделі сегментації легень для виділення цільової області та зменшення впливу фонового шуму;
3. Інтеграції підходу сегментації анатомічних структур та вилучення з рентгенограм тіней кісток;
4. Зменшення розмірності даних на основі методу t-SNE з метою виключення викидів серед розподілу сегментованих масок;
5. Застосування моделі класифікації на основі 2D згорткових мереж для визначення патологічних станів за сегментованими масками легень;
6. Застосування ансамблевих моделей для підвищення стійкості та узагальнювальної здатності результатів;
7. Впровадження механізму інтерпретації результатів на основі методу Grad-CAM для візуалізації областей зображення, що найбільше впливають на рішення моделі.

4.1 Аналіз результатів застосування методу попередньої обробки графічних даних із використання сегментації цільових ділянок

У цьому розділі представлені результати щодо впливу сегментації легень та вилучення тіней кісток на тренування моделей з урахуванням: вихідного набору даних JSRT (згадується як набір даних No 01), набору даних BSE-JSRT, тобто набір даних JSRT з якого були виключені тіні ключиць та ребер (набір даних No 02), оригінальний набір даних JSRT після сегментації (набір даних No 03) та BSE-JSRT після сегментації (набір даних No 04).

125

Цей етап сегментації раніше успішно був застосований до оригінальних знімків із набору даних JSRT (набір даних No 01, рис. 4.1а), щоб отримати їх сегментовані версії (набір даних No 03, рис. 4.1в) і складався з таких кроків:

1. Навчання CNN сегментувати легені (пошук меж легень) на наборі даних MC з вручну підготовленими масками (межами легень).
2. Прогнозування легеневих меж у формі чорно-білих масок легень (рис. 4.1б) за допомогою навченої мережі CNN для кожного з оригінальних зображень із набору даних JSRT (рис. 4.1а).
3. Вирізання областей, які представляють інтерес для подальшого аналізу (праву та ліву легеню) (рис. 4.1в) із оригінальних вхідних зображень (рис. 4.1а).

а) Оригінальний

приклад,

датасет No 01, JSRT [85]

б) Передбачена маска

легень

в) Сегментована версія

—

датасет No 03

Рисунок 4.1 — Приклад оригінального зображення з датасету No 01 а), відповідна маска легень, яка передбачена методом глибинного навчання б), та її сегментована версія в)

Така ж сама процедура була застосована до зображень без тіней кісток із набору даних BSE-JSRT (набір даних No 02, рис. 4.2а) для отримання їх сегментованих версій легень без кісток (набір даних No 04, рис. 4.2в).

Подальший потенціал для вдосконалення полягає у збільшенні досліджуваних наборів даних:

1. Розмір зображення від поточних значень 256×256 до 1024×1024 (набір

даних ChestXRay) та 2048×2048 (набір даних JSRT).

2. Кількість зображень із поточних 247 (набори даних JSRT та BSE-JSRT) до > 1000 (набір даних MC) та > 100 000 (набір даних ChestXRay).

126

а) Оригінальний

приклад,

датасет No 02

б) Передбачена маска

легень

в) Сегментована версія

—

датасет No 04

Рисунок 4.2 — Приклад оригінального зображення з датасету No 02, BSE-JSRT [86] а), відповідна маска легень, яка передбачена методом глибинного навчання б), та її сегментована версія в)

3. Шляхом збільшення даних щодо перетворень із втратами та без втрат [26], [28], [31].

Набагато більший прогрес можна досягти завдяки інтеграції багатьох подібних наборів даних з численних лікарень по всьому світу в дусі відкритих наукових даних, збору даних про волонтерів, обробки та обчислень даних [203]. Додатковий резерв розробки може бути пов'язаний із вдосконаленням алгоритмів попередньої обробки для:

1. Сегментації легень на основі більших наборів даних з масками.
2. Усунення тіней кісток на основі більш складних семантичних прийомів сегментації, що застосовуються не тільки до легень та частин тіла поза ними (наприклад, серця, рук тощо), але також до ребер і ключиць.
3. Тренування за допомогою збільшення розміру та складності мережі глибинного навчання з поточного мініатюрного розміру 4+2 шарів до > 100 шарів, як у сучасних найбільш точних мережах, таких як CheXNet, що використовується для діагностики інших захворювань [151].

Аналогічні методики були перевірені на наборі даних MC-SH [89], [90]. Він містить нормальні та аномальні зображення CXR із слідами туберкульозу. Аналіз даних показав, що цей невеликий набір даних є недостатньо збалансованим щодо захворювань, віку та статі. Ширина та висота зображень не рівні, і ці відмінності призводять до широкого та асиметричного розподілу областей зображень

127

(рис. 4.3). Поточні та попередні спроби провести навчання мережі на таких невеликих наборах даних без будь-якої попередньої обробки CXR зображень були здійснені та провалені [46], [47]. На щастя, “зовнішня сегментація” лівої та правої ділянки легень (виключення зовнішніх областей, які не відносяться до легень) була продемонстрована як ефективна методика для забезпечення успішного навчання та підвищення точності прогнозів моделі [46], [47].

Незважаючи на високу мінливість масок сегментованих легень (через різні форми та межі легень) розподіл ділянок маски легень був набагато ближчим до нормального порівняно з розподілом ділянок зображень, який був асиметричним та мав довгий хвіст для менших розмірів (рис. 4.3).

Площа (нормалізована)

Ч

ас

то

та

Рисунок 4.3 — Розподіл площі зображень (images) і масок (masks)

Деякі приклади найбільш подібних, несхожих та усереднених масок легень показано на рис. 4.4. Ця мінливість пояснюється наявністю викидів, наприклад, у певної частини дітей з меншими легеньками.

Подальший потенціал для вдосконалення DL методів полягає у застосуванні цього підходу до інших розглянутих у попередньому розділі датасетів.

128

а) б) в)

Рисунок 4.4 — Маски легень: найбільш несхожі а), найбільш подібні б) та середня в)

Зменшення розмірності даних за допомогою сегментації та вилучення тіней кісток

Одним із шляхів підвищення продуктивності моделей є зменшення розмір-

ності даних. Цього можна досягти кількома способами.

Висока мінливість масок для сегментації легень (форми та межі легень) спостерігалася навіть без урахування внутрішніх та зовнішніх частин легень. Деякі приклади найбільш подібних та несхожих масок легень наведені на рис. 4.4. На жаль, цю мінливість не можна виключити жодною універсальною маскою легень, отриманою шляхом злиття, перетину або усереднення масок, оскільки у всіх цих випадках деякі положення утворень (рис. 4.4) не можуть бути закриті універсальною маскою легень. Середня частка площі сегментації становила 0.32 ± 0.06 (рис. 4.3), що дозволило нам отримати зменшення розмірності в 3.2 ± 0.7 разів. Додаткова операція з вилучення тіней кісток (рис. 4.5) є еквівалентною вилученню нерелевантних ознак, яка має середнє значення 0.15 ± 0.04 (рис. 4.3) і дає додаткове зменшення розмірності в ~ 2 рази. Незважаючи на те, що останній підхід зі зменшення розмірності неможливо точно оцінити, оскільки він пов'язаний зі згладжуванням яскравості легень, тим не менше це дозволяє нам виключити контури тіней кісток, які ускладнюють пошук уражених ділянок легень. Подальший потенціал для вдосконалення DL методів полягає у застосуванні цього підходу до інших розглянутих у попередньому розділі датасетів.

129

а) б) в)

Рисунок 4.5 — Сегментована маска легень з датасету JSRT а), маска кісток б) і результуюча маска легень без кісток в)

4.2 Рентгенологічний аналіз туберкульозу на основі глибинного навчання з сегментацією та розширенням даних

У цій роботі представлені результати рентгенологічного аналізу грудної клітки (CXR) 2D-зображень за допомогою комп'ютерної діагностики (CADx) для отримання статистично достовірних прогнозів (наявність туберкульозу) на основі глибинного навчання. Результати демонструють ефективність виконання попередньої сегментації легень та розширення даних з втратами та без втрат інформації на рентгенограмах для комп'ютерної діагностики туберкульозу за допомогою глибокої згорткової нейронної мережі (CNN), застосованої до невеликого та навіть незбалансованого набору даних. CNN демонструє кращу здатність до навчання на попередньо обробленому наборі даних, отриманому після сегментації легень порівняно з оригінальним несегментованим набором даних. Збільшення сегментованого набору даних без втрат інформації призводить до найнижчих втрат моделі на перевірконому наборі (без перенавчання) та майже однакової точності (в межах стандартного відхилення) порівняно з оригінальним та іншими попередньо обробленими наборами даних після збільшення даних з втратою інформації. Крім використання більш складної архітектури нейронної мережі та більших наборів даних, кращий прогрес CADx для малих та незбалансованих наборів можна отримати навіть за рахунок кращої сегментації, розширення даних, стратифікації наборів даних та більш ретельного аналізу викидів навчальної вибірки.

130

Рентгенологічне дослідження органів грудної клітки широко використовується для моніторингу стану здоров'я та діагностики багатьох захворювань легень (пневмонія, туберкульоз, рак тощо) через відносно низьку вартість та легкодоступність. Ручний аналіз CXR з метою виявлення ознак, які характерні конкретному патологічному стану є тривалим та складним процесом, який проводиться експертами-рентгенологами. Деякі труднощі комп'ютерної діагностики легеневих захворювань на основі невеликих наборів даних (< 103 зображень) пов'язані з великою мінливістю розмірів зображень, якістю зображень та впливом інших регіонів поза легеньми (серце, плечі, ребра, ключиці тощо). Ця мінливість спричинена через різну стать, національність, вік, зловживання наркотичними речовинами, професійну діяльність, загальний стан здоров'я та інші особливості пацієнтів. Зокрема мінливість посилюється деякими додатковими артефактами, які можуть бути присутні на рентгенограмах (наприклад, білі прямокутники з текстом та символами показано на рисунку 4.6а у верхній частині зображення).

а) б) в)

Рисунок 4.6 — Оригінальне зображення з датасету Shenzhen Hospital (SH) а), маска легень цього зображення б) та результат сегментації за маскою в)

У роботах [26], [30] було продемонстровано доцільність та ефективність застосування деяких методів зменшення розмірності даних, таких як сегментація легень, вилучення тіней кісток та t -розподілене вкладення стохастичної близькості (t -SNE) для аналізу CXR з метою виявлення ознак патологічних станів, що спостерігається при раку легень. Незважаючи на ці спроби, CADx все ще залишається викликом для ефективного використання медичних знімків, особливо з

огляду на високу мінливість легень пацієнтів, яких досліджують.

131

4.2.1 Використане обладнання, методи та дані

Навчання CNN здійснювалося на різних графічних процесорах загального призначення (GPU) від NVIDIA: Tesla K40 (мікроархітектура Kepler), GTX 1080 Ti (Pascal) і остання найбільш потужна – Tesla V100 (Volta). Офіційні дані про продуктивність, пропускну здатність, кількість ядер, а також фактичний час навчання моделі з відповідними прискореннями (для одного й того самого набору даних та конфігурації середовища виконання) наведено в таблиці 4.1. Ця інформація представляє значний інтерес для розуміння того як можна досягти кращої продуктивності моделі на навчальному та тестовому наборах даних за допомогою апаратних засобів. Розглянута CNN не була оптимізована для розрахунків за допомогою тензорних ядер на карті V100. Ось чому отримане прискорення на карті V100 є не настільки вражаючим. Ядра тензорів або блоки обробки тензорів (TPU), наприклад, TPUv1 та TPUv2, запропоновані та спеціально розроблені Google для досягнення вищої продуктивності під час глибокого навчання, ніж це відбувається під час навчання на звичайних ядрах графічного процесора. Використання спеціалізованого апаратного забезпечення в глибокому навчанні, зокрема тензорних ядер, потребує від інженера машинного навчання додаткової оптимізації моделі з метою ефективного використання обчислювальних потужностей, що пропонує апаратне забезпечення.

Таблиця 4.1 — Порівняння продуктивності графічних процесорів

GPU

Продуктивність,

(TFLOPS)

Пропускна

здатність,

(ГБ/с)

Кількість

ядер

Час

навчання,

(год:хв)

Прискорення

K40 4.3-5.0 288 2880 12:08 1

GTX 1080

Ti

10.6 484 3584 00:50 14.56

V100 14.0 900 5120 00:33 22

Для навчання моделі було використано набір даних Shenzhen Hospital (SH).

Загальний розмір датасету – 662 рентгенограм грудної клітки (CXR), які подані у форматі PNG змінного розміру ~ 3к × 3к пікселів. У датасеті представлено 336 CXR з слідами туберкульозу та 326 CXR здорових людей. Попередній аналіз даних показав, що цей невеликий датасет є недостатньо збалансованим відносно віку та статі пацієнтів (зображення 4.7).

132

Клас

В

ік

Стать

Ч

Ж

Рисунок 4.7 — Комбінований розподіл за статтю та віком для рентгенограм без (0) та з (1) ознаками туберкульозу

Ширина та висота рентгенограм не однакові, і ці відмінності призводять до широкого та асиметричного розподілу областей зображення, який показано на рисунку 4.3. Попередні спроби провести навчання мережі на таких невеликих наборах даних без будь-якої попередньої обробки CXR були здійснені у роботах [26], [30]. На щастя, зовнішня сегментація лівої та правої ділянки легень (виключення зовнішніх областей, які не відносяться до легень) була продемонстрована як ефективна методика для забезпечення успішного навчання та підвищення точності прогнозів моделі [26], [30]. Сегментація легень була виконана нами вручну, приклад анотованої маски (рисунок 4.6, б)). Це дозволило нам отримати додатковий набір даних на основі датасету SH, а саме сегментований набір даних SH (рисунок 4.6, в)). Незважаючи на високу мінливість масок сегментованих

легень (через різні форми та межі легень) розподіл площі масок легень був набагато ближчим до нормального розподілу порівняно з розподілом площі зображень, який був асиметричним та мав довгий хвіст для менших розмірів (рисунок 4.3).

133

4.2.2 Ефект розширення даних без втрат інформації

Розширення даних без втрат інформації включало: дзеркальні відбиття (вліво-вправо та вгору-вниз) і повороти на $90n$ градусів, де $n = 1, 2, 3$. Це дозволило нам збільшити у 8 разів увесь набір даних та отримати більш реалістичні результати щодо точності та втрат моделі під час навчання та валідації. Точність навчання досягає значення 0.9 (рис. 4.8 а), точність валідації – 0.7 (рис. 4.8 б), а втрата навчання (рис. 4.9 а) наближалася до 0 із значно меншою швидкістю. Але найважливішим аспектом є те, що втрати валідації (рис. 4.9 б) тепер мають глобальний мінімум (приблизно на 3000 кроках), що відповідає найбільш реалістичній оцінці точності валідації, яка дорівнює 0.7 ± 0.1 .

а) б)

Рисунок 4.8 — Точність моделі під час кросвалідації на сегментованому наборі SH з розширенням даних без втрат інформації: навчання а) та валідація б)

4.2.3 Ефект розширення даних з втратою інформації

Додаткове розширення даних із втратою інформації для 2D CXR включало повороти на 5 градусів. У цьому випадку точність навчання була нижчою за 0.85 (рис. 4.10 а) з нижчим стандартним відхиленням (усередненого та згладженого значення), точність валідації була нижчою за 0.65 (рис. 4.11 б), а втрата навчання (рис. 4.11 а) була не нижчою 0.35. Але знову ж таки найважливішим аспектом тут є те, що втрати валідації (рис. 4.11 б) мають глобальний мінімум (приблизно

134

а) б)

Рисунок 4.9 — Втрати моделі під час кросвалідації на сегментованому наборі SH з розширенням даних без втрат інформації: навчання а) та валідація б) на 2500 кроках), що відповідає найбільш реалістичній оцінці точності валідації, яка дорівнює 0.64 ± 0.1 .

Незважаючи на виконану меншу кількість циклів навчання/валідації для наборів з розширенням даних без втрат та з втратою інформації порівняно з 7 циклами для сегментованого набору даних, стандартне відхилення усередненого та згладженого значення (позначено інтервал синім кольором на рис. 4.12- 4.11) точності валідації завжди була нижчою для розширених наборів даних (рис. 4.8 б та рис. 4.10 б). Більш цікаве спостереження пов'язане зі значно меншими втратами валідації для розширених наборів даних (рис. 4.9 б та рис. 4.11 б) порівняно з сегментованим набором даних (рис. 4.13 б), але лише до моменту, коли втрати валідації досягають локального мінімуму (рис. 4.9 б та рис. 4.11 б), що відповідає навчання без перенавчання.

4.2.4 Навчання та валідація моделей

Згортоква нейронна мережа [30] була спроектована за допомогою фреймворку машинного навчання TensorFlow (keras) та навчена у режимі GPU для передбачення туберкульозу з рентгенограм грудної клітки взятих з датасету SH. Датасет було розділено у відношенні 8:1:1 на навчальну, валідаційну та тестову вибірки відповідно. Рентгенограми навчальної, валідаційної та тестової вибірок було

135

а) б)

Рисунок 4.10 — Точність моделі під час кросвалідації на сегментованому наборі SH з розширенням даних з втратою інформації: навчання а) та валідація б) нормалізовано $1./255$ та масштабовано до розміру 2048×2048 пікселів. Було виконано кілька циклів навчання та валідації CNN моделі з дропаутом до 100 епох на наступних наборах даних: сегментованому наборі SH, сегментованому наборі SH з розширенням даних без втрат інформації та сегментованому наборі SH з розширенням даних з втратою інформації.

Сегментований набір SH

Приклади значень точності та втрат моделі для 7 циклів запусків показано на рис. 4.12 (точність) і рис. 4.13 (втрати): для навчання та валідації моделі, після усереднення їх значень за циклами (червона лінія на рис. 4.12 та рис. 4.13) та після згладжування усереднених часових рядів (синя лінія на рис. 4.12 та рис. 4.13) за допомогою методу локально зваженої поліноміальної регресії [204]. Виражене перенавчання моделі можна спостерігати порівнявши точність та втрати на навчальній та валідаційній вибірках (рис. 4.12 та рис. 4.13). Усереднене та згладжене значення точності навчання (рис. 4.12 а) прямує до теоретичного

максимуму 1, а втрата навчання (рис. 4.13 а) прямує до 0. У той же час усереднене та згладжене значення точності валідації (рис. 4.12 б) не перевищує 0.76, а втрати валідації (рис. 4.12 б) дуже високі та продовжують зростати. Перенавчання можна пояснити відносно великою складністю моделі та використанням ма-

136

а) б)

Рисунок 4.11 — Втрати моделі під час кросвалідації на сегментованому наборі SH з розширенням даних з втратою інформації: навчання а) та валідація б) тим розміром навчального набору даних, проте частково цей ефект перенавчання можна зменшити за допомогою методів розширення даних. Для цього було окремо досліджено роль та застосовано два типи розширення даних без втрат та з втратами інформації.

4.2.5 Аналіз результатів дослідження

Ретельний аналіз значень точності та втрат моделі на навчальній та валідаційній вибірках (рис. 4.14) для наступних наборів даних: сегментованому наборі SH, сегментованому наборі SH з розширенням даних без втрат інформації та з втратою інформації, дозволяє нам зробити наступні спостереження та висновки. Найвища точність навчання досягається на сегментованому наборі SH (рис. 4.14 а, червона суцільна лінія), але це можна пояснити очевидним перенавчанням моделі. Це підтверджується зростанням втрат валідації (рис. 4.14 б, червона штрихова лінія) та великою різницею між навчальною (рис. 4.14 а, червона суцільна лінія) та валідаційною (рис. 4.14 а, червона штрихова лінія) точністю, а також великою різницею між втратами під час навчання (рис. 4.14 б, червона суцільна лінія) та втратами валідації (рис. 4.14 б, червона штрихова лінія). Незважаючи на те, що точність моделі на сегментованому наборі SH з розширенням

137

а) б)

Рисунок 4.12 — Точність моделі під час кросвалідації на сегментованому наборі SH: навчання а) та валідація б) даних без втрат інформації (рис. 4.14 а, синя суцільна лінія) та сегментованому наборі SH з розширенням даних з втратою інформації (рис. 4.14 а, зелена суцільна лінія) набагато нижча, ніж точність навчання на сегментованому наборі даних (рис. 4.14 а, червона суцільна лінія), проте при цьому розширення даних дозволяє нам уникнути перенавчання моделі. Крім того, значення втрат для обох розширених наборів даних дуже близькі (рис. 4.14 б, зелена та синя лінії) до моменту, коли втрати валідації досягають локального мінімуму (рис. 4.9 б та рис. 4.11 б), що відповідає фазі без перенавчання моделі. Для розширеного набору даних без втрат інформації значення точності навчання та валідації (рис. 4.14 а, сині лінії) стають рівними на певному етапі, а точність валідації досягає максимуму поблизу локального мінімуму втрати валідації.

Але значення точності навчання та валідації для набору з розширенням даних з втратою інформації ніколи не стають близькими (рис. 4.14 а, зелені лінії), і різниця між ними лише продовжує зростати. Це можна вважати наслідком втрати інформації для розширених даних з втратою інформації (фактично поворот до 5 градусів). Різні методи розширення даних з втратою інформації можуть призвести як до позитивних так і негативних наслідків для прогнозу моделі під час CADx, тому роль втрати інформації слід досліджувати окремо більш ретельно. Крім того, вплив викидів і довгих хвостів у розподілі площі легень можна виключити за допомогою зменшення розмірності, використовуючи сегментацію кісток та t-SNE метод, що дозволяє покращити точність моделі навіть для дуже низької

138

а) б)

Рисунок 4.13 — Втрати моделі під час кросвалідації на сегментованому наборі SH: навчання а) та валідація б) частки відфільтрованих викидів (5%) [26]. У цьому сенсі дуже перспективним буде більш ретельний попередній аналіз та обробка даних з відфільтруванням легневих груп для людей різного віку, статі та географічного походження. Отримані нами результати демонструють, що сегментація та розширення даних можуть підвищити точність моделі для здійснення передбачень захворювань легень (наявність туберкульозу) навіть для відносно невеликих наборів даних, таких як SH (662 рентгенограм) [89], [90]. Раніше нами було досліджено вплив неоднорідності та викидів для рентгенологічного аналізу даних з набору JSRT [26], [30]. Попередньо оброблений набір даних JSRT, отриманий після сегментації легень, видалення тіней кісток та виключення викидів серед розподілу

сегментованих масок за допомогою t-SNE, продемонстрував найвищу швидкість навчання та найкращу точність порівняно з іншими попередньо обробленими наборами даних. У поточній роботі ми працювали з набором даних SH для виявлення ознак туберкульозу за допомогою згорткової нейронної мережі. У цій роботі ми продемонстрували, що подібна техніка сегментації легень дозволяє навчати (на жаль, із надмірним перенавчанням) глибоку CNN на маленькому та недостатньо збалансованому наборі даних SH (це було б неможливо для набору даних SH без сегментації). Крім того, розширення даних без втрат інформації дозволяє нам визначити глобальний мінімум функції втрат, таким чином ми можемо визначити оптимальний рівень навчання моделі без надмірного запам'ятовування даних (перенавчання). Ефект додаткового збільшення даних із втратою інформації

139

а) б)

Рисунок 4.14 — Усереднені та згладжені значення точності а) та втрат б) навчання та валідації на наборах даних: сегментованому наборі SH (червоний колір), сегментованому наборі SH з розширенням даних без втрат інформації (синій колір) та сегментованому наборі SH з розширенням даних із втратою інформації (зелений колір)

ції (повороти на 5 градусів) має таку ж саму тенденцію до навчання. Але вплив збільшення даних із втратою інформації у більш ширшому розумінні (з більшими кутами поворотів, масштабуванням, спотворенням тощо) на прогнози моделі визначати ознаки туберкульозу залишається відкритим і його слід досліджувати на більших наборах даних.

Перший очевидний спосіб покращення результатів діагностики легневих патологічних станів за допомогою нейронних мереж пов'язаний зі збільшенням наборів даних від поточної кількості 662 зображень (SH) до > 100 000 зображень (набір даних ChestXRay). У цьому сенсі прогресу можна досягти шляхом обміну подібними наборами даних по всьому світу в дусі відкритої науки, добровільного збору даних, обробки та обчислень [203], [205], [206]. Другий спосіб – використання адаптованих та більш складних архітектур глибоких CNN, таких як CheXNet з > 100 шарами [151] та їх тонкого налаштування.

140

4.3 Вибір та налаштування моделей глибокого навчання із застосуванням штучного розширення різноманітності даних

У даному розділі подано результати дослідження методу обробки медичних зображень, а саме:

1. Тренування стандартних і новітніх нейронних моделей глибокого навчання із використанням методу крос-валідації (k-fold cross validation) і штучного збільшення кількості варіантів тренувальних зображень (data augmentation – DA).

2. Тестування отриманих моделей із залученням методу штучного збільшення кількості варіантів тестових зображень (post-training/testing time data augmentation – TTA).

3. Результати порівняльного аналізу отриманих даних на різних інфраструктурах, моделях і їх параметрах для дослідження впливу типу інфраструктури (TPU/GPU), типу і розміру моделей на час і точність прогнозування за стандартними метриками.

Результати цього дослідження виконано у рамках грантової підтримки НФДУ [41]: “The work was partially supported by the National Research Foundation of Ukraine by the grant 2020.01/0490 – Artificial Intelligence Platform for Distant Computer-Aided Detection (CADE) and Computer-Aided Diagnosis (CADx) of Human Diseases”.

Навчання моделей та аналіз отриманих результатів

У даному параграфі дається підсумковий аналіз отриманих і опублікованих результатів у розгорнутому форматі з підсумками відповідно до технічного завдання і поставлених метрик (AUC – таблиця 4.2, та час тестування – таблиця 4.3) і статичні оцінки розкиду значень цих метрик.

141

таблиця 4.2 — Величини показника якості класифікації та середнього квадратичного відхилення кожного типу архітектури моделі з урахуванням test-time augmentation

Модель	TTA_AUC_mean	TTA_AUC_std
EfficientNetB0	0.942	0.033
EfficientNetB6	0.931	0.027
DenseNet121	0.917	0.044
MobileNetV2	0.841	0.03
InceptionV3	0.926	0.04
ResNet101	0.928	0.054
ResNet101V2	0.917	0.03
InceptionResNetV2	0.944	0.043
VGG16	0.878	0.012

Xception 0.898 0.0352

18. Таблиця 4.3 — Показники часу тестування та середнього квадратичного відхилення для моделей, що були використані з урахуванням test-time augmentation

Модель TTA_time_mean TTA_time_std EfficientNetB0 0.00102 0.000010

EfficientNetB6 0.00137 0.0000118

18. DenseNet121 0.00104 0.0000057

MobileNetV2 0.00102 0.000008

InceptionV3 0.00106 0.0000078

ResNet101 0.00105 0.0000081

ResNet101V2 0.00104 0.0000084

InceptionResNetV2 0.00140 0.000012

VGG16 0.00101 0.000011

Xception 0.00103 0.000006

На основі здобутих результатів було визначено, що:

Найменшими за розміром є мережі: 1. MobileNetV2

142

2. EfficientNetB0 3. DenseNet121 Найбільшу точність в межах похибки демонструють мережі: 1. EfficientNetB0 2. EfficientNetB6 3.

InceptionResNetV Найшвидшими без TTA є мережі: 1. MobileNetV2 2. EfficientNetB0 3. VGG16 та Xception мають майже ідентичні результати

Найшвидшими із TTA є мережі: 1. VGG16 2. MobileNetV2 3. EfficientNetB0 Отже, було сформульовано наступні рекомендації для практичного

викори-

стання розглянутих мереж та конфігурацій апаратного забезпечення.

Використання:

1. Для завдань із невисокими вимогами до часу прогнозу на стаціонарних пристроях із необмеженими ресурсами (хмарні ресурси на базі GPU-TPU вузлів) найбільш ефективно було б використовувати архітектури мережі EfficientNet, віддаючи перевагу мережі EfficientNetB0 з найбільшим середнім значенням для метрики AUC.

2. Для завдань із високими вимогами до часу прогнозу на стаціонарних пристроях із обмеженими ресурсами (локальні ресурси на базі GPU карт) найбільш ефективно було б використовувати мережі із найбільшою точністю і найбільшою швидкістю: EfficientNetB0 єдина серед досліджених моделей, що здатна сумістити у собі всі три фактори. На пристроях із обмеженими ресурсами (пристроях із портативними TPU-модулями, наприклад, Google Coral або Intel Movidius):

1. Для завдань із високими вимогами до часу прогнозу найбільш ефектив-

но було б використовувати мережі найменшого розміру та найбільшою швидкістю: EfficientNetB0 та MobileNetV2, що мають найкращі результати у даних показниках.

143

2. Для завдань із невисокими вимогами до часу прогнозу найбільш ефективно було б використовувати мережі найменшого розміру та найбільшою точністю: EfficientNetB0 має найкращу комбінацію даних показників.

4.4 Сегментація легень та вилучення тіней кісток для рентгенологічного аналізу новоутворень легень за допомогою глибинного навчання
У проведеному дослідженні [30] продемонстровано ефективність сегментації легень та техніки вилучення тіней кісток для аналізу 2D рентгенограм методом глибинного навчання з метою полегшення виявлення та інтерпретації рентгенологами патологічних станів легень з ознаками захворювання на рак. Навчання та перевірка моделей проводилась на наступних наборах даних: оригінальному наборі даних JSRT (набір даних No 01), BSE-JSRT1(набір даних No 02), сегментованому JSRT (набір даних No 03) та сегментованому BSE-JSRT (набір даних No 04). Результати демонструють ефективність та користь розглянутих методів попередньої обробки знімків грудної клітки навіть у спрощеній конфігурації порівняно з необробленими знімками. Отримана модель на наборі даних без тіней кісток (набір даних No 02) демонструє кращу точність у порівнянні з точністю інших моделей на сегментованих даних (набори даних No 03 та No 04).
Сьогодні для виявлення підозрілих на рак уражень легень використовується кілька підходів скринінгу. Комп'ютерна томографія (КТ) є дуже чутливою методикою з виявлення небажаних новоутворень та дозволяє підвищити точність діагностики рентгенологів. Рентгенографію грудної клітки часто вважають застарілим медичним методом візуалізації, але стрімке використання цифрових технологій та методів ML/DL дозволяє переглянути важливість цього методу в медичній діагностиці. Наприклад, рентгенографія грудної клітки дозволяє виявляти більше різних видів кардіоторакальних уражень і є особливо чутливим до виявлення небажаних легеневих новоутворень на рентгенівських знімках. Успіх для обробки медичних даних посилюється швидким розвитком у галузі ML/DL та розвитком обчислень на GPU/TPU. Нещодавно було отримано кілька багатообіцяючих результатів у галузі діагностики захворювань легень за допомогою машинного навчання, особливо за допомогою підходів, що базуються на глибинному навчанні.

144

Як результат, нинішні платформи на базі GPU можуть обробляти сотні медичних зображень з високою роздільною здатністю в секунду. Наявність відкритих наборів даних, отриманих за допомогою КТ та рентгенографії грудної клітки, дозволяє вченим з обробки даних навчати, перевіряти та налаштовувати свої нові алгоритми для більш точної та ранньої діагностики легеневих захворювань. Поява бази даних, яка містить знімки вражених на рак легень та знімки здорових людей, запропонованої Японським товариством радіологічних технологій (Japanese Society of Radiological Technology – JSRT), відкриває цей шлях для багатьох дослідницьких груп у всьому світі [85]. Ця база даних була створена JSRT у співпраці з Японським радіологічним товариством (JRS) у 1998 році. З тих пір JSRT використовується багатьма дослідниками у світі для різних дослідницьких цілей, таких як обробка зображень, стиснення зображень, оцінка відображення зображень, автоматизована діагностика (CADx), система архівування та комунікації зображень, а також для навчання та тестування моделей. Стенфордська група машинного навчання представила модель CheXNet, яка може автоматично виявляти пневмонію з рентгенівських знімків грудної клітки на рівні, що перевищує практикуючих рентгенологів [151]. CheXNet є згортовою нейронною мережею, яка складається з 121-шару та була навчена на наборі даних ChestX-ray14. Для підвищення точності прогнозів моделі дослідники намагалися виключити ділянки, які не відносяться до легень або не представляють інтерес. Таке завдання включає сегментацію лівої та правої легеневої ділянки на стандартних 2D рентгенограмах. Нещодавно було запропоновано кілька підходів сегментації, які базуються на моделях активних фігур, моделях активного зовнішнього вигляду та методі класифікації багатороздільних пікселів. Ці методи апробовані на сегментованому наборі даних JSRT [161]. Незважаючи на те, що останнім часом було запропоновано багато нових методів застосування сегментації рентгенограм грудної клітки та MPT-зображень [162], задача сегментації ділянок легень все ще залишається викликом.

Ще один перспективний варіант для поліпшення прогнозу моделі виявляти захворювання, пов'язаний з вилученням зі знімку деяких частин тіла, які закривають легені, наприклад, ребра та ключиці. Дослідницька група з діагностики грудної клітки (Будапешт, Угорщина) надала у якості послуги для спільноти, яка займається візуалізацією медичних зображень, версію набору даних JSRT, а саме BSE-JSRT, без тіней кісток [86]. В іншому дослідженні двоступеневий ал-

145

горитм усунення тіней зі знімків CXR, спричинених кістками ребер, базувався на розмежуванні ребер за допомогою нового гібридного підходу самошаблону (self-template), а потім на придушенні цих окреслених ребер за допомогою регресійної моделі, яка враховує зміну проксимальної товщини кісток по вертикальній осі [87]. Нижче наведено додаткові відомості про набори даних, використані у нашому дослідженні.

4.4.1 Дані та методи

Метод сегментації об'єктів був застосований до таких наборів даних як JSRT та BSE-JSRT. Детально ці набори даних були розглянуті та описані у параграфі 2.1. Одним із завдань цієї роботи було перевірити різницю в ефективності застосування підходу глибокого навчання до оригінального набору даних JSRT (набір даних No 01) та до набору даних без тіней кісток BSE-JSRT (набір даних No 02).

Для сегментації легень, тобто для вирізання лівої та правої ділянки легень від серця та інших частин тіла з 2D рентгенограм грудної клітки, була застосована згортова нейронна мережа на основі UNet. UNet використовується для семантичної сегментації зображень. Ця архітектура демонструє високу точність у ряді завдань, присвячених сегментації нейрональних структур в електронно-мікроскопічних стеках, виявлення карієсу при рентгенографії прикусу тощо [21]. Нещодавно цей підхід був успішно використаний для сегментації таких наборів даних як MC та JSRT для яких були вручну підготовлені маски легень [165]. Сьогодні на практиці можна зустріти ряд модифікацій UNet, які адаптовані під особливості вирішуваної задачі та направлені на підвищення загальної продуктивності моделі сегментації: Attention U-Net [207], UNet++ [208], Unet 3+ [209] та інші. Додаткова мета проведеного дослідження полягала у вивченні впливу сегментації легень на ефективність діагностики захворювань за допомогою глибокого навчання. Дослідження цього впливу проводилось на сегментованому наборі даних JSRT (набір даних No 03) та на сегментованому наборі даних BSE-JSRT (набір

даних No 04).

146

4.4.2 Навчання та валідація моделей

Проста нейронна мережа з 4 згорткових та 2 повнозв'язних шарів була спроєктована за допомогою фреймворку TensorFlow та навчена у режимі GPU (NVIDIA Tesla K40c) на згаданих вище наборах: JSRT, BSE-JSRT, сегментованому JSRT та сегментованому BSE-JSRT. Отримані результати (рис. 4.15) чітко демонструють суттєву різницю у результатах навчання та валідації моделей на оригінальному наборі даних JSRT (набір даних No 01) та будь-якому із попередньо оброблених наборів даних: BSE-JSRT (набір даних No 02), сегментованому JSRT (набір даних No 03) або сегментованому BSE-JSRT (набір даних No 04). Незважаючи на те, що мережа на оригінальному наборі даних JSRT (крива 01 на рис. 4.15) не показує жодних ознак навчання через малий розмір рентгенограм (256 × 256 пікселів) та досить малий розмір вузликів у легенях², проте на усіх попередньо оброблених наборах даних: BSE-JSRT, сегментованому JSRT та сегментованому BSE-JSRT (криві 02, 03 та 04 на рис. 4.15) мережа має тенденцію до навчання та демонструє високу навчальну точність на рівні 87% навіть у спрощеній конфігурації.

2 Вузлики у легенях зазвичай мають розмір від 0.5 см до 3 см. Існує кілька причин, чому утворюються у легенях вузлики, наприклад через інфекцію. Неракові вузлики зазвичай не потребують лікування. Вузлики розміром понад 3 см можуть бути раковими. Лікар разом з пацієнтом розробляє план моніторингу цих вузликів і визначає, коли потрібна біопсія [210].

147

Епохи

To

чн

іс

ть

а) Точність навчання

Епохи

To

чн

іс

ть

б) Точність валідації

Епохи

В

тр

ат

и

в) Втрати навчання

Епохи

В

тр

ат

и

г) Втрати валідації

Рисунок 4.15 — Точність навчання а), точність валідації б), втрати навчання в) та втрати валідації г) на наборах даних JSRT (крива 01), BSE-JSRT (крива 02), сегментованому JSRT (крива 03) та сегментованому BSE-JSRT (крива 04) Більш ретельний аналіз отриманих результатів на навчальній та валідаційній вибірках попередньо оброблених наборів даних No 02, No 03 та No 04 на рис. 4.16 дозволяє встановити, що точність моделі на навчальній вибірці набагато вища, ніж на валідаційній. Це можна вважати явним проявом перенавчання моделі. Тим не менш, можна побачити, що модель на попередньо обробленому наборі даних без кісток (набір даних No 02) демонструє кращу точність порівняно з іншими попередньо обробленими наборами даних з урахуванням сегментації легень (набори даних No 03 та No 04).

148

Епохи

To

чн

іс

ть

а) Точність навчання

Епохи

То

чн

іс

ть

б) Точність валідації

Епохи

В

тр

ат

и

в) Втрати навчання

Епохи

В

тр

ат

и

г) Втрати валідації

Рисунок 4.16 — Точність навчання а), точність валідації б), втрати навчання в) та втрати валідації г) на наборах даних BSE-JSRT (крива 02), сегментованому JSRT (крива 03) та сегментованому BSE-JSRT (крива 04)

Подальший потенціал для покращення моделі полягає у збільшенні навчального набору даних та роздільної здатності зображень, а саме:

– збільшення розміру зображень від поточних значень 256×256 до

1024×1024 (набір даних ChestXRy) та 2048×2048 (набір даних JSRT)

– збільшення кількості зображень від поточних 247 (набір даних JSRT і BSE-JSRT) до > 1000 (набір даних MC) та > 100 000 (набір даних ChestXRy)

– розширення (augmentation) даних враховуючи перетворення з втратами та без втрат [28].

Набагато більший прогрес може бути досягнутий завдяки інтеграції подібних наборів даних з різних лікарень, які розташовані у різних куточках планети в дусі відкритих наукових даних, збору даних волонтерами, обробки даних та обчислень [203]. У підсумку, отримані результати демонструють, що розглянуті

149

методи попередньої обробки даних дозволяють покращити ефективність моделі виявляти патологічні стани легень навіть у спрощеній конфігурації. Додатковий потенціал покращення ефективності моделі може бути пов'язаний із вдосконаленням алгоритмів попередньої обробки для:

– сегментації легень на основі більших наборів даних

– вилученням тіней кісток на основі складніших технік семантичної сегментації, що застосовуються не тільки до легень і частин тіла поза ними (наприклад, серця, рук тощо), але також до ребер і ключиць

– збільшення розміру та складності мережі глибинного навчання від поточного мініатюрного розміру 4+2 шарів до > 100 шарів, як у нинішніх найбільш точних мережах, таких як CheXNet, що використовується для діагностики одразу 14 патологічних станів легень [151].

4.4.3 Час навчання моделі та прискорення

Вибір мережі для навчання був мотивований простотою проєктування і використання, а також незначним часом навчання, щоб дослідити ефект сегментації та вилучення тіней кісток в спрощеній конфігурації без акценту на якомога більшу точність та менші втрати моделі (це буде досліджено в подальшому). Для виконання поставлених завдань була використана мережа, яка складалась лише з 7 двовимірних згорткових шарів, навчених на згаданих вище наборах: JSRT, BSE-JSRT, сегментованому JSRT та сегментованому BSE-JSRT. Численні тести були проведені для визначення часу навчання (рис. 4.17) та прискорення (рис. 4.18) моделі для зображень різного розміру та навчальних пакетів у таких режимах: “single-CPU” (1 ядро Intel i7), “multi-CPU” (8 ядер Intel i7), а також в режимі “GPU” на графічному процесорі NVIDIA Tesla K40c.

150

а) CPU б) GPU

Рисунок 4.17 — Час навчання моделі у режимах CPU а) та GPU б) для різних розмірів пакету та різних розмірів зображень

а) Час навчання б) Прискорення

Рисунок 4.18 — Час навчання моделі а) та прискорення б) для різних розмірів зображень та режимів

Отримані результати продемонстрували максимальне прискорення в 3.0 рази у режимі багатопроцесорного процесора та в 9.5 разів у режимі графічного процесора для зображень розміром 1024×1024 пікселів та розміру пакету 8 зображень. Ці результати дозволили оцінити реалістичні сценарії застосування на практиці таких технік як сегментація та вилучення тіней кісток. Зрештою, зображення розміром 256×256 пікселів були обрані для навчання моделі та подальшого

151

представлення результатів дослідження. Результати використання більш складних моделей та зображень більшого розміру опубліковані у роботі [31].

4.5 Вплив доповнення даних та сегментації на автоматизовану

інтерпретацію рентгенограм грудної клітки при захворюваннях легень

У ході цього дослідження [31] було підтверджено важливість попередньої обробки даних для підвищення точності систем автоматизованої діагностики захворювань легень на основі глибокого навчання. Для експериментів використовувався набір даних CheXpert, який містить понад 224 тис. рентгенограм грудної клітки для 65 240 пацієнтів з мітками, які охоплюють 14 діагностичних категорій (патології та відсутність відхилень). У роботі застосовувалася версія (CheXpert-v1.0-small), де всі зображення приведені до єдиного розміру 320×320 пікселів. Навчальна вибірка налічувала понад 200 тис. зображень, валідаційна – 234 знімки від 200 пацієнтів, тестова – 500 досліджень від різних пацієнтів. На рисунку 4.19 наведено приклад оригінального зображення з набору CheXpert та його сегментовану версію.

Рисунок 4.19 — Оригінальне зображення з CheXpert (ліворуч) та його сегментоване зображення (праворуч)

Попередньо проведені дослідження продемонстрували ефективність окремих методів обробки даних, таких як сегментація легень, вилучення тіней кісток та використання t-розподіленого стохастичного вкладення сусідів (t-SNE) для вилучення аномалій на невеликих наборах (< 103 зображень) при аналізі рентгенограм грудної клітки (CXR) з метою виявлення ознак раку легень та туберкульозу [26], [28], [30]. У даному дослідженні для підвищення якості аналізу CXR-

152

зображень були застосовані деякі з цих методів, зокрема сегментація легень та розширення (аугментація) даних. Сегментацію легень виконували автоматично за допомогою попередньо навченої моделі [26], [28], [30], побудованої на основі архітектури U-Net [21], для всього набору CheXpert. Аугментація включала випадкові перетворення зображень: горизонтальне й вертикальне віддзеркалення, обертання до 5° , варіації кольору, масштабоване кадрування (із коефіцієнтами 0.9-1.0 за масштабом та 0.9-1.1 за співвідношенням сторін), а також перспективні спотворення (scale = 0.1).

У роботі використано модель глибокого навчання з архітектурою згортової нейронної мережі DenseNet121 [155], яка, згідно з результатами попередніх досліджень, забезпечувала найвищі показники ефективності серед аналогічних архітектур [47]. Вхідні зображення масштабувалися до розміру 320×320 пікселів. Навчання здійснювалося із застосуванням оптимізатора Adam з параметрами $\beta_1 = 0.9$, $\beta_2 = 0.999$ та сталою швидкістю навчання 10

–4. Розмір мініпакета

складав 32 зображення. Для обробки випадків наявності невизначених міток усі такі мітки було замінено на «1» (наявність патології, підхід U-Ones) [47].

4.5.1 Результати експериментального дослідження

Модель навчалася на графічному процесорі NVIDIA Titan 1080 із використанням фреймворку машинного навчання TensorFlow [211] для таких варіантів даних: оригінальний набір (O), сегментований набір (S), оригінальний набір із застосуванням аугментації (OA) та сегментований набір із застосуванням аугментації (SA). Навчання проводилося протягом 3 епох (для O та S) та 18 епох (для OA та SA) з контролем результатів кожні 2240 ітерацій та обчисленням функцій втрат для навчальної і валідаційної вибірок. На кожному контрольному етапі модель зберігалася лише у випадку, коли поточна валідаційна втрата була меншою за мінімальне значення втрати на попередніх етапах. Для моделі з мінімальною валідаційною втратою було побудовано ROC-криві для всіх 14 патологій груд-3 Геометричні зміни об'єкта на зображенні, що виникають через кут огляду або відстань камери, які можуть змінювати пропорції та форму об'єкта.

4 Крива ROC (Receiver Operating Characteristic) відображає ефективність моделі класифікації на всьому діапазоні порогових значень, показуючи залежність між чутливістю (True Positive Rate, TPR) та часткою хибнопозитивних

результатів (False Positive Rate, FPR).

153

ної клітки (перелічених у табл. 4.4, стовпець «Pathologies»), після чого обчислено площі під кривими (AUC).

Таблиця 4.4 — Значення AUC для моделей, навчених із використанням різних підходів. Значення у дужках отримані після додаткового навчання протягом 15 епох (2-й / 3-й запуск)

Pathology O OA (+15 epochs) S SA (+15 epochs)

No Findings 0.82 0.86 (0.88/0.88) 0.83 0.86 (0.84/0.83)

Enlarged Cardiomegaly 0.64 0.63 (0.65/0.59) 0.50 0.56 (0.60/0.61)

Cardiomegaly 0.82 0.84 (0.88/0.86) 0.76 0.81 (0.85/0.81)

Lung Opacity 0.66 0.73 (0.72/0.75) 0.70 0.69 (0.69/0.72)

Lung Lesion 0.77 0.79 (0.76/0.83) 0.68 0.79 (0.78/0.77)

Edema 0.82 0.85 (0.82/0.87) 0.81 0.84 (0.87/0.84)

Consolidation 0.65 0.67 (0.66/0.69) 0.68 0.67 (0.69/0.66)

Pneumonia 0.71 0.70 (0.71/0.81) 0.69 0.68 (0.69/0.71)

Atelectasis 0.67 0.68 (0.71/0.72) 0.64 0.66 (0.71/0.72)

Pneumothorax 0.75 0.83 (0.79/0.80) 0.74 0.71 (0.77/0.79)

Pleural Effusion 0.81 0.84 (0.86/0.85) 0.78 0.83 (0.81/0.81)

Pleural Other 0.75 0.70 (0.79/0.84) 0.79 0.69 (0.74/0.79)

Fracture 0.76 0.83 (0.71/0.86) 0.71 0.63 (0.71/0.65)

Support Devices 0.88 0.85 (0.88/0.89) 0.80 0.82 (0.84/0.83)

mAUC (mean AUC) 0.75 0.77 (0.77/0.80) 0.72 0.73 (0.76/0.75)

Оригінальний набір даних. Значення AUC (Табл. 4.4, стовпець O) показують, що для деяких патологій (No Finding, Cardiomegaly, Edema, Pleural Effusion, Support Devices) можна передбачити з вищою ефективністю (AUC > 0.80) у порівнянні з іншими (Enlarged Cardiomegaly, Lung Opacity, Consolidation, Atelectasis), для яких ефективність є значно нижчою (AUC < 0.70).

Сегментований набір даних. Значення AUC (Табл. 4.4, стовпець S) демонструють розділення патологій на три групи: із високим, середнім та низьким рівнем точності прогнозування. Порівняно з моделлю, навченою на оригінальному наборі даних, зростання значень AUC спостерігається лише для 4 із 14 патологій (No Finding, Lung Opacity, Consolidation, Pleural Other), тоді як для 10 інших патологій відбулося зниження точності.

154

Рисунок 4.20 — ROC-криві та значення AUC для моделі, навченої на оригінальному наборі даних із застосуванням аугментації (OA). По вертикальній осі відкладено значення показника істиннопозитивних результатів (True Positive Rate, TPR), а по горизонтальній — частку хибнопозитивних результатів (False Positive Rate, FPR). Кольорові точки (в електронній версії) відображають дані трьох експертів радіологів (Rad1, Rad2, Rad3) та їхню більшість голосів (RadMaj) для порівняння за відповідними захворюваннями [47]

Оригінальний набір даних із застосуванням аугментації. Порівняно з моделлю, навченою на оригінальному наборі даних, спостерігається зростання значень AUC (Рис. 4.20; Табл. 4.4, стовпець OA) майже для всіх патологій (10 із 14), за винятком Enlarged Cardiomegaly, Pneumonia, Pleural Other та Support

155

Devices. Водночас слід зазначити, що додаткове навчання протягом 15 епох призвело до підвищення значень AUC для всіх патологій (вони наведені в дужках у стовпці OA, Табл. 4.4). У підсумку, використання OA дозволило покращити AUC для 14 патологій із 14.

Сегментований набір даних із застосуванням аугментації. Порівняно з моделлю, навченою на оригінальному наборі даних, спостерігалось зростання значень AUC (Табл. 4.4, стовпець SA) для деяких патологій (6 із 14), а саме для No Finding, Lung Opacity, Lung Lesion, Edema, Consolidation та Pleural Effusion. Додаткове навчання протягом 15 епох призвело до підвищення значень AUC (вони наведені в дужках у стовпці SA, Табл. 4.4) ще для 4 патологій: Cardiomegaly, Atelectasis, Pneumothorax та Pleural Other. У підсумку, використання SA дозволило покращити AUC для 10 патологій із 14.

4.5.2 Аналіз та оцінювання результатів

Отримані результати підсумовано в таблиці 4.4 та виділено різними кольорами: найвищі значення AUC після 3 епох навчання — чорним напівжирним шрифтом, найвищі значення AUC після 18 епох навчання — червоним напівжирним шрифтом, а найнижчі значення AUC — синім. Значення AUC у дужках відповіда-

ють різним запуском та ілюструють розкид результатів. Результати свідчать про різний вплив сегментації та аугментації даних на ефективність автоматизованої інтерпретації рентгенограм грудної клітки. Застосовані методи дозволяють підвищити значення AUC для всіх патологій, однак найбільший приріст спостерігається завдяки аугментації оригінального набору даних (OA). При цьому досягається продуктивність, що є близькою або співставною з результатами експертних радіологів (Rad1, Rad2, Rad3, RadMaj на рис. 4.20), навіть для зображень відносно невеликої роздільної здатності (320 × 320 пікселів). Цей ефект проявляється у переважанні чорних напівжирних значень AUC (після 3 епох) та червоних напівжирних значень (після 18 епох) у стовпці OA (табл. 4.4).

Натомість сегментація переважно призводить до зниження значень AUC майже для всіх патологій, що підтверджується переважанням значень позначених синім кольором у стовпцях S та SA (табл. 4.4). Для великого набору CheXpert ці результати відрізняються від наших попередніх спостережень на дуже малих вибірках (662 зображення), де сегментація та аугментація покращували точність

156

прогнозування легневих захворювань [28], [30]. Це свідчить про те, що завдяки зменшенню кількості нерелевантних ознак (шляхом усунення ділянок поза легеньми) сегментація є корисною переважно для невеликих наборів даних. Водночас для великих наборів її внесок вже не є критичним, оскільки подібні нерелевантні ознаки нівелюються під час обробки значної кількості зображень. Водночас методи аугментації даних залишаються важливими, оскільки відтворюють варіативність умов отримання зображень (різні кути, невеликі спотворення, масштабування тощо). Однак для великих рентгенівських наборів, таких як CheXpert, особливого значення набуває ретельне дослідження особливостей аугментації з метою визначення оптимального набору гіперпараметрів (кутів, масштабів тощо).

Слід відзначити, що значна варіативність значень AUC для окремих патологій на одній і тій самій валідаційній вибірці після різних навчальних запусків (табл. 4.4) залишається серйозним викликом для практичного застосування розглянутих методів та моделей у медицині. Це особливо актуально з огляду на високу індивідуальну мінливість морфології та фізіології легень у пацієнтів різного віку, статі, географічного походження, умовами професійної діяльності, станом здоров'я та іншими факторами. У цьому контексті суттєвого прогресу можна очікувати завдяки подальшому обміну подібними наборами даних на глобальному рівні у душі відкритої науки, залученню волонтерів до збору та обробки даних, а також колективному використанню обчислювальних ресурсів [203], [205].

4.6 Аналіз результатів застосування ансамблю опорних моделей у федеративному навчанні

У цьому дослідженні розглядаються конфігурації ансамблю з кількома базовими архітектурами нейронних мереж як альтернатива існуючим підходам, що ґрунтуються на збільшенні глибини моделей у федеративному навчанні. У дослідженні оцінюються ефективності ансамблю, де кілька паралельних базових моделей проходять синхронне навчання з подальшою агрегацією прогнозів для підвищення точності та ефективності. Така стратегія, орієнтована на збільшення ширини, протиставляється звичним архітектурам, орієнтованим на збільшення глибини, особливо у застосуваннях федеративного навчання.

Підхід ансамблю з кількома базовими архітектурами нейронних мереж має особливе значення для систем штучного інтелекту з обмеженими ресурсами. За-

157

вдяки розподілу обчислень між паралельними базовими архітектурами метод підвищує швидкість і точність інференсу за рахунок паралелізму, зберігаючи при цьому керовані розміри та складність моделі. Це робить його особливо придатним для розгортання на периферійних пристроях із обмеженими обчислювальними можливостями.

Метою цього дослідження є підвищення продуктивності глибоких нейронних мереж у федеративному навчанні шляхом використання ансамблю з кількома базовими архітектурами. У роботі вивчаються різні конфігурації ансамблю на основі сімейства компактних глибоких нейронних мереж LCNet з метою перевірки їхньої придатності для розгортання у федеративному навчанні на периферійних пристроях з обмеженою обчислювальною потужністю. Реалізовано стандартний робочий процес класифікації у глибокому навчанні з використанням набору даних CIFAR-100, при цьому основну увагу зосереджено на визначенні впливу ансамблю моделей на показники продуктивності.

Основні параметри FedAvg та їхні типові конфігурації у фреймворку Flower подано з детальним поясненням в таблиці 4.5.

Датасет. У експериментах використовувався набір даних CIFAR-100, який складається з 60 000 невеликих зображень розміром 32×32 пікселів і часто застосовується для тестування широкого спектра алгоритмів комп'ютерного зору, машинного та глибокого навчання [198]. У цьому федеративному налаштуванні дані були незалежно і однаково розподілені (IID) між клієнтами з рівномірним розподілом класів, де кожен клієнт має приблизно однакову пропорцію всіх класів, а також зі збалансованим обсягом даних, тобто клієнти мають подібну кількість зразків.

Гіперпараметри та метрики. Моделі глибоких нейронних мереж були ініціалізовані вагами, попередньо навченими на наборі даних ImageNet [16], а потім навчалися протягом 100 епох із використанням оптимізатора Adam [212]. Гіперпараметри Adam включали швидкість навчання 0.001, коефіцієнти експоненційного згасання 0.9 і 0.99 для оцінок першого та другого моментів відповідно, а також константу $\epsilon = 10^{-7}$. Під час етапів навчання та валідації всього робочого процесу оцінювалися наступні стандартні метрики: втрати на валідаційній вибірці (validation loss) та точність на валідаційній вибірці (validation accuracy). Централізовані метрики оцінювалися на відкладеній валідаційній вибірці, тоді як фе-

158

Таблиця 4.5 — Основні параметри FedAvg у фреймворку Flower та їхні значення, використані в експериментах

Параметр	Значення	Опис
<code>num_server_rounds</code>	20	Загальна кількість раундів федеративного навчання між сервером і клієнтами.
<code>local_epochs</code>	1, 10, 100	Число епох локального навчання клієнта в межах одного раунду.
<code>batch_size</code>	32, 512, 8192	Кількість прикладів, які клієнт обробляє перед оновленням локальних параметрів моделі.
<code>fraction_fit</code>	1.0	Частка (0, 1] доступних клієнтів, обраних для навчання в кожному раунді.
<code>fraction_evaluate</code>	1.0	Частка (0, 1] доступних клієнтів, обраних для оцінювання в кожному раунді.
<code>num-supernodes</code>	10	Число віртуальних клієнтів.
		деративні метрики обчислюються шляхом агрегування локальних оцінок клієнтів.

4.6.1 Отримані результати

Модель-орієнтир у федеративному навчанні

Вплив розміру пакета даних на продуктивність. Вплив розміру пакета (N_b) на продуктивність моделі було систематично оцінено для архітектури LCNet050 з кількістю базових мереж $NMB = 1$ для $N_b \in \{32, 512, 8192\}$. Як показано на рисунку 4.21, менші розміри пакетів демонстрували кращі властивості збіжності. Найвища точність на валідаційній вибірці (рис. 4.21б) та найменша втрата на валідаційній вибірці (рис. 4.21а) спостерігалися для $N_b = 32$.

159

а) б)

Рисунок 4.21 — Динаміка зміни валідаційних втрат а) та точності б) LCNet050 ($NMB = 1$) для різних розмірів пакету $N_b \in \{32, 512, 8192\}$

Вплив ємності (версії) моделі на продуктивність. Вплив ємності моделі на її продуктивність було систематично оцінено для базових версій ($NMB = 1$) архітектур LCNet (зокрема, LCNet050, LCNet075, LCNet100, LCNet150, LCNet200, LCNet250) для $N_b \in \{512\}$. Це значення було обрано для дослідження ефекту, а не для пошуку абсолютно найкращої моделі (рис. 4.22). Як показано на рисунку 4.22, спостерігається сталий розрив у продуктивності між метриками централізованої валідації та метриками федеративного навчання з тенденцією до значно швидшого навчання для версій із більшою ємністю.

160

а) б)

в) г)

Рисунок 4.22 — Типові криві валідаційних втрат (а, б) та валідаційної точності (в, г) для різних версій архітектури LCNet [195], [213] з кількістю опорних моделей $NMB = 1$ для розміру пакету $N_b = 512$. Графіки (а, в) відображають результати для метрик централізованої валідації, а (б, г) — для метрик федеративного навчання. У легенді наведено суфікси для версій LCNet. Опорні моделі в налаштуванні федеративного навчання

Вплив кількості опорних моделей на продуктивність. У цій частині дослідження оцінювався вплив кількості опорних моделей на продуктивність для архітектур з $NMB \in \{1, 2, 4, 8\}$ опорними моделями (див. рис. 4.23). Збільшення кількості опорних моделей («ширина моделі») призводить до подібного ефекту на продуктивність, як і збільшення версії моделі (ємності) (див. рис. 4.22). Для кожного раунду (включно до четвертого) спостерігаються найвищі значення валідаційної точності для моделі з найбільшою кількістю опорних моделей. У наступних раундах спостерігається та сама тенденція, проте не всі експерименти з нав-

161

чання для більших моделей були можливі через обмеженість пам'яті під час цих симуляцій федеративного навчання.

а) б)

Рисунок 4.23 — Типові криві валідаційних втрат а) та валідаційної точності б) для архітектури LCNet050 [195], [213] з різною кількістю опорних моделей $NMB \in \{1, 2, 4, 8\}$ для розміру пакету $Nb = 32$

Вплив кількості опорних моделей та локальних епох на продуктивність. Зазвичай для моделей із однією опорною моделлю менші значення локальних епох супроводжуються менш ретельною локальною оптимізацією і можуть вимагати більшої кількості загальних раундів для збіжності. Крім того, менші значення локальних епох можуть спричиняти сильні ефекти усереднення у багатопорних моделях. Таким чином слід перевірити, як кількість опорних моделей та локальних епох впливає на кінцеву продуктивність (див. рис. 4.24).

162

а) б)

Рисунок 4.24 — Типові криві валідаційних втрат а) та валідаційної точності б) для архітектури LCNet050 [195], [213] з різною кількістю опорних моделей $NMB \in \{1, 2, 4\}$, кількістю локальних епох $Nle \in \{1, 10, 100\}$ для розміру пакету $Nb = 32$

4.6.2 Аналіз результатів дослідження

Аналіз результатів, представлених на рисунку 4.24 та в таблиці 4.6 показав, що валідаційні втрати (рис. 4.24 а) та точність (рис. 4.24 б) для архітектури LCNet050 демонструють подібну тенденцію при збільшенні кількості опорних моделей NMB та локальних епох Nle , як і при зростанні версії моделі (ємності) (рис. 4.22). Збільшення числа локальних епох Nle сприяє досягненню вищих значень валідаційної точності для всіх розглянутих конфігурацій NMB та Nle . Найбільша різниця між спостережуваними значеннями валідаційної точності складає 4.2 %: для багатопорної моделі (МВЕ) при $NMB = 4$ вона становить 0.4825, тоді як для однієї опорної моделі $NMB = 1$ – 0.4405, за однакової кількості локальних епох $Nle = 100$.

Для найбільшої багатопорної моделі $NMB = 4$ різниця між найвищим спостережуваним значенням валідаційної точності для максимальної кількості локальних епох (0.4825 для $Nle = 100$) та для мінімальної кількості локальних епох (0.3486 для $Nle = 1$ є значно більшою і становить 13.39%. Для проміжної багатопорної моделі ($NMB = 2$) різниця між 0.4675 та 0.4175 значно менша і дорівнює 5%. Для моделі $NMB = 1$ різниця між значенням валідаційної точності при максимальній кількості локальних епох (0.4405 для $Nle = 100$) та мінімальній кількості локальних епох (0.4216 для $Nle = 1$) також невелика і становить

163

Таблиця 4.6 — Максимальні значення точності досягнуті для різної кількості локальних епох Nle та кількості опорних моделей NMB . Жирним шрифтом виділено максимальне значення точності для конкретного Nle серед усіх розглянутих опорних моделей NMB

Локальні епохи (Nle) Кількість опорних моделей (NMB)

1 2 4

1 0.4216 0.4175 0.3486

10 0.4447 0.4506 0.4603

100 0.4405a 0.4675 0.4825

а Отримане значення відповідає проміжному етапу навчання, коли через обмеженість пам'яті завершення стадії насичення не було можливим.

1.89%. Це свідчить про те, що моделі з кількома базовими архітектурами через вищу варіативність траєкторій навчання між опорними моделями значно більш чутливі до процедур усереднення після кожного раунду FedAvg. При більш частих раундах FedAvg відмінності між їхніми вагами зменшуються, а варіативність траєкторій навчання між опорними моделями зникає, що призводить до зниження

продуктивності.

4.7 Аналіз результатів застосування генеративної аугментації даних методом дистилляції набору даних

4.7.1 Синтезовані та реконструйовані зображення

Результати дистилляції набору даних для CIFAR-10 (рис. 4.25) та CIFAR-100 показують, що синтетичні зображення ефективно фіксують специфічну для класу інформацію навіть за високого ступеня стиснення. Синтезовані та реконструйовані візуалізації для 1 зображення на клас (IPC) (рис. 4.25а) та 4.25б) демонструють нечіткі, але впізнавані представлення. Наприклад, зліва направо: птах (1-й), автомобіль (2-й), птах (3-й), кіт (4-й), олень (5-й), собака (6-й) тощо для CIFAR-10 (рис. 4.25). Це свідчить про те, що процес оптимізації ефективно виокремлює ключові ознаки для розпізнавання. Оскільки завдання обмежене єдиним синтетичним IPC, модель змушена стискати суттєву інформацію в лише одне пред-

164

ставлення. Коли ж це обмеження послаблюється, дозволяючи кілька синтетичних IPC (наприклад, 10 IPC), процес оптимізації розподіляє ознаки класу між кількома зразками. Це призводить до формування більш різноманітного та структурованого набору синтетичних зображень (рис. 4.25в) та 4.25г). Наприклад, замість єдиного стисненого представлення набір даних містить різноманітні приклади об'єктів у межах класу. Цей результат підкреслює, що дистилляція набору даних вирає від збільшення кількості синтетичних зразків на клас, оскільки це дозволяє моделі краще апроксимувати реальну різноманітність даних, зберігаючи при цьому компактний розмір набору. Отримані результати підтверджують ефективність дистилляції набору даних для генерації високоінформативних та виразних синтетичних наборів даних, які потребують значно меншого обсягу пам'яті для зберігання порівняно з оригінальним набором даних.

а) б)

в) г)

Рисунок 4.25 — Приклади синтезованих (ліворуч) та реконструйованих (праворуч) зображень із набору даних CIFAR-10 для різної кількості зображень на клас: 1 (а, б) та 10 (в, г)

Для специфічних медичних наборів даних із колекції MedMNIST (зокрема PathMNIST) (рис. 4.26) синтезовані та реконструйовані зображення виявилися менш розпізнаваними навіть за високих значень IPC. Це пояснюється специ-

165

фічністю та складністю візуальних патернів окремих патологій, що ускладнює їх компактне кодування порівняно зі стандартними наборами природних зображень.

а) б)

в) г)

Рисунок 4.26 — Приклади синтезованих (ліворуч) та реконструйованих (праворуч) зображень із набору даних PathMNIST для різної кількості зображень на клас: 1 (а, б) та 10 (в, г)

4.7.2 Вплив на ефективність моделі кількості дистильованих зображень на клас для наборів даних CIFAR

У цій частині дослідження було проведено 5 випробувань навчання на дистильованому наборі даних для різних значень IPC (від 1 до 10000) з метою оцінити вплив кількості IPC на фактичну продуктивність моделі. Насичення (тобто вихід точності на валідаційній вибірці на плато) спостерігалось за різної кількості епох. Наприклад, для набору даних CIFAR-10 (рис. 4.27) для IPC від 1 до 100 – до 5000 епох; для IPC від 1000 до 2000 – до 1000 епох; для IPC від 4000 до 5000 – до 500 епох; для IPC 10000 – до 120 епох.

166

Рисунок 4.27 — Набір даних CIFAR-10. Точність на валідаційній вибірці залежно від кількості епох, де легенда містить значення дистильованої кількості зображень на клас (IPC) (ліворуч) та максимальна точність на валідаційній вибірці залежно від IPC (праворуч), де легенда також містить порівняльні значення з роботи [22]. Похибки на графіку відображають стандартні відхилення точності за результатами 5 випробувань

CIFAR-10. Для кожного значення IPC (від 1 до 10000 для CIFAR-10) максимальні значення точності на валідаційній вибірці були нанесені на графік залежно від значень IPC (рис. 4.27, праворуч). Варто зазначити, що навчання на значеннях IPC від 1 до 50 (які використовувалися в [22]) дає однакові результати щодо максимального значення точності на валідаційній вибірці, отриманого усередненням за 5 випробуваннями після кількості епох, за якої спостерігалось

насичення точності. Більше того, після певного значення IPC (у цьому випадку – 4000) максимальна точність ($0,879 \pm 0,001$) стає вищою за точність, отриману після навчання на повному оригінальному наборі даних ($0,848 \pm 0,001$) (позначено символом «+» на рис. 4.27, праворуч). Тут символ «+» відповідає значенню IPC (5000) для повного набору даних, проте покращення, що перевищує стандартне відхилення ($0,001$), спостерігалось вже для меншого значення IPC, що дорівнює 4000. Це означає, що дистильована версія набору даних CIFAR-10 із 40000 навчальних прикладів може забезпечити кращу точність, ніж оригінальна версія набору даних CIFAR-10 із 50000 навчальних прикладів. Для CIFAR-10 загальне по-

167

кращення точності на валідаційній вибірці за рахунок дистилляції набору даних (DD) становить понад $3,1 \pm 0,1\%$ (табл. 4.7).

CIFAR-100. Аналогічно, для набору даних CIFAR-100 після певного значення IPC (у цьому випадку – 400) максимальна точність ($0,591 \pm 0,003$) перевищує точність, отриману після навчання на повному оригінальному наборі даних ($0,562 \pm 0,003$) (позначено символом «+» на рис. 4.28, праворуч). Символ «+» тут відповідає значенню IPC (500) для повного набору даних, проте покращення, що перевищує стандартне відхилення ($0,003$), спостерігалось вже для меншого значення IPC, яке дорівнює 400. Це також свідчить про те, що дистильована версія набору даних CIFAR-100 із 40000 навчальних прикладів здатна забезпечити вищу точність порівняно з оригінальною версією набору даних CIFAR-100 із 50000 навчальних прикладів. Для CIFAR-100 загальне підвищення точності на валідаційній вибірці за рахунок дистилляції набору даних (DD) становить понад $2,9 \pm 0,3\%$ (табл. 4.7).

Рисунок 4.28 — Набір даних CIFAR-100. Точність на валідаційній вибірці залежно від кількості епох, де легенда містить значення дистильованої кількості зображень на клас (IPC) (ліворуч) та максимальна точність на валідаційній вибірці залежно від IPC (праворуч), де легенда також містить порівняльні значення з роботи [22]. Похибки на графіку відображають стандартні відхилення точності за результатами 5 випробувань

168

Таблиця 4.7 — Максимальні значення точності на валідаційній вибірці для збалансованих наборів даних CIFAR

Експеримент CIFAR-10 CIFAR-100

DD, повний оригінальний набір даних [22] $0,848 \pm 0,001$ $0,562 \pm 0,003$

Наш метод, дистильований менший набір даних (рис. 4.27, 4.28) $0,879 \pm 0,001$ $0,591 \pm 0,003$

Загалом, використання DD для наборів даних CIFAR-10 та CIFAR-100 у межах методу генеративної аугментації даних шляхом дистилляції набору даних (GDADD) дає змогу застосовувати менші синтетичні набори даних (40000 зображень) замість більших оригінальних наборів (50000 зображень), забезпечуючи при цьому підвищення точності приблизно на $3 \pm 0,3\%$.

4.7.3 Вплив на ефективність моделі кількості дистильованих зображень на клас для наборів даних MedMNIST

Варто зазначити, що наведені вище результати стосуються стандартних (класичних) наборів даних, а їхня потенційна практична цінність має бути перевірена на більш специфічних наборах даних, які точніше відображають реальні умови застосування. Для цієї мети було використано медичні еталонні набори даних із колекції MedMNIST [201], [202].

PathMNIST. У цьому дослідженні підвищення точності класифікації було отримано для спроектованої згортової нейронної мережі (ConvNet), а результати порівняно з раніше опублікованими даними [201], [202], отриманими для різних інших методів, зокрема ResNet-18, ResNet-50, auto-sklearn, AutoKeras та Google AutoML Vision (рис. 4.29).

169

Рисунок 4.29 — Набір даних PathMNIST. Точність на валідаційній вибірці залежно від кількості епох, де легенда містить значення дистильованої кількості зображень на клас (IPC) (ліворуч) та максимальна точність на валідаційній вибірці залежно від IPC (праворуч), де легенда містить значення для порівняння з [201], [202]. Похибки на графіку відображають стандартні відхилення точності за результатами 5 випробувань

Після певного значення IPC (у цьому випадку – 100) максимальні значення точності, отримані методом GDADD на меншій синтетичній версії набору даних PathMNIST, поступово перевищують значення точності, отримані згаданими вище методами на повному оригінальному наборі даних PathMNIST. Після певного

значення IPC (у цьому випадку – 10000) максимальна точність ($0,917 \pm 0,003$) стає вищою за найкращу точність, отриману після навчання ResNet-50 на повному оригінальному наборі даних (0,911) (позначено символом «·» на рис. 4.29, праворуч). Символ «·» на графіку позначає точність ResNet-50, отриману на повному наборі даних, розміщену на позначці $IPC = 10000$ для зручності порівняння. При цьому перевищення цієї базової точності (на межі стандартного відхилення 0,003) було досягнуто дистильованою версією набору даних саме за такого самого значення $IPC = 10000$. Знову ж таки, це означає, що дистильована версія набору даних PathMNIST із 90000 навчальних прикладів здатна забезпечити дещо вищу ефективність порівняно з оригінальною версією набору даних PathMNIST із тими самими 90000 навчальними прикладами. Для PathMNIST загальне підвищення точності на валідаційній вибірці за рахунок дистилляції набору даних (DD)

170

становить понад $0,6 \pm 0,3\%$ (табл. 4.8). Порівняно з добре збалансованими CIFAR-10/CIFAR-100, це покращення менше, що можна пояснити дещо незбалансованим розподілом зображень між класами в PathMNIST.

DermaMNIST. Тут незначне підвищення точності спостерігалось зі зростанням IPC, і воно було меншим порівняно з раніше опублікованими результатами [201], [202], отриманими для різних інших методів, зокрема ResNet-18, ResNet-50, auto-sklearn, AutoKeras та Google AutoMLVision (рис. 4.30). Порівняно з добре збалансованими наборами даних CIFAR-10/CIFAR-100 та незначно незбалансованим набором даних PathMNIST, навіть це покращення значно менше, що, знову ж таки, можна пояснити дисбалансом розподілу зображень між класами.

Рисунок 4.30 — Набір даних DermaMNIST. Точність на валідаційній вибірці залежно від кількості епох, де легенда містить значення дистильованої кількості зображень на клас (IPC) (ліворуч) та максимальна точність на валідаційній вибірці залежно від IPC (праворуч), де легенда містить значення для порівняння з [201], [202]. Похибки на графіку відображають стандартні відхилення точності за результатами 5 випробувань

RetinaMNIST. Цей набір даних подібний до DermaMNIST за незбалансованим розподілом зображень між класами та незначним підвищенням точності зі зростанням IPC, яке також є меншим порівняно з раніше опублікованими результатами [201], [202], отриманими для різних інших методів, зокрема ResNet-18, ResNet-50, auto-sklearn, AutoKeras та Google AutoML Vision (рис. 4.31).

171

Для незначно незбалансованого (PathMNIST) та значно незбалансованих (DermaMNIST, RetinaMNIST) наборів даних вплив GDADD на максимальні значення точності на валідаційній вибірці узагальнено в табл. 4.8.

Рисунок 4.31 — Набір даних RetinaMNIST. Точність на валідаційній вибірці залежно від кількості епох, де легенда містить значення дистильованої кількості зображень на клас (IPC) (ліворуч) та максимальна точність на валідаційній вибірці залежно від IPC (праворуч), де легенда містить значення для порівняння з [201], [202]. Похибки на графіку відображають стандартні відхилення точності за результатами 5 випробувань

Таблиця 4.8 — Максимальні значення точності на валідаційній вибірці для датасету зі слабким дисбалансом класів (PathMNIST) та датасетів із вираженим дисбалансом класів (DermaMNIST, RetinaMNIST)

Модель

Слабкий Виражений

PathMNIST DermaMNIST RetinaMNIST

ResNet-18 (28) 0.907 0.735 0.524

ResNet-50 (28) 0.911 0.735 0.528

auto-sklearn 0.716 0.719 0.515

AutoKeras 0.834 0.749 0.503

Google AutoML Vision 0.728 0.768 0.531

Наш метод (GDADD) (рис. 4.29, 4.30, 4.31) 0.917 ± 0.003 0.655 ± 0.009 0.440 ± 0.020

172

4.7.4 Аналіз результатів дослідження

Для кожного набору даних (синтетичного та оригінального) було обчислено глобальний максимум точності на валідаційній вибірці за всіма значеннями IPC. Отримані максимальні значення точності було нанесено на графік відповідно до значень IPC, за яких вони спостерігалися (рис. 4.32).

Рисунок 4.32 — Порівняння загальної максимальної точності на валідаційній вибірці залежно від значення IPC, де легенда містить значення для порівняння

з [22] та [201], [202]. Похибки на графіку відображають стандартні відхилення точності за результатами 5 випробувань

Варто зазначити, що загальні максимальні значення точності на валідаційній вибірці для синтетичних версій наборів даних (незафарбовані символи на рис. 4.32) вирівнюються вздовж однієї лінії (пунктирна лінія на рис. 4.32). Натомість загальні максимальні значення точності на валідаційній вибірці для оригінальних версій наборів даних (зафарбовані символи на рис. 4.32) не вирівнюються вздовж однієї лінії, а слідує ламаній лінії (штрихова лінія на рис. 4.32).

173

Встановлено, що синтетичні набори даних, отримані методом GDADD, демонструють єдину закономірність залежності точності від IPC незалежно від предметної області набору даних (природні зображення чи медичні дані), тоді як оригінальні набори даних такої закономірності не виявляють — це вказує на внутрішню властивість самого методу узгодження навчальних траєкторій, а не на випадковий побічний ефект окремого набору даних. Похибки на графіку (червоні — для DermaMNIST, зелені — для RetinaMNIST) позначають стандартні відхилення розподілу IPC для оригінальних наборів даних за результатами 5 випробувань. Вони характеризують дисбаланс розподілу IPC, належність точки до лінії тренду в межах стандартного відхилення, а також нездатність поточної конфігурації GDADD врахувати цей дисбаланс для підвищення точності.

Фактично, цей графік (рис. 4.32) дає змогу отримати наочне уявлення про переваги поточної конфігурації GDADD щодо підвищення точності для добре збалансованих наборів даних, а також про недоліки, коли дисбаланс розподілу IPC не враховується (у поточній конфігурації).

Загалом, GDADD є інноваційним методом аугментації наборів даних, що ґрунтується на використанні експертних траєкторій, отриманих під час навчання на реальних даних. Такий підхід дає змогу здійснювати траєкторно-кероване розширення даних, за якого експертна траєкторія скеровує еволюцію синтетичного набору даних, забезпечуючи збереження ключових ознак з оригінального набору даних. Навіть за меншої кількості дистильованих зображень на клас (IPC) GDADD успішно кодує основні ознаки, що робить цей метод ефективним підходом до аугментації даних. Хоча метод є ефективним для стандартних наборів даних, таких як CIFAR-10 та CIFAR-100, результати на медичних наборах даних, зокрема з колекції MedMNIST, свідчать про необхідність доменно-специфічних вдосконалень. Потенціал GDADD у застосуваннях в охороні здоров'я, зокрема у федеративному навчанні є значним, оскільки синтетичні набори даних можуть замінювати реальні дані пацієнтів, знижуючи ризики порушення конфіденційності та водночас здійснювати спільне навчання між установами. Крім того, хоча набори медичних зображень часто страждають від дисбалансу класів і обмеженої кількості даних, GDADD здатен генерувати різноманітні синтетичні зразки, підвищуючи стійкість моделі. Узгоджуючи дистильовані набори даних із траєкторіями навчання з кількох установ, моделі можуть досягати кращої узагальнювальної здатності без прямого доступу до реальних даних пацієнтів.

174

GDADD пропонує низку переваг порівняно з існуючими методами дистилляції наборів даних та аугментації даних. По-перше, метод знижує обчислювальні витрати завдяки використанню попередньо навчених моделей для спрямування траєкторії дистилляції, що прискорює проведення експериментів. По-друге, GDADD демонструє стійку узагальнювальну здатність навіть за меншої кількості зразків, суттєво знижуючи вимоги до обсягу пам'яті та обчислювальних ресурсів. По-третє, метод забезпечує збереження точності моделі, оскільки моделі, навчені на синтетичних даних, тісно відтворюють тенденції точності моделей, навчених на реальних даних. Крім того, підвищена різноманітність синтетичних зразків із зростанням значень IPC приводить до формування більш деталізованих синтетичних наборів даних, які точніше апроксимують варіативність реальних даних. Незважаючи на свої переваги, GDADD має певні обмеження. Серед них — залежність від початкових експертних траєкторій, значні обчислювальні витрати на початкове навчання експертних моделей, а також ризик поширення упереджень у даних. Річ у тім, що якість дистильованих наборів даних значною мірою залежить від ефективності експертної траєкторії: погано навчені експертні моделі можуть призвести до субоптимальних синтетичних даних. Хоча сам процес дистилляції є обчислювально ефективним, генерування експертних траєкторій потребує значних обчислювальних ресурсів на початковому етапі. Крім того, будь-які упередження, наявні в оригінальному наборі даних або в траєкторії навчання, можуть переноситися на дистильований набір даних, впливаючи на узагальню-

вальну здатність моделі.

Окрім зазначених обмежень, отримані результати свідчать про те, що залежність DDMTT від експертних траєкторій робить цей метод за своєю природою вразливим до якості та зміщення початкового процесу навчання. Нижча продуктивність на незбалансованих наборах даних вказує на те, що цільова функція узгодження траєкторій може надавати пріоритет переважаючим класам. Крім того, значні обчислювальні витрати на генерування експертних моделей створюють практичний бар'єр для доступного впровадження методу в різних застосуваннях. Подальші дослідження мають бути спрямовані на пошук ефективніших методів вибірки траєкторій та вивчення методів регуляризації, щоб запобігти посиленню зміщення під час дистиляції.

Для подолання розриву на шляху до клінічного застосування подальші дослідження мають передбачати тісну співпрацю з медичними експертами. Це дасть

175

змогу перевірити діагностичну релевантність синтезованих зображень, а також інтегрувати доменно-специфічні обмеження безпосередньо у функцію втрат дистиляції. Крім того, неоднорідна точність на незбалансованих медичних наборах даних підкреслює необхідність доменно-специфічної адаптації методу. Ключовим наступним кроком стане адаптація методу GDADD спеціально для сфери охорони здоров'я, зокрема, шляхом впровадження класово-збалансованого зважування або використання траєкторій моделей, навчених на рідкісних класах. Це дозволить синтетичним даним ефективніше долати проблеми обмеженої кількості клінічних даних та дисбалансу класів.

4.8 Інтеграція розроблених методів до складу платформи дистанційного автоматизованого виявлення та діагностики патологій та аномалій у медичних даних

Розроблені у цій дисертаційній роботі методи ідентифікації, класифікації та семантичної сегментації цільових об'єктів, а також результати їх експериментальної апробації лягли в основу платформи штучного інтелекту для дистанційного автоматизованого виявлення (Computer-Aided Detection, CAdE) та автоматизованої діагностики (Computer-Aided Diagnostics, CAdx) патологій та аномалій у медичних даних [44].

На основі наукових результатів, отриманих та висвітлених у цій дисертаційній роботі, було сформовано колекцію медичних даних (датасетів), бібліотеку моделей, описи конфігураційних параметрів та рекомендації щодо їх застосування. Для практичної імплементації розроблених методів і моделей та перевірки спроможності їх використання в реальних робочих умовах було розроблено платформу штучного інтелекту (ШІ-платформу), до складу якої входять апаратні та програмні засоби.

Апаратні засоби:

1. Спеціалізовані прискорювачі на основі графічного процесора (GPU).
2. Сервери, на базі яких використовуються спеціалізовані прискорювачі.
3. Спеціалізовані прискорювачі на основі тензорних процесорів (TPU) для периферійних обчислень (Edge Computing, EC).

Програмні засоби:

176

1. Програмний конвеєр для автоматизованого навчання, валідації та тестування ШІ-моделей.
2. Програмні модулі для використання ШІ-моделей як допоміжних інструментів лікаря (ШІ-асистентів лікаря).
3. Веб-інфраструктура для дистанційного доступу до ШІ-асистентів лікаря у вигляді ШІ-веб-сервісів для медичного застосування.
4. Програмне забезпечення для використання лікарем ШІ-асистентів у польових умовах без серверних спеціалізованих прискорювачів та доступу до глобальної мережі у вигляді недорогих портативних пристроїв для периферійних обчислень.

До складу платформи інтегровано понад 30 ШІ-моделей, які можуть бути використані як допоміжні інструменти лікаря (ШІ-асистенти лікаря) для шести різних типів практичних застосувань (ШІ-послуг), див. рис. 4.33:

1. Класифікація аномалій в легенях людини за 14 типами легеневих патологій.

27. 2. Детекція аномалій в легенях за 14 типами легеневих патологій (визначення розташування та класу аномалій).

3. Класифікація аномалій в легенях людини по ознаках COVID-19.

27. 4. Класифікація аномалій шкіри (меланома).

Перші чотири із зазначених видів практичних застосувань реалізовано на основі методів ідентифікації, класифікації та семантичної сегментації, розроблених та представлених у цій дисертаційній роботі.

177

Рисунок 4.33 — Типи практичних застосувань (ШІ-послуг) на платформі Платформа доступна у вигляді веб-сервісу за адресою <https://med.comsys.kpi.ua> і надає потенційним медичним працівникам дистанційний доступ до ШІ-асистентів для обробки медичних даних та виявлення відхилень і ознак захворювань.

Результати обробки медичних зображень на платформі представлено, зокрема, у вигляді ймовірностей та локалізацією виявлених аномалій за 14 типами легеневих патологій та за ознаками COVID-19. Демонстраційний приклад подання таких результатів наведено на рис. 4.34.

178

Рисунок 4.34 — Приклад результату обробки рентгенограми з локалізацією ймовірних зон аномалій

Детальний опис методів класифікації аномалій в легенях за 14 патологічними станами, підготовку медичних даних, навчання та валідацію відповідних моделей наведено в попередніх розділах цієї дисертаційної роботи, а також у публікаціях [26], [28], [30], [31].

4.9 Висновки до розділу

У даному розділі виконано узагальнений аналіз результатів застосування методу глибокого машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів, який включає в себе попередню обробку 2D рентгенограм за допомогою аугментації та сегментації ділянок, які містять цільові об'єкти, сегментацію анатомічних структур та вилучення з рентгенограм тіней кісток, зменшення розмірності даних на основі t-SNE з метою виключення викидів серед розподілу сегментованих масок, а також підвищення ефективності та надійності класифікації у федеративному навчанні на основі ансамблю опорних

179

моделей, а також генеративну аугментацію даних на основі дистиляції навчальних траєкторій (GDADD).

На основі результатів застосування розробленого методу було проведено оцінку його ефективності у порівнянні з існуючими підходами без використання запропонованих рішень.

За результатами застосування сегментації легень та методів аугментації даних встановлено, що навіть відносно прості згорткові нейронні мережі демонструють здатність до ефективного навчання на невеликих та незбалансованих наборах даних. При цьому аугментація без втрат інформації забезпечує найнижче значення функції втрат на валідації та дозволяє уникнути перенавчання, тоді як аугментація з втратами інформації потребує більш детального вивчення з урахуванням особливостей конкретних наборів даних та їх неоднорідності.

Аналіз впливу зменшення розмірності даних на основі t-SNE показав, що вилучення викидів у поєднанні з сегментацією та вилученням тіней кісток може покращити точність класифікації. Водночас надмірна складність попередньої обробки може спричинити появу додаткових артефактів та викидів (наприклад, поява різних форм легень чи варіації контурів їх меж), що негативно позначається на результатах узагальнення моделі. Слід зазначити, що кількісний внесок виключення викидів серед розподілу сегментованих масок за допомогою t-SNE окремо від інших етапів попередньої обробки (сегментації, вилучення тіней кісток) у цій роботі не був виділений в окремому абляційному експерименті – це обмеження визнається як напрям подальшого дослідження.

У задачах аналізу рентгенологічних зображень для діагностики раку легень підтверджено ефективність попередньої обробки у вигляді вилучення тіней кісток та сегментації, що забезпечує покращення показників точності та зменшення втрат моделі. Подальше вдосконалення результатів можливе завдяки збільшенню датасетів, застосуванню складніших алгоритмів сегментації, інтеграції кількох медичних наборів та використанню глибших моделей глибокого навчання.

У випадку великих датасетів (CheXpert) встановлено, що сегментація легень має обмежений вплив на якість діагностики, оскільки модель здатна самостійно вивчити потрібні ознаки з даних напряму. Натомість застосування методів аугментації забезпечує стабільне зменшення втрат моделі під час валідації та

підвищення AUC для більшості патологій, що підтверджує важливість ретельного підбору гіперпараметрів для аугментації медичних даних. Зіставлення ре-

180

зультатів на малих наборах даних (JSRT, BSE-JSRT) і на великому наборі даних (CheXpert) дозволяє сформулювати загальну закономірність: ефективність зменшення розмірності вхідних даних за допомогою сегментації обернено пов'язана з масштабом навчальної вибірки – для малих і незбалансованих наборів вона суттєво покращує здатність моделі до навчання, тоді як для великих наборів (десятки тисяч зображень) її внесок стає обмеженим або нейтральним. Це визначає межу застосовності запропонованої технології попередньої обробки та дозволяє свідомо обирати доцільність її використання залежно від обсягу доступних медичних даних.

Результати дослідження ансамблю опорних моделей у контексті федеративного навчання підтвердили ефективність підходу «ширина важливіша за глибину» для підвищення точності та узагальнювальної здатності моделі з низькою обчислювальною складністю. Експериментальні результати показали, що збільшення кількості опорних моделей (NMB) суттєво підвищує продуктивність, причому найвищі показники точності спостерігаються для $NMB = 4$. Крім того, менші розміри пакетів (N_b) та більша кількість локальних епох (N_{le}) додатково підвищують ефективність та точність моделі, що підкреслює важливість і необхідність додаткової оптимізації цих гіперпараметрів. У подальших дослідженнях доцільно розглянути неоднорідні розподіли медичних даних, гетерогенні особливості пристроїв та вдосконалені стратегії агрегування результатів локальних моделей з метою розширення можливостей застосування запропонованого підходу у контексті федеративного навчання. Також перспективним напрямком є вивчення гібридних архітектур, які поєднують принципи збільшення ширини та глибини нейронних мереж для можливого подальшого покращення результатів запропонованого підходу. Отримані результати створюють надійну основу для впровадження ансамблю архітектур з низькою обчислювальною складністю у системах федеративного навчання на периферійних пристроях та відкривають перспективи їх практичного застосування у різних галузях, зокрема в охороні здоров'я. Результати застосування методу GDADD показали, що для добре збалансованих наборів даних (CIFAR-10, CIFAR-100) дистильовані набори значно меншого розміру забезпечують точність, вищу за точність моделей, навчених на повному оригінальному наборі даних, що підтверджує здатність методу до ефективного стиснення інформативного вмісту навчальних даних. Водночас для незбалансованих медичних наборів даних (PathMNIST, DermaMNIST, RetinaMNIST)

181

підвищення точності зі зростанням кількості синтетичних зображень на клас виявилось менш вираженим, а його масштаб корелює зі ступенем дисбалансу класів: найменше покращення спостерігалось для найбільш незбалансованих наборів даних (DermaMNIST, RetinaMNIST). Це вказує на чутливість поточної реалізації методу до дисбалансу класів. Перспективним напрямом подальших досліджень є доменно-специфічна адаптація GDADD для задач медичної діагностики. Зокрема, це може передбачати впровадження класово-збалансованого зважування або використання траєкторій моделей, навчених на рідкісних класах.

129

Таким чином, узагальнюючи результати проведеного дослідження, можна зробити висновок, що сегментація анатомічних структур, вилучення з рентгенограм тіней кісток, зменшення розмірності даних на основі t-SNE, використання оптимізованих процедур аугментації та ансамблю опорних моделей разом із адаптивними стратегіями навчання, а також генеративна аугментація даних на основі дистилляції навчальних траєкторій (GDADD) дозволяє підвищити ефективність та надійність систем комп'ютерної діагностики, які використовують моделі глибокого машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів.

Основні результати даного розділу опубліковані у роботах [26], [28], [30], [31], [35], [37], [41].

182

ВИСНОВКИ

У дисертаційному дослідженні розв'язане актуальне наукове завдання, яке спрямоване на покращення результатів аналізу медичних даних, зокрема діагностики легеневих захворювань, шляхом створення та оптимізації методів і моделей глибокого машинного навчання для ідентифікації, класифікації та семантичної сегментації об'єктів, зокрема алгоритмів семантичної сегментації анатоміч-

них структур і вилучення тіней кісток з рентгенограм, ансамблевої класифікації у федеративному навчанні, а також методів виключення викидів серед розподілу сегментованих масок та генеративної аугментації даних методом дистиляції набору даних (GDADD). У результаті було отримано такі наукові і практичні результати:

1. Проведено аналіз сучасних методів машинного та глибинного навчання, які використовуються для задач комп'ютерного зору; цей аналіз сформував аналітичне підґрунтя для отримання наукових результатів, викладених у пунктах 2–7. Встановлено переваги та недоліки розглянутих підходів, що дозволило сформулювати шляхи для вдосконалення ефективності діагностики легеневих захворювань на основі 2D рентгенограм. Проведений аналіз показав високий потенціал методів глибинного навчання для досягнення точності діагностики на рівні лікарів-експертів, зменшення навантаження на медичний персонал та прискорення обробки великих обсягів медичних даних. Виявлено ключові фактори, що обмежують широке впровадження штучного інтелекту у клінічну практику, зокрема потреба у великих та збалансованих наборах даних, варіативність апаратів і протоколів отримання знімків, а також необхідність забезпечення інтерпретованості результатів для лікарів.
2. Вперше запропоновано інтегровану технологію попередньої обробки 2D рентгенограм, яка поєднує сегментацію цільових ділянок на основі глибких нейронних мереж типу кодер-декодер із подальшою класифікацією патологій. На відміну від класифікації за ознаками всього зображення, запропонована технологія дозволяє зосередити аналіз на клінічно значущих ділянках і покращити результати діагностики окремих легеневих захворювань за рахунок зменшення впливу нецільових анатомічних структур на результат класифікації та зменшення розмірності вхід-

183

них даних у $3,2 \pm 0,7$ рази (середня частка площі сегментації – $0,32 \pm 0,06$). Експериментально встановлено, що вплив сегментації на результати класифікації є нерівномірним залежно від типу патології та розміру вибірки: для малих та незбалансованих наборів даних (JSRT, BSE-JSRT) сегментація суттєво покращує здатність моделі до навчання, тоді як для великого набору даних (CheXpert) її вплив на якість діагностики є обмеженим, оскільки модель здатна самостійно виокремити релевантні ознаки з достатньо великої вибірки; покращення діагностичної точності на CheXpert спостерігалось лише для окремих класів патологій (Lung Opacity, Consolidation та Pleural Other)..

Застосування сегментації у поєднанні з аугментацією даних забезпечило покращення діагностичної точності для 10 із 14 досліджуваних патологій порівняно з моделлю, навченою лише на сегментованих зображеннях (без аугментації). Зменшення кількості нерелевантних ознак завдяки сегментації є особливо корисним для невеликих вибірок, де обмежена кількість прикладів підвищує ризик того, що модель почне враховувати випадкові патерни у фонових областях зображення (поза межами легень) замість клінічно значущих ознак. Для великих вибірок цей ризик зменшується, оскільки достатня кількість прикладів дозволяє моделі самостійно навчитися ігнорувати нерелевантні області зображення без попередньої сегментації.

3. Вперше запропоновано метод класифікації у федеративному навчанні, що ґрунтується на ансамблі опорних моделей у поєднанні з архітектурами низької обчислювальної складності за стратегією «ширина важливіша за глибину», який на відміну від існуючих підходів до збільшення глибини нейронних мереж, ³³ дозволяє підвищити узагальнювальну здатність моделі та зменшити ризик перенавчання за рахунок зменшення дисперсії передбачень при агрегуванні частково некорельованих помилок окремих моделей. Експериментально встановлено, що чутливість моделі до кількості локальних епох між раундами усереднення FedAvg зростає зі збільшенням кількості опорних моделей в ансамблі. Найбільшу різницю валідаційної точності між максимальною та мінімальною кількістю локальних епох отримано для моделі з чотирма опорними архітектурами (NMB = 4) – 13,39%. Для моделі з двома опорними архітек-

184

турами (NMB = 2) ця різниця становила 5%, а для однієї базової моделі (NMB = 1) лише 1,89%. Це свідчить про те, що при недостатній кілько-

сті локальних епох траєкторії навчання опорних моделей зближуються, що знижує виграш від ансамблювання.

4. Удосконалено метод глибинного навчання на основі згорткових нейронних мереж шляхом доповнення його етапами сегментації анатомічних структур та вилучення з рентгенограм тіней кісток, що дозволяє зменшити перекриття патологічних ознак кістковими структурами, а також додатково скоротити розмірність вхідних даних приблизно у 2 рази (середнє значення частки релевантної площі – $0,15 \pm 0,04$) за рахунок вилучення нерелевантних ознак, що знижує ризик перенавчання моделі за умов обмеженого розміру навчальної вибірки.

5. Отримав подальший розвиток метод виключення викидів серед сегментованих масок, який, на відміну від відомих підходів, ґрунтується на проєкції розподілу масок у простір зниженої розмірності за допомогою методу t-SNE з подальшою пороговою фільтрацією відносно ядра даних, що дозволило покращити якість вхідних даних для методів глибинного навчання під час класифікації патологічних станів легень за 2D-рентгенограмами.

6. Отримав подальший розвиток метод дистиляції набору даних шляхом узгодження навчальних траєкторій (DDMTT): запропоновано генеративну аугментацію даних GDADD, яка, на відміну від DDMTT, суттєво збільшує кількість синтетичних зображень на клас, синтезуючи набір даних, обсяг якого наближається до реального набору даних. За рахунок цього синтезовані зображення кодують ширший спектр інформативних ознак, що дозволяє моделям, навченим на такому наборі, досягати узагальнювальної здатності, зіставної з моделями, навченими на значно більшому реальному наборі даних. Експериментально підтверджено, що на збалансованому наборі даних PathMNIST валідаційна точність класифікації моделей, навчених на даних, синтезованих методом GDADD ($0,917 \pm 0,003$), є дещо вищою за класичні згорткові архітектури (ResNet-18, ResNet-50) та перевищує результати методів автоматизованого машинного навчання (auto-sklearn, AutoKeras, Google AutoML Vision) на 9,9-28,1%.

185

7. Розроблені методи з використанням сегментації, вилучення тіней кісток, виключення викидів, генеративної аугментації даних та ансамблювання опорних моделей у рамках федеративного навчання є взаємодоповнювальними за характером дії: перші чотири методи спрямовані на послідовне зменшення різних типів надлишковості та шуму на рівні вхідних даних (просторової – сегментація, структурної – вилучення тіней кісток, статистичної – виключення викидів) та компенсацію дефіциту репрезентативності класів (аугментація даних), тоді як ансамблювання опорних моделей забезпечує підвищення надійності рішення на рівні агрегації прогнозів. Ефективність кожного компонента підтверджено експериментально за окремою лінією дослідження; частину методів інтегровано на рівні програмної платформи (розд. 4.8), що обґрунтовує перспективність подальшого застосування розроблених методів для підвищення узагальнювальної здатності та надійності систем автоматизованого аналізу візуальних даних до рівня продуктивності, зіставного з лікарями-експертами; кількісна оцінка сукупного ефекту в єдиному наскрізному експерименті становить завдання подальших досліджень.

До перспективних напрямів продовження досліджень за тематикою дисертації належить інтеграція мультимодальних медичних даних, зокрема 2D рентгенограм, результатів комп'ютерної томографії та електронних медичних записів, у єдині інтелектуальні діагностичні системи, створення гібридних архітектур глибоких нейронних мереж, що поєднують принципи розширення глибини та ширини обчислювальних структур для підвищення продуктивності та узагальнювальної здатності, а також розробка інтерпретованих моделей штучного інтелекту, результати роботи яких можуть бути інтегровані у клінічні робочі процеси для підтримки прийняття рішень.

Потенційними користувачами отриманих результатів в Україні є Міністерство охорони здоров'я України як центральний орган державного управління, відповідальний за формування та реалізацію політики у сфері охорони здоров'я, медичні установи та діагностичні центри, а також науково-дослідні інститути та університети.

186

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

1. Stanford Institute for Human-Centered Artificial Intelligence (HAI), Artificial intelligence index report 2025, 2025. [Online]. Available: <https://hai.stanford.edu/ai-index/2025-ai-index-report>.
2. S. Grigorescu, B. Trasnea, T. Cocias, and G. Macesanu, "A survey of deep learning techniques for autonomous driving," *Journal of field robotics*, vol. 37, no. 3, pp. 362–386, 2020.
3. A. Gupta, A. Anpalagan, L. Guan, and A. S. Khwaja, "Deep learning for object detection and scene perception in self-driving cars: Survey, challenges, and open issues," *Array*, vol. 10, p. 100 057, 2021.
4. M. Wang and W. Deng, "Deep face recognition: A survey," *Neurocomputing*, vol. 429, pp. 215–244, 2021.
5. Y. Taigman, M. Yang, M. Ranzato, and L. Wolf, "Deepface: Closing the gap to human-level performance in face verification," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2014, pp. 1701–1708.
6. G. Litjens, T. Kooi, B. E. Bejnordi, et al., "A survey on deep learning in medical image analysis," *Medical image analysis*, vol. 42, pp. 60–88, 2017.
7. A. Esteva, B. Kuprel, R. A. Novoa, et al., "Dermatologist-level classification of skin cancer with deep neural networks," *nature*, vol. 542, no. 7639, pp. 115–118, 2017.
8. American Medical Association, Physician sentiments around the use of AI in health care: Motivations, opportunities, risks, and use cases – shifts from 2023 to 2024, AMA Augmented Intelligence Research Report, 2025. [Online]. Available: <https://www.optomed.com/us/wp-content/uploads/sites/2/2025/06/physician-ai-sentiment-report-2025.pdf> (visited on 07/11/2026).
9. L. Guo, C. Zhou, J. Xu, C. Huang, Y. Yu, and G. Lu, "Deep learning for chest x-ray diagnosis: Competition between radiologists with or without artificial intelligence assistance," *Journal of Imaging Informatics in Medicine*, vol. 37, no. 3, pp. 922–934, 2024.

187

10. P. Rajpurkar, J. Irvin, R. L. Ball, et al., "Deep learning for chest radiograph diagnosis: A retrospective comparison of the chexnext algorithm to practicing radiologists," *PLoS medicine*, vol. 15, no. 11, e1002686, 2018.
11. M. A. Abdou, "Literature review: Efficient deep neural networks techniques for medical image analysis," *Neural Computing and Applications*, vol. 34, no. 8, pp. 5791–5812, 2022.
12. R. Wang, T. Lei, R. Cui, B. Zhang, H. Meng, and A. K. Nandi, "Medical image segmentation using deep learning: A survey," *IET image processing*, vol. 16, no. 5, pp. 1243–1267, 2022.
13. E. Goh, D. Wu, C. Walton, et al., "Toward a test of medical AI superintelligence," *Nature Medicine*, 2026. [Online]. Available: <https://doi.org/10.1038/s41591-026-04539-8>.
14. Latest global cancer data: Cancer burden rises to 18.1 million new cases and 9.6 million cancer deaths in 2018, The International Agency for Research on Cancer. World Health Organization, 2018. [Online]. Available: <https://www.who.int/cancer/PRGlobocanFinal.pdf>.
15. S. Waite, J. Scott, B. Gale, T. Fuchs, S. Kolla, and D. Reede, "Interpretive error in radiology," *American Journal of Roentgenology*, vol. 208, no. 4, pp. 739–749, 2017.
16. A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," *Advances in neural information processing systems*, vol. 25, 2012.
17. K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv preprint arXiv:1409.1556*, 2014.
18. C. Szegedy, W. Liu, Y. Jia, et al., "Going deeper with convolutions," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, pp. 1–9.
19. J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 779–788.

188

20. A. Dosovitskiy, L. Beyer, A. Kolesnikov, et al., "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.
21. O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for

biomedical image segmentation," in International Conference on Medical image computing and computer-assisted intervention, Springer, 2015, pp. 234–241.

22. G. Cazenavette, T. Wang, A. Torralba, A. A. Efros, and J.-Y. Zhu, "Dataset distillation by matching training trajectories," in Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022, pp. 4750–4759.

23. Y. Kochura, S. Stirenko, O. Alienin, M. Novotarskiy, and Y. Gordienko, "Comparative analysis of open source frameworks for machine learning with use case in single-threaded and multi-threaded modes," in Proceedings of the 12th International Scientific and Technical Conference on Computer Sciences and Information Technologies, CSIT 2017, vol. 1, Institute of Electrical and Electronics Engineers Inc., 2017, pp. 373–376, ISBN: 978-153861638-3. DOI: 10.1109/STC-CSIT.2017.8098808.

24. Y. Kochura, S. Stirenko, and Y. Gordienko, "Comparative performance analysis of neural networks architectures on h2o platform for various activation func-

tions," in 2017 IEEE International Young Scientists Forum on Applied Physics and Engineering, YSF 2017, Institute of Electrical and Electronics Engineers Inc., 2017, pp. 70–73, ISBN: 978-153862994-9. DOI: 10.1109/YSF.2017.8126654.

25. Y. Kochura, S. Stirenko, O. Alienin, M. Novotarskiy, and Y. Gordienko, "Performance analysis of open source machine learning frameworks for various parameters in single-threaded and multi-threaded modes," in Advances in Intelligent Systems and Computing, N. Shakhovska and V. Stepashko, Eds., vol. 689, Cham: Springer, 2018, pp. 243–256, ISBN: 978-331970580-4. DOI: 10.1007/978-3-319-70581-1_17.

26. P. Gang, W. Zhen, W. Zeng, et al., "Dimensionality reduction in deep learning for chest x-ray analysis of lung cancer," in Proceedings - 2018 10th International Conference on Advanced Computational Intelligence, ICACI 2018, Institute of Electrical and Electronics Engineers Inc., 2018, pp. 878–883, ISBN: 978-153864362-4. DOI: 10.1109/ICACI.2018.8377579.

189

27. V. Taran, Y. Gordienko, N. Gordienko, et al., "Performance evaluation of deep learning networks for semantic segmentation of traffic stereo-pair images," in ACM International Conference Proceeding Series, B. Rachev and A. Smrikarov, Eds., Association for Computing Machinery, 2018, pp. 73–80, ISBN: 978-145036425-6. DOI: 10.1145/3274005.3274032.

28. S. Stirenko, Y. Kochura, O. Alienin, et al., "Chest x-ray analysis of tuberculosis by deep learning with segmentation and augmentation," in 2018 IEEE 38th International Conference on Electronics and Nanotechnology, ELNANO 2018 - Proceedings, Institute of Electrical and Electronics Engineers Inc., 2018, pp. 422–428, ISBN: 978-153866383-7. DOI: 10.1109/ELNANO.2018.8477564.

29. P. Gang, J. Hui, S. Stirenko, et al., "User-driven intelligent interface on the basis of multimodal augmented reality and brain-computer interaction for people with functional disabilities," in Advances in Intelligent Systems and Computing, K. Aral, S. Kapoor, and R. Bhatia, Eds., vol. 886, Cham: Springer, 2018, pp. 612–631, ISBN: 978-303003401-6. DOI: 10.1007/978-3-030-03402-3_43.

30. Y. Gordienko, P. Gang, J. Hui, et al., "Deep learning with lung segmentation and bone shadow exclusion techniques for chest x-ray analysis of lung cancer," in Advances in Intelligent Systems and Computing, Z. Hu, S. Petoukhov, I. Dy-chka, and M. He, Eds., vol. 754, Cham: Springer, 2018, pp. 638–647, ISBN: 978-331991007-9. DOI: 10.1007/978-3-319-91008-6_63.

31. P. Gang, W. Zeng, Y. Gordienko, et al., "Effect of data augmentation and lung mask segmentation for automated chest radiograph interpretation of some lung diseases," in Communications in Computer and Information Science, T. Gedeon, K. W. Wong, and M. Lee, Eds., vol. 1142, Cham: Springer, 2019, pp. 333–340, ISBN: 978-303036807-4. DOI: 10.1007/978-3-030-36808-1_36.

32. Y. Gordienko, Y. Kochura, V. Taran, N. Gordienko, A. Bugaiov, and S. Stirenko, "Adaptive iterative pruning for accelerating deep neural networks," in 2019 11th International Scientific and Practical Conference on Electronics and Information Technologies, ELIT 2019 - Proceedings, Institute of Electrical and Electronics Engineers Inc., 2019, pp. 173–178, ISBN: 978-172813561-8. DOI: 10.1109/ELIT.2019.8892346.

190

33. Y. Kochura, Y. Gordienko, V. Taran, et al., "Batch size influence on performance of graphic and tensor processing units during training and inference phases," in Advances in Intelligent Systems and Computing, Z. Hu, S. Petoukhov, I. Dy-chka, and M. He, Eds., vol. 938, Cham: Springer, 2019, pp. 658–668, ISBN: 978-303016620-5. DOI: 10.1007/978-3-030-16621-2_61.

34. ³⁶ Gordienko, Y. Kochura, V. Taran, et al., ³⁵Scaling analysis of specialized tensor processing architectures for deep learning models," in *Studies in Computational Intelligence*, vol. 866, Cham: Springer, 2020, pp. 65–99. DOI: 10.1007/978-3-030-31756-0_3.

35. Y. Gordienko, N. Gordienko, E. M. El Mhamdi, Y. Kochura, and S. Stirenko, "Multi-backbone ensembling for performance improvement in federated learning setup," in *Lecture Notes in Networks and Systems*, N. Min-Allah, K. Alissa, P. Sitek, M. Sano, S. Rodriguez, and A. Nongaillard, Eds., vol. 1598, Cham: Springer Nature Switzerland, 2026, pp. 129–138, ISBN: 978-303204159-3. DOI: 10.1007/978-3-032-04160-9_12.

36. Y. Kochura, Y. Trochun, V. Taran, Y. Gordienko, O. Rokovyi, and S. Stirenko, "UAeroNet: Domain-specific dataset for automation of unmanned aerial vehicles," *Information, Computing and Intelligent systems*, no. 7, pp. 83–95, 2025. DOI: 10.20535/2786-8729.7.2025.341779.

37. ⁴³ Gordienko, G. Nowakowski, Y. Kochura, V. Taran, and S. Stirenko, "Generative data augmentation by dataset distillation," in *Communications in Computer and Information Science*, C. Tommasino, C. Russo, and M. Bernardini, Eds., vol. 2696, Cham: Springer Nature Switzerland, 2026, pp. 105–118, ISBN: 978-303217215-0. DOI: 10.1007/978-3-032-17216-7_9.

38. Y. Gordienko, M. Shulha, Y. Kochura, et al., "Multimodal metadata augmentation for federated learning in medical applications," in *Lecture Notes in Networks and Systems*, X.-S. Yang, S. Sherratt, N. Dey, and A. Joshi, Eds., vol. 1002, Springer Science and Business Media Deutschland GmbH, 2024, pp. 537–547, ISBN: 978-981973298-2. DOI: 10.1007/978-981-97-3299-9_43.

39. ²⁰ Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, O. Alienin, and S. Stirenko, "Fuzzy metadata augmentation for multimodal data classification," in *Lecture Notes on Data Engineering and Communications Technologies*, vol. 166,

191
¹ Springer Science and Business Media Deutschland GmbH, 2023, pp. 157–172. DOI: 10.1007/978-981-99-0835-6_11.

40. Y. Gordienko, M. Shulha, Y. Kochura, et al., "Ensemble knowledge distillation for edge intelligence in medical applications," in *Studies in Computational Intelligence*, vol. 1100, Springer Science and Business Media Deutschland GmbH, 2023, pp. 135–168. DOI: 10.1007/978-3-031-32095-8_5.

41. V. Doms, Y. Gordienko, ³⁵ Kochura, O. Rokovyi, O. Alienin, and S. Stirenko, "Deep learning for melanoma detection with testing time data augmentation," in *Lecture Notes on Data Engineering and Communications Technologies*, vol. 82, Springer Science and Business Media Deutschland GmbH, 2021, pp. 131–140. DOI: 10.1007/978-3-030-80475-6_13.

42. ³⁶ Taran, Y. Gordienko, O. Rokovyi, O. Alienin, Y. Kochura, ³⁶ and S. Stirenko, "Edge intelligence for medical applications under field conditions," in *Lecture Notes on Data Engineering and Communications Technologies*, vol. 135, Springer Science and Business Media Deutschland GmbH, 2022, pp. 71–80. DOI: 10.1007/978-3-031-04809-8_6.

43. ³⁶ Gordienko, Y. Kochura, V. Taran, et al., ³⁵ "Last mile" optimization of edge computing ecosystem with deep learning models and specialized tensor processing architectures," in *Advances in Computers*, S. Kim and G. C. Deka, Eds., vol. 122, Academic Press Inc., 2021, pp. 303–341, ISBN: 978-012823123-4. DOI: 10.1016/bs.adcom.2020.10.003.

44. O. Alienin, ³⁶ O. Rokovyi, Y. Gordienko, ³⁵ Y. Kochura, V. Taran, and S. Stirenko, "Artificial intelligence platform for distant computer-aided detection (CADE) and computer-aided diagnosis (CADx) of human diseases," in *Lecture Notes on Data Engineering and Communications Technologies*, vol. 135, Springer Science and Business Media Deutschland GmbH, 2022, pp. 91–100. DOI: 10.1007/978-3-031-04809-8_8.

45. The rise of the data-driven physician, Stanford University School of Medicine, 2020. [Online]. Available: <https://med.stanford.edu/dean/healthtrends.html>.

46. ¹¹⁷ Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri, and R. Summers, ⁴⁰ "Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," in *IEEE CVPR*, vol. 7, 2017.

192
⁴⁰ J. Irvin, P. Rajpurkar, M. Ko, et al., "Chexpert: A large chest radiograph dataset with uncertainty labels and expert comparison," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 33, 2019, pp. 590–597.

48. ⁵ J. Yanase and E. Triantaphyllou, "A systematic survey of computer-aided diagnosis in medicine: Past and present developments," *Expert Systems with Ap-*

lications, vol. 138, p. 112 821, 2019. DOI: 10.1016/j.eswa.2019.112821.

[12] [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957417419305238>.

49. P. Putha, M. Tadepalli, B. Reddy, et al., "Can artificial intelligence reliably report chest x-rays?: Radiologist validation of an algorithm trained on 2.3 million x-rays," *arXiv preprint arXiv:1807.07455*, 2018.

50. A. Majkowska, S. Mittal, D. F. Steiner, et al., "Chest radiograph interpretation with deep learning models: Assessment with radiologist-adjudicated reference standards and population-adjusted evaluation," *Radiology*, vol. 294, no. 2, pp. 421–431, 2020.

51. X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri, and R. M. Summers, "Chestx-ray8: Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 2097–2106.

52. J. Islam and Y. Zhang, "Towards robust lung segmentation in chest radiographs with deep learning," *arXiv preprint arXiv:1811.12638*, 2018.

53. P. Lakhani and B. Sundaram, "Deep learning at chest radiography: Automated classification of pulmonary tuberculosis by using convolutional neural networks," *Radiology*, vol. 284, no. 2, pp. 574–582, 2017.

54. J. Guendel, S. Grbic, B. Georgescu, S. Liu, A. Maier, and D. Comaniciu, "Learning to recognize abnormalities in chest x-rays with location-aware dense networks," in *Iberoamerican Congress on Pattern Recognition*, Springer, 2018, pp. 757–765.

55. S. Singla, B. Pollack, J. Chen, and K. Batmanghelich, "Explanation by progressive exaggeration," *arXiv preprint arXiv:1911.00483*, 2019.

193

56. J. Rubin, D. Sanghavi, C. Zhao, K. Lee, A. Qadir, and M. Xu-Wilson, "Large scale automated reading of frontal and lateral chest x-rays using dual convolutional neural networks," *arXiv preprint arXiv:1804.07839*, 2018.

57. K. Singhal, S. Azizi, T. Tu, et al., "Large language models encode clinical knowledge," *Nature*, vol. 620, no. 7972, pp. 172–180, 2023.

58. J. Ma, Y. He, F. Li, L. Han, C. You, and B. Wang, "Segment anything in medical images," *Nature Communications*, vol. 15, no. 1, p. 654, 2024.

59. J. Couzin-Frankel, "Medicine contends with how to use artificial intelligence," 2019.

60. G. V. Research, "AI In Healthcare Market Size, Share, And Trends Analysis Report By Component (Hardware, Services), By Application, By End Use, By Technology, By Region (North America, Europe, APAC, Latin America, MEA), And Segment Forecasts, 2025 - 2030." [Online]. Available: <https://www.grandviewresearch.com/industry-analysis/artificial-intelligence-ai-healthcare-market#> (visited on 06/20/2025).

61. I. I. Mayba, R. Gaiua, R. A. Kyle, and M. A. Shampo, "Ukrainian physicist contributes to the discovery of x-rays," *Mayo Clinic Proceedings*, vol. 72, no. 7, p. 658, 1997. DOI: [https://doi.org/10.1016/S0025-6196\(11\)63573-8](https://doi.org/10.1016/S0025-6196(11)63573-8). [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0025619611635738>.

62. Чудо-промені видатного українця. Іван Пулюй, Укрінформ: Українське національне інформаційне агентство. url: <https://www.ukrinform.ua/rubric-culture/2867756-cudopromeni-vidatnogo-ukrainca-ivan-puluj.html> (дата зверн. 2020).

63. P. Suetens, *Fundamentals of medical imaging*. Cambridge university press, 2009.

64. Basics of x-ray physics, *RadiologyMasterclass*, 2022. [Online]. Available: https://www.radiologymasterclass.co.uk/tutorials/physics/x-ray_physics_production#top_1st_img.

65. Communicating radiation risks in paediatric imaging, *World Health Organization*. [Online]. Available: https://www.who.int/ionizing_radiation/pub_meet/chapter1.pdf (visited on 2022).

194

66. D. Mathers and D. Loncar, "Projections of global mortality and burden of disease from 2002 to 2030," *PLOS Medicine*, vol. 3, no. 11, e442, 2006. DOI:

[10.1371/journal.pmed.0030442](https://doi.org/10.1371/journal.pmed.0030442). [Online]. Available: <https://app.dimensions.ai/details/publication/pub.1002063116>.

67. Електронні направлення: які медичні аналізи та діагностику найчастіше призначали українцям, Національна служба здоров'я України. url: <https://www.kmu.gov.ua/news/elektronni-napravlennya-yaki-medichni-analizi-ta-diaagnostiku-najchastishe-priznachali-ukrayincyam>.

68. Chest radiograph, Radiopaedia.org, 2025. [Online]. Available: <https://radiopaedia.org/articles/chest-radiograph>.
69. Інструкції про періодичність рентгенівських обстежень органів грудної порожнини певних категорій населення України, Міністерство охорони здоров'я України. url: <https://zakon.rada.gov.ua/laws/show/z0524-08#Text> (дата зверн.: 2022).
70. D. Li, J. Yang, K. Kreis, A. Torralba, and S. Fidler, "Semantic segmentation with generative models: Semi-supervised learning and strong out-of-domain generalization," in Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021, pp. 8300–8311.
71. K. Singhal, T. Tu, J. Gottweis, et al., "Toward expert-level medical question answering with large language models," Nature Medicine, vol. 31, no. 3, pp. 943–950, 2025.
72. J. W. Kim, H. Y. Jang, K. W. Kim, Y. Shin, and S. H. Park, "Design characteristics of studies reporting the performance of artificial intelligence algorithms for diagnostic analysis of medical images: Results from recently published papers," Korean journal of radiology, vol. 20, no. 3, pp. 405–410, 2019.
73. D. Zha, Z. P. Bhat, K.-H. Lai, et al., "Data-centric artificial intelligence: A survey," ACM Computing Surveys, vol. 57, no. 5, pp. 1–42, 2025.
74. M. Mazumder, C. Banbury, X. Yao, et al., "Dataperf: Benchmarks for data-centric ai development," Advances in Neural Information Processing Systems, vol. 36, pp. 5320–5347, 2023.
75. N. Sambasivan, S. Kapania, H. Highfill, D. Akrong, P. Paritosh, and L. M. Aroyo, "“Everyone wants to do the model work, not the data work”: Data cascades in high-stakes AI," in proceedings of the 2021 CHI Conference on Human Factors in Computing Systems, 2021, pp. 1–15.
76. J. Buolamwini and T. Gebru, "Gender shades: Intersectional accuracy disparities in commercial gender classification," in Conference on fairness, accountability and transparency, PMLR, 2018, pp. 77–91.
77. L. Aroyo, M. Lease, P. Paritosh, and M. Schaekermann, "Data excellence for ai: Why should you care?" Interactions, vol. 29, no. 2, pp. 66–69, 2022.
78. J. Kaplan, S. McCandlish, T. Henighan, et al., "Scaling laws for neural language models," arXiv preprint arXiv: 2001.08361, 2020.
79. J. Hoffmann, S. Borgeaud, A. Mensch, et al., "An empirical analysis of compute-optimal large language model training," in Advances in Neural Information Processing Systems, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35, Curran Associates, Inc., 2022, pp. 30 016–30 030. DOI: 10.52202/068431 - 2176. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/c1e2faff6f588870935f114ebe04a3e5-Paper-Conference.pdf.
80. S. Gunasekar, Y. Zhang, J. Aneja, et al., "Textbooks are all you need," arXiv preprint arXiv:2306.11644, 2023.
81. M. J. Willemink, W. A. Koszek, C. Hardell, et al., "Preparing medical imaging data for machine learning," Radiology, vol. 295, no. 1, pp. 4–15, 2020.
82. G. Frija, I. Blažić, D. P. Frush, et al., "How to improve access to medical imaging in low-and middle-income countries?" EClinicalMedicine, vol. 38, 2021.
83. H. Hricak, M. Abdel-Wahab, R. Atun, et al., "Medical imaging and nuclear medicine: A lancet oncology commission," The Lancet Oncology, vol. 22, no. 4, e136–e172, 2021.
84. N. L. S. T. R. Team, "Reduced lung-cancer mortality with low-dose computed tomographic screening," New England Journal of Medicine, vol. 365, no. 5, pp. 395–409, 2011.
85. J. Shiraishi, S. Katsuragawa, J. Ikezoe, et al., "Development of a digital image database for chest radiographs with and without a lung nodule: Receiver operating characteristic analysis of radiologists' detection of pulmonary nodules," American Journal of Roentgenology, vol. 174, no. 1, pp. 71–74, 2000.
86. S. Juhász, A. Horváth, L. Nikhazy, and G. Horváth, "Segmentation of anatomical structures on chest radiographs," in XII Mediterranean Conference on Medical and Biological Engineering and Computing 2010, Springer, 2010, pp. 359–362.
87. H. Oğul, B. B. Oğul, A. M. Ağildere, T. Bayrak, and E. Sümer, "Eliminating rib shadows in chest radiographic images providing diagnostic assistance," Computer methods and programs in biomedicine, vol. 127, pp. 174–184, 2016.
88. G. Armato III, G. McLennan, L. Bidaut, et al., "The lung image database consortium (lidc) and image database resource initiative (idri): A completed reference database of lung nodules on ct scans," Medical physics, vol. 38, no. 2, pp. 915–931, 2011.
89. S. Jaeger, S. Candemir, S. Antani, Y.-X. J. Wang, P.-X. Lu, and G. Thoma, "Two public chest x-ray datasets for computer-aided screening of pulmonary diseases," Quantitative imaging in medicine and surgery, vol. 4, no. 6, p. 475, 2014.
90. S. Jaeger, A. Karargiris, S. Candemir, et al., "Automatic tuberculosis screening using chest radiographs," IEEE transactions on medical imaging, vol. 33, no. 2, pp. 233–245, 2013.

91. A. ⁹⁶Justos, A. ⁹⁶Pertusa, J.-M. ⁹⁶Salinas, and M. de la ⁹⁶Iglesia-Vayá, "Padchest: A large chest x-ray image dataset with multi-label annotated reports," *Medical image analysis*, vol. 66, p. 101 797, 2020.
92. ⁹⁷N. ⁹⁷Bien, P. ⁹⁷Rajpurkar, R. L. ⁹⁷Ball, et al., "Deep-learning-assisted diagnosis for knee magnetic resonance imaging: Development and retrospective validation of mrnet," *PLoS medicine*, vol. 15, no. 11, e1002699, 2018.
93. ⁴⁸A. ⁴⁸E. ⁴⁸Johnson, T. J. ⁴⁸Pollard, N. R. ⁴⁸Greenbaum, et al., "Mimic-cxr-jpg, a large publicly available database of labeled chest radiographs," *arXiv preprint arXiv:1901.07042*, 2019.
94. P. ¹²²Rajpurkar, J. ¹²²Irvin, A. ¹²²Bagul, et al., "Mura: Large dataset for abnormality detection in musculoskeletal radiographs," *arXiv preprint arXiv:1712.06957*, 2017.
- 197
95. ⁹³Report of the who-china joint mission on coronavirus disease 2019 (covid-19), World Health Organization (WHO), 2020. [Online]. Available: [https://www.who.int/publications/i/item/report-of-the-who-china-joint-mission-on-coronavirus-disease-2019-\(covid-19\)](https://www.who.int/publications/i/item/report-of-the-who-china-joint-mission-on-coronavirus-disease-2019-(covid-19)).
96. ⁶²C. ⁶²Huang, Y. ⁶²Wang, X. ⁶²Li, et al., "Clinical features of patients infected with 2019 novel coronavirus in wuhan, china," *The lancet*, vol. 395, no. 10223, pp. 497–506, 2020.
97. ¹²⁰J. ¹²⁰Kanne, B. ¹²⁰Little, J. ¹²⁰Chung, et al., "Essentials for radiologists on covid-19: An update," *Radiology*, vol. 296, no. 2, 2020. DOI: 10.1148/radiol.202000527.
98. ⁹⁹J. ⁹⁹Rodrigues, S. ⁹⁹Hare, A. ⁹⁹Edey, et al., "An update on covid-19 for the radiologist- a british society of thoracic imaging statement," *Clinical radiology*, vol. 75, no. 5, p. 323, 2020.
99. ⁷⁴H. ⁷⁴Y. F. ⁷⁴Wong, H. ⁷⁴Y. S. ⁷⁴Lam, A. ⁷⁴H.-T. ⁷⁴Fong, et al., "Frequency and distribution of chest radiographic findings in patients positive for covid-19," *Radiology*, vol. 296, no. 2, E72–E78, 2020.
100. ⁴⁴M. ⁴⁴Prokop, W. ⁴⁴Van ⁴⁴Everdingen, T. ⁴⁴van ⁴⁴Rees ⁴⁴Vellinga, et al., "Covid-19 standardized reporting working group of the dutch radiological society. co-rads: A categorical ct assessment scheme for patients suspected of having covid-19- definition and evaluation," *Radiology*, vol. 296, no. 2, E97–E104, 2020.
101. Covid-19 chest x-ray segmentations dataset, covid-19 detection with heat-map visualization, <https://github.com/ieee8023/covid-chestxray-dataset>, <https://www.kaggle.com/basu369victor/covid-19-detection-with-heat-map-visualization>, 2021.
102. Covid-19 image data collection, 2020. [Online]. Available: <https://github.com/GeneralBlockchain/covid-19-chest-xray-segmentations-dataset>.
103. Covid-19 chest x-ray lung bounding boxes dataset, 2020. [Online]. Available: <https://github.com/GeneralBlockchain/covid-19-chest-xray-lung-bounding-boxes-dataset>.
104. Covid-19 xray dataset, 2020. [Online]. Available: <https://github.com/v7labs/covid-19-xray-dataset>.
- 198
105. ⁶⁰D. ⁶⁰Kermany, K. ⁶⁰Zhang, M. ⁶⁰Goldbaum, et al., "Labeled optical coherence tomography (oct) and chest x-ray images for classification," *Mendeley data*, vol. 2, no. 2, 2018.
106. ¹⁵²Chest x-ray images (pneumonia), 2018. [Online]. Available: <https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia/data>.
107. P. ⁵⁶Soda, N. C. ⁵⁶D'Amico, J. ⁵⁶Tessadori, et al., "Aiforcovid: Predicting the clinical outcomes in patients with covid-19 applying ai to chest-x-rays. an italian multicentre study," *Medical image analysis*, vol. 74, p. 102 216, 2021.
108. Covid-ct-dataset, 2021. [Online]. Available: <https://github.com/UCSD-AI4H/COVID-CT>.
109. X. ⁵⁶Yang, X. ⁵⁶He, J. ⁵⁶Zhao, Y. ⁵⁶Zhang, S. ⁵⁶Zhang, and P. ⁵⁶Xie, "Covid-ct-dataset: A ct scan dataset about covid-19," *arXiv preprint arXiv:2003.13865*, 2020.
110. M. I. ⁵⁶Vaya, J. M. ⁵⁶Saborit, J. ⁵⁶A. ⁵⁶Montell, et al., "Bimcv covid-19+: A large annotated dataset of rx and ct images from covid-19 patients," *arXiv preprint arXiv:2006.01174*, 2020.
111. Bimcv-covid19+: A large annotated dataset of rx and ct images of no covid19 patients. [Online]. Available: <https://github.com/BIMCV-CSUSP/BIMCV-COVID-19>.
112. F. ⁵⁶Tavora, Y. ⁵⁶Zhang, M. ⁵⁶Zhang, et al., "Cardiomegaly is a common arrhythmogenic substrate in adult sudden cardiac deaths, and is associated with obesity," *Pathology*, vol. 44, no. 3, pp. 187–191, 2012.
113. Icd-11 for mortality and morbidity statistics, Version: 05/2021. [Online]. Available: <https://icd.who.int/browse11/l-m/en#/http%3a%2f%2fid.who.int%2fid%2fentfity%2f1948124976>.
114. ¹⁰⁴S. ¹⁰⁴Kooraki, M. ¹⁰⁴Hosseiny, L. ¹⁰⁴Myers, and A. ¹⁰⁴Gholamrezanezhad, "Coronavirus (covid-19) outbreak: What the department of radiology

- should know," *Jurnal* of the American college of radiology, vol. 17, no. 4, pp. 447–451, 2020.
115. J. Cleverley, J. Piper, and M. M. Jones, "The role of chest radiography in confirming covid-19 pneumonia," *bmj*, vol. 370, 2020.
 116. P. Ai, Z. Yang, H. Hou, et al., "Correlation of chest ct and rt-pcr testing for coronavirus disease 2019 (covid-19) in china: A report of 1014 cases," *Radiology*, vol. 296, no. 2, E32–E40, 2020.
 117. W.-j. Guan, Z.-y. Ni, Y. Hu, et al., "Clinical characteristics of coronavirus disease 2019 in china," *New England journal of medicine*, vol. 382, no. 18, pp. 1708–1720, 2020.
 118. N. Chen, M. Zhou, X. Dong, et al., "Epidemiological and clinical characteristics of 99 cases of 2019 novel coronavirus pneumonia in wuhan, china: A descriptive study," *The lancet*, vol. 395, no. 10223, pp. 507–513, 2020.
 119. M. Chung, A. Bernheim, X. Mei, et al., "Ct imaging features of 2019 novel coronavirus (2019-ncov)," *Radiology*, vol. 295, no. 1, pp. 202–207, 2020.
 120. "Covid-19 bsti reporting templates," *The British Society of Thoracic Imaging*, 2020. [Online]. Available: <https://www.bsti.org.uk/covid-19-resources/covid-19-bsti-reporting-templates/>.
 121. G. A. Raptis, M. M. Hammer, R. G. Short, et al., "Chest ct and coronavirus disease (covid-19): A critical review of the literature to date," *American Journal of Roentgenology*, vol. 215, no. 4, pp. 839–842, 2020.
 122. B. Ozmen, AutoML for data augmentation. [Online]. Available: <https://github.com/barisozmen/deepaugment> (visited on 2024).
 123. S. Shorten and T. M. Khoshgoftaar, "A survey on image data augmentation for deep learning," *Journal of big data*, vol. 6, no. 1, p. 60, 2019.
 124. J. Wang, J.-Y. Zhu, A. Torralba, and A. A. Efros, "Dataset distillation," *arXiv preprint arXiv:1811.10959*, 2018.
 125. J. Cui, R. Wang, S. Si, and C.-J. Hsieh, "Scaling up dataset distillation to imagenet-1k with constant memory," in *International Conference on Machine Learning*, PMLR, 2023, pp. 6565–6590.
 126. S. Lei and D. Tao, "A comprehensive survey of dataset distillation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 1, pp. 17–32, 2024. DOI: 10.1109/TPAMI.2023.3322540. [Online]. Available: <http://dx.doi.org/10.1109/TPAMI.2023.3322540>.
 127. Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
 128. K. Fukushima, "Neural network model for a mechanism of pattern recognition unaffected by shift in position-neocognitron," *IEICE Technical Report, A*, vol. 62, no. 10, pp. 658–665, 1979.
 129. G. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
 130. A. G. Ivakhnenko and V. G. Lapa, *Cybernetic Predicting Devices*. CCM Information Corporation, 1965.
 131. H. J. Kelley, "Gradient theory of optimal flight paths," *Ars Journal*, vol. 30, no. 10, pp. 947–954, 1960.
 132. J. Schmidhuber, Deep learning, 2015. [Online]. Available: http://www.scholarpedia.org/article/Deep_Learning.
 133. B. Zhao and H. Bilen, "Dataset condensation with distribution matching," in *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, 2023, pp. 6514–6523.
 134. B. Zhao, K. R. Mopuri, and H. Bilen, "Dataset condensation with gradient matching," *arXiv preprint arXiv:2006.05929*, 2020.
 135. Y. Bengio, A. Courville, and P. Vincent, "Representation learning: A review and new perspectives," *IEEE transactions on pattern analysis and machine intelligence*, vol. 35, no. 8, pp. 1798–1828, 2013.
 136. D. Zhang, J. Yin, X. Zhu, and C. Zhang, "Network representation learning: A survey," *IEEE transactions on Big Data*, vol. 6, no. 1, pp. 3–28, 2018.
 137. A. Rosasco, A. Carta, A. Cossu, V. Lomonaco, and D. Bacciu, "Distilled replay: Overcoming forgetting through synthetic samples," in *International Workshop on Continual Semi-Supervised Learning*, Springer, 2021, pp. 104–117.
 138. F. Wiewel and B. Yang, "Condensed composite memory continual learning," in *2021 International Joint Conference on Neural Networks (IJCNN)*, IEEE, 2021, pp. 1–8.
 139. G. Li, G. Qian, I. C. Delgadillo, M. Muller, A. Thabet, and B. Ghanem, "Sgas: Sequential greedy architecture search," in *Proceedings of the IEEE/CVF Conference on computer vision and pattern recognition*, 2020, pp. 1620–1630.
 140. G. White, P. Jain, S. Nayak, G. Ramakrishnan, et al., "Speeding up nas with adaptive subset selection," *arXiv preprint arXiv:2211.01454*, 2022.
 141. J. Goetz and A. Tewari, "Federated learning via synthetic data," *arXiv preprint*

201

142. ³⁷U. Chen, R. Kerkouche, and M. Fritz, "A unified view of differentially private deep generative modeling," arXiv preprint arXiv:2309.15696, 2023.
143. ³⁷N. Loo, R. Hasani, A. Amini, and D. Rus, "Efficient dataset distillation using random feature approximation," *Advances in Neural Information Processing Systems*, vol. 35, pp. 13 877–13 891, ³⁷2022.
144. G. Cazenavette, T. Wang, A. Torralba, A. A. Efros, and J.-Y. Zhu, "Wearable imagenet: Synthesizing tileable textures via dataset distillation," in ⁸²Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, ³⁷2022, pp. 2278–2282.
145. Y. Chen, Z. Wu, Z. Shen, and J. Jia, "Learning from designers: Fashion compatibility analysis via dataset distillation," in *2022 IEEE International Conference on Image Processing (ICIP)*, IEEE, 2022, pp. 856–860.
146. G. Li, R. Togo, T. Ogawa, and M. Haseyama, "Dataset distillation for medical dataset sharing," ⁴³arXiv preprint arXiv:2209.14603, 2022.
147. ²¹J. Cohn, L. Atlas, and R. Ladner, "Improving generalization with active learning," *Machine learning*, vol. 15, no. 2, pp. 201–221, 1994.
148. ⁸⁰R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 618–626.
149. J. D. Owens, D. Luebke, N. Govindaraju, et al., ³⁰"A survey of general-purpose computation on graphics hardware," in *Computer graphics forum*, Wiley Online Library, vol. 26, 2007, pp. 80–113.
150. E. Smistad, T. L. Falch, M. Bozorgi, A. C. Elster, and F. Lindseth, "Medical image segmentation on gpus," ¹⁴⁰comprehensive review, *Medical image analysis*, vol. 20, no. 1, pp. 1–18, 2015.
151. ¹⁴⁵T. Rajpurkar, J. Irvin, K. Zhu, et al., "CheXnet: Radiologist-level pneumonia detection on chest x-rays with deep learning," arXiv preprint arXiv:1711.05225, 2017.
152. Towards Geometric Deep Learning, The Gradient, 2025. [Online]. Available: <https://thegradient.pub/towards-geometric-deep-learning/>.

202

153. ⁴⁶J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "Imagenet: A large-scale hierarchical image database," in *2009 IEEE conference on computer vision and pattern recognition*, IEEE, 2009, pp. 248–255.
154. ⁴⁶K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
155. G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected ⁷³convolutional networks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 4700–4708.
156. ⁷³G. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi, "Inception-v4, inception-resnet and the impact of residual connections on learning," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 31, 2017.
157. ⁸¹F. Chollet, "Xception: Deep learning with depthwise separable convolutions," ³⁸Proceedings of the IEEE conference on computer vision and pattern recognition, 2017, pp. 1251–1258.
158. ³⁸M. Tan and Q. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *International conference on machine learning*, PMLR, 2019, pp. 6105–6114.
159. ³⁸Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A convnet for the 2020s," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 11 976–11 986.
160. ³⁸Z. Liu, Y. Lin, Y. Cao, et al., ³⁸"Swin transformer: Hierarchical vision transformer using shifted windows," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 10 012–10 022.
161. ⁷¹B. Van Ginneken, M. B. Stegmann, and M. Loog, "Segmentation of anatomical structures in chest radiographs using supervised methods: A comparative study on a public database," *Medical image analysis*, vol. 10, no. 1, pp. 19–40, 2006.
162. A. Hashemi, A. H. Pilevar, and R. Rafeh, "Mass detection in lung ct images using region growing segmentation and decision making based on fuzzy inference system and artificial neural network," ³¹*International Journal of Image, Graphics and Signal Processing*, vol. 5, no. 6, p. 16, 2013.

203

163. ⁴⁵L.-C. Chen, G. Papandreou, I. Kokkinos, K. Murphy, and A. L. Yuille, "Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs," *IEEE transactions on pattern analysis and machine intelligence*, vol. 40, no. 4, pp. 834–848, 2017.

164. Long, E. Shelhamer, and T. Darrell, "Fully convolutional networks for semantic segmentation," in Proceedings of the IEEE conference on computer vision and pattern recognition, 2015, pp. 3431–3440.
 165. I. Pazhtnykh and V. Petsiuk, Lung segmentation (2d), 2017. [Online]. Available: <https://github.com/imlab-uitp/lung-segmentation-2d>.
 166. Y. LeCun, B. Boser, J. S. Denker, et al., "Backpropagation applied to handwritten zip code recognition," Neural computation, vol. 1, no. 4, pp. 541–551, 1989.
 167. A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," Advances in neural information processing systems, vol. 25, 2012. [Online]. Available: <https://proceedings.neurips.cc/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf>.
 168. S. Xie, R. Girshick, P. Dollár, Z. Tu, and K. He, "Aggregated residual transformations for deep neural networks," in Proceedings of the IEEE conference on computer vision and pattern recognition, 2017, pp. 1492–1500.
 169. A. G. Howard, M. Zhu, B. Chen, et al., "Mobilenets: Efficient convolutional neural networks for mobile vision applications," arXiv preprint arXiv:1704.04861, 2017.
 170. I. Radosavovic, R. Kosaraju, R. Girshick, K. He, and P. Dollár, "Designing network design spaces," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020, pp. 10 428–10 436.
 171. A. Zhang, Z. C. Lipton, M. Li, and A. J. Smola, Dive into Deep Learning. 2021, ch. Optimization Algorithms, <https://d2l.ai>.
 172. F. Chollet, Deep learning with Python. Simon and Schuster, 2021.
 173. S. Han, X. Liu, H. Mao, et al., "EIE: Efficient inference engine on compressed deep neural network," ACM SIGARCH Computer Architecture News, vol. 44, no. 3, pp. 243–254, 2016.
- 204
174. S. He, X. Zhang, and J. Sun, "Channel pruning for accelerating very deep neural networks," in Proceedings of the IEEE international conference on computer vision, 2017, pp. 1389–1397.
 175. K. Yu, A. Li, C.-F. Chen, et al., "Nisp: Pruning networks using neuron importance score propagation," in Proceedings of the IEEE conference on computer vision and pattern recognition, 2018, pp. 9194–9203.
 176. M. Cordts, M. Omran, S. Ramos, et al., "The cityscapes dataset for semantic urban scene understanding," in Proceedings of the IEEE conference on computer vision and pattern recognition, 2016, pp. 3213–3223.
 177. W. B. Geyer, A. Post, and H. Hatabu, "Commonly missed findings on chest radiographs: Causes and consequences," Chest, vol. 163, no. 3, pp. 650–661, 2023.
 178. M. A. Bruno, E. A. Walker, and H. H. Abujudeh, "Understanding and confronting our mistakes: The epidemiology of error in radiology and strategies for error reduction," Radiographics, vol. 35, no. 6, pp. 1668–1676, 2015.
 179. S. Schalekamp, B. van Ginneken, I. A. Van Den Berk, et al., "Bone suppression increases the visibility of invasive pulmonary aspergillosis in chest radiographs," PloS one, vol. 9, no. 10, e 108551, 2014.
 180. Clearread xray bone suppress, Riverain Technologies. [Online]. Available: <https://www.riveraintech.com/clearread-ai-solutions/clearread-xray/>.
 181. Carestream's new bone suppression software receives fda clearance, Imaging Technology News, 2014. [Online]. Available: <https://www.itnonline.com/content/carestream%E2%80%99s-new-bone-suppression-software-receives-fda-clearance>.
 182. I. Goodfellow, J. Pouget-Abadie, M. Mirza, et al., "Generative adversarial nets," Advances in neural information processing systems, vol. 27, 2014.
 183. L. Van der Maaten and G. Hinton, "Visualizing data using t-sne," Journal of machine learning research, vol. 9, no. 11, 2008.
 184. M. Yetisgen-Yildiz, M. L. Gunn, F. Xia, and T. H. Payne, "A text processing pipeline to extract recommendations from radiology reports," Journal of biomedical informatics, vol. 46, no. 2, pp. 354–362, 2013.
- 205
185. A. Ng, AI Transformation Playbook. Landing AI, 2020. [Online]. Available: https://landing.ai/wp-content/uploads/2020/05/LandingAI_Transformation_Playbook_11-19.pdf.
 186. S.-H. Gao, M.-M. Cheng, K. Zhao, X.-Y. Zhang, M.-H. Yang, and P. Torr, "Res2net: A new multi-scale backbone architecture," IEEE transactions on pattern analysis and machine intelligence, vol. 43, no. 2, pp. 652–662, 2019.
 187. K. Sun, B. Xiao, D. Liu, and J. Wang, "Deep high-resolution representation learning for human pose estimation," in Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019, pp. 5693–5703.
 188. Z. Wang, Y. Wu, J. Wang, J. Xu, and W. Shao, "Res2fusion: Infrared and visible image fusion based on dense res2net and double nonlocal attention mod-

- els, ⁴⁵IEEE Transactions on Instrumentation and Measurement, vol. 71, pp. 1–12, 2022.
189. H. Li, F. Wang, J. Liu, H. Song, Z. Hou, and P. Dai, "Ensemble model for rail surface defects detection," PLoS one, vol. 17, no. 5, e0268518, 2022.
190. ¹⁰⁸N. Shazeer, A. Mirhoseini, K. Maziarz, et al., "Outrageously large neural networks: The sparsely-gated mixture-of-experts layer," ¹⁴⁹arXiv preprint arXiv:1701.06538, 2017.
191. N. Gordienko, Y. ²⁵Gordienko, and S. Stirenko, "Synchronized multi- augmentation with multi-backbone ensembling for enhancing deep learning performance," Applied System Innovation, vol. 8, no. 1, p. 18, 2025.
192. G. ⁸⁹Giaparrone, F. Bardozzo, M. D. Priscoli, J. L. Kallewaard, M. R. Zuluaga, and R. Tagliaferri, "A comparative analysis of multi-backbone mask r-cnn for surgical tools detection," in 2020 International Joint Conference on Neural Networks (IJCNN), IEEE, 2020, pp. 1–8.
193. Z. ²¹Guyang, J. Niu, T. Ren, Y. Li, J. Cui, and J. Wu, "Mbbnet: An edge iot computing-based traffic light detection solution for autonomous bus," Journal of Systems Architecture, vol. 109, p. 101 835, 2020.
194. G. Ciubotariu and G. Czibula, "Mbmt-net: A multi-task learning based convolutional neural network architecture for dense prediction tasks," IEEE Access, vol. 10, pp. 125 600–125 615, 2022.
- 206
195. C. Cui, T. Gao, S. Wei, et al., "Pp-lcnet: A lightweight cpu convolutional neural network," arXiv preprint arXiv:2109.15099, 2021.
196. ⁹⁰D. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," in Artificial intelligence and statistics, PMLR, 2017, pp. 1273–1282.
197. D. J. Beutel, T. Topal, A. Mathur, et al., "Flower: A friendly federated learning research framework," arXiv preprint arXiv:2007.14390, ¹⁰⁹2020.
198. A. Krizhevsky, G. Hinton, et al., "Learning multiple layers of features from tiny images," 2009.
199. A. Howard, M. Sandler, G. Chu, et al., "Searching for mobilenetv3," in Proceedings of the IEEE/CVF international conference on computer vision, 2019, pp. 1314–1324.
200. ¹¹²J. Hu, L. Shen, and ¹³⁶G. Sun, "Squeeze-and-excitation networks," in Proceedings of the IEEE conference on computer vision and pattern recognition, 2018, pp. 7132–7141.
201. ³⁸J. Yang, R. Shi, and B. Ni, "Medmnist classification decathlon: A lightweight automl benchmark for medical image analysis," in 2021 IEEE 18th international symposium on biomedical imaging (ISBI), IEEE, 2021, pp. 191–195.
202. ³⁸J. Yang, R. Shi, D. Wei, et al., ³⁸Medmnist v2-a large-scale lightweight benchmark for 2d and 3d biomedical image classification," Scientific data, ¹³⁹vol. 10, no. 1, p. 41, 2023.
203. N. Gordienko, O. Lodygensky, G. Fedak, and Y. Gordienko, "Synergy of volunteer measurements and volunteer computing for effective data collecting, processing, simulating and analyzing on a worldwide scale," in 2015 34th International Convention on Information and Communication Technology, Electronics and Microelectronics (MIPRO), IEEE, 2015, pp. 193–198.
204. ¹¹⁵G. Atkeson, A. W. Moore, and S. Schaal, "Locally weighted learning," Lazy learning, pp. 11–73, 1997.
205. N. N. Rather, C. O. Patel, and S. A. Khan, "Using deep learning towards biomedical knowledge discovery," Int. J. Math. Sci. Comput.(IJMSC), vol. 3, no. 2, pp. 1–10, 2017.
- 207
206. ⁸⁷J. Gordienko, S. Stirenko, Y. Kochura, O. Alienin, M. Novotarskiy, and N. Gordienko, "Deep learning for fatigue estimation on the basis of multimodal human-machine interactions," arXiv preprint arXiv:1801.06048, 2017.
207. ⁴²O. Oktay, J. Schlemper, L. L. Folgoc, ⁴²et al., "Attention u-net: Learning where to look for the pancreas," arXiv preprint arXiv:1804.03999, 2018.
208. ⁴²Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh, and J. Liang, "Unet++: A nested u-net architecture for medical image segmentation," in Deep learning in medical image analysis and multimodal learning for clinical decision support, Springer, 2018, pp. 3–11.
209. ⁴²H. Huang, L. Lin, R. Tong, ⁴²et al., "Unet 3+: A full-scale connected unet for medical image segmentation," in ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), IEEE, 2020, pp. 1055– 1059.
210. What to know about nodules, Healthline, 2019. [Online]. Available: <https://www.healthline.com/health/nodules>.
211. ¹⁴⁶M. Abadi, A. Agarwal, P. Barham, ⁸⁴et al., "Tensorflow: Large-scale machine learning on heterogeneous distributed systems," arXiv preprint arXiv:1603.04467, 2016.
212. D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," arXiv preprint arXiv:1412.6980, 2014.
213. leondgarse, Awsaf, D. Cleres, and M. A. Haghpanah, Leondgarse/keras_cv_attention_models: Cspnext_pretrained, Zenodo, 2024. [Online]. Available: <https://zenodo.org/records/10499598>.

СПИСОК РИСУНКІВ

1.1 Електромагнітний спектр [63]	35
1.2 Схема вакуумної трубки для генерації X-променів а). Розподіл інтенсивності у рентгенівському спектрі молібдену для різних напруг б). Потенціал збудження K-серії становить 20.1 кВ. Цей ряд з'являється як характерні піки на кривій 25 кВ. Піки Kα і Kβ обумовлені падінням електрона з L-оболонки та M-оболонки відповідно [63]	36
1.3 Машинне та глибинне навчання у задачах діагностичного аналізу медичних даних	41
1.4 Велика мовна модель Med-PaLM M аналізує рентгенограму [57] . .	42
1.5 Анатомічні структури, патологічні стани та методи медичної візуалізації разом з масками експертної анотації та результатами сегментації моделі-основи MedSAM [58]	44
2.1 Приклад оригінального зображення (2048 × 2048 пікселів) JSRT [85] з ділянкою ракової пухлини а), відповідного зображення без кісток з набору даних BSE-JSRT [86] б) та метаданих, яка відповідає цьому зображенню в). Розташування та область пухлини позначаються відповідно точкою та колом а)	50
2.2 Фрагмент лістингу міток з Chexpert	59
2.3 Фрагмент лістингу міток з COVID-19 (ieee8023)	66
2.4 Штучне розширення набору даних [122], [123]	69
2.5 Складові для організації високоякісної підготовки даних	74
2.6 Алгоритм активного навчання [147]	77
2.7 Блок-схема робочого процесу для збору, підготовки та попередньої обробки даних	78
2.8 Візуалізація теплових карт для перших 25 (з 50) тестових зображень	84
2.9 Візуалізація теплових карт для наступних 25 (з 50) тестових зображень	85
2.10 Переможці конкурсу ILSVRC з 2012 року ґрунтуються на глибокому навчанні [152]	87

2.11 Роздільна згортка по глибині	88
2.12 Візуальне сприйняття зображення людиною а) та комп'ютером б) .	92
2.13 Розмір карти ознак на виході згорткового шару	93
2.14 Фільтри та карти ознак	94
2.15 Архітектура згорткової мережі	97
2.16 Порівняльне прискорення обчислень на GPU K80 та TPUv2 [33] . .	98
2.17 Глибоке навчання на мобільних пристроях	99
2.18 Порівняння точності сегментації та часу обчислень для ICNet і PSPNet [27]	101
3.1 Метод попередньої обробки графічних даних із використанням сегментації ділянок, які містять цільові об'єкти	106
3.2 Метод попередньої обробки графічних даних без кісткових структур із використанням сегментації ділянок, які містять цільові об'єкти	108
3.3 Архітектура U-Net з пропусковими зв'язками між шарами енкодера та декодера	109
3.4 Візуалізація моделі t-SNE для багатомірної маски легень за допомогою тривимірної точки, де подібні маски легень моделюються за допомогою точок, що знаходяться поруч, а найбільш неподібні маски відображаються як віддалені точки. Легенда: червоний колір – маски зображень з новоутвореннями (вузликами) у легенях, синій – без новоутворень	111
3.5 Візуалізація масок легень із трансформацією t-SNE, що зберігає відстань з рис. 3.4, щоб скласти враження про найбільш несхожі (віддалені) маски легень	112
3.6 Метод попередньої обробки графічних даних із використанням сегментації ділянок, які містять цільові об'єкти, та виключення викидів серед розподілу сегментованих масок за допомогою t-SNE	113
3.7 Приклади багатобазових версій архітектури LCNNet050 для різної кількості бекбонів (NMB), застосованих до набору даних CIFAR-100: а) NMB = 1 (орієнтир), б) NMB = 2 та в) NMB = 4 . .	117

3.8 Стратегія агрегації локальних моделей FedAvg у Flower: (1) на кроці t сервер розсилає глобальну модель θ_t клієнтам; (2) клієнти виконують локальне навчання та обчислюють оновлені значення ваг $\theta_{it}+1$; (3) сервер агрегує локальні оновлення ваг для формування нової глобальної моделі θ_{t+1}	118
4.1 Приклад оригінального зображення з датасету No 01 а), відповідна маска легень, яка передбачена методом глибинного навчання б), та її сегментована версія в)	125
4.2 Приклад оригінального зображення з датасету No 02, BSE-JSRT [86] а), відповідна маска легень, яка передбачена методом глибинного навчання б), та її сегментована версія в) . . .	126
4.3 Розподіл площі зображень (images) і масок (masks)	127
4.4 Маски легень: найбільш несхожі а), найбільш подібні б) та середня в)	128
4.5 Сегментована маска легень з датасету JSRT а), маска кісток б) і результуюча маска легень без кісток в)	129
4.6 Оригінальне зображення з датасету Shenzhen Hospital (SH) а), маска легень цього зображення б) та результат сегментації за маскою в)	130
4.7 Комбінований розподіл за статтю та віком для рентгенограм без (0) та з (1) ознаками туберкульозу	132
4.8 Точність моделі під час кросвалідації на сегментованому наборі SH з розширенням даних без втрат інформації: навчання а) та валідація б)	133
4.9 Втрати моделі під час кросвалідації на сегментованому наборі SH з розширенням даних без втрат інформації: навчання а) та валідація б)	134
4.10 Точність моделі під час кросвалідації на сегментованому наборі SH з розширенням даних з втратою інформації: навчання а) та валідація б)	135
4.11 Втрати моделі під час кросвалідації на сегментованому наборі SH з розширенням даних з втратою інформації: навчання а) та валідація б)	136

4.12 Точність моделі під час кросвалідації на сегментованому наборі SH: навчання а) та валідація б)	137
4.13 Втрати моделі під час кросвалідації на сегментованому наборі SH: навчання а) та валідація б)	138
4.14 Усереднені та згладжені значення точності а) та втрат б) навчання та валідації на наборах даних: сегментованому наборі SH (червоний колір), сегментованому наборі SH з розширенням даних без втрат інформації (синій колір) та сегментованому наборі SH з розширенням даних з втратою інформації (зелений колір)	139
4.15 Точність навчання а), точність валідації б), втрати навчання в) та втрати валідації г) на наборах даних JSRT (крива 01), BSE-JSRT (крива 02), сегментованому JSRT (крива 03) та сегментованому BSE-JSRT (крива 04)	147
4.16 Точність навчання а), точність валідації б), втрати навчання в) та втрати валідації г) на наборах даних BSE-JSRT (крива 02), сегментованому JSRT (крива 03) та сегментованому BSE-JSRT (крива 04)	148
4.17 Час навчання моделі у режимах CPU а) та GPU б) для різних розмірів пакету та різних розмірів зображень	150
4.18 Час навчання моделі а) та прискорення б) для різних розмірів зображень та режимів	150
4.19 Оригінальне зображення з CheXpert (ліворуч) та його сегментоване зображення (праворуч)	151
4.20 ROC-криві та значення AUC для моделі, навченої на оригінальному наборі даних із застосуванням аугментації (OA). По вертикальній осі відкладено значення показника істиннопозитивних результатів (True Positive Rate, TPR), а по горизонтальній – частку хибнопозитивних результатів (False Positive Rate, FPR). Кольорові точки (в електронній версії)	

відображають дані трьох експертів радіологів (Rad1, Rad2, Rad3)
та їхню більшість голосів (RadMaj) для порівняння за
відповідними захворюваннями [47] 154

212

4.21 Динаміка зміни валідаційних втрат а) та точності б) LCNet050
(NMB = 1) для різних розмірів пакету $N_b \in \{32, 512, 8192\}$ 159
4.22 Типові криві валідаційних втрат (а, б) та валідаційної точності (в,
г) для різних версій архітектури LCNet [195], [213] з кількістю
опорних моделей NMB = 1 для розміру пакету $N_b = 512$. Графіки
(а, в) відображають результати для метрик централізованої
валідації, а (б, г) – для метрик федеративного навчання. У легенді
наведено суфікси для версій LCNet 160
4.23 Типові криві валідаційних втрат а) та валідаційної точності б) для
архітектури LCNet050 [195], [213] з різною кількістю опорних
моделей $NMB \in \{1, 2, 4, 8\}$ для розміру пакету $N_b = 32$ 161
4.24 Типові криві валідаційних втрат а) та валідаційної точності б) для
архітектури LCNet050 [195], [213] з різною кількістю опорних
моделей $NMB \in \{1, 2, 4\}$, кількістю локальних епох
 $N_{le} \in \{1, 10, 100\}$ для розміру пакету $N_b = 32$ 162
4.25 Приклади синтезованих (ліворуч) та реконструйованих
(праворуч) зображень із набору даних CIFAR-10 для різної
кількості зображень на клас: 1 (а, б) та 10 (в, г) 164
4.26 Приклади синтезованих (ліворуч) та реконструйованих
(праворуч) зображень із набору даних PathMNIST для різної
кількості зображень на клас: 1 (а, б) та 10 (в, г) 165
4.27 Набір даних CIFAR-10. Точність на валідаційній вибірці залежно
від кількості епох, де легенда містить значення дистильованої
кількості зображень на клас (IPC) (ліворуч) та максимальна
точність на валідаційній вибірці залежно від IPC (праворуч), де
легенда також містить порівняльні значення з роботи [22].
Похибки на графіку відображають стандартні відхилення
точності за результатами 5 випробувань 166

213

4.28 Набір даних CIFAR-100. Точність на валідаційній вибірці
залежно від кількості епох, де легенда містить значення
дистильованої кількості зображень на клас (IPC) (ліворуч) та
максимальна точність на валідаційній вибірці залежно від IPC
(праворуч), де легенда також містить порівняльні значення з
роботи [22]. Похибки на графіку відображають стандартні
відхилення точності за результатами 5 випробувань 167
4.29 Набір даних PathMNIST. Точність на валідаційній вибірці
залежно від кількості епох, де легенда містить значення
дистильованої кількості зображень на клас (IPC) (ліворуч) та
максимальна точність на валідаційній вибірці залежно від IPC
(праворуч), де легенда містить значення для порівняння з [201],
[202]. Похибки на графіку відображають стандартні відхилення
точності за результатами 5 випробувань 169
4.30 Набір даних DermaMNIST. Точність на валідаційній вибірці
залежно від кількості епох, де легенда містить значення
дистильованої кількості зображень на клас (IPC) (ліворуч) та
максимальна точність на валідаційній вибірці залежно від IPC
(праворуч), де легенда містить значення для порівняння з [201],
[202]. Похибки на графіку відображають стандартні відхилення
точності за результатами 5 випробувань 170
4.31 Набір даних RetinaMNIST. Точність на валідаційній вибірці
залежно від кількості епох, де легенда містить значення
дистильованої кількості зображень на клас (IPC) (ліворуч) та
максимальна точність на валідаційній вибірці залежно від IPC
(праворуч), де легенда містить значення для порівняння з [201],
[202]. Похибки на графіку відображають стандартні відхилення
точності за результатами 5 випробувань 171
4.32 Порівняння загальної максимальної точності на валідаційній
вибірці залежно від значення IPC, де легенда містить значення
для порівняння з [22] та [201], [202]. Похибки на графіку
відображають стандартні відхилення точності за результатами 5

випробувань	172
4.33 Типи практичних застосувань (ШІ-послуг) на платформі	177

214

4.34 Приклад результату обробки рентгенограми з локалізацією ймовірних зон аномалій	178
---	-----

215

СПИСОК ТАБЛИЦЬ

2.1 Порівняння популярних архітектур згорткових мереж для прогнозування на рівні всього зображення	89
4.1 Порівняння продуктивності графічних процесорів	131
4.2 Величини показника якості класифікації та середнього квадратичного відхилення кожного типу архітектури моделі з урахуванням test-time augmentation	141
4.3 Показники часу тестування та середнього квадратичного відхилення для моделей, що були використані з урахуванням test-time augmentation	141
4.4 Значення AUC для моделей, навчених із використанням різних підходів. Значення у дужках отримані після додаткового навчання протягом 15 епох (2-й / 3-й запуск)	153
4.5 Основні параметри FedAvg у фреймворку Flower та їхні значення, використані в експериментах	158
4.6 Максимальні значення точності досягнуті для різної кількості локальних епох Nle та кількості опорних моделей NMB. Жирним шрифтом виділено максимальне значення точності для конкретного Nle серед усіх розглянутих опорних моделей NMB ..	163
4.7 Максимальні значення точності на валідаційній вибірці для збалансованих наборів даних CIFAR	168
4.8 Максимальні значення точності на валідаційній вибірці для датасету зі слабким дисбалансом класів (PathMNIST) та датасетів із вираженим дисбалансом класів (DermaMNIST, RetinaMNIST) ..	171
A.1 Апробація результатів дослідження	220

216

3 ДОДАТОК А СПИСОК ПУБЛІКАЦІЙ ЗДОБУВАЧА ЗА ТЕМОЮ ДИСЕРТАЦІЇ ТА ВІДОМОСТІ ПРО АПРОБАЦІЮ РЕЗУЛЬТАТІВ	
A.1 Список публікацій здобувача за темою дисертації 1. Y. Gordienko, G. Nowakowski, Y. Kochura, V. Taran, and S. Stirenko, "Generative data augmentation by dataset distillation," in Communications in Computer and Information Science, C. Tommasino, C. Russo, and M. Bernardini, Eds. Cham: Springer Nature Switzerland, 2026, vol. 2696, pp. 105–118. DOI: 10.1007/978-3-032-17216-7_9. ISSN 1865-0929. ISBN 978-303217215-0. SCOPUS, Q4.	
2. Y. Gordienko, N. Gordienko, E. M. El Mhamdi, Y. Kochura, and S. Stirenko, "Multi-backbone ensembling for performance improvement in federated learning setup," in Lecture Notes in Networks and Systems, N. Min-Allah, K. Alissa, P. Sitek, M. Sano, S. Rodriguez, and A. Nongailard, Eds. Cham: Springer Nature Switzerland, 2026, vol. 1598, pp. 129–138. DOI: 10.1007/978-3-032-04160-9_12. ISSN 2367-3370. ISBN 978-303204159-3. SCOPUS, Q4.	
3. Y. Kochura, Y. Trochun, V. Taran, Y. Gordienko, O. Rokovyi, and S. Stirenko, "AeroNet: Domain-specific dataset for automation of unmanned aerial vehicles," Information, Computing and Intelligent systems, no. 7, pp. 83–95, 2025. DOI: 10.20535/2786-8729.7.2025.341779. ISSN 2786-8729. Scientific Professional Publications of Ukraine (Category B).	
4. Y. Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, V. Taran, O. Alienin, and S. Stirenko, "Multimodal metadata augmentation for federated learning in medical applications," in Lecture Notes in Networks and Systems, X.-S. Yang, S. Sherratt, N. Dey, and A. Joshi, Eds. Springer Science and Business Media Deutschland GmbH, 2024, vol. 1002, pp. 537–547. DOI: 10.1007/978-981-97-3299-9_43. ISSN 2367-3370. ISBN 978-981973298-2. SCOPUS, Q4.	
5. Y. Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, O. Alienin, V. Taran, and S. Stirenko, "Ensemble knowledge distillation for edge intelligence in medical applications," in Studies in Computational Intelligence. Springer Science and Business Media Deutschland GmbH, 2023, vol. 1100, pp. 135–168. DOI: 10.1007/978-3-031-32095-8_5. ISSN 1860-949X. SCOPUS, Q4.	
6. Y. Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, O. Alienin, and S. Stirenko, "Fuzzy metadata augmentation for multimodal data classification," in Lecture Notes on Data Engineering and Communications Technologies, Springer Science	

217

cal applications," in Studies in Computational Intelligence. Springer Science and Business Media Deutschland GmbH, 2023, vol. 1100, pp. 135–168. DOI: 10.1007/978-3-031-32095-8_5. ISSN 1860-949X. SCOPUS, Q4.	
6. Y. Gordienko, M. Shulha, Y. Kochura, O. Rokovyi, O. Alienin, and S. Stirenko, "Fuzzy metadata augmentation for multimodal data classification," in Lecture Notes on Data Engineering and Communications Technologies, Springer Science	

- and Business Media Deutschland GmbH, 2023, vol. 166, pp. 157–172. DOI: 10.1007/978-981-99-0835-6_11. ISSN 2367-4512. SCOPUS, Q 3.
7. V. Taran, Y. Gordienko, O. Rokovyi, O. Alienin, Y. Kochura, and S. Stirenko, "Edge intelligence for medical applications under field conditions," in *Lecture Notes on Data Engineering and Communications Technologies*. Springer Science and Business Media Deutschland GmbH, 2022, vol. 135, pp. 71–80. DOI: 10.1007/978-3-031-04809-8_6. ISSN 2367-4512. SCOPUS, Q3.
8. O. Alienin, O. Rokovyi, Y. Gordienko, Y. Kochura, V. Taran, and S. Stirenko, "Artificial intelligence platform for distant computer-aided detection (CAdE) and computer-aided diagnosis (CAdx) of human diseases," in *Lecture Notes on Data Engineering and Communications Technologies*. Springer Science and Business Media Deutschland GmbH, 2022, vol. 135, pp. 91–100. DOI: 10.1007/978-3-031-04809-8_8. ISSN 2367-4512. SCOPUS, Q3.
9. V. Doms, Y. Gordienko, Y. Kochura, O. Rokovyi, O. Alienin, and S. Stirenko, "Deep learning for melanoma detection with testing time data augmentation," in *Lecture Notes on Data Engineering and Communications Technologies*. Springer Science and BusinessMedia Deutschland GmbH, 2021, vol. 82, pp. 131–140. DOI: 10.1007/978-3-030-80475-6_13. ISSN 2367-4512. SCOPUS.
10. Y. Gordienko, Y. Kochura, V. Taran, N. Gordienko, O. Rokovyi, O. Alienin, and S. Stirenko, "Last mile" optimization of edge computing ecosystem with deep learning models and specialized tensor processing architectures," in *Advances in Computers*. S. Kim and G. C. Deka, Eds. Academic Press Inc., 2021, vol. 122, pp. 303–341. DOI: 10.1016/bs.adcom.2020.10.003. ISSN 0065-2458. ISBN 978-012823123-4. SCOPUS, Q1.
- 218
11. Y. Gordienko, Y. Kochura, V. Taran, N. Gordienko, A. Rokovyi, O. Alienin, and S. Stirenko, "Scaling analysis of specialized tensor processing architectures for deep learning models," in *Studies in Computational Intelligence*. Cham: Springer, 2020, vol. 866, pp. 65–99. DOI: 10.1007/978-3-030-31756-0_3. ISSN 1860-949 X. SCOPUS, Q4.
12. P. Gang, W. Zeng, Y. Gordienko, Y. Kochura, O. Alienin, O. Rokovyi, and S. Stirenko, "Effect of data augmentation and lung mask segmentation for automated chest radiograph interpretation of some lung diseases," in *Communications in Computer and Information Science*, T. Gedeon, K. W. Wong, and M. Lee, Eds. Cham: Springer, 2019, vol. 1142, pp. 333–340. DOI: 10.1007/978-3-030-36808-1_36. ISSN 1865-0929. ISBN 978-303036807-4. SCOPUS, Q3.
13. Y. Gordienko, Y. Kochura, V. Taran, N. Gordienko, A. Bugaiov, and S. Stirenko, "Adaptive iterative pruning for accelerating deep neural networks," in *2019 11th International Scientific and Practical Conference on Electronics and Information Technologies, ELIT 2019 - Proceedings*. Institute of Electrical and Electronics Engineers Inc., 2019, pp. 173–178. DOI: 10.1109/ELIT.2019.8892346. ISBN 978-172813561-8. SCOPUS.
14. Y. Kochura, Y. Gordienko, V. Taran, N. Gordienko, A. Rokovyi, O. Alienin, and S. Stirenko, "Batch size influence on performance of graphic and tensor processing units during training and inference phases," in *Advances in Intelligent Systems and Computing*, Z. Hu, S. Petoukhov, I. Dychka, and M. He, Eds. Cham: Springer, 2019, vol. 938, pp. 658–668. DOI: 10.1007/978-3-030-16621-2_61. ISSN 2194-5357. ISBN 978-303016620-5. SCOPUS, Q4.
15. V. Taran, Y. Gordienko, N. Gordienko, A. Rokovyi, Y. Kochura, O. Alienin, and S. Stirenko, "Performance evaluation of deep learning networks for semantic segmentation of traffic stereo-pair images," in *ACM International Conference Proceeding Series*, B. Rachev and A. Smrikarov, Eds. Association for Computing Machinery, 2018, pp. 73–80. DOI: 10.1145/3274005.3274032. ISBN 978-145036425-6. SCOPUS.
16. S. Stirenko, Y. Kochura, O. Alienin, O. Rokovyi, Y. Gordienko, P. Gang, and W. Zeng, "Chest x-ray analysis of tuberculosis by deep learning with segmentation and augmentation," in *2018 IEEE 38th International Conference on Electronics and Nanotechnology, ELNANO 2018 - Proceedings*. Institute of Electrical and Electronics Engineers Inc., 2018, pp. 422–428. DOI: 10.1109/ELNANO.2018.8477564. ISBN 978-153866383-7. SCOPUS.
17. P. Gang, W. Zhen, W. Zeng, Y. Gordienko, Y. Kochura, O. Alienin, O. Rokovyi, and S. Stirenko, "Dimensionality reduction in deep learning for chest x-ray analysis of lung cancer," in *Proceedings - 2018 10th International Conference on Advanced Computational Intelligence, ICACI 2018*. Institute of Electrical and Electronics Engineers Inc., 2018, pp. 878–883. DOI: 10.1109/ICACI.2018.8377579. ISBN 978-153864362-4. SCOPUS.
18. Y. Gordienko, P. Gang, J. Hui, W. Zeng, Y. Kochura, O. Alienin, O. Rokovyi,

and S. Stirenko, "Deep learning with lung segmentation and bone shadow exclusion techniques for chest x-ray analysis of lung cancer," in *Advances in Intelligent Systems and Computing*, Z. Hu, S. Petoukhov, I. Dychka, and M. He, Eds. Cham: Springer, 2018, vol. 754, pp. 638–647. DOI: 10.1007/978-3-319-91008-6_63. ISSN 2194-5357. ISBN 978-331991007-9. SCOPUS, Q3.

19. Y. Kochura, S. Stirenko, O. Alienin, M. Novotarskiy, and Y. Gordienko, "Performance analysis of open source machine learning frameworks for various parameters in single-threaded and multi-threaded modes," in *Advances in Intelligent Systems and Computing*, N. Shakhovska and V. Stepashko, Eds. Cham: Springer, 2018, vol. 689, pp. 243–256. DOI: 10.1007/978-3-319-70581-1_17. ISSN 2194-5357. ISBN 978-331970580-4. SCOPUS, Q3.

20. P. Gang, J. Hul, Y. Stirenko, Y. Gordienko, T. Shemsedinov, O. Alienin, Y. Kochura, N. Gordienko, A. Rojbi, J. Lopez Benito, and E. Artetxe Gonzalez, "User-driven intelligent interface on the basis of multimodal augmented reality and brain-computer interaction for people with functional disabilities," in *Advances in Intelligent Systems and Computing*, K. Arai, S. Kapoor, and R. Bhatia, Eds. Cham: Springer, 2018, vol. 886, pp. 612–631. DOI: 10.1007/978-3-030-03402-3_43. ISSN 2194-5357. ISBN 978-303003401-6. SCOPUS, Q3.

21. Y. Kochura, S. Stirenko, and Y. Gordienko, "Comparative performance analysis of neural networks architectures on h2o platform for various activation functions."

220

in 2017 IEEE International Young Scientists Forum on Applied Physics and Engineering, YSF 2017. Institute of Electrical and Electronics Engineers Inc., 2017, pp. 70–73. DOI: 10.1109/YSF.2017.8126654. ISBN 978-153862994-9. SCOPUS.

22. Y. Kochura, S. Stirenko, O. Alienin, M. Novotarskiy, and Y. Gordienko, "Comparative analysis of open source frameworks for machine learning with use case in single-threaded and multi-threaded modes," in *Proceedings of the 12th International Scientific and Technical Conference on Computer Sciences and Information Technologies, CSIT 2017*, vol. 1. Institute of Electrical and Electronics Engineers Inc., 2017, pp. 373–376. DOI: 10.1109/STC-CSIT.2017.8098808. ISBN 978-153861638-3. SCOPUS.

A 2 Відомості про апробацію результатів

29. Таблиця А.1 — Апробація результатів дослідження № 3/п Тип конференції Назва конференції Місце і дата

проведення

Форма

участі

1.

Міжнародна

науково-технічна

конференція

4. 12th International Scientific and Technical Conference on Computer Sciences and Information Technologies (CSIT)

м. Львів, Україна,

05–08 вересня 2017

р.

Очна

2.

Форум молодих

науковців IEEE

IEEE Young Scientists Forum on Applied Physics and Engineering (YSF)

м. Львів, Україна,

17–20 жовтня 2017

р.

Очна

3.

Міжнародна

конференція

35. The First International Conference on Computer Science, Engineering and Education Applications (ICCSEEA2018)

м. Київ, Україна,

18–20 січня 2018 р.

Очна

4.

Міжнародна

конференція IEEE

6 IEEE 38th International

Conference on Electronics

and Nanotechnology

(ELNANO)

м. Київ, Україна,

22–24 квітня 2018

р.

Очна

221

Продовження таблиці А.1

No

з/п

Тип конференції Назва конференції

Місце і дата

проведення

Форма

участі

5.

Міжнародна

конференція

19 9-th International

Conference on Computer

Systems and Technologies

(CompSysTech'18)

м. Русе, Болгарія,

10–14 вересня 2018

р.

Очна

6.

Міжнародна

конференція

The Second 35 International

Conference on Computer

Science, Engineering and

Education Applications

(ICCSEEA2019)

м. Київ, Україна,

26–27 січня 2019 р.

Очна

7.

Міжнародна

науково-практична

конференція

35 35th International Scientific

and Practical Conference on

Electronics and Information

Technologies (ELIT- 2019)

м. Львів, Україна,

16–18 вересня 2019

р.

Очна

8.

Міжнародна

конференція

22nd International

Conference on Distributed

Computing and Artificial

Intelligence

Лілльський

університет,

Франція, 25–27

червня 2025 р.
Заочна